

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse

Eksamensdag: Onsdag 4. desember, 2024

Tid for eksamen: 15.00–19.00.

Oppgavesettet er på 4 sider.

Vedlegg: Ingen

Tillatte hjelpemidler: Godkjent kalkulator
Formelsamling for STK1110

Kontroller at oppgavesettet er komplett før
du begynner å besvare spørsmålene.

Oppgave 1

Anta at $X_1, X_2, \dots, X_n$ er uavhengige og identisk fordelte stokastiske variable med tetthet $f(x; \alpha) = \alpha x^{\alpha-1}$ for $0 < x < 1$ (altså over intervallet $[0, 1]$) og der $\alpha > 0$.

- (a) Man kan lett vise at $E(X_i) = \frac{\alpha}{\alpha+1}$ (det skal du ikke gjøre).

Finn på denne bakgrunn en momentestimator for parameteren α .

- (b) Men tilsvarende har man også at $Y_{ri} = X_i^r$ er uavhengige og identisk fordelte med forventning $E(Y_{ri}) = \frac{\alpha}{\alpha+r}$ (for vilkårlig $r > -\alpha$. Det skal du heller ikke vise).

Finn momentestimatorer for α basert på Y_{ri} -ene.

Kommenter på en svakhet ved momentestimering knyttet til dette.

- (c) Vis at maximum likelihood estimatoren (MLE) for α er gitt ved $\hat{\alpha} = \frac{n}{-\sum_{i=1}^n \ln(X_i)}$

- (d) Angi uten bevis tilnærmet fordeling for MLE $\hat{\alpha}$ når n er tilstrekkelig stor.

Vis at variansen i denne tilnærmede fordelingen gis ved $\frac{\alpha^2}{n}$.

- (e) La $Z = \frac{\hat{\alpha} - \alpha}{\hat{\alpha}/\sqrt{n}}$ og merk at Z da er tilnærmet standard normalfordelt når n er stor.

Utleid et tilnærmet 95% konfidensintervall for α basert på tilnærmet fordeling for Z .

Beregn intervallet når $n = 20$ og $\sum_{i=1}^n \ln(X_i) = -9.82$.

(Fortsettes på side 2.)

- (f) Merk at hvis $\alpha = 1$ så er X_i -ene uniformt fordelt på $[0, 1]$. Benytt intervallet i (e) til å teste nullhypotesen om at X_i -ene er uniformt fordelt mot alternativet at de ikke er det med nivå 5%.

Finn også P-verdien for tilsvarende test. P-verdien må her angis ved et intervall den må ligge innenfor bestemt av kvantiler q_γ i standardnormalfordelingen i tabellen under som angitt $P(Z \leq q_\gamma) = \gamma$ når $Z \sim N(0, 1)$.

Sannsynlighet γ	0.001	0.005	0.010	0.015	0.020	0.025	0.050	0.100	0.200
Kvantil q_γ	-3.09	-2.58	-2.33	-2.17	-2.05	-1.96	-1.64	-1.28	-0.84

Oppgave 2

En enkel lineær regresjonsmodell er spesifisert ved at responser $Y_i, i = 1, \dots, n$ er uavhengige og normalfordelte med samme varians σ^2 og med forventninger $E(Y_i) = \beta_0 + \beta_1 x_i$ der x_i er kjente forklaringsvariable.

- (a) Minste kvadraters estimatoren for β_1 kan gis ved

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (Y_i - \bar{Y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

der $\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$ og $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ (Dette skal du ikke vise).

Vis at $\hat{\beta}_1$ er forventningsrett for β_1 .

Alternativ kan man skrive opp $\hat{\beta}_1$ på formen (det skal du heller ikke vise)

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n Y_i (x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Utledd fra denne formelen at variansen til $\hat{\beta}_1$ er gitt ved uttrykket

$$V(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

- (b) I en studie av 600 barnehagebarn i Oslo registrerte man x_i = barnas høyde (i cm) samt deres lungefunksjon Y_i via målet "forced vital capacity" (FVC, som er mengden luft en person klarer å blåse ut, her målt i liter). Den (litt editerte) utskriften på neste side gir resultater fra en enkel lineær regresjon med respons Y_i og forklaringsvariabel x_i .

Angi og fortolk estimatene for modellens parametre.

Angi en formel for t-verdien knyttet til høyde og forklar hvilken nullhypotese og hvilken alternativ hypotese dette er en testobservator for.

Hva er fordelingen til testobservatoren under nullhypotesen?

Formuler en konklusjon på testen.

(Fortsettes på side 3.)

Call:

```
lm(formula = fvc ~ hoyde, data = lunge)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-2.293767	0.115758	-19.82	<2e-16 ***
hoyde	0.031443	0.001057	29.74	<2e-16 ***

Residual standard error: 0.197 on 598 degrees of freedom


Multiple R-squared: 0.5966, Adjusted R-squared: 0.5959

F-statistic: 884.5 on 1 and 598 DF, p-value: < 2.2e-16

- (c) Definer tilpassede (predikerte) verdier $\hat{y}_i$ og residualer e_i .

Diskuter hvordan $\hat{y}_i$ og e_i kan benyttes til å sjekke modellforutsetninger grafisk i lineære regresjonsmodeller. Du kan i denne sammenheng gjøre bruk av residualplott fra den enkle lineære regresjonsmodellen i punkt (b). (Ignorer at to av plottene benytter standardiserte residualer i stedet for vanlige residualer e_i).

Konkluder om modellen som ble brukt synes å passe med data. Begrunn svaret.



- (d) En multipel lineær regresjonsmodell med to forklaringsvariable x_{i1} og x_{i2} gis ved følgende modell for responsen $Y_i, i = 1, \dots, n$:

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$$

der $\varepsilon_i \sim N(0, \sigma)$ er uavhengige og β_j er regresjonsparametre.

Regresjonsparametrene estimeres vanligvis ved å minimere kvadratsummen $g(b_0, b_1, b_2) = \sum_{i=1}^n (Y_i - b_0 - b_1 x_{i1} - b_2 x_{i2})^2$. Vis at en finner estimatene $\hat{\beta}_0, \hat{\beta}_1$ og $\hat{\beta}_2$ ved å løse tre lineære ligninger med tre ukjente.

Sett opp disse ligningene på komponentform og skriv så dette om til matriseform.

Utled løsningen for $\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2)'$ på matriseform.

Angi betingelsen for at det eksisterer en entydig løsning.

(Fortsettes på side 4.)

- (e) I en videre analyse av barnehagebarnas lungekapasitet Y_i er det benyttet multippel lineær regresjon med to forklaringsvariable x_{i1} = høyde (i cm) og x_{i2} = vekt (i kg). Resultater fra analysen er gjengitt i utskrift fra R under.

Gi en (kvalitativ) forklaring på endringen i estimert regresjonskoeffisient for høyde sammenlignet med estimatet fra punkt (b). Du kan benytte at x_{i1} og x_{i2} er positivt korrelert i disse dataene.

Angi også et uttrykk for størrelsen Multiple R-squared og forklar hvorfor denne kan fortolkes som andel forklart variasjon (evt. varians).

Sammenlign med den tilsvarende størrelsen i den enkle lineære regresjonen. Kommenter.

For enkel lineær regresjon er størrelsen R^2 knyttet til korrelasjonskoeffisienten mellom respons og forklaringsvariabel. Angi eksakt hvordan.

Uttrykk en tilsvarende sammenheng ved den multiple lineære regresjonen.

Call:

```
lm(formula = fvc ~ hoyde + vekt, data = lunge)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-2.037726	0.122648	-16.614	< 2e-16 ***
hoyde	0.026209	0.001416	18.504	< 2e-16 ***
vekt	0.017394	0.003220	5.403	9.49e-08 ***

Residual standard error: 0.1925 on 597 degrees of freedom

Multiple R-squared: 0.6154, Adjusted R-squared: 0.6141

F-statistic: 477.7 on 2 and 597 DF, p-value: < 2.2e-16

SLUTT

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse
Korrigert versjon

Eksamensdag: 28. november - 2023

Tid for eksamen: 15.00 – 19.00.

Oppgavesettet er på 5 sider.

Vedlegg: Ingen

Tillatte hjelpemidler: Godkjent kalkulator
Formelsamling for STK1110

Kontroller at oppgavesettet er komplett før
du begynner å besvare spørsmålene.

Tabell over øvre kvantiler for Normal, noen T-fordelinger og noen F-fordelinger:

Fordeling	Kvantiler				
	0.5	0.05	0.025	0.01	0.005
Normal	0.000	1.645	1.960	2.326	2.576
T_{155}	0.000	1.655	1.975	2.351	2.608
T_{154}	0.000	1.655	1.975	2.351	2.608
T_{30}	0.000	1.697	2.042	2.457	2.750
T_{29}	0.000	1.699	2.045	2.462	2.756
T_{28}	0.000	1.701	2.048	2.467	2.763
T_{27}	0.000	1.703	2.052	2.473	2.771
$T_{24.569}$	0.000	1.709	2.061	2.488	2.791
T_3	0.000	2.353	3.182	4.541	5.841
T_2	0.000	2.920	4.303	6.965	9.925
T_1	0.000	6.314	12.706	31.821	63.657
$F_{13,13}$	1.000	2.577	3.115	3.905	4.573
$F_{14,14}$	1.000	2.484	2.979	3.698	4.299
$F_{15,15}$	1.000	2.403	2.862	3.522	4.070


Oppgave 1

Plottet nedenfor viser data fra et studie på funksjonalitet av nyrer på 157 friske frivillige individer. Individenes alder er gitt på x -aksen mens y -aksen gir et sammensatt mål **tot** for generell funksjon. Funksjonen avtar generelt med alder, noe som tydelig sees av plottet. Den rette linjen viser en tilpasning basert på lineær regresjon:

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

der $\hat{\beta}_0, \hat{\beta}_1$ er beregnet utifra minste kvadraters prinsippet. Her er x = Alder og Y = tot.

(Fortsettes på side 2.)



- (a) Utskriften nedenfor viser oppsummering av tilpasningen:

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2.860673	0.359561	7.956	3.49e-13
Alder	-0.078601	0.009056	-8.680	5.14e-15

Residual standard error: 1.801 on 155 degrees of freedom

Multiple R-squared: 0.3271, Adjusted R-squared: 0.3227

F-statistic: 75.34 on 1 and 155 DF, p-value: 5.137e-15

Forklar hva de ulike delene i denne utskriften beskriver.

- (b) Gir utskriften ovenfor indikasjon på at **Alder** er en viktig forklaringsvariabel? Begrunn svaret.

Lag et 95% konfidensintervall for β_1 .

Kommentér også verdien på R^2 .

- (c) En alternativ modell er å ta med et kvadratisk ledd for alder. Utskriften nedenfor gir en oppsummering for tilpasning en modell

$$Y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$$

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2.5867806	1.1051749	2.341	0.0205

(Fortsettes på side 3.)

```

Alder      -0.0644796  0.0546218  -1.180    0.2396
Alder^2    -0.0001523  0.0005808  -0.262    0.7935

```

```

Residual standard error: 1.806 on 154 degrees of freedom
Multiple R-squared:  0.3274, Adjusted R-squared:  0.3186
F-statistic: 37.48 on 2 and 154 DF,  p-value: 5.477e-14

```

Du får her også oppgitt at estimert korrelasjon mellom $\hat{\beta}_1$ og $\hat{\beta}_2$ er -0.986.

Prøv å forklare hvorfor tilsynelatende hverken **Alder** eller **Alder**² er signifikant forskjellige fra null, men at man likevel får en svært signifikant P-verdi i siste linje av utskriften.

- (d) Anta nå vi ønsker å predikere responsen tot for **Alder**=20 og **Alder**=90. Tabellen nedenfor viser prediksjonsestimater med 95% prediksjonsintervaller for modellen med kun lineært ledd (Modell 1) og modellen med kvadratisk ledd (Modell 2). Her er **lwr** og **upr** nedre og øvre grenser, henholdsvis.

Forklar hvorfor intervallene er ganske brede selv om usikkerheten i $\hat{\beta}_j$ estimatene er ganske små.

Forklar hvorfor det er rimelig at resultatene er ganske like for **Alder**=20 mens de er mer forskjellige for **Alder**=90.

Modell	Alder	Estimat	lwr	upr
1	20	1.289	-2.292	4.870
1	90	-3.427	-7.081	0.226
2	20	1.236	-2.377	4.850
2	90	-3.546	-7.318	0.226

Oppgave 2

Anta vi har to uavhengige stokastiske variable, X og Y der

$$X \sim \text{Gamma}(\alpha, \beta);$$

$$Y \sim \text{Gamma}(3\alpha, \beta).$$

Anta α er kjent, mens β er ukjent.

- (a) Sett opp likelihoodfunksjonen for β basert på observasjonene X og Y og vis at log-likelihood funksjonen (der noen ledd som ikke avhenger av β er fjernet) er

$$\ell(\beta) = -4\alpha \log(\beta) - \frac{1}{\beta}(x + y).$$

Merk: I ditt likelihood uttrykk skal alle ledd være med!

- (b) Utled en formel for maksimum likelihood estimatet for β , $\hat{\beta}_{ML}$.

Beregn forventning og varians for ML estimatet til $\hat{\beta}_{ML}$.

(Fortsettes på side 4.)

- (c) Hvis α er et stort heltall, argumenter hvorfor $\hat{\beta}_{ML}$ er tilnærmet normalfordelt.

Hvis $\alpha = 20$, $x = 12.907$ og $y = 26.863$, beregn en tilnærmet verdi for variansen til $\hat{\beta}$.

Oppgave 3

Tabellen nedenfor viser årlig skillsmisserate for noen europeiske og asiatiske land (FN, 1994). Vi ønsker å teste om det er forskjell i skillsmissehyppighet mellom de to verdensdelene representert ved disse spesifikke landene.

Europa	0.80	2.10	1.30	1.90	2.70	2.50	2.40	1.10
	2.90	1.90	0.90	2.40	2.20	2.80	0.60	
Asia	1.30	1.60	1.20	0.80	1.00	0.80	1.30	1.40
	1.60	1.90	1.50	0.80	2.80	0.90	1.30	

Vi har også følgende oppsummerende mål:

	Mean	S^2
Europa	1.900	0.596
Asia	1.347	0.273

- (a) Anta dataene er uavhengige og normalfordelte med henholdsvis $N(\mu_1, \sigma_1^2)$ for data fra Europa og $N(\mu_2, \sigma_2^2)$ for data fra Asia.

Utfør en test for å sjekke om variansene i de to utvalg er forskjellige. Formuler en konklusjon på testen.

- (b) Basert på formler i formelsamlingen, *utled* hvordan konfidensintervall for $\mu_1 - \mu_2$ generelt ser ut.

Beregn både et 95% konfidensintervall og et 99% konfidensintervall for $\mu_1 - \mu_2$.

Spesifiser hvilken metode du bruker for å lage disse konfidensintervallene og hvilke ekstra antagelser du gjør.

- (c) En kan vise at P-verdien for en test av hypotesen $H_0 : \mu_1 = \mu_2$ mot alternativet $H_a : \mu_1 \neq \mu_2$, basert på normalfordelingsantagelsen, ligger mellom 0.01 og 0.05.

Hvordan vil du konkludere med hensyn på å teste de to hypotesene mot hverandre?



I forhold til konfidensintervallene du fikk i (b), virker det rimelig at P-verdien ligger i intervallet $[0.01, 0.05]$?

- (d) I kurset har vi lært om også lært om Wilcoxon signed rank-test for ett utvalg. Denne metoden kan imidlertid også brukes for testing av forskjell mellom to utvalg (detaljene er ikke viktige her, bortsett fra at denne utvidelsen også bygger på at fordelingene er symmetriske). For det konkrete datasettet får vi da en P-verdi på 0.061.

Hvorfor er det rimelig at man nå får en høyere P-verdi?

(Fortsettes på side 5.)

Plottene nedenfor viser normal kvantilplot for data fra Europa (venstre) og Asia (høyre). Basert på disse plottene, hvilken test vil du foretrekke å bruke?



SLUTT

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse

Eksamensdag: Torsdag 8. desember 2022

Tid for eksamen: 09.00 – 13.00

Oppgavesettet er på 6 sider.

Vedlegg: Ingen

Tillatte hjelpemidler: Godkjent kalkulator
Formelsamling for STK1110

Kontroller at oppgavesettet er komplett før
du begynner å besvare spørsmålene.

Nedenfor er det gitt kritiske verdier $t_{\alpha,\nu}$ for t-fordelingen med ν frihetsgrader for noen verdier av α og ν . Du vil få bruk for tabellen i Oppgave 1 og 3.

$\alpha :$	0.10	0.05	0.025	0.0125	0.01	0.005
$t_{\alpha,13}$	1.350	1.771	2.160	2.533	2.650	3.012
$t_{\alpha,14}$	1.345	1.761	2.145	2.510	2.624	2.977
$t_{\alpha,15}$	1.341	1.753	2.131	2.490	2.602	2.947
$t_{\alpha,16}$	1.337	1.746	2.120	2.473	2.583	2.921
$t_{\alpha,17}$	1.333	1.740	2.110	2.458	2.567	2.898
$t_{\alpha,18}$	1.330	1.734	2.101	2.445	2.552	2.878

Oppgave 1

Under er det vist gjennomsnittlig sjøtemperatur i aprilmåned, målt utenfor Ekofisk-feltet i løpet av 15 år i perioden 1995 til 2022 (målingene er oppgitt i $^{\circ}\text{C}$):

6.6 4.6 6.3 7.1 6.8 5.8 6.5 6.9 4.8 7.9 7.7 7.4 7.5 6.4 7.2

La X_i være i -te måling av temperaturen. Det antas at $X_1, \dots, X_{15} \stackrel{\text{uif}}{\sim} N(\mu, \sigma^2)$ (målingene av temperaturen er gjort med nokså lange mellomrom, slik at antakelsen om uavhengighet er rimelig).

a

- Utled et 95% konfidensintervall for forventet sjøtemperatur.

- Beregn intervallet for dataene over, når du får vite at observert snitt og standardavvik er $\bar{x} = (1/15) \sum_{i=1}^{15} x_i = 6.63$ og $s = \sqrt{(1/14) \sum_{i=1}^{15} (x_i - \bar{x})^2} = 0.967$.

(Fortsettes på side 2.)

Temperaturen har tidligere vært på gjennomsnittlig 6.2°C , men forskere tror den kan ha endret seg. De vil derfor teste hypotesene

$$H_0 : \mu = 6.2 \text{ mot } H_a : \mu \neq 6.2.$$

b

- Utled en hypotesetest for disse hypotesene med signifikansnivå 5%.
- Hva blir konklusjonen ut fra de observasjonene som ble gjort?

c

- Forklar hva en P-verdi generelt betyr, altså definér hva den er.
- Finn et uttrykk for P-verdien til testen i Oppgave **b**.
- Bruk tabellen over kritiske verdier for t-fordelingen til å si noe om størrelsesorden for P-verdien.

Oppgave 2

La $X_1, \dots, X_n$ være uavhengige stokastiske variabler fra $\text{Gamma}(4, \beta)$ -fordelingen, dvs. med sannsynlighetstetthet

$$f(x; \beta) = \frac{1}{6\beta^4} x^3 e^{-\frac{x}{\beta}}, \quad x > 0,$$

med $\beta > 0$ som ukjent parameter. Anta så at vi har observasjoner $x_1, \dots, x_n$ av disse.

a

Sett opp likelihood- og log-likelihood-funksjonen, og vis at maksimum likelihood-estimatoren blir $\hat{\beta}_{ML} = \frac{1}{4}\bar{X}$.

b

Vis at Fisher-informasjonen i én observasjon er $I(\beta) = \frac{4}{\beta^2}$.

c

Begrunn at $\hat{\beta}_{ML}$ er tilnærmet normalfordelt $N(\beta, \sigma_{\hat{\beta}}^2)$ -fordelt for store n , og finn et uttrykk for $\sigma_{\hat{\beta}}^2$.

La nå $\psi = \frac{1}{\beta}$.

d

Begrunn at maksimum likelihood-estimatoren for ψ er $\hat{\psi}_{ML} = 4/\bar{X}$.

(Fortsettes på side 3.)

Vi ønsker nå i stedet å bruke Bayes-estimatoren til å estimere ψ , og spesifiserer derfor apriorifordelingen $\psi \sim \text{Gamma}(\alpha_0, \beta_0)$. Sannsynlighetstettheten til hvert enkelt datapunkt kan da reparametriseres til

$$f(x|\psi) = \frac{\psi^4}{6} x^3 e^{-\psi x}, \quad x > 0.$$

e

- Hva vil det si at en apriorifordeling er konjugert med fordelingen til dataene?

- Vis at apriorifordelingen til ψ er konjugert med fordelingen til $X_1, \dots, X_n | \psi$, og nærmere bestemt at

$$[\psi | X_1 = x_1, \dots, X_n = x_n] \sim \text{Gamma}\left(\alpha_0 + 4n, \frac{1}{\frac{1}{\beta_0} + \sum_{i=1}^n x_i}\right).$$

- Finn Bayes-estimatoren for ψ , og sammenlikn denne med maksimum likelihood-estimatoren fra Oppgave d.

Oppgave 3

En ønsker å undersøke hvordan nivået på årlige importen til et land avhenger av det årlige forbruket. Dataene nedenfor viser årlig import og forbruk i Frankrike i millioner FRF (franske franc) i løpet av de 18 årene fra 1949 til 1966:

import forbruk

15.9	108.1
16.4	114.8
19.0	123.2
19.1	126.9
18.8	132.1
20.4	137.7
22.7	146.0
26.5	154.1
28.1	162.3
27.6	164.3
26.3	167.6
31.1	176.8
33.3	186.6
37.0	199.7
43.3	213.9
49.0	223.8
50.3	232.0
56.6	242.9

Vi tilpasser først en enkel lineær regresjonsmodell med import som responsvariabel Y og forbruk som forklaringsvariabel x_1 , dvs.

$$Y_i = \beta_0 + \beta_1(x_{i1} - \bar{x}_1) + \epsilon_i, \quad i = 1, \dots, 18, \quad (1)$$

der $\bar{x}_1 = (1/18) \sum_{i=1}^{18} x_{i1}$, og vi antar at $\epsilon_1, \dots, \epsilon_{18} \stackrel{wif}{\sim} N(0, \sigma^2)$. Resultatet av denne analysen er gitt i R-utskriften på neste side.

(Fortsettes på side 4.)

R-utskrift fra tilpasning til modell (1):

Call:

```
lm(formula = import ~ I(forbruk - mean(forbruk)))
```

Residuals:

Min	1Q	Median	3Q	Max
-3.8435	-1.4407	-0.5032	1.6780	4.1982

Coefficients:

Estimate	Std. Error	t value	Pr(> t)
(Intercept)	30.07778	0.52732	57.04 < 2e-16 ***
I(forbruk - mean(forbruk))	0.29559	0.01305	22.65 1.39e-13 ***

---Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.237 on 16 degrees of freedom

Multiple R-squared: 0.9698, Adjusted R-squared: 0.9679


F-statistic: 513.1 on 1 and 16 DF, p-value: 1.392e-13

a


- Gi en fortolkning av estimatene $\hat{\beta}_0$ og $\hat{\beta}_1$.
- Lag så et 95% konfidensintervall for β_1 (du trenger ikke å utlede det, men skriv opp formelen du bruker).
- Kan en forvente at importen øker med omtrent 0.25 millioner FRF når forbruket øker med 1 million FRF?

Residualplott for modell (1) er vist under:


Residualer mot
tilpassede verdier



Normalfordelingsplott
av standardiserte residualer



Standardiserte residualer
mot tilpassede verdier



b

- Hvilke modellantakelser har en gjort i modell (1)?
- Hvordan sjekker en hver av modellantakelsene med ved hjelp av residualplottene over?
- Benytt residualplottene over til å vurdere gyldigheten av modellantakelsene i modell (1).

(Fortsettes på side 5.)

Ut fra resultatene i residualplottene i Oppgave **b**, velger vi å tilpasse følgende multiple lineære regresjonsmodell i stedet:

$$Y_i = \gamma_0 + \gamma_1(x_{i1} - \bar{x}_1) + \gamma_2 x_{i2} + \varepsilon_i, \quad i = 1, \dots, 18, \quad (2)$$

der $x_{i2} = (x_{i1} - \bar{x}_1)^2$ og $\varepsilon_1, \dots, \varepsilon_{18} \stackrel{uif}{\sim} N(0, \tau^2)$.

c

- Vis at forventet import nå er en kvadratisk funksjon av forbruket.
- Hvor mye øker forventet import når forbruket øker med én enhet fra x_1^* (altså fra x_1^* til $x_1^* + 1$)?
- Hva er nå fortolkningen av konstantleddet γ_0 , og hva med fortolkningen av γ_1 ?

Under og på neste side vises

- R-utskriften fra en test av modell (2) mot modell (1).
- R-utskriften fra tilpasningen til modell (2)
- residualplott for modell (2)

d

- Hvilke hypoteser er det som testes i R-utskriften under?
- Hvilken av modellene (1) og (2) vil du velge basert på hypotesetesten og R-utskriften fra tilpasningen? Begrunn svaret ditt.
- Bruk residualplottene til å sjekke modellantakelsene for modell (2), og sammenlikn med Oppgave **b**.

R-utskrift fra hypotesetest av modell (2) mot modell (1):

Analysis of Variance Table

```
Model 1: import ~ I(forbruk - mean(forbruk))
Model 2: import ~ I(forbruk - mean(forbruk)) + I((forbruk - mean(forbruk))^2)
  Res.Df    RSS Df Sum of Sq    F    Pr(>F)
1      16 80.082
2      15 16.397  1    63.685 58.261 1.528e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

(Fortsettes på side 6.)

R-utskrift fra tilpasning til modell (2):

Call:

```
lm(formula = import ~ I(forbruk - mean(forbruk)) + I((forbruk -
  mean(forbruk))^2))
```

Residuals:

	Min	1Q	Median	3Q	Max
	-1.79590	-0.52376	-0.04364	0.47666	1.92453

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	28.034259	0.363875	77.044	< 2e-16 ***
I(forbruk - mean(forbruk))	0.277111	0.006561	42.233	< 2e-16 ***
I((forbruk - mean(forbruk))^2)	0.001251	0.000164	7.633	1.53e-06 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 1.046 on 15 degrees of freedom

Multiple R-squared: 0.9938, Adjusted R-squared: 0.993


F-statistic: 1204 on 2 and 15 DF, p-value: < 2.2e-16

Residualplott for modell (2):


Residualer mot
tilpassede verdier



Normalfordelingsplott
av standardiserte residualer



Standardiserte residualer
mot tilpassede verdier



END

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse

Eksamensdag: Fredag 3. desember 2021

Tid for eksamen: 09.00 – 13.00

Oppgavesettet er på 5 sider.

Vedlegg: Ingen

Tillatte hjelpemidler: Alle hjelpemidler tillatt

Kontroller at oppgavesettet er komplett før
du begynner å besvare spørsmålene.

Nedenfor er det gitt kritiske verdier $t_{\alpha,\nu}$ for t-fordelingen med ν frihetsgrader for noen verdier av α og ν . Du vil få bruk for tabellen i Oppgave 1 og 3.

α :	0.05	0.025	0.0125	0.01	0.005	0.001	0.0001	0.00001
$t_{\alpha,15}$	1.753	2.131	2.490	2.602	2.947	3.733	4.880	6.109
$t_{\alpha,16}$	1.746	2.120	2.473	2.583	2.921	3.686	4.791	5.959
$t_{\alpha,17}$	1.740	2.110	2.458	2.567	2.898	3.646	4.714	5.832
$\vdots$				$\vdots$				$\vdots$
$t_{\alpha,69}$	1.667	1.995	2.291	2.382	2.649	3.213	3.929	4.580
$t_{\alpha,70}$	1.667	1.994	2.291	2.381	2.648	3.211	3.926	4.576
$t_{\alpha,71}$	1.667	1.994	2.290	2.380	2.647	3.209	3.923	4.571

Oppgave 1

17 unge kvinner blir lagt inn til behandling mot anorexia. De ble veid ved innleggelsestidspunktet, samt etter en periode med familieterapi. Et utdrag av før- og ettermålingene av vekt i lb (pund), samt differansen mellom de to, er vist under.

Før	Etter	Differanse
83.8	95.2	11.4
83.3	94.3	11.0
86.0	91.5	5.5
.	.	.
.	.	.
.	.	.
89.9	93.8	3.9
86.0	91.7	5.7
87.3	98.0	10.7

La D_i differansen mellom vekten til kvinne nummer i etter terapien og før terapien, altså vektøkningen fra første til siste måling. Det antas at

(Fortsettes på side 2.)

$D_1, \dots, D_{17} \stackrel{uif}{\sim} N(\mu_D, \sigma_D^2)$. En ønsker å undersøke om terapien virker ved å lage et konfidensintervall for μ_D , samt ved å test hypotesene

$$H_0 : \mu_D \leq 0 \text{ mot } H_a : \mu_D > 0.$$

a

- Utled et 95% konfidensintervall for forventet vektøkning μ_D etter terapien.
- Beregn intervallet for dataene over, når du får vite at observert snitt og standardavvik for vektdifferensene er $\bar{d} = (1/17) \sum_{i=1}^{17} d_i = 7.26$ og $s_d = \sqrt{(1/16) \sum_{i=1}^{17} (d_i - \bar{d})^2} = 7.16$.

b

- Utled en hypotesetest med signifikansnivå 5% for hypotesene over vedrørende effekten av terapien på vektøkningen.
- Hva blir konklusjonen ut fra de observasjonene som ble gjort?

c

- Forklar hva en P-verdi generelt betyr, altså definér hva den er.
- Finn et uttrykk for P-verdien til testen i punkt c).
- Bruk tabellen over kritiske verdier for t-fordelingen til å si noe om størrelsesorden for P-verdien.

Oppgave 2

La $X_1, \dots, X_n$ være uavhengige stokastiske variabler fra Weibull-fordelingen, dvs. med sannsynlighetstetthet

$$f(x; \alpha, \beta) = \frac{\alpha}{\beta^\alpha} x^{\alpha-1} e^{-\left(\frac{x}{\beta}\right)^\alpha}, \quad x > 0,$$

med $0 < \alpha$ og $0 < \beta$. I hele oppgaven antas det at α er kjent og at $\alpha > 1$, mens β er ukjent. Videre får du oppgitt at for en Weibull-fordelt variabel er $E(X^r) = \beta^r \Gamma\left(1 + \frac{r}{\alpha}\right)$ for en hvilken som helst $r > 0$ når $\alpha > 1$, der $\Gamma(\cdot)$ er gammafunksjonen.

a

Vis at momentestimatoren for β er $\tilde{\beta} = \frac{\bar{X}}{\Gamma(1+\frac{1}{\alpha})}$, der $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$.

b

Bruk sentralgrenseteoremet til å vise at $\tilde{\beta}$ er tilnærmet $N(\beta, \sigma_{\tilde{\beta}}^2)$ -fordelt for store n , med $\sigma_{\tilde{\beta}}^2 = \frac{\beta^2}{n} \left(\Gamma\left(1 + \frac{2}{\alpha}\right) / \Gamma\left(1 + \frac{1}{\alpha}\right)^2 - 1 \right)$.

c

Sett opp likelihood- og log-likelihood-funksjonen, og finn et uttrykk for maksimum likelihood-estimatoren $\hat{\beta}$.

(Fortsettes på side 3.)

d

- Begrunn at $\hat{\beta}$ er tilnærmet $N(\beta, \sigma_{\hat{\beta}}^2)$ -fordelt for store n , og finn et uttrykk for $\sigma_{\hat{\beta}}^2$ når du får vite at Fisher-informasjonen i én observasjon er $I(\beta) = \frac{\alpha^2}{\beta^2}$.
- Hvilken av estimatorene $\tilde{\beta}$ og $\hat{\beta}$ vil du foretrekke? Begrunn svaret ditt (*Hint*: du kan bruke at $\alpha^2 \left(\Gamma\left(1 + \frac{2}{\alpha}\right) / \Gamma\left(1 + \frac{1}{\alpha}\right)^2 - 1 \right) > 1$ når $\alpha > 1$).

Oppgave 3

Vi går tilbake til vektdataene fra Oppgave 1. Det fulle datasettet inkluderer vektmålinger av 72 unge kvinner på to forskjellige tidspunkter. Av de 72 kvinnene fikk 17 familieterapi (dette er dataene fra Oppgave 1), 29 fikk kognitiv behandling og 26 fikk ingen behandling, og utgjør en kontrollgruppe.

Vi velger først å analysere dataene ved hjelp av enveis variansanalyse, der målingene av interesse er differensen mellom siste og første vektmåling, dvs. vektøkningen fra første til siste måling (disse ble kalt D_i i Oppgave 1), og grupperingen er gjort med type behandling som faktor. Resultatene fra analysen er vist under.

```

              Df Sum Sq Mean Sq F value Pr(>F)
factor(behandling)  2      615   307.32    5.422 0.0065 **
Residuals          69     3911    56.68
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

a

- Forklar oppsettet for å utføre en slik analyse på dette datasettet, altså skriv ned modellen og forklar hvilke antakelser som gjøres og hvilke hypoteser som testes.
- Hva kan du si om effekten av behandling ut fra resultatene?

Et alternativ til enveis variansanalyse er en lineær regresjonsmodell, med målt vektøkning som responsvariabel Y . Videre velger vi i denne omgang å gruppere kvinnene etter om de fikk behandling eller ikke, uten å spesifisere hvilken behandling de eventuelt fikk. Vår ene forklaringsvariabel x er da gitt ved:

$$x_i = \begin{cases} 1, & \text{kvinne } i \text{ fikk behandling} \\ 0, & \text{kvinne } i \text{ fikk ikke behandling} \end{cases}$$

og modellen er:

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i,$$

der vi antar at $\varepsilon_i \stackrel{uif}{\sim} N(0, \sigma^2)$. Resultatet av denne analysen er gitt i R-utskriften nedenfor.

Call:

```
lm(formula = vekt.diff ~ behandling.gruppert)
```

Residuals:

(Fortsettes på side 4.)

Min	1Q	Median	3Q	Max
-13.6804	-5.3054	-0.8804	6.1946	16.9196

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.450	1.502	-0.300	0.76535
behandling.gruppert	5.030	1.879	2.677	0.00924 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.658 on 70 degrees of freedom

Multiple R-squared: 0.09289, Adjusted R-squared: 0.07993

F-statistic: 7.168 on 1 and 70 DF, p-value: 0.009239

b

- Bruk utskriften fra R til å angi hva estimatene $\hat{\beta}_0$ og $\hat{\beta}_1$ er.
- Vis at

$$E(Y_i|x_i = 0) = \beta_0 \quad \text{og} \quad E(Y_i|x_i = 1) = \beta_0 + \beta_1,$$

og bruk dette til å gi en fortolkning av $\hat{\beta}_0$ og $\hat{\beta}_1$.

- Lag også et 95% konfidensintervall for β_1 (du trenger ikke å utlede det, men skriv opp formelen du bruker).
- Hva kan du si om effekten av behandling på forventet vektøkning ut fra intervallet?

Vi ønsker nå å undersøke effekten av de to ulike behandlingene. Vi definerer derfor de to forklaringsvariablene x_1 og x_2 ved:

$$x_{1i} = \begin{cases} 1, & \text{kvinne } i \text{ fikk behandling 1} \\ 0, & \text{kvinne } i \text{ fikk ikke behandling 1} \end{cases} \quad x_{2i} = \begin{cases} 1, & \text{kvinne } i \text{ fikk behandling 2} \\ 0, & \text{kvinne } i \text{ fikk ikke behandling 2} \end{cases}$$

der behandling 1 er familierterapi og behandling 2 er kognitiv behandling. Vår nye modell er da gitt ved:

$$Y_i = \gamma_0 + \gamma_1 x_{1i} + \gamma_2 x_{2i} + \varepsilon_i^*,$$

der vi antar at $\varepsilon_i^* \stackrel{uif}{\sim} N(0, (\sigma^*)^2)$. Resultatet av denne analysen er gitt i R-utskriften nedenfor.

Call:

lm(formula = vekt.diff ~ factor(behandling), x = TRUE)

Residuals:

Min	1Q	Median	3Q	Max
-12.565	-4.543	-1.007	3.846	17.893

(Fortsettes på side 5.)

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.450	1.476	-0.305	0.7614
factor(behandling)1	7.715	2.348	3.285	0.0016 **
factor(behandling)2	3.457	2.033	1.700	0.0936 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.528 on 69 degrees of freedom

Multiple R-squared: 0.1358, Adjusted R-squared: 0.1108

F-statistic: 5.422 on 2 and 69 DF, p-value: 0.006499

c

- Finn $E(Y_i | x_{1i} = j, x_{2i} = k)$ for de tre mulige kombinasjonene $(0, 0)$, $(1, 0)$ og $(0, 1)$ for j, k , og bruk disse til å gi en fortolkning av $\hat{\gamma}_0$, $\hat{\gamma}_1$ og $\hat{\gamma}_2$.
- Hvorfor er $\gamma_0 = \beta_0$, der β_0 er konstantleddet fra Oppgave a)?

Vi ønsker å finne ut om hver av de to behandlingsformene har en effekt på forventet vektøkning eller ikke. Vi vil derfor teste hypotesene

$$H_0 : \gamma_j = 0 \text{ mot } H_a : \gamma_j \neq 0,$$

for $j = 1, 2$.**d**

- Forklar hvilke testobservatorer og tilhørende forkastningsområder du kan bruke for å teste hypotesene over med 5% signifikansnivå.
- Utfør så testene for $j = 1$ og 2 basert på R-utskriftene.
- Hva kan du si om effekten av familieterapi (behandling 1) og kognitiv behandling (behandling 2), og hvordan samsvarer disse resultatene med resultatene fra Oppgave a) og b)?

END

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse

Eksamensdag: Torsdag 26. november 2020

Tid for eksamen: 09.00 – 13.00

Oppgavesettet er på 6 sider.

Vedlegg: Ingen

Tillatte hjelpemidler: Alle hjelpemidler tillatt

Kontroller at oppgavesettet er komplett før
du begynner å besvare spørsmålene.

Nedenfor er det gitt kritiske verdier $t_{\alpha,\nu}$ for t-fordelingen med ν frihetsgrader for noen verdier av α og ν . Du vil få bruk for tabellen i Oppgave 1 og 3.

$\alpha :$	0.05	0.025	0.01	0.005	0.001	0.0001	0.00001
$t_{\alpha,8}$	1.860	2.306	2.896	3.355	4.501	6.442	8.907
$t_{\alpha,9}$	1.833	2.262	2.821	3.250	4.297	6.010	8.102
$t_{\alpha,10}$	1.812	2.228	2.764	3.169	4.144	5.694	7.527
$\vdots$				$\vdots$			$\vdots$
$t_{\alpha,26}$	1.706	2.056	2.479	2.779	3.435	4.324	5.197
$t_{\alpha,27}$	1.703	2.052	2.473	2.771	3.421	4.299	5.157
$t_{\alpha,28}$	1.701	2.048	2.467	2.763	3.408	4.275	5.120

Oppgave 1

En eplebonde har fått målt gjennomsnittlig vekt i gram per eple på 28 av epletrærne sine. Dataene er vist under.

85.3 86.9 96.8 108.5 113.8 87.7 94.5 99.9 92.9 67.3 90.6
129.8 48.9 117.5 100.8 94.5 94.4 98.9 96.0 99.4 79.1 108.5
84.6 117.5 70.0 104.4 127.1 135.0

La X_i være gjennomsnittlig vekt per eple på tre nummer i . Det antas at $X_1, \dots, X_{28} \stackrel{uif}{\sim} N(\mu, \sigma^2)$.

a

Utled et 99% konfidensintervall for forventet gjennomsnittlig vekt μ per eple. Beregn intervallet for dataene over, når du får vite at observert snitt og standardavvik er $\bar{x} = 1/28 \sum_{i=1}^{28} x_i = 97.52$ og $s = \sqrt{1/27 \sum_{i=1}^{28} (x_i - \bar{x})^2} = 18.95$.

Ifølge MatPrat veier et gjennomsnittlig eple 115 gram. Eplebonden ønsker å finne ut om epletrærne hans gir epler av normal størrelse, eller om de er litt

(Fortsettes på side 2.)

små. Han vil derfor teste hypotesene

$$H_0 : \mu \geq 115 \text{ mot } H_a : \mu < 115.$$

b

Utleid en test med signifikansnivå 1%. Hva blir konklusjonen ut fra de observasjonene som ble gjort?

c

Finn et uttrykk for P-verdien. Forklar hva den betyr. Bruk tabellen over kritiske verdier for t-fordelingen til å si noe om størrelsesorden for P-verdien.

Oppgave 2

La $X_1, \dots, X_n$ være uavhengige stokastiske variabler med punktsannsynlighet

$$f(x; \theta) = \frac{e^{-\theta x} (\theta x)^{x-1}}{x!}, \quad x = 0, 1, 2, \dots$$

med $0 < \theta < 1$. Vi sier at de stokastiske variablene er Borel-fordelt. For Borel-fordelingen har vi $E(X) = \frac{1}{1-\theta}$ (du skal ikke vise dette).

a

Vis at momentestimatoren for θ er $\tilde{\theta} = \frac{\bar{X}-1}{\bar{X}}$, der $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$.

b

Sett opp likelihood- og log-likelihood-funksjonen, og finn et uttrykk for maksimum likelihood-estimatoren $\hat{\theta}$.

c

Vis at Fisher-informasjonen i én observasjon er $I(\theta) = \frac{1}{\theta(1-\theta)}$.

d

Begrunn at $\hat{\theta}$ er tilnærmet $N(\theta, \sigma_{\hat{\theta}}^2)$ -fordelt og finn et uttrykk for $\sigma_{\hat{\theta}}^2$.

Oppgave 3


En ønsker å finne ut hvordan billettsalget for en kinofilm avhenger av produksjons- og markedsføringskostnadene. Dataene, som er basert på 10 Hollywood-filmer, består av

- responsvariabel y : **billettsalg**
- forklaringsvariabel x_1 : **produksjonskostnader**
- forklaringsvariabel x_2 : **markedsføringskostnader**,

(Fortsettes på side 3.)

alle oppgitt i millioner USD, og er vist i tabellen og matrisespredningsplottet under.

	bill.salg	prod.kost	mark.kost
1	85.1	8.5	5.1
2	106.3	12.9	5.8
3	50.2	5.2	2.1
4	130.6	10.7	8.4
5	54.8	3.1	2.9
6	30.3	3.5	1.2
7	79.4	9.2	3.7
8	91.0	9.0	7.6
9	135.4	15.1	7.7
10	89.3	10.2	4.5



Vi gjør først en regresjonsanalyse med produksjonskostnader som eneste forklaringsvariabel. Vi tilpasser da den lineære regresjonsmodellen:

$$Y_i = \beta_0 + \beta_1(x_{i1} - \bar{x}_1) + \epsilon_i, \quad i = 1, \dots, 10,$$

der $\bar{x}_1 = 1/n \sum_{i=1}^n x_{i1}$ og vi antar at $\epsilon_1, \dots, \epsilon_{10} \stackrel{uif}{\sim} N(0, \sigma^2)$. Resultatet av denne analysen er gitt i R -utskriften nedenfor.

Call:

```
lm(formula = bill.salg ~ I(prod.kost - mean(prod.kost)), data = film.data)
```

Residuals:

Min	1Q	Median	3Q	Max
-13.136	-9.029	-3.689	3.208	29.723

(Fortsettes på side 4.)

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	85.240	4.509	18.906	6.34e-08 ***
I(prod.kost - mean(prod.kost))	7.978	1.223	6.522	0.000184 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1




Residual standard error: 14.26 on 8 degrees of freedom

Multiple R-squared: 0.8417, Adjusted R-squared: 0.8219

F-statistic: 42.54 on 1 and 8 DF, p-value: 0.0001838

a

Gi en fortolkning av estimatene $\hat{\beta}_0$ og $\hat{\beta}_1$. Lag så et 95% konfidensintervall for β_1 . Et produksjonsselskap lurer på om de kan forvente å få økt billettsalget med 10 millioner USD per ekstra million de investerer. Kan du si noe om dette basert på konfidensintervallet du har laget?

Residualer mot
forklaringsvariabelNormalfordelingsplott
av standardiserte residualerStandardiserte residualer
mot tilpassede verdier**b**

Benytt residualplottene over, som er fra den enkle lineære regresjonsmodellen vurdert så langt, til å vurdere gyldigheten av modellantagelsene. Forklar spesielt hvordan avvik fra modellen kan påvises i de forskjellige plottene.

La x_1^* være en ny verdi av produksjonskostnadene, og la Y være det tilsvarende billettsalget. Videre la

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1(x_1^* - \bar{x})$$

være det predikerte billettsalget. Det kan vises (dette skal du ikke å gjøre) at $\hat{Y}$ kan skrives som

$$\hat{Y} = \sum_{i=1}^{10} \left(\frac{1}{10} + \frac{(x_1^* - \bar{x}_1)(x_{i1} - \bar{x}_1)}{S_{xx}} \right) Y_i$$

med $S_{xx} = \sum_{i=1}^{10} (x_{i1} - \bar{x}_1)^2$.

(Fortsettes på side 5.)

c

Bruk resultatene over til å argumentere for at $\hat{Y} \sim N(\mu_{Y|x^*}, \sigma_{\hat{Y}}^2)$. Vis at $\mu_{Y|x^*} = E(Y|x^*)$ og $\sigma_{\hat{Y}}^2 = \text{Var}(\hat{Y}) = \sigma^2 \left(\frac{1}{10} + \frac{(x_1^* - \bar{x}_1)^2}{S_{xx}} \right)$ (du kan ta for gitt at $\hat{\beta}_0$ og $\hat{\beta}_1$ er forventningsrette for β_0 og β_1).

d

Bruk resultatene fra c) til å utlede et $100 \cdot (1 - \alpha)\%$ konfidensintervall for $\mu_{Y|x^*}$ når du også kan ta for gitt at $(28 - 2)S^2/\sigma^2 \sim \chi_{28-2}^2$ og $\hat{Y}$ er uavhengige, der S^2 er den vanlige forventningsrette estimatoren for σ^2 .

Den nye James Bond-filmen (som etter planen skulle hatt premiere i november) har kostet utrolige 301 millioner USD.

Hva er det forventede billettsalget på denne filmen basert på modellen over?

Lag et 95% konfidensintervall for denne forventningen når du får vite at $\bar{x}_1 = 8.74$ og $S_{xx} = \sum_{i=1}^{10} (x_{i1} - \bar{x}_1)^2 = 135.864$.

Kan du stole på resultatene du har fått? Begrunn svaret ditt.

En ønsker nå å vurdere om også markedsføringskostnader bør være med i modellen, dvs.:

$$Y_i = \beta_0 + \beta_1(x_{i1} - \bar{x}_1) + \beta_2 x_{i2} + \epsilon_i, \quad i = 1, \dots, 10, \quad \epsilon_1, \dots, \epsilon_{10} \stackrel{uif}{\sim} N(0, \sigma^2).$$

R-utskriftene under viser resultatene av tilpasningen til den multiple lineære regresjonsmodellen over, samt fra en hypotesetest som sammenligner denne med den enkle lineære regresjonsmodellen brukt tidligere i oppgaven.

e

Gi en fortolkning av estimatene $\hat{\beta}_0$, $\hat{\beta}_1$ og $\hat{\beta}_2$ i denne nye modellen. Sett i lys av matrisepredningsplottet, hvordan forklarer du at $\hat{\beta}_1$ har endret seg sammenlignet med den enkle lineære regresjonsmodellen?

Formulér så hypotesene som blir testet i hypotesetesten gjengitt i variansanalysetabellen, altså under "Analysis of Variance Table".

Hvilken modell vil du velge? Begrunn svaret ditt.

Call:

```
lm(formula = bill.salg ~ I(prod.kost - mean(prod.kost)) + mark.kost,
    data = film.data)
```

Residuals:

Min	1Q	Median	3Q	Max
-15.4168	-2.5696	0.8052	2.1200	11.0463

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	48.803	9.227	5.289	0.00114 **
I(prod.kost - mean(prod.kost))	4.228	1.153	3.667	0.00800 **
mark.kost	7.436	1.806	4.117	0.00448 **

(Fortsettes på side 6.)

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.241 on 7 degrees of freedom

Multiple R-squared: 0.9537, Adjusted R-squared: 0.9405

F-statistic: 72.14 on 2 and 7 DF, p-value: 2.131e-05

Analysis of Variance Table

Model 1: bill.salg ~ I(prod.kost - mean(prod.kost))

Model 2: bill.salg ~ I(prod.kost - mean(prod.kost)) + mark.kost

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	8	1626.27				
2	7	475.37	1	1150.9	16.947	0.004478 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

END

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse

Eksamensdag: Mandag 16. desember 2019.

Tid for eksamen: 14.30 – 18.30.

Oppgavesettet er på 4 sider.

Vedlegg: Tabell over standardnormalfordelingen.

Tillatte hjelpemidler: Godkjent kalkulator.
Formelsamling til STK1100 og STK1110.

Kontroller at oppgavesettet er komplett før
du begynner å besvare spørsmålene.

Nedenfor er det gitt kritiske verdier $t_{\alpha, \nu}$ for t-fordelingen med ν frihetsgrader for noen verdier av α og ν . Du vil få bruk for tabellen i Oppgave 3.

α :	0.05	0.025	0.01	0.005
$t_{\alpha, 17}$:	1.740	2.110	2.567	2.898
$t_{\alpha, 18}$:	1.734	2.101	2.552	2.878
$t_{\alpha, 19}$:	1.729	2.093	2.539	2.861

Oppgave 1

Etter forskriftene skal mengden av organisk karbon i drikkevannet ikke overstige 5.0 mg/l. Ingeniørene ved et vannverk tar fem prøver av drikkevannet for å kontrollere vannkvaliteten. La $X_1, \dots, X_5$ være mengden av organisk karbon i hver av de fem prøvene. Vi vil anta at X_i -ene er uavhengige og $N(\mu, \sigma^2)$ -fordelte, der μ er den faktiske konsentrasjonen av organisk karbon i drikkevannet. I punktene a-d vil vi anta at $\sigma = 0.5$ mg/l.

- a) Ingeniørene ved vannverket vil bruke hypotesetesting til å vurdere om drikkevannet inneholder for mye organisk karbon. De diskuterer om de skal teste

$$H_0 : \mu \leq 5.0 \quad \text{mot} \quad H_a : \mu > 5.0,$$

eller om de skal teste

$$H_0 : \mu \geq 5.0 \quad \text{mot} \quad H_a : \mu < 5.0.$$

Diskuter de to formuleringene av hypotesetestingsproblemet. Kommenter spesielt hvilken konklusjon en vil få for hver av de to formuleringene hvis nullhypotesen blir forkastet.

I resten av oppgaven vil vi se på testing av $H_0 : \mu \geq 5.0$ mot $H_a : \mu < 5.0$.

Innholdet av organisk karbon i de fem vannprøvene ingeniørene tok var

5.37, 4.88, 4.32, 4.59, 4.14

(Fortsettes på side 2.)

- b) Utled en test med signifikansnivå 5%.
Hva blir konklusjonen ut fra de fem observasjonene som ble gjort?
- c) Bestem P-verdien og forklar hva den betyr.
- d) Hvor mange vannprøver må ingeniørene ta for at sannsynligheten for feil av type II skal være høyst 10% hvis konsentrasjonen av organisk karbon er 4.5 mg/l.

Vi har i punktene a-d antatt at $\sigma = 0.5$ mg/l. I praksis vil ikke σ være kjent, så den må estimeres fra vannprøvene.

- e) Forklar hvordan du nå vil gå fram for å teste $H_0 : \mu \geq 5.0$ mot $H_a : \mu < 5.0$.
(Du skal ikke gjøre noen beregninger her.)

Oppgave 2

La $X_1, X_2, \dots, X_n$ være uavhengige stokastiske variabler med sannsynlighetstetthet

$$f(x) = \begin{cases} \frac{1}{\theta^2} x e^{-x^2/(2\theta^2)} & \text{for } x > 0, \\ 0 & \text{ellers.} \end{cases}$$

Vi sier at de stokastiske variablene er Rayleigh fordelt. For Rayleigh fordelingen har vi at $E(X_i) = \theta\sqrt{\pi/2}$ og $E(X_i^2) = 2\theta^2$. (Du skal ikke vise dette.)

- a) Vis at momentestimatoren er $\tilde{\theta} = \bar{X}\sqrt{2/\pi}$, der $\bar{X} = \sum_{i=1}^n X_i/n$.

Bruk sentralgrensesetningen til å vise at $\tilde{\theta}$ er tilnærmet $N(\theta, \sigma_{\tilde{\theta}}^2)$ -fordelt, der

$$\sigma_{\tilde{\theta}}^2 = \frac{4 - \pi}{n\pi} \theta^2.$$

- b) Sett opp likelihooden og log-likelihooden og finn et uttrykk for maksimum likelihood estimatoren $\hat{\theta}$.
- c) Vis at Fisher informasjonen i én observasjon er $I(\theta) = 4/\theta^2$.
- d) Begrunn at $\hat{\theta}$ er tilnærmet $N(\theta, \sigma_{\hat{\theta}}^2)$ -fordelt og finn et uttrykk for $\sigma_{\hat{\theta}}^2$.
Hvilken av estimatorene $\tilde{\theta}$ og $\hat{\theta}$ vil du foretrekke? Begrunn svaret ditt.

Oppgave 3


Det har blitt gjort en studie av utslipp av dinitrogenoksid (N_2O) fra en liten dieseldrevet lastebil. Formålet med studien var å finne ut hvordan utslippet varierer med luftfuktigheten og lufttrykket. Det ble tilsammen gjort 20 målinger av utslippet under ulike forhold.

Vi vil bruke lineær regresjon til å analysere dataene. Responsen, N_2O , er utslipp av dinitrogenoksid (ppm), mens forklaringsvariablene er:

trykk lufttrykk (mmHg),
fukt luftfuktighet (prosent).

På neste side er det gitt et matrise-spredingsplott som gir en oversikt over dataene.

(Fortsettes på side 3.)



Vi gjør først en regresjonsanalyse med lufttrykk som eneste forklaringsvariabel. Vi tilpasser da den lineære regresjonsmodellen

$$Y_i = \beta_0 + \beta_1 x_{i1} + \epsilon_i, \quad (1)$$

der responsen Y_i er utslipp av dinitrogenoksid og forklaringsvariabelen x_{i1} er lufttrykk minus 750 mmHg. Resultatet av denne analysen er gitt i R-utskriften nedenfor. (Vi har fjernet en del av resultatene i utskriften.)

Call:

```
lm(formula = N20 ~ I(trykk - 750), data = utslipp)
```

Coefficients:

	Estimate	Std. Error
(Intercept)	1.033773	0.020147
I(trykk - 750)	0.018195	0.003384

Residual standard error: 0.07343

Multiple R-squared: 0.6163

- a) Gi en fortolkning av estimatene for β_0 og β_1 og bestem et 99% konfidensintervall for β_1 .

Vi gjør så en regresjonsanalyse med både lufttrykk og luftfuktighet som forklaringsvariabler. Vi tilpasser da den lineære regresjonsmodellen

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \epsilon_i, \quad (2)$$

der Y_i og x_{i1} er som for modell (1) og x_{i2} er luftfuktighet minus 50 prosent. Resultatet av denne analysen er gitt i R-utskriften på neste side.

(Fortsettes på side 4.)

Call:

```
lm(formula = N20 ~ I(trykk - 750) + I(fukt - 50), data = utslipp)
```

Coefficients:

	Estimate	Std. Error
(Intercept)	0.9737589	0.0199131
I(trykk - 750)	0.0064514	0.0036226
I(fukt - 50)	-0.0026547	0.0006131

Residual standard error: 0.05211

Multiple R-squared: 0.8175

- b) Sammenlign estimatene for β_1 i modell (1) og modell (2). Hvordan kan du forklare at estimatene er såpass forskjellige?
- c) Bestem et estimat for forventet utslipp når lufttrykket er 740 mmHg og luftfuktigheten er 80 prosent. Forklar hvorfor du ikke kan finne standardfeilen til dette estimatet ut fra informasjonen i R-utskriften.

Vi innfører nå matrisen

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} \\ 1 & x_{21} & x_{22} \\ 1 & x_{31} & x_{32} \\ \vdots & \vdots & \vdots \\ 1 & x_{20,1} & x_{20,2} \end{pmatrix}.$$

Da har vi at

$$(\mathbf{X}'\mathbf{X})^{-1} = \begin{pmatrix} 0.1460 & 0.0212 & 0.00313 \\ 0.0212 & 0.00483 & 0.000612 \\ 0.00313 & 0.000612 & 0.000138 \end{pmatrix}.$$

- d) Bruk resultatet ovenfor og R-utskriften til å bestemme standardfeilen til estimatet i punkt c. Bestem også et 95% konfidensintervall for forventet utslipp når lufttrykket er 740 mmHg og luftfuktigheten er 80 prosent.

SLUTT

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse 1

Eksamensdag: Tirsdag 18. desember 2018

Tid for eksamen: 09.00 – 13.00

Oppgavesettet er på 5 sider.

Vedlegg: Tabell over normalfordelingen

Tillatte hjelpemidler: Formelsamling for STK1100/STK1110.
Godkjent kalkulator.

Kontroller at oppgavesettet er komplett før
du begynner å besvare spørsmålene.

Oppgave 1

La X være binomisk fordelt med parametre n som antall forsøk og p som suksessansynlighet, $X \sim B(n, p)$. En estimator for p er da gitt ved $\hat{p} = \frac{X}{n}$.

a

Vis at $\hat{p}$ er forventningsrett.

Utleid et uttrykk for variansen til $\hat{p}$.

b

Forklar hva en likelihoodfunksjon er og vis at $L(p) = \binom{n}{X} p^X (1-p)^{n-X}$ er likelihooden for p i dette tilfellet.

Vis at $\hat{p} = \frac{X}{n}$ er maksimum likelihood estimator for p .

Benytt likelihoodteori for å finne et (tilnærmet) uttrykk for variansen til $\hat{p}$.
Sammenlign med variansuttrykket fra punkt a.

c

Tilnærmet has at

$$Z(p) = \frac{\hat{p} - p}{\sqrt{p(1-p)}} \sqrt{n}$$

er godt standardnormalfordelt når $np > 10$ og $n(1-p) > 10$.

Bruk dette til å konstruere en hypotesetest med tilnærmet 5% nivå for $H_0 : p = p_0$ mot $H_a : p \neq p_0$.

Utfør testen når $X = 15$, $n = 50$ og $p_0 = 0.5$. Finn også tilnærmet P-verdi for testen.

(Fortsettes på side 2.)

d

Forklar hvorfor mengden $\{p : |Z(p)| < 1.96\}$ blir et tilnærmet 95% konfidensintervall for p .

Vis hvordan dette intervallet kan avleses grafisk ved å plotte $Z(p)$ mot p .

Vis også at intervallet kan finnes analytisk ved å løse en 2.gradsulikhet (men du skal ikke utlede de faktiske løsningene, de er oppgitt under).

e

Løsningen på 2.gradsulikheten kan uttrykkes som

$$\frac{\hat{p} + 1.96^2/2n}{1 + 1.96^2/n} \pm \frac{1.96}{\sqrt{n}} \frac{\sqrt{\hat{p}(1 - \hat{p}) + 1.96^2/4n}}{1 + 1.96^2/n}$$

(dette skal du ikke vise!)

Når n er stor kan ledd av typen a/n ignoreres. Finn forenklingen av intervallet etter denne tilnærmingen.

Sammenlign dette intervallet med det tilnærmede 95% konfidensintervallet du får basert på at

$$\frac{\hat{p} - p}{\sqrt{\hat{p}(1 - \hat{p})}} \sqrt{n}$$

er tilnærmet standardnormalfordelt.

Vis utledningen av konfidensintervallet basert på denne tilnærmingen.

Oppgave 2

Dataene i denne oppgaven kommer fra et eksperiment vedrørende reduksjon i isoleringsevne for en elektrisk isolator som har blitt utsatt for ulike nivåer av temperatur over varierende lengde av tid. Responsvariabelen er isoleringsevne i kilo-volt og forklaringsvariablene er tid i uker og temperatur målt i Celciusgrader. Totalt antall observasjoner er $n = 128$ og det er fire målinger av isoleringsevne for hver kombinasjon av temperatur (med nivåer 180, 225, 250 og 275 grader i Celcius) og tid (med 8 nivåer 1, 2, 4, 8, 16, 32, 48 og 64 uker). Vi har således et balansert design. Vi vil benytte forklaringsvariablene kodet numeriske som $x_{1i} = \text{grader Celcius}$ og $x_{2i} = \log(\text{Tid})$ og respons variabelen $Y_i = \text{isoleringsevne i KVolt}$ for observasjon nr. i .

a

I en første modell betraktes en enkel lineær regresjonsmodell $Y_i = \beta_0 + \beta_1 x_{1i} + \varepsilon_i$ for $i = 1, \dots, n$ der ε_i -ene antas uavhengige og normalfordelte med forventning null og ukjent varians σ^2 .

Bestem og fortolk minste kvadraters estimatene for β_0, β_1 samt estimatet for σ fra R-output øverst på neste side.

Forklar hvordan minste kvadraters estimer bestemmes (det spørres ikke om en detaljert utledning av formler for estimatene).

(Fortsettes på side 3.)

Forklar hvordan P-verdien for variabelen Temperatur beregnes. Spesifiser null hypotesen og den alternative hypotesen som testes.

Benytt utskriften til å finne empiriske korrelasjon mellom x_{1i} -ene og Y_i -ene.

```
> summary(lm(Strength~Temperature))
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	30.511906	1.767079	17.27	<2e-16
Temperature	-0.082898	0.007515	-11.03	<2e-16

Residual standard error: 2.983 on 126 degrees of freedom

Multiple R-squared: 0.4913, Adjusted R-squared: 0.4872

F-statistic: 121.7 on 1 and 126 DF, p-value: < 2.2e-16

b

Under ser du utskrift fra tilpasning av en modell $Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \varepsilon_i$, altså med forklaringsvariabel x_{2i} lagt til i modellen og ellers de samme antagelsen for ε_i -ene som i punkt a).

Forklar hvorfor estimatet for β_1 er det samme som i punkt a).

Gi en diskusjon av hva som har skjedd med estimatet for σ og for den multiple R-squared verdien.

Forklar også effekten på standardfeilen til $\hat{\beta}_1$. Gi en forklaring for disse endringene.

Bestem korrelasjonen mellom Y_i -ene og x_{2i} -ene.

```
> summary(lm(Strength~Temperature+log(Time)))
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	33.735643	1.347989	25.03	<2e-16
Temperature	-0.082898	0.005573	-14.87	<2e-16
log(Time)	-1.399549	0.137163	-10.20	<2e-16

Residual standard error: 2.212 on 125 degrees of freedom

Multiple R-squared: 0.7224, Adjusted R-squared: 0.718

F-statistic: 162.7 on 2 and 125 DF, p-value: < 2.2e-16


c

Benytt residualplottene på neste side, som er fra modellen i punkt b), til å vurdere gyldigheten av modellantagelsene.

Forklar spesielt hvilke størrelser som plottes og hvordan avvik fra modellen kan påvises.

Foreslå mulige forbedringer av modellen.

(Fortsettes på side 4.)



Oppgave 3

Anta en multipl linear regresjonsmodell

$$Y_i = \beta_0 + \beta_1 x_{1i} + \dots + \beta_k x_{ki} + \varepsilon_i, i = 1, \dots, n$$

der Y_i er respons, $x_{ji}, j = 1, \dots, k$ forklaringsvariable og ε_i feilledd for enhet i og $\beta_j, j = 0, \dots, k$ regresjonskoeffisienter. Vi antar at ε_i er uavhengige og normalfordelte med forventning 0 og varians σ^2 .

La $\hat{\beta}_j, j = 0, \dots, k$ være minste kvadraters estimatorene for β_j -ene, $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \dots + \hat{\beta}_k x_{ki}$ og $SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$ residual kvadratsum. Da has at $SSE/\sigma^2 \sim \chi_{n-k-1}^2$, dvs. er kji-kvadratfordelt med $n - k - 1$ frihetsgrader. (Dette skal du ikke vise).

a

Forklar hvorfor forventningen til $s^2 = SSE/(n - k - 1)$ er lik σ^2 .

Vis at $V(s^2)$ går mot 0 når $n - k$ går mot uendelig og argumenter for at dette betyr at s^2 er konsistent for σ^2 , dvs. konvergerer i sannsynlighet mot σ^2 .

Anta så at $\beta_1 = \beta_2 = \dots = \beta_k = 0$. Forklar hvorfor nå også $SST/(n - 1)$, der $SST = \sum_{i=1}^n (Y_i - \bar{Y})^2$, er konsistent for σ^2 .

b

Forklart andel av varians er definert som $R^2 = 1 - SSE/SST$. Anta at både n og k går mot uendelig på en slik måte at $k/n \rightarrow \rho$ der $0 < \rho < 1$. Anta videre $\beta_1 = \beta_2 = \dots = \beta_k = 0$.

(Fortsettes på side 5.)

Vis at da vil $R^2 \rightarrow \rho$ (som er en verdi større enn 0).

Hint: Du kan bruke at hvis både $U_n \rightarrow u$ og $V_n \rightarrow v$ i sannsynlighet der V_n og U_n er (sekvenser av) stokastiske variable og u og v er skalare verdier så vil $V_n/U_n \rightarrow v/u$ når $u \neq 0$.

Finn tilsvarende grense for justert R^2 definert som $R_{adj}^2 = 1 - \frac{SSE/(n-k-1)}{SST/(n-1)}$ (under samme forutsetninger).

SLUTT

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse 1

Eksamensdag: Torsdag 14. desember 2017

Tid for eksamen: 09.00 – 13.00

Oppgavesettet er på 4 sider.

Vedlegg: Tabeller over normal-, t- og χ^2 -fordelingene

Tillatte hjelpemidler: Formelsamling for STK1100/STK1110.
Godkjent kalkulator.

Kontroller at oppgavesettet er komplett før
du begynner å besvare spørsmålene.

Oppgave 1

La $X_1, \dots, X_n$ være uavhengige og normalfordelte stokastiske variable med forventning μ og varians σ^2 . De observerte verdiene av X_i angis med x_i .

a

Anta at μ og σ^2 er ukjente, men estimert med henholdsvis $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = 2.72$ og $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = 3.14$ når vi har $n = 25$ observasjoner.

Test nullhypotesen $H_0 : \mu = 2$ mot $H_a : \mu \neq 2$ med signifikansnivå $\alpha = 0.05$ ved en vanlig t-test. Formuler en konklusjon på testen.

Angi spesielt et intervall for testens P-verdi.

b

Formelen for et $(1 - \alpha)100\%$ konfidensintervall for μ i denne situasjonen gis ved $\bar{x} \pm t_{\alpha/2, s} / \sqrt{n}$ der t_{α} er $(1 - \alpha)100$ -persentilen i t-fordelingen med $n - 1$ frihetsgrader og $s = \sqrt{s^2}$.

Vis at dette konfidensintervallet er lik mengden av μ_0 slik at t-testen for $H_0 : \mu = \mu_0$ mot $H_a : \mu \neq \mu_0$ med nivå α ikke leder til forkastning.

Illustrer dette resultatet på dataene fra punkt a med $n = 25$, $\bar{x} = 2.72$, $s^2 = 3.14$ og $\alpha = 0.05$.

c

En tests styrkefunksjon er definert ved $\gamma(\theta) = P(\text{Forkaste nullhypotesen} \mid \theta)$ der θ er den faktiske verdien av parameteren θ .

Hva er sammenhengen mellom sannsynligheten for Type II feil og styrkefunksjonen?

(Fortsettes på side 2.)

Anta at variansen σ^2 til X_i -ene definert først i oppgaven er kjent. Vis at med en test som gir forkastning hvis $|\bar{x} - \mu_0| \sqrt{n}/\sigma > z_{\alpha/2}$ der z_{α} er $(1 - \alpha)100$ -persentilen i standardnormalfordelingen får man styrkefunksjon

$$\gamma(\mu) = 1 - \Phi(z_{\alpha/2} - (\mu - \mu_0)\sqrt{n}/\sigma) + \Phi(-z_{\alpha/2} - (\mu - \mu_0)\sqrt{n}/\sigma)$$

der $\Phi(z)$ er kumulativ fordelingsfunksjon for standardnormalfordelingen.

Oppgave 2

La X være antall dødsulykker i trafikken i Norge i 2016. Siden X er en tellevariabel skal vi modellere denne med en Poissonfordeling med en forventning λ , kort skrives dette $X \sim \text{Po}(\lambda)$.

a

Vis at maximum likelihood estimatoren for λ gis ved $\hat{\lambda} = X$.

Hvorfor er $\hat{\lambda}$ også momentestimator?

b

Når λ er stor gjelder tilnærmet at $Z = (\hat{\lambda} - \lambda)/\sqrt{\hat{\lambda}}$ er standardnormalfordelt. Dette skal du ikke vise.

Forklar hvorfor $\hat{\lambda} \pm 1.96\sqrt{\hat{\lambda}}$ er et tilnærmet 95% konfidensintervall for λ .

Beregn intervallet basert på at det var $X = 135$ dødsulykker i trafikken i Norge i 2016.

Er det grunn til å tro at tilnærmingen er god?

c

Et alternativt, også tilnærmet, 95% konfidensintervall for λ gis ved uttrykket $\hat{\lambda} + 1.96^2/2 \pm \sqrt{4 * 1.96^2 \hat{\lambda} + 1.96^4/2}$. (Med $\hat{\lambda} = 135$ blir dette intervallet lik $(114.07, 159.77)$).

Vis hvordan man kan utlede dette konfidensintervallet.

Beskriv også hvordan intervallet kan avleses grafisk.

Oppgave 3


Også i denne oppgaven skal du se på data om dødsulykker i trafikken i Norge, nå i perioden 1999-2016. På neste side er det satt opp en tabell over antall dødsfall for hvert av disse årene samt en figur over utviklingen.

La Y_i være antall dødsulykker i år nummer i . Vi skal anta en enkel lineær regresjonsmodell for dataene slik at $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ der x_i er årstall-2000 (og altså tar verdier -1 til 16) og ε_i er uavhengige feilledd med forventning 0 og varians σ^2 . I utskriften på neste side er det satt opp et sammendrag av analysen.

(Fortsettes på side 3.)

År	1999	2000	2001	2002	2003	2004	2005	2006	2007
Dødsfall	304	341	275	310	280	257	224	242	233

År	2008	2009	2010	2011	2012	2013	2014	2015	2016
Dødsfall	255	212	208	168	145	187	147	117	135



Coefficients:

```

              Estimate Std. Error t value Pr(>|t|)
(Intercept) 311.4104      8.6506   36.00 < 2e-16 ***
aar          -11.5955      0.9486  -12.22 1.57e-09 ***
---

```

Residual standard error: 20.88 on 16 degrees of freedom

Multiple R-squared: 0.9033, Adjusted R-squared: 0.8972

a

Angi og fortolk parameterestimatene i modellen fra utskriften.

Finn et 95% konfidensintervall for β_1 og test hypotesen $H_0 : \beta_1 = -10$ mot $H_a : \beta_1 \neq -10$.Diskuter graden av samsvar mellom x_i -er og Y_i -er.**b**Parameterestimatene for β_0 og β_1 er minste kvadraters estimater. Forklar hva dette innebærer.

Angi en betingelse for at de også er maksimum likelihood estimater. Vis denne egenskapen.

(Fortsettes på side 4.)

c

Minste kvadraters estimatoren $\hat{\beta}_1$ for β_1 kan skrives som følgende uttrykk:

$$\hat{\beta}_1 = \frac{\sum_i (x_i - \bar{x})(Y_i - \bar{Y})}{\sum_i (x_i - \bar{x})^2} = \frac{\sum_i (x_i - \bar{x})Y_i}{\sum_i (x_i - \bar{x})^2}$$

hvor summen er over alle i og $\bar{Y}$ og $\bar{x}$ er gjennomsnittet av henholdsvis Y_i -er og x_i -er. Dette skal du ikke vise.


Vis at $\hat{\beta}_1$ er forventningsrett.

Utledd også at variansen til $\hat{\beta}_1$ kan skrives som $\sigma^2 / \sum_i (x_i - \bar{x})^2$.

d

Plottene under er residualplottene for regresjonsanalysen. Forklar og fortolk plottene. Finner du betydelig avvik fra modellen?

I Oppgave 2 antok vi at antall dødsfall i trafikken i et år var Poissonfordelt. Passer dette med regresjonsmodellen i denne oppgaven? Kommenter.



SLUTT

UNIVERSITETET I OSLO

Matematisk Institutt

EKSAMEN I: **STK 1110 – Statistiske metoder og dataanalyse 1**
TID FOR EKSAMEN: **Mandag 28. november 2016, kl. 14:30–18:30**
HJELPEMIDLER: **Formelsamling til STK 1100 og STK 1110,
godkjent kalkulator**

Dette eksamenssettet inneholder fire oppgaver og er på seks sider (inkludert et kort appendiks på siste side, som kan være til hjelp under løsningen av visse punkter).

Oppgave 1

I denne oppgaven skal vi se på problemstillinger knyttet til den eksponentielle fordelingen, med først ett og deretter to utvalg.

- (a) Anta at observasjoner $X_1, \dots, X_n$ er uavhengige og eksponentialfordelte med rate θ , altså at tettheten for en enkeltobservasjon er på formen

$$f(x, \theta) = \frac{1}{\theta} \exp\left(-\frac{x}{\theta}\right) \quad \text{for } x > 0.$$

Vis at variablene

$$V_i = \frac{2X_i}{\theta}$$

har χ^2 -fordelingen med 2 frihetsgrader. – Her minner jeg om at χ^2 -fordelingen med ν frihetsgrader har tettheten

$$h(z) = \frac{1}{2^{\nu/2} \Gamma(\nu/2)} z^{\nu/2-1} \exp(-\tfrac{1}{2}z) \quad \text{for } z > 0,$$

og at dennes forventning og varians er ν og 2ν .

- (b) Vis at X_i har forventning θ og varians θ^2 .
(c) Vis at $\hat{\theta} = \bar{X}$, gjennomsnittet $(1/n) \sum_{i=1}^n X_i$ av de n observasjonene, er en forventningsrett estimator for θ . Finn dens varians.
(d) Forklar hva sentralgrenseteoremet (the central limit theorem) medfører for fordelingen for $\hat{\theta}$, og bruk dette til å sette opp et konfidensintervall for θ , med dekningsgrad tilnærmet lik 95%.
(e) Anta vi observerer $X_1, \dots, X_{20}$ fra laboratorium A, antatt uavhengige og eksponentielle med rate θ_1 , samt $Y_1, \dots, Y_{20}$ fra laboratorium B, uavhengige og eksponentielle med rate θ_2 . Vi vil teste hypotesen H_0 at $\theta_1 = \theta_2$. Her har X_i -ene gjennomsnitt $\bar{X} = 2.222$ og empirisk standardavvik 2.468, mens Y_i -ene har gjennomsnitt $\bar{Y} = 4.444$ og empirisk standardavvik 4.987. Lag en testobservator for H_0 , av typen

$$t = \frac{\bar{Y} - \bar{X}}{W},$$

der du skal konstruere W slik at t har en tilnærmet $N(0, 1)$ -fordeling dersom H_0 er korrekt. Beregn t for denne situasjonen, og kommenter det du finner ut.

- (f) Finn også et 95% konfidensintervall, eksakt eller tilnærmet, for brøkparameteren $\rho = \theta_2/\theta_1$, basert på disse dataverdiene. Du kan her få bruk for verdier gitt i tabellen bakerst i oppgavesettet.

Oppgave 2

En bestemt type operasjon blir jevnlig utført på barn under ett år med en viss type dramatisk hjertelidelse (der barna vil dø om de ikke blir operert). Operasjonen ender av og til med at barnet ikke kan reddes. Tabellen under viser dødsratene, i prosent, for elleve britiske sykehus, over en periode på noen få år. I tillegg til å forstå risikoen for død, samt hvilken type omstendigheter som øker denne risikoen, er man interessert i å finne ut om det er systematiske forskjeller mellom de elleve sykehus, eller om dødsrisikoen for små barn med denne ekstreme hjertelidelsen essensielt er den samme ved hvert av dem.

1	Leicester	13.37
2	Leeds	7.43
3	Oxford	18.85
4	Guys	15.24
5	Liverpool	10.37
6	Southampton	10.04
7	Great Ormond St	11.00
8	Newcastle	13.33
9	Harefield	14.12
10	Birmingham	9.98
11	Brompton	10.30

En mer detaljert analyse er mulig, men i denne oppgaven skal vi for enkelhets skyld se på disse estimatene som resultatet av uavhengige stokastiske variable

$$\hat{\theta}_i \sim N(\theta_i, \sigma^2) \quad \text{for } i = 1, \dots, 11,$$

der standardavviket $\sigma = 2.112$ er såpass godt estimert at den kan anses som en kjent verdi. Parameterverdiene $\theta_1, \dots, \theta_{11}$ ses på som de reelle, underliggende rater, som vi altså ikke kan observere eksakt, kun estimere, med de data vi har (som er det vi har gjort over).

- (a) Finn to 95% konfidensintervall, ett for parameteren θ_1 og ett for θ_2 , dødsfrekvensen for slike operasjoner utført ved sykehusene i henholdsvis Leicester og Leeds.
- (b) For å analysere i hvilken grad θ_i -ene varierer fra sykehus til sykehus, eller om de kanskje er essensielt like, tenker vi oss at $\theta_1, \dots, \theta_{11}$ selv er uavhengige stokastiske variable, fra fordelingen

$$\theta_i \sim N(\theta_0, \tau^2).$$

Her er θ_0 og τ faste, men ukjente, parametre. Vi kan skrive

$$\theta_i = \theta_0 + \delta_i \quad \text{og} \quad \hat{\theta}_i = \theta_i + \varepsilon_i \quad \text{for } i = 1, \dots, 11,$$

der $\delta_i \sim N(0, \tau^2)$ og $\varepsilon_i \sim N(0, \sigma^2)$ er uavhengige. Forklar hvorfor dette leder til

$$\hat{\theta}_i \sim N(\theta_0, \sigma^2 + \tau^2) \quad \text{for } i = 1, \dots, 11.$$

(c) For estimatene over kan vi beregne

$$S^2 = \frac{1}{10} \sum_{i=1}^{11} (\hat{\theta}_i - \bar{\theta})^2 = 10.0607 = 3.1719^2,$$

der $\bar{\theta}$ er gjennomsnittet $(1/11) \sum_{i=1}^{11} \hat{\theta}_i = 12.1857$. Bruk dette til å estimere τ .

- For punktene (d) og (e) under kan du anvende at kvantilene 0.025, 0.050, 0.500, 0.950, 0.975 for χ^2_{10} , altså χ^2 -fordelingen med 10 frihetsgrader, er
- 3.2470 3.9403 9.3418 18.3070 20.4832

(d) Lag en test med nivå 0.05 for hypotesen om at θ_i -ene er helt like, mot alternativet at det altså er forskjeller. Utfør testen.

(e) Lag til sist et 95% konfidensintervall for τ .

Oppgave 3

Anta at X er binomisk fordelt (n, p) , altså med de klassiske punktsannsynligheter

$$f(x, p) = \binom{n}{x} p^x (1-p)^{n-x} \quad \text{for } x = 0, 1, \dots, n.$$

- (a) For et gitt utfall x , sett opp log-likelihood-funksjonen $\ell(p)$, og vis at denne maksimeres for $\hat{p} = x/n$.
- (b) Anta at vi har tre uavhengige binomiske eksperimenter,

$$X \sim \text{bin}(n, p), \quad Y \sim \text{bin}(n, q), \quad Z \sim \text{bin}(n, r).$$

Sett opp et uttrykk for log-likelihood-funksjonen $\ell(p, q, r)$. Dersom hypotesen H_0 at de tre sannsynlighetene er like, altså $p = q = r$, holder, hva er da maximum-likelihood-estimatet for den felles verdi av denne sannsynligheten?

- (c) Anta at $n = 50$ og at man i de tre eksperimenter observerer $X = 17$, $Y = 22$, $Z = 14$. Finn verdier for

$$\ell_{\max}(\text{big}) \quad \text{og} \quad \ell_{\max}(H_0),$$

der $\ell_{\max}(\text{big})$ er maksimum av log-likelihood-funksjonen under modellen der p, q, r er frie parametre, og $\ell_{\max}(H_0)$ tilsvarende maksimum av samme funksjon under H_0 . Utfør en test for H_0 og kommenter det du finner.

Oppgave 4

Tabellen under viser et helsepolitisk og historisk viktig datasett, fra 1963, idet det ble benyttet for å arbeide frem og etter noen år gjennomføre vedtak, i flere land, om at sigarettpakker skulle utstyres med en advarsel. For hvert av de angitte land vises

x = gjennomsnittlig antall sigaretter pr. person pr. år,

y = antall døde, av hjerte-og-karsykdommer, pr. hundre tusen innbyggere.

Gjennomsnittstallet x omfatter altså både røykere og ikke-røykere, av alle over 18 år. Populasjonene det ble rapportert om for y , i disse undersøkelsene, gjelder dem fra 35 til 64 år.

	x	y	
1962	3350	211.6	Canada
1962	3220	238.1	Australia
1962	3220	211.8	New Zealand
1962	2790	194.1	United Kingdom
1962	2780	124.5	Switzerland
1962	2770	187.3	Ireland
1962	2290	110.5	Iceland
1962	2160	233.1	Finland
1963	1890	150.3	West Germany
1962	1810	124.7	Netherlands
1962	1800	41.2	Greece
1962	1770	182.1	Austria
1962	1700	118.1	Belgium
1962	1680	31.9	Mexico
1963	1510	114.3	Italy
1961	1500	144.9	Denmark
1962	1410	59.7	France
1962	1270	126.9	Sweden
1961	1200	43.9	Spain
1962	1090	136.3	Norway
1962	3900		USA

En enkel lineær regresjonsmodell setter

$$y_i = a + bx_i + \varepsilon_i \quad \text{for } i = 1, \dots, n,$$

der ε_i -ene tenkes uavhengige og $N(0, \sigma^2)$. Her tar vi med de $n = 20$ land i tabellen over, der vi har både x og y ; USA er altså ikke med i denne delen av analysen. Den vanlige kommandoen `lm(y ~ x)` i programpakken **R** gir bl.a. følgende:


Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	18.03462	33.28179	0.542	0.59455
x	0.05884	0.01529	3.848	0.00118 **

Jeg opplyser også om at $\sum_{i=1}^n (y_i - \hat{a} - \hat{b}x_i)^2 = 41388.09$, der $\hat{a}$ og $\hat{b}$ er minste-kvadratsums-estimatene. Dataene, med regresjonslinjen, er også vist frem i figuren neste side.

- Gi verdiene for $\hat{a}$ og $\hat{b}$, og vis at det vanlige estimatet for σ , det som tar utgangspunkt i forventningsretthet for $\hat{\sigma}^2$, blir $\hat{\sigma} = 47.951$.
- Dersom sigarettkonsumet i et land går ned, så meget at gjennomsnittstallet for antall sigaretter går ned med 100 (pr. person pr. år), hvor mange færre døde vil da dette landet senere kunne forvente, av hjerte-og-karsykdommer, i dette alderssegmentet fra 35 til 64 år?

- (c) Sambandsstatene (USA) hadde altså så høyt sigarettkonsum i 1962 som 3900 pr. voksenperson pr. år. La Y_0 være antallet døde av hjerte-og-karsykdommer i 1962, i USA, per hundre tusen, i alderen 35 til 64 år. Gi et estimat for Y_0 .



- (d) I tillegg til estimatet $\hat{y}_0$ for $Y_0 = a + bx_0 + \varepsilon_0$ ønsker vi oss et fullt prediksjonsintervall. Vi innfører $Z_0 = Y_0 - \hat{a} - \hat{b}x_0$, der $x_0 = 3900$. Finn forventning og varians til Z_0 . Her kan du bruke følgende, fra pensum:

$$\hat{a} + \hat{b}x_0 = \bar{Y} + \hat{b}(x_0 - \bar{x}),$$

der $\bar{x} = (1/n) \sum_{i=1}^n x_i = 2060.500$ og $\bar{Y} = (1/n) \sum_{i=1}^n Y_i = 139.265$ er gjennomsnittene, og $\hat{b} = \sum_{i=1}^n (x_i - \bar{x})Y_i / M$, med $M = \sum_{i=1}^n (x_i - \bar{x})^2 = 9833895$.

- (e) Beregn et intervall som med sannsynlighet 90% (eksakt eller tilnærmet) inneholder Y_0 . Kommenter kort forutsetninger som ligger til grunn. Du kan få bruk for at 0.95-kvantilen for t -fordelingen med 18 frihetsgrader er $qt(0.95, 18) = 1.734$.
- (f) Ifølge offisielt tilgjengelige kilder har Ungarn i 2014 en dødsrate på 172.6 pr. hundre tusen, relatert til hjerte-og-karsykdommer. Hva tror du sigarettkonsumet er i Ungarn?

Appendiks: en liten F-tabell

Her er en tabell over (low, up), 0.025-kvantilen og 0.975-kvantilen i F -fordelingen (Fisher-fordelingen) med frihetsgrader (m_1, m_2) , der vi i denne situasjonen kun ser på $m_1 = m_2 = m$, og for m -verdier fra 15 til 45.

m1	m2	low	up
15	15	0.349	2.862
16	16	0.362	2.761
17	17	0.374	2.673
18	18	0.385	2.596
19	19	0.396	2.526
20	20	0.406	2.464
21	21	0.415	2.409
22	22	0.424	2.358
23	23	0.433	2.312
24	24	0.441	2.269
25	25	0.448	2.230
26	26	0.456	2.194
27	27	0.463	2.161
28	28	0.470	2.130
29	29	0.476	2.101
30	30	0.482	2.074
31	31	0.488	2.049
32	32	0.494	2.025
33	33	0.499	2.002
34	34	0.505	1.981
35	35	0.510	1.961
36	36	0.515	1.942
37	37	0.520	1.924
38	38	0.524	1.907
39	39	0.529	1.891
40	40	0.533	1.875
41	41	0.538	1.860
42	42	0.542	1.846
43	43	0.546	1.833
44	44	0.550	1.820
45	45	0.553	1.807

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse 1

Eksamensdag: Mandag 30. november 2015.

Tid for eksamen: 14.30 – 18.00.

Oppgavesettet er på 5 sider.

Vedlegg: Ingen

Tillatte hjelpemidler: Godkjent kalkulator og formelsamling
for STK1100/STK1110

Kontroller at oppgavesettet er komplett før
du begynner å besvare spørsmålene.

Nedenfor får du oppgitt følgende øvre kvantiler i standard normal fordelingen som kan brukes ulike steder i oppgavesettet.

α	0.100	0.050	0.025	0.010	0.001	0.0001	0.00001	0.000001
z_α	1.281	1.645	1.960	2.326	3.090	3.719	4.265	4.753

Oppgave 1

Vi har observert $n = 20$ datapunkter $x_1, \dots, x_{20}$:

13.46	13.85	5.73	0.82	4.46	17.37	2.20	10.29	4.36	9.15
4.12	2.49	9.99	3.95	13.25	4.90	19.27	5.36	16.42	4.96

Du får også oppgitt at $\sum_{i=1}^n x_i = 166.40$ og $\sum_{i=1}^n \ln(x_i) = 37.15$. Vi vil anta observasjonene er uavhengige og identiske fordelte fra en kontinuerlig fordeling med sannsynlighetstetthetsfunksjon

$$f(x; \theta) = \frac{1}{\theta^2} x e^{-x/\theta}, \quad 0 < x < \infty; 0 < \theta < \infty$$

En kan vise at $E[X] = 2\theta$ og $V(X) = 2\theta^2$ for denne fordelingen (dette behøver du ikke å vise).

(Fortsettes på side 2.)

- (a) Sett opp likelihoodfunksjonen og vis at log-likelihoodfunksjonen kan skrives som

$$l(\theta) = -2n \ln \theta + \sum_{i=1}^n \ln(x_i) - \frac{1}{\theta} \sum_{i=1}^n x_i.$$

- (b) Forklar prinsippet bak maksimum likelihood (ML) estimering og vis at ML estimatoren for θ er

$$\hat{\theta} = \frac{1}{2n} \sum_{i=1}^n x_i.$$

- (c) Vis at $\hat{\theta}$ også er momentestimatoren for θ .


Er $\hat{\theta}$ forventningsrett?

- (d) Regn ut $\hat{\theta}$ for de gitte data. Hva blir standardfeilen for $\hat{\theta}$ og estimatet på denne i dette tilfellet?

Generelle resultater om ML estimatører tilsier at $\hat{\theta}$ er tilnærmet normalfordelt for n stor (dette behøver du ikke å vise).

- (e) Utled et (tilnærmet) 95% konfidensintervall for θ . Hva blir dette intervallet for de gitte data?

Nedenfor er vist et histogram av bootstrapsimuleringer av $\hat{\theta}^*$ basert på ikke-parametrisk bootstrapping.



Tabellen nedenfor viser også ulike empiriske kvantiler av de simulerte $\hat{\theta}^*$:

Kvantil	0.01	0.025	0.05	0.95	0.975	0.99
Verdil	2.83	2.98	3.14	5.21	5.40	5.59

- (f) Forklar hva vi mener med ikke-parametrisk bootstrapping. Bruk bootstrapsimuleringene til å lage et 95% konfidensintervall.

Diskuter likheter/forskjeller i forhold til intervallet du fant i (e).

(Fortsettes på side 3.)

Oppgave 2

Data som vi vil bruke i denne oppgaven er knyttet til prostatakreft og er hentet fra Stamey et al. (1989). Responsvariabelen angir nivå av en prostata-spesifikk antigen `lpsa` mens en rekke mulige forklaringsvariable (ulike kliniske målinger) samtidig er samlet inn. Vi vil her konsentrere oss om 3 av disse, prostata volum på log-skala (`lcavol`), vekt av prostata på log-skala (`lweight`) og alder (`age`).

Tabellen nedenfor viser de 6 første av totalt 97 målinger:

	<code>lpsa</code>	<code>lcavol</code>	<code>lweight</code>	<code>age</code>
1	-0.4307829	-0.5798185	2.769459	50
2	-0.1625189	-0.9942523	3.319626	58
3	-0.1625189	-0.5108256	2.691243	74
4	-0.1625189	-1.2039728	3.282789	58
5	0.3715636	0.7514161	3.432373	62
6	0.7654678	-1.0498221	3.228826	50

Vi vil i første omgang se på en enkel regresjonsmodell

$$Y_i = \beta_0 + \beta_1 x_{i1} + \varepsilon_i, i = 1, \dots, n \quad (*)$$

der x_{i1} er `lcavol` mens y_i er `lpsa`. Her følger ε_i -ene de vanlige antagelsene, dvs uavhengige og $N(0, \sigma^2)$ fordelte. En utskrift fra tilpasning av en slik modell til de gitte data er gitt nedenfor.

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.50730	0.12194	12.36	<2e-16
<code>lcavol</code>	0.71932	0.06819	10.55	<2e-16

Residual standard error: 0.7875 on 95 degrees of freedom

Multiple R-squared: 0.5394, Adjusted R-squared: 0.5346

F-statistic: 111.3 on 1 and 95 DF, p-value: < 2.2e-16

- (a) Vis at maksimum likelihood estimatorene for β_0 og β_1 svarer til minste kvadraters estimatorene.

(Du behøver ikke å utlede selve formlene, kun vise at det svarer til samme prinsipp).

- (b) Vi ønsker å utføre en test på $H_0 : \beta_1 = 0$ mot $H_a : \beta_1 \neq 0$. Spesifiser hva slags test-observator du kan bruke til dette og utled fordelingen til denne.

Utfør testen basert på utskriften ovenfor og konkluder.

(Fortsettes på side 4.)

Vi vil nå utvide modellen ovenfor til

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \varepsilon_i, i = 1, \dots, n \quad (**)$$

der x_{i2} er `lweight` og x_{i3} er `age`. En tilpasning av denne modellen til de gitte data ga følgende resultat:

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.146941	0.772372	0.190	0.84953
lcavol	0.687819	0.067418	10.202	< 2e-16
lweight	0.549937	0.163838	3.357	0.00114
age	-0.009486	0.011003	-0.862	0.39081

Residual standard error: 0.7517 on 93 degrees of freedom

Multiple R-squared: 0.5892, Adjusted R-squared: 0.576


F-statistic: 44.47 on 3 and 93 DF, p-value: < 2.2e-16

(c) Basert på resultatene, vil du si at modell (**) ovenfor er en bedre modell enn modell (*) på forrige side? Begrunn svaret.

(d) For å sjekke en modell, bruker vi ofte residualene, som på vektorform kan defineres ved $\mathbf{E} = \mathbf{Y} - \hat{\mathbf{Y}}$ der $\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$.

Vis at $\mathbf{E} = [\mathbf{I} - \mathbf{H}]\mathbf{Y}$ (der $\mathbf{I}$ er identitetsmatrisen mens du selv må finne ut hva $\mathbf{H}$ er) og bruk dette til å vise at residualene er normalfordelte med forventning 0 og varians $\sigma^2(1 - h_{ii})$ for den i te residual. Her er h_{ii} diagonalelement nr i av $\mathbf{H}$.

Plottet nedenfor viser ulike residualplott (basert på standardiserte residualer).



(e) Forklar hva standardiserte residualer er og hvorfor det er mer hensiktsmessig å bruke disse enn residualene selv.

Basert på disse plottene, diskuter om antagelsene som ligger til grunn for modell (**) er rimelige.

(Fortsettes på side 5.)

Oppgave 3

Tabellen nedenfor viser antall personer involvert i alvorlige sykkelulykker (fordelt på kjønn) samt hvor mange av de som ble testet positiv for alkohol.

Kjønn	n	Y (testet positiv)	$\hat{p}$ (andel testet positiv)
Menn	1520	515	0.339
Kvinner	191	27	0.141

Vi vil anta at alle disse ulykkene er skjedd uavhengige av hverandre.

La p_M være sannsynligheten for at menn som er involvert i alvorlige sykkelulykker tester positiv på alkohol og p_K tilsvarende for kvinner. Vår interesse vil være i å sammenlikne p_K med p_M .

(a) La

$$Z = \frac{\hat{p}_K - p_K}{\sqrt{p_K(1 - p_K)/n_K}}.$$

Her er $\hat{p}_K = Y_K/n_K$ der Y_K er Y tilhørende gruppen av kvinner og tilsvarende for n_K .

Hva blir forventning og varians til Z ? Hva slags fordeling har Z tilnærmet når n_K er stor?

(b) Utfør en test av

$$H_0 : p_K = 0.339 \text{ mot } H_a : p_K \neq 0.339.$$

Hva blir konklusjonen hvis du velger signifikansnivå $\alpha = 0.05$?

(c) Test så istedet

$$H_0 : p_K = p_M \text{ mot } H_a : p_K \neq p_M$$

Hva blir konklusjonen i dette tilfellet? Angi i dette tilfellet en øvre grense for P-verdien til testen.

(d) Argumenter for hvorfor testen i (c) er mer fornuftig å bruke enn testen i (b).

Hvorfor får vi ikke så veldig forskjellige svar i (b) og (c) i dette tilfellet?

(e) Forklar hvordan du kunne brukt logistisk regresjon for å teste

$$H_0 : p_K = p_M \text{ mot } H_a : p_K \neq p_M.$$

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse 1.

Eksamensdag: Mandag 1. desember 2014.

Tid for eksamen: 14.30 – 18.30.

Oppgavesettet er på 5 sider.

Vedlegg: Tabell over normal-, t -, og χ^2 -fordeling.

Tillatte hjelpemidler: Godkjent kalkulator og formelsamling for STK1100/STK1110.

Kontroller at oppgavesettet er komplett før du begynner å besvare spørsmålene.

Oppgave 1. Vi skal undersøke hyppigheten av ulykker i forbindelse med dykkerarbeid i Nordsjøen. La λ være en parameter som angir forventet antall ulykker per timeverk. Vi har samlet inn data fra n forskjellige offshore-anlegg et bestemt år. La X_i betegne antall ulykker i løpet av et år ved i -te anlegg, $i = 1, 2, \dots, n$. Hver ulykke antas å opptre uavhengig av alle andre ulykker. Det er da rimelig å anta at X_i er Poisson-fordelt med parameter λt_i , der t_i er totalt antall timeverk per år i i -te anlegg. Dvs.

$$P(X_i = x_i) = \frac{(\lambda t_i)^{x_i}}{x_i!} \exp(-\lambda t_i), \quad x_i = 0, 1, 2, \dots$$

Videre er $X_1, X_2, \dots, X_n$ uavhengige tilfeldige variable.

a) En mulig estimator for λ er

$$\hat{\lambda} = \frac{\sum_{i=1}^n X_i}{\sum_{i=1}^n t_i}.$$

Vis at $\hat{\lambda}$ er en forventningsrett estimator for λ . Finn variansen til $\hat{\lambda}$. Hva blir estimatet av λ med data for $n = 5$ anlegg gitt til slutt i oppgaven (neste side)?

b) Vis at $\hat{\lambda}$ er sannsynlighetsmaksimerings-estimatoren (maximum likelihood estimator) for λ .

c) En annen mulig estimator for λ er

$$\hat{\lambda} = \frac{\sum_{i=1}^n X_i t_i}{\sum_{i=1}^n t_i^2}.$$

Hvilken av de to estimatorene vil du foretrekke? Begrunn svaret ditt.

(Fortsettes på side 2.)

Anlegg	1	2	3	4	5
t_i	$3.00 \cdot 10^4$	$2.00 \cdot 10^4$	$0.87 \cdot 10^4$	$2.50 \cdot 10^4$	$0.63 \cdot 10^4$
x_i	9	4	4	7	3

Oppgave 2. De siste ukene, spesielt etter fremlegging av statsbudsjettet, har opposisjonspartiet Ap opplevd rekordhøy oppslutning i flere meningsmålinger. Siste partibarometer fra 12. november 2014 viste at 42.2 % av de spurte ville ha stemt Ap hvis det hadde vært valg denne dagen. Vi kan lese på nettsidene til Opinion Perduco, som har gjennomført målingen, at de har spurt 960 personer.

a) Kan vi med dette si at det er nesten sikkert at Ap ville ha fått minst 40 % av stemmene i et eventuelt stortingsvalg den dagen? Besvar spørsmålet ved å formulere og gjennomføre en hypotesetest.

Oppgave 3. Forurensninger i vannet på to strender A og B i Oslofjorden skal undersøkes. Det mistenkes at strand A er mer forurenset enn strand B. Det blir tatt 9 prøver, 4 fra strand A og 5 fra strand B. La $X_1, X_2, \dots, X_4$ betegne målingene fra strand A, som kan antas uavhengige identisk fordelte variable fra normalfordelingen $N(\mu_A, \sigma^2)$. La $Y_1, Y_2, \dots, Y_5$ være målingene fra strand B, som kan antas uavhengige identisk fordelte fra normalfordelingen $N(\mu_B, \sigma^2)$. Målingene fra strand A og strand B er også uavhengige av hverandre. Vi skal først anta at variansen σ^2 er kjent lik 4.

Observasjonene var

Forurensning strand A (x_i) (i ppm): 16, 12, 14, 10

Forurensning strand B (y_i) (i ppm): 11, 8, 14, 7, 10

a) Gir målingene grunnlag for å konkludere med at strand A er mer forurenset enn strand B? Besvar spørsmålet ved å gjennomføre en hypotesetest. Husk å spesifisere hypotesene, beregn forkastningsområde og skriv en skikkelig konklusjon. Bruk signifikansnivå $\alpha = 0.01$.

b) Hva er en P-verdi? Finn P-verdien for testen ovenfor.

c) Hvor mange prøver må man ta hvis man skal ha like mange prøver fra A som fra B, og man i testen i a) foruten signifikansnivået på 1% forlangte at sannsynligheten for å forkaste H_0 når $\mu_A - \mu_B = 4$ skal være minst 95%?

d) Variansen σ^2 er i virkeligheten ukjent og må estimeres. Finn et estimat for variansen basert på de tilsammen 9 målingene fra de to strendene. Du kan bruke at de empiriske variansene for A og B er hhv. $s_A^2 = 6.67$ og $s_B^2 = 7.50$. Gjennomfør testen i a) når variansen er ukjent.

(Fortsettes på side 3.)

e) Utled et 99% konfidensintervall for forskjellen $\mu_A - \mu_B$, fremdeles med ukjent varians som må estimeres. Forklar hvordan et slikt intervall skal tolkes.

Oppgave 4. Når et fast stoff skal løses i vann og løsningsprosessen er forbundet med forbruk av varme, stiger løseligheten (målt i gram oppløst stoff per 100 gram vann) med stigende temperatur. Løselighetskurven for et salt S skal bestemmes ved følgende forsøk: 100 g vann varmes opp til x grader Celsius, og man bestemmer antall gram (Y) av saltet som løses i vannet ved denne temperaturen.

Forsøket utføres 18 ganger. Vi antar at $Y_1, Y_2, \dots, Y_{18}$ er uavhengige og normalfordelte med samme ukjente varians σ^2 og forventning gitt ved

$$E(Y_i) = \beta_0 + \beta_1 x_i,$$

der x_i er temperaturen i forsøk i . I utskriften fra R nedenfor finner du observasjonene og flere analyser av datasettet.

a) Hvilke tall i R-utskriften er minste kvadraters estimater for β_0 , β_1 og σ ? Diskuter hvor godt modellen passer til data på bakgrunn av utskrift og figurer.

b) Beregn et 95% konfidensintervall for β_1 . Du kan hente ut størrelser du trenger fra R-utskriften.

c) Forklar hvordan konfidensintervallet ovenfor henger sammen med å teste hypotesen

$$H_0 : \beta_1 = 0 \quad \text{mot} \quad H_a : \beta_1 \neq 0$$

på signifikansnivå $\alpha = 0.05$.

d) Du vil anslå løseligheten ved 35 grader Celsius. Forklar hva som er forskjellen på et konfidensintervall for forventet løselighet og et prediksjonsintervall for en ny observasjon ved denne temperaturen. Finn begge ved hjelp av utskriften.

e) Fra teorien burde løselighetskurven for salt S være et polynom heller enn en linje. Skriv opp en regresjonsmodell der du legger til et annengradsledd. En slik analyse er også gjennomført i R, se vedlagte utskrift. Vurder om annengradsmodellen er mer passende enn den lineære.

```
>
> x=c(10, 10, 10, 20, 20, 20, 30, 30, 30, 40, 40, 40, 50, 50, 50, 60, 60, 60)
> y=c(56.3, 59.9, 58.6, 63.7, 63.6, 65.4, 68.3, 70.6, 69.6, 74.1, 76.3, 74.6,
      80.5, 79.7, 79.1, 84.7, 85.9, 84.9)
> plot(x,y)
>
>
>
```

(Fortsettes på side 4.)

```
> fit=lm(y~x)
> summary(fit)
```

Call:

```
lm(formula = y ~ x)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.3603	-0.5203	-0.1732	0.5654	1.6454

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	53.32889	0.55615	95.89	<2e-16 ***
x	0.53314	0.01428	37.33	<2e-16 ***

Signif. codes: 0 *** 0.001 ** 0.01 * 0.05 . 0.1 1

Residual standard error: 1.035 on 16 degrees of freedom

Multiple R-squared: 0.9887, Adjusted R-squared: 0.9879

F-statistic: 1394 on 1 and 16 DF, p-value: < 2.2e-16

```
>
> abline(fit)
> plot(fit$res)
> qqnorm(fit$res)
>
> new=data.frame(x=35)
> predict(fit,new,interval="confidence")
      fit      lwr      upr
1 71.98889 71.47187 72.50591
> predict(fit,new,interval="prediction")
      fit      lwr      upr
1 71.98889 69.73523 74.24254
```

```
> fit2=lm(y~x+I(x^2))
> summary(fit2)
```

Call:

```
lm(formula = y ~ x + I(x^2))
```

Residuals:

Min	1Q	Median	3Q	Max
-2.0726	-0.4243	-0.2073	0.7668	1.5274

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	52.5233333	1.0765078	48.790	< 2e-16 ***
x	0.5935595	0.0704281	8.428	4.51e-07 ***
I(x^2)	-0.0008631	0.0009849	-0.876	0.395

(Fortsettes på side 5.)



Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.042 on 15 degrees of freedom


Multiple R-squared: 0.9892, Adjusted R-squared: 0.9878

F-statistic: 687.2 on 2 and 15 DF, p-value: 1.777e-15

>



Normal Q-Q Plot



SLUTT

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse 1.

Eksamensdag: Torsdag 12. desember 2013.

Tid for eksamen: 14.30 – 18.30.

Oppgavesettet er på 4 sider.

Vedlegg: Tabell over normal-, t -, og χ^2 -fordeling.

Tillatte hjelpemidler: Godkjent kalkulator og formelsamling for STK1100/STK1110.

Kontroller at oppgavesettet er komplett før du begynner å besvare spørsmålene.

Oppgave 1.

Samme størrelse måles gjentatte ganger med to forskjellige måleinstrumenter med ulik presisjon. La $X_1, X_2, \dots, X_m$ betegne m målinger med instrument A, som kan antas uavhengige identisk fordelte variable fra normalfordelingen $N(\mu, \sigma_1^2)$. La $Y_1, Y_2, \dots, Y_n$ være n målinger med instrument B, som kan antas uavhengige identisk fordelte fra normalfordelingen $N(\mu, \sigma_2^2)$. Målingene fra instrument A og B er også uavhengige av hverandre. De to variansene σ_1^2 og σ_2^2 er kjent for de to instrumentene.

Vi skal først studere resultatene fra instrument A.

a) Utled et 99% konfidensintervall for μ basert på de m observasjonene fra instrument A. Forklar hvordan et slikt intervall skal tolkes.

b) Hvor stor må m være for at lengden på konfidensintervallet for μ ikke skal være lenger enn w ? Hva blir m dersom $w = \sigma_1$?

Vi er i det videre interessert i å estimere forventningen μ fra alle $n + m$ observasjoner.

c) Sett opp uttrykket for likelihood og log likelihood og finn sannsynlighetsmaksimerings-estimatoren (maximum likelihood estimator) for μ basert på alle observasjonene.

d) Argumenter kort for at formen på estimatoren i c) er rimelig i forhold til hvordan antall observasjoner og presisjon i instrumentene bør påvirke estimeringen av μ . Sjekk om estimatoren er forventningsrett, og finn dens varians.

(Fortsettes på side 2.)

Oppgave 2. Mange kvinner får problemer med osteoporose (lav bentetthet) etter menopausen. Forskere ved Rikshospitalet studerer hvorledes genetiske faktorer bidrar til denne tilstanden. Vi skal studere et datasett med målt bentetthet for 84 kvinner i den aktuelle alderen, samt genekspresjon (et mål på hvor aktivt et gen er) for 20.000 gener i de samme kvinnenenes benceller. Vi skal ikke analysere hele dette høydimensjonale datasettet her, men studere hvordan genekspresjonen til fire utvalgte gener er assosiert med bentetthet hos kvinner etter menopause.

I utskriften nedenfor er variabelen bentetthet kalt 'bone' og de fire genene respektivt 'gene1', 'gene2', 'gene3' og 'gene4'.

a) Vi gjennomfører først en univariat analyse med gen 1 alene som kovariat og bentetthet som responsvariabel. Sett opp en enkel lineær regresjonsmodell med vanlige antakelser. Sett opp nullhypotese og alternativ og test om gen 1 er en signifikant forklaringsvariabel for bentetthet. Du skal spesifisere en testobservator, bruke nivå $\alpha = 0.05$ og beregne forkastningsområde. Sett inn tall fra R-utskrift (I) og konkluder.

b) Hva er en P-verdi? Finn en øvre grense for P-verdien for testen ovenfor.

c) Beregn et 95% konfidensintervall for stigningstallet i modellen i a). Gjør kort rede for sammenhengen mellom hypotesetesting med tosidig alternativ og konfidensintervall.

d) Vi inkluderer deretter gen 2 i en multippel regresjonsanalyse og får resultatene (II) på neste side. Forklar kort hva som skjer med effekten av gen 1 når også gen 2 inkluderes i modellen, og hvorfor dette kan skje. Du kan benytte tilleggsinformasjon som du finner i utskriften etter resultatene (II).

e) Til slutt inkluderer vi også gen 3 og gen 4 i modellen. Tilpasning til to alternative modeller finnes i R-utskriften på neste side (III). Velg beste modell, og begrunn valget ditt godt. Skriv en tolkning av de estimerte effektene av genekspresjonene på bentettheten i din utvalgte modell.

(I)

Call:

```
lm(formula = bone ~ gene1)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.9309	1.5477	2.54	0.01298
gene1	-1.1297	0.3609		

(edited output)

(Fortsettes på side 3.)

(II)

Call:

lm(formula = bone ~ gene1 + gene2)

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	7.8276	2.0564	3.806	0.000273
gene1	-0.1102	0.5082	-0.217	0.828876
gene2	-1.9110	0.6954	-2.748	0.007387

(edited output)

> cor(gene1, gene2)

[1] 0.7300616

(III)

Call:

lm(formula = bone ~ gene1 + gene2 + gene3 + gene4)

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-8.1091	2.9757	-2.725	0.007912
gene1	-0.2141	0.3848	-0.556	0.579455
gene2	-1.8064	0.5182	-3.486	0.000804
gene3	2.4974	0.6097	4.096	0.000101
gene4	1.7865	0.2731	6.541	5.56e-09

Residual standard error: 1.088 on 79 degrees of freedom

Multiple R-squared: 0.5588, Adjusted R-squared: 0.5365

F-statistic: 25.02 on 4 and 79 DF, p-value: 2.114e-13

Call:

lm(formula = bone ~ gene2 + gene3 + gene4)

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-8.2321	2.9546	-2.786	0.00666
gene2	-2.0106	0.3643	-5.519	4.09e-07
gene3	2.5455	0.6009	4.236	6.05e-05
gene4	1.7658	0.2694	6.554	5.03e-09

Residual standard error: 1.083 on 80 degrees of freedom

Multiple R-squared: 0.5571, Adjusted R-squared: 0.5405

F-statistic: 33.54 on 3 and 80 DF, p-value: 3.863e-14

(Fortsettes på side 4.)

Oppgave 3. En undersøkelse presentert i siste nummer av Universitas viser at 28% av studentene i Oslo og Akershus føler seg ensomme. I artikkelen får vi vite at undersøkelsen er basert på et representativt utvalg på 1016 studenter. Det står også i samme artikkel at en av fire hos den øvrige befolkningen føler seg ensomme.

a) Er studenter i Oslo og Akershus signifikant mer ensomme enn resten av befolkningen? Kall andelen ensomme studenter for p , og test $H_0 : p = 0.25$ mot passende alternativ. Du kan teste ved å beregne en P-verdi. Konkluder og kommenter kort.

Oppgave 4.

La X være inntekten til en tilfeldig valgt lønnsinntaker i en bestemt befolkningsgruppe. Det er vanlig å anta at X følger en pareto-fordeling, dvs. at X har sannsynlighetstetthet

$$f(x) = \frac{\theta c^\theta}{x^{\theta+1}}$$

når $c < x < \infty$, og $f(x) = 0$ ellers. Her er c minsteinntekten i befolkningsgruppen, mens $\theta > 0$ er en parameter som beskriver lønnsforskjellene i befolkningsgruppen. I denne oppgaven forutsetter vi at minsteinntekten c er kjent, mens θ skal estimeres fra uavhengige observasjoner $X_1, X_2, \dots, X_n$ av inntekter i den aktuelle befolkningsgruppen.

Det kan vises at sannsynlighetsmaksimerings-estimatoren (maximum likelihood estimator) for θ er

$$\hat{\theta} = \frac{n}{\sum_{i=1}^n \log X_i - n \log c}.$$

Det kan også vises at $2n\theta/\hat{\theta}$ er χ^2 -fordelt med $2n$ frihetsgrader.

Vi skal benytte opplysningene over til å konstruere en test for å undersøke om det er grunnlag for å påstå at $\theta > \theta_0$, der θ_0 er et gitt tall, dvs. teste hypotesen

$$H_0 : \theta = \theta_0 \quad \text{mot} \quad H_a : \theta > \theta_0.$$

a) Vis at med signifikansnivå α vil testen bli 'Forkast H_0 dersom $\hat{\theta} \geq 2n\theta_0/\chi_{1-\alpha, 2n}^2$ '.

b) La $\alpha = 0.01$ og $n = 20$. De 20 observerte inntektene gir $\sum_{i=1}^{20} \log x_i = 235$, mens minimumsinntekten i befolkningsgruppen er 100.000 kr. Gir dette grunnlag for å påstå at $\theta > 2$?

c) Fremdeles for $\alpha = 0.01$, $n = 20$ og $\theta_0 = 2$, finn et uttrykk $\beta(\theta')$ for sannsynligheten for type-II-feil når forskjellsparameteren i realiteten er θ' (der $\theta' > 2$). Hvor stor må θ' være for at sannsynligheten for type-II-feil blir så liten som 0.05?

SLUTT

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse 1.

Eksamensdag: Tirsdag 11. desember 2012.

Tid for eksamen: 14.30 – 18.30.

Oppgavesettet er på 5 sider.

Vedlegg: Tabell over Poisson-, normal-, t -, og F-fordeling.

Tillatte hjelpemidler: Godkjent kalkulator og formelsamling for STK1100/STK1110.

Kontroller at oppgavesettet er komplett før du begynner å besvare spørsmålene.

Oppgave 1.

Lånekassen definerer en *fulltidsstudent* som en som samler minst 30 studiepoeng per semester. Vi skal ved hjelp av en spørreundersøkelse finne ut om andelen fulltidsstudenter er forskjellig ved NTNU i Trondheim og ved UiO i Oslo. Kall andelen fulltidsstudenter ved UiO for p_1 og andelen fulltidsstudenter ved NTNU for p_2 . Vi spør et tilfeldig utvalg på størrelse n fra UiO og et tilfeldig utvalg på størrelse m fra NTNU om de oppfyller dette kravet inneværende semester.

a) Utled en test på nivå $\alpha = 0.05$ for å teste

$$H_0 : p_1 - p_2 = 0$$

mot en tosidig alternativhypotese. Anta at n og m er store nok til at du kan bruke tilnærming til normalfordeling.

b) Konstruer et 95% konfidensintervall for forskjellen $p_1 - p_2$. Forklar hvorfor uttrykket for variansen blir forskjellig fra det du brukte i a).

c) La $n = 200$ og $m = 400$. 102 av de spurte studentene ved UiO og 248 av de spurte ved NTNU kvalifiserte som fulltidsstudenter. Sett inn både i a) og b) og kommenter.

Oppgave 2.

Et advokatfirma i USA blir kontaktet av en gruppe kvinnelige ansatte i et elektronikkfirma, som mener at firmaet de jobber i gir kvinnene dårligere lønnsvilkår enn mennene. Advokatfirmaet plukker ut tilfeldige ansatte i elektronikkfirmaet, 10 kvinner og 9 menn, og gjennomgår deres lønnsopplysninger. Spesielt samler de tall for utbytte ved siste

(Fortsettes på side 2.)

personlige lønnsforhandling (i \$) og en vurdering (0-100 poeng) for hvor tilfreds nærmeste overordnet er med medarbeiderens arbeid det siste året. Det sies fra firmaet at utbyttet ved lønnsforhandling blant annet baseres på denne vurderingen (variabelen 'score'). Data er lagt ved til slutt i oppgavesettet, sammen med en utskrift fra R og et plott. Lønnsøkning fra lønnsforhandlingene heter der 'salary_incr'. Variabelen 'sex' er medarbeiderens kjønn, kodet som 1 for kvinner og 0 for menn.

Det er opplagt at kvinnene i utvalget i gjennomsnitt har fått langt lavere lønnstillegg enn mennene. Firmaet svarer advokatene at det må være fordi kvinnene generelt har fått lavere poengsum for arbeidsinnsatsen. Du skal først undersøke disse poengene for arbeidsinnsats (score). Gjennomsnittlig score i utvalget for kvinner var 43.5, og for menn var den 55.56. Vi oppgir også at estimerte varianser var 922.50 for score for kvinner og 552.78 for score for menn.

a) Vi antar at variabelen score er normalfordelt både for kvinner og for menn, med forventning henholdsvis μ_1 og μ_2 og samme varians σ^2 . Gjennomfør en t-test for å avgjøre om det er grunnlag i dataene for å påstå at kvinnene gjør en dårligere jobb (målt ved score fra overordnet) enn mennene. Bruk nivå $\alpha = 0.05$. Du må skrive opp hypotesene og uttrykket for testobservator, og spesifisere hvilken fordeling du har brukt. Skriv en konklusjon. Du kan støtte deg på utskriften fra R.

b) I a) har vi antatt lik varians i fordelingene til score for kvinner og for menn. Er dette en rimelig antakelse? Svar ved hjelp av en hypotesetest. Sett opp hypoteser, testobservator og fordeling, og gjennomfør testen på nivå $\alpha = 0.1$. Hva blir din konklusjon? Du kan bruke informasjon fra R-utskriften.

Heretter skal vi betrakte score som en fast forklaringsvariabel (ikke stokastisk). For at advokatene skal kunne bruke tallmaterialet i saken mot elektronikkfirmaet, bestemmer firmaets statistikk-konsulent at man skal utføre en multippel regresjon, der utbytte i lønnsforhandling er responsen som forsøkes forklart av score og kjønn. La responsen være y , score x_1 og kjønn x_2 . Modellen vi bruker har med et interaksjonsledd, og ser slik ut:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{1i} x_{2i} + \epsilon_i$$

der ϵ_i er uavhengige og $N(0, \sigma^2)$, $i = 1, \dots, n$.

c) Spesifiser hvordan modellen over blir for hhv. kvinner og menn, og forklar hvordan parameterne kan brukes til å vurdere to typer lønnsdiskriminering: mulig forskjell i grunnleggende lønnstillegg, og mulig forskjell i uttelling for hvert poeng i arbeidsvurderingen (score).

d) Du finner den tilpassede regresjonsmodellen, basert på de $n = 19$ observasjonene, i utskriften fra R. Forklar på bakgrunn av de estimerte parameterverdiene og tilhørende P-verdier hvorfor kvinnene og advokatene deres har en god sak.

(Fortsettes på side 3.)

e) Konstruer et 99% konfidensintervall for interaksjonsparameteren β_3 . Du kan hente noen av tallene du trenger fra utskriften. Forklar hvordan et slikt konfidensintervall skal tolkes.

f) Hvordan er 'Multiple R-squared' beregnet, og hvordan skal den tolkes? Hvordan vurderer du den tilpassede modellen i forhold til vedlagte plott av dataene? Hvilke andre plott ville du ha konstruert for å vurdere modellens egnethet?

Oppgave 3.

Du skal i denne oppgaven studere en enkel lineær regresjonsmodell som vi tvinger til å gå gjennom origo, dvs. at skjæringspunktet med y -aksen er satt lik null. La responsen være y og forklaringsvariabelen x . Vi har n observasjonspaar (x_i, y_i) . Modellen er da altså

$$y_i = \beta x_i + \epsilon_i, \quad i = 1, \dots, n,$$

der ϵ_i -ene er uavhengige og normalfordelte med forventning 0 og varians σ^2 .

a) Finn minste kvadraters estimator (least squares estimator) $\hat{\beta}_{MK}$ for β . Vis at denne er forventningsrett og finn et uttrykk for estimatorens varians.

b) En alternativ estimator for β er $\hat{\beta}_A = \sum_i^n y_i / \sum_i^n x_i$. Vis at også denne er forventningsrett. Finn variansen til $\hat{\beta}_A$ og sammenlign med variansen til $\hat{\beta}_{MK}$. Hvilken estimator vil du bruke? Begrunn svaret.

Oppgave 4.

Antall tilfeller X av en sjelden, medfødt sykdom i Norge per år kan antas å følge en Poisson-fordeling med parameter λ , dvs. $X \sim \text{Poisson}(\lambda)$, slik at $P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$ for $k = 0, 1, 2, \dots$

a) Forventet antall barn født med denne sykdommen har vært ett per år. Hvor mange tilfeller må man minst observere et gitt år for å kunne forkaste $H_0 : \lambda = 1$ til fordel for $H_a : \lambda > 1$ på nivå $\alpha = 0.05$?

b) Hvor sannsynlig er det at man med testen ovenfor oppdager at λ faktisk er økt, dersom den i virkeligheten er doblet i forhold til tidligere (dvs. $\lambda = 2$)? Hva er sannsynligheten for type-II-feil i denne situasjonen?

c) Forskere vil studere forekomsten av sykdommen nærmere. For å estimere sannsynligheten p for å få et barn med sykdommen, observerer man antall fødte barn n_i og antall tilfeller X_i for hvert år i , der $i = 1, \dots, m$. Vi antar at sannsynligheten p er konstant i disse m årene. Dessuten er n_i -ene store og p liten, slik at vi kan anta at $X_i \sim \text{Poisson}(n_i p)$, $i = 1, \dots, m$.


Finn sannsynlighetsmaksimerings-estimatoren (Maximum Likelihood Estimator) for p i denne situasjonen. Finn estimatorens forventning og varians.

(Fortsettes på side 4.)

Datasett oppgave 1:

	sex	score	salary_incr
1	1	10	21
2	1	90	96
3	1	20	47
4	1	80	128
5	1	30	64
6	1	70	52
7	1	10	73
8	1	15	19
9	1	50	82
10	1	60	71
11	0	20	128
12	0	80	474
13	0	50	342
14	0	70	330
15	0	30	185
16	0	70	301
17	0	40	267
18	0	90	517
19	0	50	390

Plott av data, sort punkt kvinner, hvitt punkt menn:



(Fortsettes på side 5.)

Utskrift fra R, oppgave 1:

```
> t.test(score[1:10],score[11:19],alternative="less", var.equal=T)
```

```
Two Sample t-test
```

```
data: score[1:10] and score[11:19]
t = -0.959, df = 17, p-value = 0.1755
alternative hypothesis: true difference in means is less than 0
95 percent confidence interval:
 -Inf 9.812306
sample estimates:
mean of x mean of y
 43.50000  55.55556
```

```
> var.test(score[1:10],score[11:19])
```

```
F test to compare two variances
```

```
data: score[1:10] and score[11:19]
F = 1.6688, num df = 9, denom df = 8, p-value = 0.4822
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval:
 0.3830055 6.8455251
sample estimates:
ratio of variances
 1.66884
```

```
> fit=lm(salary_incr~score+sex+score*sex)
> summary(fit)
```

```
Call:
```

```
lm(formula = salary_incr ~ score + sex + score * sex)
```

```
Residuals:
```

```
      Min       1Q   Median       3Q      Max
-93.626 -21.684   0.266  29.609  90.394
```

```
Coefficients:
```

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  62.0553    40.7630   1.522 0.148723
score         4.7510     0.6815   6.972 4.49e-06 ***
sex        -31.1230    48.3228  -0.644 0.529259
score:sex     -3.9609     0.8437  -4.695 0.000288 ***
---

```

```
Signif. codes:  0 *** 0.001 ** 0.01 * 0.05 . 0.1 1
```

```
Residual standard error: 45.32 on 15 degrees of freedom
Multiple R-squared:  0.9327,    Adjusted R-squared:  0.9192
F-statistic: 69.29 on 3 and 15 DF,  p-value: 5.101e-09
```

SLUTT

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse 1

Eksamensdag: Fredag 9. desember 2011

Tid for eksamen: 14.30 – 18.30

Oppgavesettet er på 4 sider.

Vedlegg: Tabell over normalfordeling,
tabell over t-fordeling og
tabell over χ^2 -fordeling

Tillatte hjelpemidler: Formelsamling STK1100/STK1110 og
godkjent kalkulator

Kontroller at oppgavesettet er komplett før
du begynner å besvare spørsmålene.

Oppgave 1

Utgangspunktet for denne oppgaven er en biologisk undersøkelse der vekten i gram til 9 fisk er bestemt sammen med fiskenes lengde i mm og alder i år. Hensikten er å undersøke sammenhengen mellom vekten på den ene siden og lengde og alder på den andre. Vekt er derfor respons og lengde og alder de uavhengige variablene. Nedenfor er utsnitt av en R-utskrift fra tilpasning av regresjonsmodellen med forventet respons

$$E(Y_i) = \beta_0 + \beta_1 \text{lengde}_i + \beta_2 \text{alder}_i, \quad i = 1, \dots, 9$$

Call:

```
lm(formula = vekt ~ lengde + alder, data = fisk)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-1647.3967	224.8228	-7.328	0.000330	***
lengde	5.3173	0.5872	9.055	0.000102	***
alder	7.1498	4.0309	1.774	0.126468	

Signif. codes: *** 0.001 ** 0.01 * 0.05 0.1 1

Residual standard error: 29.23 on 6 degrees of freedom


Multiple R-squared: 0.9663, Adjusted R-squared: 0.9551

F-statistic: 86 on 2 and 6 DF, p-value: 3.83e-05

I figuren på neste side er det gjengitt fire plott, som kan brukes for å vurdere hvor god tilpasningen eller føyningen er.

I denne oppgaven antar vi at feileddene ϵ_i , $i = 1, \dots, 9$ er uavhengige $N(0, \sigma^2)$ fordelte.

(Fortsettes på side 2.)



Figur 1: Plott for å vurdere føyningen

- Forklar hvordan føyningen, eller tilpasningen, av modellen kan vurderes ut fra den vedlagte utskriften og plottene.
- Bruk resultatene i utskriften til å beregne et 95% konfidensintervall for koeffisienten til alder, det vil si β_2 .
- Hva er konklusjonen av en ensidig test med nivå 0.05 av testen for nullhypotesen $H_0 : \beta_2 = 0$ mot alternativet $H_a : \beta_2 > 0$? Hva er P-verdien?

Oppgave 2

I en Bernoulli forsøksrekke er en vanlig test å bruke den observerte andelen suksesser for å teste nullhypoteser om andelen p . Et alternativ er å ta utgangspunkt i antall forsøk som er nødvendige for å observere en suksess. Denne variabelen er geometrisk fordelt med punktsannsynlighet

$$P(X = x) = (1 - p)^{x-1}p, \quad x = 1, 2, \dots$$

- Begrunn at en rimelig test for nullhypotesen $H_0 : p = \frac{1}{2}$ mot den alternative hypotesen $H_a : p < \frac{1}{2}$ er å forkaste hvis antallet slike forsøk er stort.
- Bestem forkastningsområdet for testen i punkt a) når nivået er 10%.

(Fortsettes på side 3.)

- c) Forklar hva feil av type II er, og finn sannsynligheten for denne feilen i testen i punkt b) når $p = 1/4$. Begrunn hvorfor testen du utledet i punkt b) også har nivå 10% for å teste nullhypotesen $H_0 : p \geq \frac{1}{2}$ mot den alternative hypotesen $H_a : p < \frac{1}{2}$.

Oppgave 3

Nedenfor er et utsnitt av utskrift av tilpasning av en enkel lineær regresjon til samme data som i oppgave 1 med vekt som respons og lengde som uavhengig variabel, det vil si modellen med forventet respons

$$E(Y_i) = \beta_0 + \beta_1 \text{lengde}_i, \quad i = 1, \dots, 9.$$

Call:

```
lm(formula = vekt ~ lengde, data = fisk)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-1828.0294	229.1108	-7.979	9.27e-05 ***
lengde	5.9667	0.5249	11.368	9.13e-06 ***

Signif. codes: 0 *** 0.001 ** 0.01 * 0.05 . 0.1 1

Residual standard error: 33.41 on 7 degrees of freedom

Multiple R-squared: 0.9486, Adjusted R-squared: 0.9413

F-statistic: 129.2 on 1 and 7 DF, p-value: 9.134e-06

Hvis $y_1, \dots, y_9$ er vektene og $x_1, \dots, x_9$ er lengdene til fiskene er $\sum_{i=1}^9 y_i = 6961$, $\sum_{i=1}^9 x_i = 3924$, $\sum_{i=1}^9 y_i x_i = 3059173$ og $\sum_{i=1}^9 x_i^2 = 1714916$.

I denne oppgaven antar vi fortsatt at feileddene ϵ_i , $i = 1, \dots, 9$ er uavhengige $N(0, \sigma^2)$ fordelte.

- Hvorfor er minste kvadraters estimatorene for β_0 og β_1 i denne modellen også sannsynlighetsmaksimeringsestimatorene? Hva er sannsynlighetsmaksimeringsestimatoren til σ^2 ? Er denne forvenningsrett?
- Betrakt nullhypotesen $H_0 : \beta_1 = 5$ og den alternative hypotesen $H_a : \beta_1 \neq 5$. Hva er en rimelig testobservator i denne situasjonen? Forklar hva fordelingen under nullhypotesen er, og hvordan testen kan utføres ved hjelp av resultatene i utskriften ovenfor.
- Gjennomfør beregningene du forklarte i punkt b) ved hjelp av resultatene i utskriften når testen har nivå $\alpha = 0.05$. Bruk de vedlagte tabellene til å angi en øvre og nedre grense for P-verdien.
- Finn et 95% konfidensintervall for forventet vekt av fisker med lengde 50cm.
- Finn et 95% prediksjonsintervall for vekten til en fisk som har denne lengden, det vil si 50cm. Hva er fortolkningen av et slikt intervall?

(Fortsettes på side 4.)

- f) Forklar hva "Multiple R-squared: 0.9486" i utskriften ovenfor er og hva tolkningen er. Det er denne størrelsen som betegnes med r^2 i læreboka. Hvis $(x_1, y_1), \dots, (x_9, y_9)$ er de observerte vektene og lengdene, vis sammenhengen mellom r^2 og den empiriske, eller utvalgs, korrelasjonskoeffesienten

$$\frac{\sum_{i=1}^9 (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^9 (x_i - \bar{x})^2 \sum_{i=1}^9 (y_i - \bar{y})^2}}$$

der $\bar{x} = \frac{1}{9} \sum_{i=1}^9 x_i$ og $\bar{y} = \frac{1}{9} \sum_{i=1}^9 y_i$?

SLUTT

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse 1.

Eksamensdag: 10. desember 2010.

Tid for eksamen: 14.30 – 18.30.

Oppgavesettet er på 4 sider.


Vedlegg: 1) Data over bensinforbruk for 19 personbiler.
2) Tabell for standardnormalfordelingen.
3) Tabell for t -fordelingene.
4) Tabell for kji-kvadrat fordelingene.

Tillatte hjelpemidler: Godkjent lommeregner.
Formelsamling for STK1100 og STK1110.

Kontroller at oppgavesettet er komplett før
du begynner å besvare spørsmålene.

Oppgave 1

I denne oppgaven skal vi se nærmere på hvordan bensinforbruket til en bil avhenger av ulike tekniske data for bilen. I vedlegg 1 er det gitt tekniske data og informasjon om bensinforbruket (i liter per mil) for 19 ulike personbiler. (Dataene er tatt med for fullstendighetens skyld, og det er ikke nødvendig å se på dataene for å løse oppgaven.) De tekniske dataene er antall hestekrefter for motoren, vekten til bilen (i kg) og slagvolumet til motoren (i liter). I R-utskriftene står **hk** for antall hestekrefter, **vekt** for bilens vekt, **vol** for slagvolum og **bruk** for bensinforbruk. Plottet nedenfor gir en oversikt over dataene.



(Fortsettes på side 2.)

Resultatet av en multippel lineær regresjon med bensinforbruk som respons og antall hestekrefter, vekt og slagvolum som forklaringsvariabler er gitt nedenfor. Merk at R-utskriften er redigert (ved at noe av informasjonen er fjernet fra utskriften).


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.01033	0.11966	0.086	0.9323
hk	0.00604	0.00148	4.076	0.0010
vekt	0.00071	0.00023	3.005	0.0089
vol	-0.23979	0.07335		

Residual standard error: 0.0577

Multiple R-squared: 0.8212

- Forklar kort hva de ulike delene av R-utskriften forteller deg.
- Bruk en hypotesetest til å avgjøre om slagvolumet til motoren har signifikant betydning for bensinforbruket. Hvordan kan du forklare at den estimerte effekten av slagvolum er negativ selv om sammenhengen ser ut til å være positiv i plottet først i oppgaven?
- La θ være forventet endring i bensinforbruket når styrken til motoren økes med 10 hestekrefter (og vekt og slagvolum ikke endres). Bestem et 95% konfidensintervall for θ og forklar hva intervallet sier deg.

Nedenfor er det gitt ulike plott av residualene for den tilpassede modellen.



- Beskriv de forutsetningene regresjonsanalysen bygger på og bruk residualplottene til å vurdere om disse forutsetningene er rimelig godt oppfylt.

(Fortsettes på side 3.)

Oppgave 2

Menneskene har hatt terninger i flere tusen år. De eldste terningene var skåret ut av et bein fra sauefoten, eller de var lagd av stein, metall eller keramikk. Vi regner i dag med at sannsynligheten er $1/6$ for å få sekser når vi kaster en terning. Men var det tilfellet også for de terningene som ble brukt i tidligere tider?

På British Museum i London fins det flere terninger fra romertiden, blant annet en terning av marmor og en terning av jern. Det har blitt gjort forsøk med å kaste disse terningene. Da marmorterningen ble kastet 204 ganger, fikk en sekser i 54 av kastene.

- a) La p være sannsynligheten for at et kast med marmorterningen vil gi sekser. Bestem en test med signifikansnivå 5% for testing av nullhypotesen $H_0 : p = \frac{1}{6}$ mot den alternative hypotesen $H_a : p > \frac{1}{6}$. Hva blir konklusjonen din?
- b) Forklar hva P -verdien til en test er. Bestem P -verdien for situasjonen i punkt a.

Terningen av jern har også blitt kastet 204 ganger. Da fikk en sekser i 42 av kastene.

- c) La nå p være sannsynligheten for at et kast med terningen av jern vil gi sekser. Test nullhypotesen $H_0 : p = \frac{1}{6}$ mot den alternative hypotesen $H_a : p > \frac{1}{6}$. Bruk signifikansnivå 5%. Hva blir konklusjonen din?
- d) Forklar hva vi mener med feil av type II. Bestem sannsynligheten for feil av type II hvis sannsynligheten for å få sekser med terningen av jern er $p = 0.20$.
- e) Hvor mange kast må en gjøre med terningen av jern for at sannsynligheten for feil av type II skal være 20% hvis $p = 0.20$?

Oppgave 3

Vi ser på den lineære regresjonsmodellen

$$Y_i = \beta_0 + \beta_1(x_i - \bar{x}) + \epsilon_i; \quad i = 1, 2, \dots, n; \quad (1)$$

der x_i -ene er gitte størrelser, ϵ_i -ene er uavhengige og $N(0, \sigma^2)$ -fordelte og β_0 , β_1 og σ^2 er ukjente parametere. Merk at vi i (1) har trukket fra gjennomsnittet av x_i -ene. Vi sier at vi har sentrert forklaringsvariabelen.

- a) Vis at minste kvadraters estimatorer for β_0 og β_1 kan gis på formen

$$\hat{\beta}_0 = \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i \quad \text{og} \quad \hat{\beta}_1 = \sum_{i=1}^n \frac{x_i - \bar{x}}{S_{xx}} Y_i$$

$$\text{der } S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2.$$

(Fortsettes på side 4.)

b) Vis at $\hat{\beta}_0$ og $\hat{\beta}_1$ er forventningsrette.

c) Bestem $V(\hat{\beta}_0)$ og $V(\hat{\beta}_1)$ og vis at $\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = 0$.

Hint: Hvis $Z_1, \dots, Z_n$ er uavhengige stokastiske variabler og $a_1, \dots, a_n$ og $b_1, \dots, b_n$ er konstanter, så er $\text{Cov}(\sum_{i=1}^n a_i Z_i, \sum_{i=1}^n b_i Z_i) = \sum_{i=1}^n a_i b_i V(Z_i)$.

Vi er interessert i å estimere $\mu_{Y \cdot x^*} = \beta_0 + \beta_1(x^* - \bar{x})$, dvs. forventet respons når $x = x^*$.

d) Vis at $\hat{\mu}_{Y \cdot x^*} = \hat{\beta}_0 + \hat{\beta}_1(x^* - \bar{x})$ er en forventningsrett estimator for $\mu_{Y \cdot x^*}$ og bestem variansen til estimatoren.

En estimator for σ^2 er

$$S^2 = \frac{1}{n-2} \sum_{i=1}^n \left(Y_i - \hat{\beta}_0 - \hat{\beta}_1(x_i - \bar{x}) \right)^2.$$

Det er kjent at S^2 er uavhengig av $\hat{\beta}_0$ og $\hat{\beta}_1$ og at $(n-2)S^2/\sigma^2$ er kji-kvadrat fordelt med $n-2$ frihetsgrader. (Du skal ikke vise det.)

e) Forklar at

$$\frac{\hat{\mu}_{Y \cdot x^*} - \mu_{Y \cdot x^*}}{S \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}}}$$

er t -fordelt med $n-2$ frihetsgrader og bruk det til å bestemme et $100(1-\alpha)\%$ konfidensintervall for $\mu_{Y \cdot x^*}$.

SLUTT

Vedlegg 1: Data for personbiler

Nedenfor er det gitt ulike tekniske data og data om bensinforbruk for 19 ulike merker av personbiler. Hver linje i tabellen gir informasjon for et bilmerke, og kolonnene i tabellen gir antall hestekrefter, vekt (i kg), slagvolumet til motoren (i liter) og bensinforbruket (i liter per mil).

hk	vekt	vol	bruk
68	980	1.6	0.78
95	1160	2.2	0.85
97	1040	2.0	0.86
75	1010	1.7	0.76
115	1270	2.0	1.09
88	1170	2.3	0.89
65	900	1.4	0.69
80	870	1.6	0.67
80	1210	2.0	0.86
71	900	1.5	0.75
68	970	1.6	0.80
90	1210	2.5	0.83
90	1160	2.5	0.70
70	1000	1.7	0.69
65	920	1.4	0.74
69	970	1.5	0.63
78	990	1.6	0.77
110	1180	2.0	1.09
71	870	1.5	0.74

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i STK1110 — Statistiske metoder og dataanalyse 1

Eksamensdag: Onsdag, 2. desember 2009

Tid for eksamen: 9.00 – 12.00

Oppgavesettet er på 4 sider.

Vedlegg: Tabell for χ^2 -fordeling, tabell for t -fordeling

Tillatte hjelpemidler: Godkjent lommeregner og
Formelsamling for STK1100 og STK1110

Kontroller at oppgavesettet er komplett før
du begynner å besvare spørsmålene.

Oppgave 1

En investor vil saksøke aksjemegler A fordi han mener avkastningen på porteføljen megleren forvalter for ham, er for lav. Vi har registrert månedlig avkastning (i prosent) for de 36 månedene megleren har tatt hånd om porteføljen. Vi ønsker å sammenligne med månedlig avkastning for de samme 36 månedene for en tilsvarende portefølje forvaltet av en annen megler B. Vi parrer observasjonene (diff = megler A - megler B) hver måned, og antar at differansene i avkastning for de 36 månedene kan betraktes som uavhengige av hverandre. Gjennomsnittet av de 36 månedlige avkastningene for megler A var -1.10 prosent, tilsvarende for megler B var 0.95 prosent.

Empirisk standardavvik for de 36 differansene var 5.89 prosent. Et normalfordelingsplott av de 36 differansene viser ingen ekstreme verdier eller skjevheter i fordelingen.

a) Anta at fordelingen til differansene har forventning μ og standardavvik σ . Forklar hvorfor det er naturlig å teste hypotesene

$$H_0 : \mu = 0 \quad \text{mot} \quad H_a : \mu < 0.$$

Finn en passende testobservator, og spesifiser dennes fordeling når nullhypotesen er sann. Gjør rede for hvilke antakelser du legger til grunn.

b) Beregn forkastningsområdet svarende til at testen skal ha nivå 0.01, og

(Fortsettes på side 2.)

konkluder på bakgrunn av tallene i oppgaveteksten. Beregn også tilhørende P-verdi (så godt du kan fra vedlagte tabell). Bør investoren gå til søksmål?

c) Beregn et 95% konfidensintervall for standardavviket σ .

d) Det ble også vurdert å bruke en to-utvalgstest istedenfor testen basert på de parrede observasjonene. Hvorfor ville to-utvalgstesten være et bedre alternativ under visse forutsetninger, og hvorfor tror du den parrede testen ble brukt i dette tilfellet?

Oppgave 2

En ny antikoagulant (legemiddel mot blodpropp) er under utvikling. Som et ledd i utprøvingen fikk 12 friske menn og 8 friske kvinner antikoagulant i ulike doser (i milligram), og prothrombin-tid ble målt for hver av dem (i sekunder). Prothrombin-tid er et mål som sier noe om hvor raskt blodet koagulerer. Man ønsker å bruke datamaterialet til å belyse sammenhengen mellom dose av antikoagulant, kjønn og prothrombin-tid ved å utføre en regresjonsanalyse med dose x_1 og kjønn x_2 som forklaringsvariable og prothrombin-tid som respons Y .

I figuren på neste side er prothrombin-tid plottet mot dose, med forskjellige symboler for kvinner og menn. Regresjonsmodellen vi vil bruke er

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \epsilon_i \quad (1)$$

der x_{i1} er dose for person i og $x_{i2} = 0$ hvis person i er en mann og $x_{i2} = 1$ hvis person i er en kvinne. ϵ_i er uavhengige og normalfordelte $N(0, \sigma^2)$, $i = 1, \dots, 20$.

a) Gi en tolkning av parametrene β_1 og β_2 . Virker modellen rimelig i forhold til plottet av dataene? Begrunn svaret.

Vi skal uansett gå videre med modell (1) i punkt b) og c). En analyse av datasettet gir følgende estimater ved minste kvadraters metode: $\hat{\beta}_0 = 7.155$, $\hat{\beta}_1 = 0.05849$ og $\hat{\beta}_2 = 3.7866$. Estimert standardfeil er beregnet til hhv. $s_{\hat{\beta}_0} = 2.445$, $s_{\hat{\beta}_1} = 0.01201$ og $s_{\hat{\beta}_2} = 0.3886$.


b) Beregn et 95% konfidensintervall for forventet forskjell i prothrombin-tid mellom kvinner og menn ved lik dose. Bruk intervallet til å teste om denne forskjellen er signifikant forskjellig fra 0. Hva blir signifikansnivået for denne testen?

c) Hvordan beregnes residualene i denne modellen (du skal ikke beregne dem!)? Beskriv kort forskjellige plott som kaster lys over hvor godt modellen

(Fortsettes på side 3.)

passer til data. Multipl R^2 er beregnet til 87.3 %. Hvordan skal dette tallet tolkes?

d) Finn et uttrykk for endringen i forventet prothrombin-tid når dosen økes med d milligram. Vis at denne endringen er den samme for kvinner og menn. Hvordan vil du modifisere regresjonsmodellen dersom forventet endring i prothrombin-tid for en gitt endring i dose antas forskjellig for kvinner og menn? Se igjen på figuren og diskuter kort om dette er en rimelig utvidelse av modellen.



Oppgave 3

I frykt for en pandemisk influensa planlegger Folkehelseinstituttet å massevaksinere befolkningen. Det er ønskelig at mer enn 60% av befolkningen vaksineres. På et gitt tidspunkt utføres en spørreundersøkelse for å finne ut hvor stor vaksinasjonsviljen er i befolkningen. Anta at p er andelen av befolkningen som sier ja til vaksinen. Et tilfeldig utvalg på n personer trekkes ut, og disse må svare på om de vil vaksineres eller ikke. La X være den tilfeldige variabelen som beskriver antallet som sier ja blant de n . Vi er interessert i å estimere p .

a) Vis at den intuitive estimatoren for p , $\hat{p} = X/n$, faktisk er sannsynlighetsmaksimerings-estimatoren (maximum likelihood estimator) for p . Er den også en momentestimator for p ?

b) Finn forventning $E(\hat{p})$ og varians $V(\hat{p})$ for $\hat{p}$ og vis at estimatoren er

(Fortsettes på side 4.)

konsistent, altså at $\hat{p}$ konvergerer i sannsynlighet mot p når n vokser. (Tips: Bruk Chebyshevs ulikhet fra formelsamlingen.)

c) Anta at utvalgsstørrelsen n er så stor at fordelingen til $\hat{p}$ kan tilnærmes med en normalfordeling. Utled og gjennomfør en hypotesetest for å undersøke om innsamlede data viser at p er så stor som Folkehelseinstituttet ønsker. Du kan bruke at $n = 200$ og at 122 av disse svarte ja.

d) Finn sannsynlighetsmaksimerings-estimatorer for $E(X)$ og $V(X)$. Vis at den resulterende estimatoren for $V(X)$ ikke er forventningsrett, og foreslå en modifisert estimator som er det.

SLUTT

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i:	STK1110 — Statistiske metoder og dataanalyse 1.
Eksamensdag:	Onsdag 3. desember 2008.
Tid for eksamen:	9.00 – 12.00.
Oppgavesettet er på 4 sider.	
Vedlegg:	Tabell for normal, χ^2 - og t -fordelingen.
Tillatte hjelpemidler:	Godkjent lommeregner og Formelsamling for STK1100 og STK1110.

Kontroller at oppgavesettet er komplett før du begynner å besvare spørsmålene.

Oppgave 1.

For å bestemme usikkerheten til et måleinstrument for hastighet måler man flere ganger hastigheten til en gjenstand som beveges med en kjent hastighet. Målingene nedenfor angir resultatet fra 5 slike forsøk der gjenstanden hadde en hastighet på 100 km per time

102.93, 99.27, 102.67, 99.82, 98.24.

En rimelig modell er her at målingene er realisasjoner av uavhengige normalfordelte variable, $X_1, \dots, X_5$, som alle er normalfordelt $N(\mu_0, \sigma^2)$, der $\mu_0 = 100$ er kjent.

- Vis at fordelingen til $\frac{1}{\sigma^2} \sum_{i=1}^5 (X_i - \mu_0)^2$ er χ^2 -fordelt med 5 frihetsgrader. Finn en forventningsrett estimator for σ^2 . Hva er variansen?
- Bruk resultater fra punkt a) til å utlede en test med nivå α for nullhypotesen

$$H_0 : \sigma^2 = \sigma_0^2 \text{ mot alternativet } H_A : \sigma^2 > \sigma_0^2$$

der σ_0^2 er kjent.

(Fortsettes side 2.)

- c) Angi en øvre og nedre grense for p-verdien til testen basert på observasjonene i begynnelsen av oppgaven når $\sigma_0^2 = 2$. Forklar omhyggelig hva p-verdier er og hvordan resultatet du fant skal tolkes.

Oppgave 2.

Følgende tabell viser et utsnitt av vektene, y_i , til 12 barn med en spesiell type spiseforstyrrelse samt deres høyde, x_i , og alder, z_i .

Table 1: Vekt i kg, y_i , høyden i meter, x_i , og alder i år, z_i , for 12 barn med spiseforstyrrelser.

Vekt, y_i	Høyde, x_i	Alder, z_i
23.9	1.44	8
26.5	1.50	10
19.8	1.24	6
$\vdots$		$\vdots$
28.3	1.55	12
25.4	1.45	9

Her er vekt respons, og høyde og alder er uavhengige variable. Betrakt først situasjonen der sammenhengen mellom vekt og høyde beskrives med en enkel lineær regresjonsmodell:

$$Y_i = \beta_0 + \beta_1 x_i + e_i, i = 1, \dots, 12.$$

- a) Forklar hvilke forutsetninger en slik modell bygger på. Hvilke egenskaper til estimatorene for parametrene β_0 og β_1 kan utledes av det som i læreboka kalles "standard statistisk modell", det vil si uten å anta at feilleddene $e_1, \dots, e_{12}$ er normalfordelte?
- b) Finn et estimat for β_1 og bestem et 95% konfidensintervall for β_1 . Her kan du bruke at $\sum_{i=1}^{12} y_i = 280.869$, $\sum_{i=1}^{12} x_i = 16.078$, $\sum_{i=1}^{12} x_i^2 = 21.873$ og $\sum_{i=1}^{12} x_i y_i = 381.526$. Residual kvadratsum er $RSS_1 = \sum_{i=1}^{12} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 = 41.645$, der $\hat{\beta}_0$ og $\hat{\beta}_1$ er estimer for parametrene β_0 og β_1 .

En lineær regresjonsmodell uten konstantledd der høyde og alder er uavhengige variable kan formuleres som

$$Y_i = \alpha_1 x_i + \alpha_2 z_i + e_i, i = 1, \dots, 12.$$

(Fortsettes side 3.)

- c) Forklar hvordan modellen kan uttrykkes på matriseform,

$$\mathbf{Y} = \mathbf{X}\alpha + \mathbf{e},$$

der $\mathbf{X}$ er en matrise av kjente tall og $\mathbf{Y}$ og $\mathbf{e}$ er vektorer av tilfeldige variable.

- d) Finn et estimat for α_2 . Her kan du i tillegg til de størrelsene som er oppgitt i punkt b), bruke at $\sum_{i=1}^{12} z_i^2 = 976$, $\sum_{i=1}^{12} x_i z_i = 144.247$ og $\sum_{i=1}^{12} z_i y_i = 2534.908$. Du kan også trenge

$$\begin{pmatrix} 21.873 & 144.247 \\ 144.247 & 976.0 \end{pmatrix}^{-1} = \begin{pmatrix} 1.804 & -0.267 \\ -0.267 & 0.040 \end{pmatrix}.$$

Residual kvadratsum er $RSS_2 = \sum_{i=1}^{12} (y_i - \hat{\alpha}_1 x_i - \hat{\alpha}_2 z_i)^2 = 28.3$, der $\hat{\alpha}_1$ og $\hat{\alpha}_2$ er estimater for koeffesientene α_1 and α_2 . Hva blir den estimerte standardfeilen til estimatoren for α_2 ?

Oppgave 3.

Tabellen nedenfor viser antall ulykker per måned på en bestemt veistrekning i løpet av en 20-måneders periode. I 9 av månedene var det altså ingen ulykker, i 7 av månedene var det en ulykke osv.

Table 2: Antall ulykker per måned i en periode på 20 måneder.

Antall ulykker	Antall måneder
0	9
1	7
2	3
3	1

En rimelig modell i denne situasjonen er at antall ulykker antas å være realisasjoner av uavhengige Poisson fordelte variable $X_1, \dots, X_{20}$ med samme punktsannsynlighet

$$P(X = x) = \frac{\lambda^x}{x!} \exp(-\lambda), \quad x = 0, 1, \dots$$

- a) Finn moment- og sannsynlighetsmaksimeringsestimatoren til λ . Beregn estimatene ved å bruke observasjonene fra tabellen i begynnelsen av oppgaven.

(Fortsettes side 4.)

- b) Utled et tilnærmet 95% konfidensintervall for λ . Beregn intervallet på grunnlag av observasjonene i tabellen.

Se nå på en situasjon der en bare bruker opplysninger om det har funnet sted ulykker i hver av de 20 månedene eller ikke. La $Y_i = 1$ hvis $X_i = 0$ og $Y_i = 0$ ellers. Da er $Y = \sum_{i=1}^{20} Y_i$ antallet ulykkesfrie måneder.

- c) Begrunn at antallet måneder der det ikke skjer ulykker, det vil si Y , er binomisk fordelt og angi punktsannsynligheten til Y . Bestem moment- og sannsynlighetsmaksimeringsestimatoren til λ i dette tilfellet. Hva blir estimatene?
- d) Utled og beregn et tilnærmet 95% konfidensintervall for λ på grunnlag av antall ulykkesfrie måneder.

SLUTT

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse 1.

Eksamensdag: Onsdag 5. desember 2007.

Tid for eksamen: 9.00 – 12.00.

Oppgavesettet er på 4 sider.

Vedlegg: Tabell for t -fordelingen.

Tillatte hjelpemidler: Godkjent lommeregner og Formelsamling for STK1100 og STK1110.

Kontroller at oppgavesettet er komplett før du begynner å besvare spørsmålene.

Oppgave 1.

I USA er Thanksgiving Day, som feires den fjerde torsdagen i november, en nasjonal høytidsdag. På denne dagen spises det tradisjonelt kalkun som festmat. Tabell 1 gir vekten (i pund) for tilfeldig valgte Thanksgiving-kalkuner fra to delstater i USA.

Tabell 1: Slaktevekt for kalkuner fra to delstater i USA.

Delstat	Virginia	Wisconsin
Vekt	13.1	11.5
(i pund)	12.4	14.2
	13.2	15.4
	11.8	13.1
		13.8
Gjennomsnitt	12.625	13.600
Empirisk standardavvik	0.655	1.440

Vi lar μ_1 være forventet vekt for en tilfeldig valgt kalkun fra Virginia, mens μ_2 er forventet vekt for en tilfeldig valgt kalkun fra Wisconsin.

(Fortsettes side 2.)

- a) Bestem et 90% konfidensintervall for $\mu_2 - \mu_1$ og diskuter hva intervallet sier deg. Beskriv hvilke forutsetninger konfidensintervallet bygger på.
- b) Angi en test med signifikansnivå 5% for nullhypotesen $H_0 : \mu_1 = \mu_2$ mot den alternative hypotesen $H_1 : \mu_1 \neq \mu_2$. Hva blir konklusjonen av testen?
- c) Forklar hva vi mener med P -verdien til en test. Bestem (så godt du kan) P -verdien for testen i punkt b.

Oppgave 2.

Thanksgiving-kalkunene i oppgave 1 var ikke like gamle da de ble slaktet. Tabell 2 viser kalkunenes alder (i uker) ved slakting. For oversiktens skyld gir vi også slaktevektene i tabellen.

Tabell 2: Slaktevekt og slaktealder for kalkuner.

Virginia		Wisconsin	
Alder	Vekt	Alder	Vekt
29	13.1	21	11.5
27	12.4	27	14.2
28	13.2	29	15.4
26	11.8	23	13.1
		25	13.8

- a) Plott vekten av kalkunene mot alderen ved slakting. Utfør plottingen i ett diagram, men benytt forskjellige symboler for de to delstatene. Kommenter plottet.

For å studere hvilken betydning delstat og alder har for slaktevekten til kalkunene, setter vi opp regresjonsmodellen

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + e_i. \quad (1)$$

I modellen (1) er:

- Y_i slaktevekten til kalkun nummer i (fra begge delstatene sett under ett),
- x_{i1} alderen ved slakting til kalkun nummer i ,
- $x_{i2} = 1$ hvis kalkun nummer i er fra Wisconsin, $x_{i2} = 0$ hvis kalkun nummer i er fra Virginia.

(Fortsettes side 3.)

- b) Gi en fortolkning av parametrene β_1 og β_2 i regresjonsmodellen (1), og beskriv hvilke forutsetninger regresjonsmodellen bygger på. Syns du modellformuleringen (1) virker rimelig i lys av plottet i punkt a?

Ut fra tallene i tabell 2 finner vi at minste kvadraters estimerer er $\hat{\beta}_0 = 0.311$, $\hat{\beta}_1 = 0.448$ og $\hat{\beta}_2 = 2.094$, og at estimert standardfeil til $\hat{\beta}_2$ er $S_{\hat{\beta}_2} = 0.235$. (Du skal *ikke* vise dette.)

- c) Angi en test med signifikansnivå 5% for nullhypotesen $H_0 : \beta_2 = 0$ mot den alternative hypotesen $H_1 : \beta_2 \neq 0$. Hva blir konklusjonen av testen? Kommenter resultatet i lys av testen i punkt b i oppgave 1.

Ut fra tallene i tabell 2 har vi at residualkvadratsummen er

$$RSS = \sum_{i=1}^9 \left(Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} \right)^2 = 0.5648.$$

Vi innfører 9×3 matrisen

$$\mathbf{X} = \begin{pmatrix} 1 & 29 & 0 \\ 1 & 27 & 0 \\ 1 & 28 & 0 \\ 1 & 26 & 0 \\ 1 & 21 & 1 \\ 1 & 27 & 1 \\ 1 & 29 & 1 \\ 1 & 23 & 1 \\ 1 & 25 & 1 \end{pmatrix}$$

Da er

$$(\mathbf{X}^T \mathbf{X})^{-1} = \begin{pmatrix} 17.06 & -0.611 & -1.778 \\ -0.611 & 0.0222 & 0.0556 \\ -1.778 & 0.0556 & 0.589 \end{pmatrix}$$

- d) Finn den estimerte standardfeilen $S_{\hat{\beta}_1}$ til $\hat{\beta}_1$ og bestem et 95 % konfidensintervall for β_1 . Forklar hva intervallet sier deg.

Oppgave 3.

En bedrift produserer lysstoffrør. Levetiden (i timer) av et tilfeldig valgt lysstoffrør antas å være en stokastisk variabel med sannsynlighetstetthet

$$f(y | \theta) = \begin{cases} \frac{y}{\theta} e^{-y^2/2\theta} & \text{for } y > 0 \\ 0 & \text{ellers} \end{cases} \quad (2)$$

der $\theta > 0$.

(Fortsettes side 4.)

- a) La $F(y|\theta)$ være den kumulative fordelingsfunksjonen som svarer til sannsynlighetstettheten (2). Medianen $y_{0.50}$ er gitt ved at $F(y_{0.50}|\theta) = 0.50$. Vis at $y_{0.50} = \sqrt{2\theta} \log 2$. (Her står “log” for den naturlige logaritmen.)

Bedriften ønsker å studere levetiden til lysstoffrørene. For å gjøre det, observerer de levetidene $Y_1, Y_2, \dots, Y_{20}$ for 20 tilfeldig valgte lysstoffrør. Vi antar at $Y_1, Y_2, \dots, Y_{20}$ er uavhengige og identisk fordelte med sannsynlighetstetthet gitt ved (2).

- b) Vis at maksimum likelihood estimatoren $\hat{\theta}$ er gitt ved $\hat{\theta} = \frac{1}{40} \sum_{i=1}^{20} Y_i^2$.
- c) Bedriften ønsker å teste nullhypotesen at median levetid er høyst 1000 timer mot alternativet at den er mer enn 1000 timer. Vis at det er det samme som å teste

$$H_0 : \theta \leq \theta_0 \quad \text{mot} \quad H_1 : \theta > \theta_0$$

der $\theta_0 = 10^6/(2 \log 2)$.

- d) En rimelig test forkaster H_0 hvis $\hat{\theta} > k$. Bestem k slik at testen får signifikansnivå 5%. (*Vink:* En kan vise at $\frac{1}{\theta} \sum_{i=1}^{20} Y_i^2$ er χ^2 -kvadratfordelt med 40 frihetsgrader. Du kan bruke dette resultatet uten å vise det. Utvalgte fraktiler i χ^2 -kvadratfordelingen med 40 frihetsgrader er gitt i tabell 3 nedenfor.)
- e) Bestem (så godt du kan) styrken for testen i punkt d hvis median levetid er 1250 timer. Hva blir da sannsynligheten for feil av type II?

Tabell 3: Fraktiler for χ^2 -kvadratfordelingen med 40 frihetsgrader.

p	0.025	0.05	0.10	0.20	0.30	0.40	0.50
χ_p^2	24.43	26.51	29.05	32.34	34.87	37.13	39.33
p	0.60	0.70	0.80	0.90	0.95	0.975	
χ_p^2	41.62	44.16	47.27	51.81	55.76	59.34	

SLUTT

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder
og dataanalyse 1.

Eksamensdag: Tirsdag 5. desember 2006.

Tid for eksamen: 15.30 – 18.30.

Oppgavesettet er på 3 sider.

Vedlegg: Tabell for normalfordeling, tabell
for t -fordeling.

Tillatte hjelpemidler: Godkjent lommeregner og Formel-
samling for STK1100 og STK1110.

Kontroller at oppgavesettet er komplett
før du begynner å besvare spørsmålene.

Oppgave 1.

- a) Forklar hva som menes med at en estimator er forventningsrett og at den er konsistent.

I resten av oppgaven er $X \sim \text{bin}(n, p)$ og $\hat{p} = \frac{X}{n}$.

- b) Forklar hvorfor $\hat{p}$ er forventningsrett og konsistent.
- c) La $\theta = p(1 - p)$. En rimelig estimator for θ er $\hat{\theta} = \hat{p}(1 - \hat{p})$. Er den forventningsrett? Hvis svaret er nei, foreslå en modifikasjon av $\hat{\theta}$ som er det.

(Fortsettes side 2.)

Oppgave 2.

Anta at $X_1, X_2, \dots, X_n$ er uavhengige og identisk fordelte med tetthet

$$f(x|\sigma) = \frac{1}{2\sigma} \exp(-|x|/\sigma), \quad -\infty < x < \infty$$

- Bestem sannsynlighetsmaksimeringsestimatoren, $\hat{\sigma}$, for σ . Finn $E(\hat{\sigma})$.
- Vis at sannsynlighetsmaksimeringsestimatoren $\hat{\sigma}$ er tilnærmet $N(\sigma, \sigma^2/n)$ når antallet observasjoner, n , er stort.
- Forklar hvorfor både intervaller av formen

$$(\hat{\sigma} - z_{1-\alpha/2} \hat{\sigma}/\sqrt{n}, \hat{\sigma} + z_{1-\alpha/2} \hat{\sigma}/\sqrt{n})$$

og

$$\left(\frac{\hat{\sigma}}{(z_{1-\frac{\alpha}{2}}/\sqrt{n}) + 1}, \frac{\hat{\sigma}}{-(z_{1-\frac{\alpha}{2}}/\sqrt{n}) + 1} \right)$$

er konfidensintervaller med tilnærmet konfidenskoeffisient $1 - \alpha$ når antallet observasjoner er stort. Her er $z_{1-\frac{\alpha}{2}}$, $1 - \alpha/2$ kvantilen i standardnormalfordelingen $N(0, 1)$.

Oppgave 3.

Dataene nedenfor er et utsnitt av 17 årlige målinger av prosentandel snøinnhold, x_i , 1. april og gjennomsnittlig vannføring om våren, y_i , målt i tommer i en elv i USA.

i	x_i	y_i
1	23.1	10.5
2	32.8	16.7
$\vdots$	$\vdots$	$\vdots$
16	21.1	10.5
17	27.6	16.1

Her er $\sum_{i=1}^{17} x_i = 511.5$, $\sum_{i=1}^{17} y_i = 267.1$, $\sum_{i=1}^{17} x_i^2 = 16628.7$, $\sum_{i=1}^{17} y_i^2 = 4549.43$
 og $\sum_{i=1}^{17} x_i y_i = 8653.45$.

(Fortsettes side 3.)

La vannføring være responsvariabel. Vi antar følgende lineære regresjonsmodell

$$Y_i = \beta_0 + \beta_1 x_i + \epsilon_i \quad i = 1, \dots, 17$$

der $\epsilon_1, \dots, \epsilon_{17}$ er uavhengige $N(0, \sigma^2)$ -fordelte variable.

- a) Beregn minste kvadraters estimatene $\hat{\beta}_0$ og $\hat{\beta}_1$ for dataene ovenfor og skisser den tilpassede regresjonslinja.
- b) Du skal også tilpasse en modell uten konstantledd, dvs.

$$Y_i = \gamma x_i + \eta_i$$

der $\eta_1, \dots, \eta_{17}$ er uavhengige $N(0, \tau^2)$ -fordelte variable.

Finn minste kvadraters estimatoren $\hat{\gamma}$. Beregn estimatet for γ i dataene ovenfor og skisser også denne regresjonslinja i samme diagram som regresjonslinja fra punkt a).

- c) Forklar hvorfor estimatoren $\hat{\beta}_0$ er normalfordelt. Hvordan kan nullhypotesen

$$H_0 : \beta_0 = 0 \quad \text{mot} \quad H_A : \beta_0 \neq 0$$

testes? Angi en øvre og nedre grense for p -verdien. Kommenter resultatet av testen i lys av resultatene du fant i punkt a) og b).

Her kan du bruke at kvadratsummen av residualene $RSS = 45.56$ og uttrykket for $\text{Var}(\hat{\beta}_0)$ fra formelsamlingen.

Oppgave 4.

En logistisk fordelt variabel har kumulativ fordelingsfunksjon

$$F(x) = \frac{1}{1 + e^{-x}}, \quad -\infty < x < \infty.$$

Forklar hvordan man beregner et $Q-Q$ plott for sammenligning av den kumulative fordelingsfunksjonen Φ til en $N(0, 1)$ -fordelt variabel og F gitt ovenfor. Angi verdiene som svarer til kvartilene og 0.1 og 0.9 kvantilene, dvs. verdiene for $p = 0.1, 0.25, 0.5, 0.75$ og 0.9. Skisser plottet og kommenter utseendet.

SLUTT

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse 1.

Eksamensdag: Mandag 5. desember 2005.

Tid for eksamen: 09.00 – 12.00.

Oppgavesettet er på 3 sider.

Vedlegg: Tabell for normalfordeling, tabell for t -fordeling.

Tillatte hjelpemidler: Godkjent lommeregner og Formelsamling for STK1100 og STK1110.

Kontroller at oppgavesettet er komplett før du begynner å besvare spørsmålene.

Oppgave 1.

- a) Forklar hvordan en t -fordeling er definert i læreboka.
- b) Anta at $X_1, \dots, X_n$ er uavhengige og identisk fordelte tilfeldige variable som er $N(\mu, \sigma^2)$. Forklar hvorfor variabelen

$$\frac{\sqrt{n}(\bar{X} - \mu)}{S}$$

er t -fordelt med $n - 1$ frihetsgrader. Her er $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

og $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$. Du kan her bruke kjente resultater om fordelingen til $\bar{X}$ og S^2 .

(Fortsettes side 2.)

Oppgave 2.

La $X_1, \dots, X_n$ være uavhengige og identisk fordelte variable som er Poisson fordelte med forventning λ .

- Begrunn at gjennomsnittet, $\hat{\lambda} = \bar{X}$, er estimatoren for λ som følger både fra moment- og sannsynlighetsmaksimeringsprinsippet.
- Finn $E(\hat{\lambda})$ og $\text{Var}(\hat{\lambda})$ og vis at $\hat{\lambda}$ er konsistent.

På en bestemt veistrekning er de årlige tallene for antall ulykker med personskaide i en femårsperiode

1 2 2 2 1 .

Anta i det følgende at dataene kan ses som realisasjon av uavhengige Poisson fordelte variable.

- Vi ønsker å teste

$$H_0 : \lambda = 1 \quad \text{mot} \quad H_A : \lambda > 1$$

og bruker en test av formen: Forkast H_0 hvis $\hat{\lambda} = \frac{1}{5} \sum_{i=1}^5 X_i > k$.

Hvorfor er det en rimelig test?

Nedenfor finner du en tabell over den kumulative fordelingsfunksjonen til en Poisson fordelt variabel med forventning 5.

x	0	1	2	3	4	5	6	7	8
$P(X \leq x)$	0.0067	0.0404	0.1247	0.2650	0.4405	0.6160	0.7622	0.8666	0.9319

	9	10	11	12	13	14	15	16
	0.9682	0.9863	0.9945	0.9980	0.9993	0.9998	0.9999	1.0000

Forklar hvordan man bestemmer k slik at testen får nivå $\alpha = 0.05$.
(Hint: Husk at summen av uavhengige Poisson fordelte variable er Poisson fordelt.)

- Gir dataene ovenfor forkastning av H_0 ? Hva er p -verdien til testen?
- Bruk normaltilnærmelsen fra sentralgrenseteoremet til å beregne den tilnærmede styrken for $\lambda = 3$.

(Fortsettes side 3.)

Oppgave 3.

I to vulkanutbrudd tas det henholdsvis 12 og 10 målinger for å bestemme andelen hydrogen i gassen fra utbruddene. Målingene fra de to utbruddene er sammenfattet i følgende tabell.

	antall	gjennomsnitt	empirisk varians
Vulkan A:	$n = 12$	$\bar{x} = 47.5$	$s_X^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = (5.2)^2$
Vulkan B:	$m = 10$	$\bar{y} = 46.7$	$s_Y^2 = \frac{1}{m-1} \sum_{i=1}^m (y_i - \bar{y})^2 = (6.7)^2$

Vi antar at målingene kan oppfattes som to uavhengige utvalg fra populasjoner med fordeling $N(\mu_X, \sigma^2)$ og $N(\mu_Y, \sigma^2)$ henholdsvis. Parametrene μ_X, μ_Y og σ^2 er ukjente.

- Utled et 95% konfidensintervall for $\mu_X - \mu_Y$. Regn ut konfidensintervallet for dataene i begynnelsen av oppgaven. Forklar hvordan resultatet skal tolkes.
Er det grunnlag for å forkaste hypotesen $H_0 : \mu_X = \mu_Y$ mot $H_A : \mu_X \neq \mu_Y$ når nivået er $\alpha = 0.05$?
- Hva er den forventede lengden av konfidensintervallet? Hvis det totale antallet målinger, $N = m + n$, er gitt, hvilke valg av m og n gir det korteste konfidensintervallet?

Oppgave 4.

La $X_1, X_2, \dots, X_n$ være uavhengige og identisk fordelte tilfeldige variable med tetthet

$$f_X(x) = \begin{cases} \exp(-(x - \theta)) & x > \theta \\ 0 & \text{ellers} \end{cases}$$

der θ er en ukjent parameter.

- Finn sannsynlighetsmaksimeringsestimatoren $\hat{\theta}$, til θ .
- Hva er tettheten i fordelingen til estimatoren $\hat{\theta}$?

SLUTT

UNIVERSITETET I OSLO

Matematisk Institutt

EKSAMEN I: **STK 1110 – Statistiske metoder og dataanalyse 1**
Avsluttende eksamen
TID FOR EKSAMEN: **Mandag 6. desember 2004, kl. 9:00–12:00**
HJELPEMIDLER: **«Formelsamling til STK 1100 og STK 1110»,
kalkulator**

Dette oppgavesettet utgjør den andre av kursets to eksamener. Det inneholder fire oppgaver og er på tre sider. Kursets første eksamen ble arrangert 14. oktober d.å.

Oppgave 1

VI SKAL UT PÅ TUR i en homogen Poisson-skog. Trærne (av den bestemte typen *Tsuga Canadensis*) er fordelt slik at (a) antall trær $N(A)$ innenfor et område A med areal $\text{ar}(A)$ (målt i kvadratmeter) er Poisson-fordelt med parameter $\lambda \text{ar}(A)$; (b) antall trær $N(A)$ og $N(B)$ innenfor ikke-overlappende områder A og B er stokastisk uavhengige. Her er λ en ukjent parameter som altså svarer til den gjennomsnittlige tre-tettheten pr. kvadratmeter.

- (a) Fra et vilkårlig utgangspunkt i skogen, la A være en sirkel med radius y . Hva er sjansen for at det skal være nøyaktig tre trær innenfor A ? Og hva er sjansen for at det ikke skal være noen trær der?
- (b) La Y være distansen fra dette utgangspunktet til nærmeste tre. Vis at Y har sannsynlighetstetthet

$$f(y, \lambda) = e^{-\lambda\pi y^2} 2\lambda\pi y \quad \text{for } y > 0.$$

- (c) I dette punktet kan du benytte deg av formlene

$$\int_0^\infty y^2 e^{-cy^2} dy = \frac{\sqrt{\pi}}{4c\sqrt{c}} \quad \text{og} \quad \int_0^\infty y^3 e^{-cy^2} dy = \frac{1}{2c^2},$$

som holder for c positiv. Vis at

$$EY = \frac{\frac{1}{2}}{\sqrt{\lambda}},$$

og finn dessuten variansen til Y .

- (d) I tillegg til Y , distansen fra utgangspunktet til det nærmeste tre, kan man observere Z , distansen fra utgangspunktet til det nest nærmeste tre. Finn en formel for sannsynlighetstettheten til Z .

Oppgave 2

OG HVOR MANGE TRÆR (av denne bestemte typen) er det i skogen? Man velger via et kart n forskjellige startsteder i skogen, alle nøyaktig spesifiserte, og fra hver av disse måler man distansen til det nærmeste tre. Dette gir målingene $Y_1, \dots, Y_n$.

- (a) I det følgende skal du anta at $Y_1, \dots, Y_n$ er uavhengige med den samme sannsynlighetstetthet, nemlig den $f(y, \lambda)$ du fant i Oppgave 1(b). Diskuter kort om disse antagelsene synes rimelige eller ikke.
- (b) Gjennomsnittet $\bar{Y}_n = \frac{1}{n} \sum_{i=1}^n Y_i$ vil konvergere i sannsynlighet når n vokser. Mot hvilken grense? Begrunn svaret.
- (c) Finn momentestimatoren for λ , og kall den λ^* . Vis at den er konsistent, altså at λ^* konvergerer i sannsynlighet mot λ når n vokser.
- (d) Vis så at ML-estimatoren (maximum likelihood-estimatoren, eller rimelighetsfunksjonsmaksimeringsestimatoren) blir

$$\hat{\lambda} = \frac{1}{\pi} \frac{1}{W_n}, \quad \text{der } W_n = \frac{1}{n} \sum_{i=1}^n Y_i^2.$$

- (e) Man foretok $n = 25$ slike målinger, og fant disse tallene, i meter:

9.55	4.92	7.85	1.27	2.91	3.77	2.94	3.39
4.29	4.14	6.13	0.16	4.94	5.59	2.53	9.16
6.71	4.42	2.64	7.66	0.85	2.21	1.38	0.94
						2.70	

For disse målingene finner man (blant annet)

$$\frac{1}{n} \sum_{i=1}^n Y_i = 4.122, \quad \frac{1}{n} \sum_{i=1}^n Y_i^2 = 23.458, \quad \text{empirisk standardavvik } 2.596.$$

Din oppgave nå er å lage et konfidensintervall for λ med konfidensgrad tilnærmet 95%.

Oppgave 3

EN BIOLOG UNDERSØKER 300 KANINER, og klassifiserer hver av dem i bestemte kategorier 1, 2, 3. Hun har en genetisk-biologisk hypotese som etter noe sannsynlighetsberegning kan formuleres som at sannsynlighetene for at kaninene skal være av type 1, type 2, type 3 kan uttrykkes som

$$p_1 = \theta^2, \quad p_2 = 2\theta(1 - \theta), \quad p_3 = (1 - \theta)^2,$$

for en passende parameter θ . Av hennes 300 kaniner viser $N_1 = 10$ seg å være av type 1, $N_2 = 80$ av type 2, og $N_3 = 210$ av type 3. Hun vil gjerne teste sin teori.

- (a) Forklar kort de forutsetninger som skal til for at likelihoodfunksjonen for data, under hennes modell, blir

$$L(\theta) = \frac{300!}{10!80!210!} p_1(\theta)^{10} p_2(\theta)^{80} p_3(\theta)^{210}.$$

Anta i det følgende at disse betingelser er oppfylt.

- (b) Finn et estimat for θ .
(c) Bruk data til å teste om modellen hennes holder.

Oppgave 4

ER MIN FORVENTNING NULL, eller er den ikke? Vi skal se på den ganske enkle modellen der $Y_1, \dots, Y_{100}$ er uavhengige observasjoner fra den samme normalfordelingen $N(\theta, 1)$, og der man altså vil teste $H_0: \theta = 0$ mot alternativet at $\theta \neq 0$.

- (a) Sett opp likelihoodfunksjonen $L_{100}(\theta)$ for modellen, og vis at ML-estimatoren under a priori-omstendigheter er $\hat{\theta} = \bar{Y}_{100}$, gjennomsnittet av observasjonene.
(b) Sett opp et generelt uttrykk for GLR_{100} , den generaliserte likelihood-ratio-testen for H_0 , og finn en så enkel formel for

$$Z_{100} = -2 \log \text{GLR}_{100},$$

i denne situasjonen, som mulig.

- (c) Hva sier den generelle teorien fra pensum om fordelingen til $Z_n = -2 \log \text{GLR}_n$, når n vokser? Hvordan fungerer dette approksimasjonsresultatet for situasjonen i denne oppgaven?
(d) Anta denne testen basert på Z_{100} blir brukt til å teste $H_0: \theta = 0$, med forkastningsgrense svarende til at testens nivå blir 0.05. Forklar hvordan man kan beregne sannsynligheten for at testen faktisk forkaster H_0 , når den virkelige θ er lik 0.33.

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse - **Løsningsforslag**
Eksamensdag: 4. desember - 2024
Tid for eksamen: 15.00–19.00.
Oppgavesettet er på 4 sider.
Vedlegg: Ingen
Tillatte hjelpemidler: Godkjent kalkulator
Formelsamling for STK1110

Kontroller at oppgavesettet er komplett før
du begynner å besvare spørsmålene.

Oppgave 1

(a) En finner momentestimatoren ved å løse ligningen $\bar{X} = \frac{\tilde{\alpha}}{\tilde{\alpha}+1}$ hvilket gir $\tilde{\alpha} = \frac{\bar{X}}{1-\bar{X}}$.

(b) For $Y_{ri} = X_i^r$ blir ligningen $\bar{Y}_r = \frac{\tilde{\alpha}_r}{\tilde{\alpha}_r+r}$ hvilket gir $\tilde{\alpha}_r = \frac{r\bar{Y}_r}{1-\bar{Y}_r} = \frac{r \sum_{i=1}^n X_i^r}{n - \sum_{i=1}^n X_i^r}$

Det er altså ikke en entydig momentestimator for α når vi betrakter ulike $Y_{ir} = X_i^r$ og det uklart hvilken av disse estimatorene som er best (minst varians, f.eks.)

(c) Likelihooden for X_i -ene blir $L(\alpha) = \prod_{i=1}^n \alpha X_i^{\alpha-1} = \alpha^n (\prod_{i=1}^n X_i)^{\alpha-1}$.

Dermed får vi log-likelihood $l(\alpha) = n \ln(\alpha) + (\alpha - 1) \sum_{i=1}^n \ln(X_i)$ som har derivert

$$l'(\alpha) = \frac{n}{\alpha} + \sum_{i=1}^n \ln(X_i)$$

Ved å løse $l'(\hat{\alpha}) = 0$ finner vi maximum likelihood estimatoren (MLE) $\hat{\alpha} = \frac{n}{-\sum_{i=1}^n \ln(X_i)}$ for α . Man sjekker at dette er et (entydig) maksimum ved at $l''(\alpha) < 0$ for alle α (se neste punkt).

(d) Når n er tilstrekkelig stor er MLE $\hat{\alpha}$ tilnærmet normalfordelt med forventning α og varians gitt som invers av forventet informasjon $I_n(\alpha)$ for hele datasettet $X_1, X_2, \dots, X_n$. Vi finner denne informasjonen som

$$I_n(\alpha) = -E(l''(\alpha)) = -E\left(-\frac{n}{\alpha^2}\right) = \frac{n}{\alpha^2}$$

altså blir variansen i den tilnærmede fordelingen for $\hat{\alpha}$ lik $1/I_n(\alpha) = \frac{\alpha^2}{n}$

(Fortsettes på side 2.)

(e) Vi har

$$0.95 \approx P(-1.96 < Z = \frac{\hat{\alpha} - \alpha}{\hat{\alpha}/\sqrt{n}} < 1.96) = P(\hat{\alpha} - 1.96\hat{\alpha}/\sqrt{n} < \alpha < \hat{\alpha} + 1.96\hat{\alpha}/\sqrt{n})$$

Dermed blir $\hat{\alpha} \pm 1.96\hat{\alpha}/\sqrt{n}$ et tilnærmet 95% konfidensintervall for α .

Med $n = 20$ og $\sum_{i=1}^n \ln(X_i) = -9.82$ blir $\hat{\alpha} = \frac{20}{9.82} = 2.03$.

Dette gir at 95% konfidensintervallet $2.03 \pm 1.96 * 2.03/\sqrt{20} = [1.14, 2.93]$

(f) Man kan gi konklusjonen på en tosidig test som $H_0 : \alpha = 1$ mot $H_0 : \alpha \neq 1$ med angitt nivå ved å sjekke om $\alpha = 1$ er innenfor intervallet.

I vårt tilfelle er $\alpha = 1$ ikke innenfor intervallet og vi forkaster da nullhypotesen på 5% nivå (siden vi sjekket med et 95% intervall).

For at et tilsvarende konfidensintervall skal inneholde $\alpha = 1$ må vi ha $\hat{\alpha} - z\hat{\alpha}/\sqrt{20} = 1$ for egnet kvantil z i $N(0, 1)$, dvs. at vi må ha $z = (\hat{\alpha} - 1)\sqrt{20}/\hat{\alpha} = 2.28$. Fra tabellen finner vi da at P-verdien ligger i intervallet $[0.02, 0.03]$ siden testen er to-sidig.

Sannsynlighet	0.001	0.005	0.010	0.015	0.020	0.025	0.050	0.100	0.200
Kvantil q_γ	-3.09	-2.58	-2.33	-2.17	-2.05	-1.96	-1.64	-1.28	-0.84

Oppgave 2

(a) Vi har at $E(Y_i) = \beta_0 + \beta_1 x_i$ og dermed dessuten at $E(\bar{Y}) = \beta_0 + \beta_1 \bar{x}$. Da får vi videre at

$$\begin{aligned} E(\hat{\beta}_1) &= \frac{\sum_{i=1}^n (x_i - \bar{x}) E(Y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ &= \frac{\sum_{i=1}^n (x_i - \bar{x}) (\beta_0 + \beta_1 x_i - \beta_0 - \beta_1 \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ &= \frac{\beta_1 \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \beta_1 \end{aligned}$$

og $\hat{\beta}_1$ er altså forventningsrett for β_1 .

Fra den andre representasjonen $\hat{\beta}_1 = \frac{\sum_{i=1}^n Y_i (x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$ fås at

$$V(\hat{\beta}_1) = \frac{\sum_{i=1}^n (x_i - \bar{x})^2 V(Y_i)}{(\sum_{i=1}^n (x_i - \bar{x})^2)^2} = \frac{\sigma^2 \sum_{i=1}^n (x_i - \bar{x})^2}{(\sum_{i=1}^n (x_i - \bar{x})^2)^2} = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

(b) Modellens estimerte parametre er $\hat{\beta}_0 = -2.29$, $\hat{\beta}_1 = 0.0314$ og $\hat{\sigma} = 0.197$. Dette betyr at når høyden endres med 1 cm så endres forventet FVC med 0.0314. Hvis vi ekstrapolerer til høyde = 0 cm (ikke så realistisk) så predikerer modellen en negativ (-2.29) forventet FVC (heller ikke spesielt realistisk). Standardavviket σ til Y_i -ene estimeres med $\hat{\sigma} = 0.197$.

t-verdien for høyde beregnes som $t_1 = \hat{\beta}_1 / se_1 = 29.74$ der $se_1 = \hat{\sigma} / \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} = 0.001057$. Under nullhypotesen $H_0 : \beta_1 = 0$ skal denne være trukket fra en t-fordeling


(Fortsettes på side 3.)

med $598=600-2$ frihetsgrader. En så stor t-verdi gir en soleklar forkastning på H_0 også med tosidig alternativ $H_a : \beta_1 \neq 0$.

(c) Tilpassede (predikerte) verdier $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ og residualene $e_i = y_i - \hat{y}_i$. For å sjekke modellantagelsene grafisk lager vi gjerne

- spredningsplott av $(\hat{y}_i, e_i)$: Hvis man ser trender som først positive, deretter negative og tilslutt positive residualer (evt. omvendt) tyder det på ikke-linearitet
- spredningsplott $(\hat{y}_i, |e_i|^{0.5})$: Hvis man f.eks. ser en økende (avtagende) trend i disse tyder det på ikke-konstant varians
- qq-plot over sorterte e_i mot kvantiler i $N(0, 1)$: Hvis disse ikke avtegner en rett linje tyder dette på avvik fra normalitet

Her er det få problemer med modellantagelsene, plottene er omtrent som man ønsker, men en kan ane en svak ikke-linearitet ved linja gjennom det første plottet. Muligens er det også litt mindre varians for de aller minste predikerte verdiene, men neppe grunn til bekymring for om at variansestimater er rimelige.



(d) Vi finner estimerte regresjonsparametre ved å partiellderivere kvadratsummen $g(b_0, b_1, b_2) = \sum_{i=1}^n (Y_i - b_0 - b_1 x_{i1} - b_2 x_{i2})^2$ mhp hhv b_0, b_1, b_2 og løse ligningene der disse er satt lik null. De partiellderivate blir

$$\frac{\partial g(b_0, b_1, b_2)}{\partial b_0} = -2 \sum_{i=1}^n (Y_i - b_0 - b_1 x_{i1} - b_2 x_{i2})$$

$$\frac{\partial g(b_0, b_1, b_2)}{\partial b_1} = -2 \sum_{i=1}^n (Y_i - b_0 - b_1 x_{i1} - b_2 x_{i2}) x_{i1}$$

$$\frac{\partial g(b_0, b_1, b_2)}{\partial b_2} = -2 \sum_{i=1}^n (Y_i - b_0 - b_1 x_{i1} - b_2 x_{i2}) x_{i2}$$

Dette gir da tre lineære ligninger med tre ukjente $\hat{\beta}_0, \hat{\beta}_1$ og $\hat{\beta}_2$

$$\sum_{i=1}^n Y_i = n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_{i1} + \hat{\beta}_2 \sum_{i=1}^n x_{i2}$$

$$\sum_{i=1}^n Y_i x_{i1} = \hat{\beta}_0 \sum_{i=1}^n x_{i1} + \hat{\beta}_1 \sum_{i=1}^n x_{i1}^2 + \hat{\beta}_2 \sum_{i=1}^n x_{i2} x_{i1}$$

$$\sum_{i=1}^n Y_i x_{i2} = \hat{\beta}_0 \sum_{i=1}^n x_{i2} + \hat{\beta}_1 \sum_{i=1}^n x_{i1} x_{i2} + \hat{\beta}_2 \sum_{i=1}^n x_{i2}^2$$

(Fortsettes på side 4.)

Med vektoren av responser $Y = (Y_1, Y_2, \dots, Y_n)'$ og designmatrisen

$$X = \begin{bmatrix} 1 & x_{11} & x_{12} \\ 1 & x_{21} & x_{22} \\ 1 & x_{31} & x_{32} \\ \dots & \dots & \dots \\ 1 & x_{n1} & x_{n2} \end{bmatrix}$$

kan vi skrive om disse ligningene til matriseformen $X'X\hat{\beta} = X'Y$ som har løsning $\hat{\beta} = (X'X)^{-1}X'Y$.

For at denne løsningen skal være entydig må $X'X$ være inverterbare som er det samme som at X har full rang, ingen kolonner kan skrives som linærkombinasjoner av andre kolonner.

- (e) I den enkle lineære regresjon var $\hat{\beta}_1 > 0$ og i de nye analysen har både høyde og vekt positive $\hat{\beta}_j$. Høyde og vekt er innbyrdes positivt korrelert. Den estimerte effekten av høyde alene (i den enkle lineære regresjonen) er da en kombinert effekt av høyde pluss en "mediert" effekt av vekt i den multiple regresjonen. Det er dermed rimelig at estimatet $\hat{\beta}_1$ i den enkle lineære regresjonen er høyere enn tilsvarende $\hat{\beta}_1$ i den multiple lineære regresjonen.

Størrelsen **Multiple R-squared** gis ved $R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$. Telleren $\sum_{i=1}^n (y_i - \hat{y}_i)^2$ er knyttet til variasjonen (generelt) og inngår i variansestimater for de aktuelle modellene, mens nevneren tilsvarende refererer til variasjonen (variansen) over y_i -ene uten å ta hensyn til forklaringsvariable. Derfor kan man oppfatte R^2 forklart andel varians.

Siden kvadratsummer må bli mindre når vi inkluderer en ny forklaringsvariabel må R^2 bli større. Her ser vi riktignok bare en moderat økning fra 0.5966 til 0.6154, så selv om det er klart signifikant betydning av både høyde og vekt i den simultane modellen er forklaringsgraden av å legge inn vekt ikke spesielt stor.

For enkel lineær regresjon har vi at R^2 bare er kvadratet av korrelasjonen mellom x_i -er og y_i -er. Men siden $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ bare er en lineær transformasjon av x_i -ene vil den også være korrelasjonen mellom $\hat{y}_i$ -er og y_i -er.

Denne siste karakteriseringen av R^2 gjelder også for multippel lineær regresjon.

SLUTT

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse

Eksamensdag: 28. november - 2023

Tid for eksamen: 15.00–19.00.

Oppgavesettet er på 4 sider.

Vedlegg: Ingen

Tillatte hjelpemidler: Godkjent kalkulator
Formelsamling for STK1110

Kontroller at oppgavesettet er komplett før
du begynner å besvare spørsmålene.

Oppgave 1

- (a) Den øverste delen av utskriften gir en tabell relatert til regresjonskoeffisientene, en rad for hver β_j . Første kolonne gir estimat, 2. kolonne gir standard feil, 3 kolonne gir T-observatoren for å teste $H_0 : \beta_j = 0$ og siste kolonne gir tilhørende P-verdi.

Nederste del gir estimat på σ (Residual standard error), multippel R^2 og dens justerte verdi samt F-observatoren for å sjekke om noen av forklaringsvariable (i dette tilfelle bare en) har signifikant betydning for å vårklare variasjonen i responsen y .

- (b) Vi får en stor $|T| = 8.680$ verdi med tilhørende svræt liten P-verdi som indikerer at **Alder** er en svært viktig forklaringsvariabel. Samtidig er R^2 ganske lav slik at det er kun en liten andel av variasjonen. Dette kan indikere at det er andre forklaringvariable som burde være med for å forklare responsen.

Et 95% konfidensintervall for β_1 (bruker at $T \sim t_{n-2}$ og $t_{0.025;155} = 1.975$):

$$-0.078601 \pm 1.975 * 0.009056 = [-0.0965, -0.0607]$$

- (c) Når vi tester hypotesen på at $H_j : \beta_j = 0$ så gjør vi det *betinget på* at de øvrige forklaringsvariable er med i modellen. Det betyr at når Alder^2 ikke ser ut til å være viktig å ta med så er det som et tillegg til at Alder allerede er med. Tilsvarende så er det ikke viktig å ta med Alder hvis Alder^2 allerede er med.

Ser man på F-observatoren og tilhørende P-verdi så er denne klart signifikant som indikerer at *enten* Alder *eller* Alder^2 er viktig å ta med.

- (d) Da prediksjonsintervallene også tar hensyn til usikkerheten i støyleddene, som har et standard avvik på 1.801, så blir intervallene ganske store.

(Fortsettes på side 2.)

Selv om regresjonskoeffisienten tilhørende **Alder**² er svært liten, så vil den ha større effekt når alder er stor, dermed slår det mer ut i forskjell på intervallene. Et annet moment er også at gjennomsnittelig alder ser ut til å ligge nærmere 20 enn 90, noe som også påvirker usikkerheten i "forventningsdelen" $\hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2$.

Oppgave 2

(a) Vi har at

$$\begin{aligned} L(\beta) &= p(x, y | \alpha, \beta) = \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-x/\beta} \frac{1}{\beta^{3\alpha} \Gamma(3\alpha)} y^{3\alpha-1} e^{-y/\beta} \\ &= \frac{1}{\beta^{4\alpha} \Gamma(\alpha) \Gamma(3\alpha)} x^{\alpha-1} y^{3\alpha-1} e^{-(x+y)/\beta} \end{aligned}$$

og

$$\begin{aligned} \ell(\alpha, \beta) &= -4\alpha \log(\beta) - \log \Gamma(\alpha) - \log \Gamma(3\alpha) - (\alpha - 1) \log(x) - \\ &\quad (3\alpha - 1) \log(y) - \frac{1}{\beta}(x + y) \\ &= \text{konst} - 4\alpha \log(\beta) - \frac{1}{\beta}(x + y) \end{aligned}$$

der **konst** består av ledd som ikke inneholder β .

Merk at selv om $X + Y \sim \text{Gamma}(4\alpha, \beta)$, så vil det ikke være helt riktig å ta utgangspunkt i dette direkte. Da kaster man bort noe informasjon (hvor stor X er i forhold til Y). I dette tilfellet når vi kun er interessert i å estimere β , så får vi det samme svaret, men det hadde ikke vært tilfelle hvis vi også skulle estimere α .

(b) Vi har

$$\frac{\partial}{\partial \beta} \ell(\alpha, \beta) = -\frac{4\alpha}{\beta} + \frac{1}{\beta^2}(x + y)$$

og vi finner estimatet som den verdi som gir den deriverte lik 0, noe som gir

$$\hat{\beta} = \frac{x + y}{4\alpha}.$$

Vi kan sjekke at det faktisk blir en maksimumsverdi ved at

$$\frac{\partial^2}{\partial \beta^2} \ell(\alpha, \beta) = +\frac{4\alpha}{\beta^2} - \frac{2}{\beta^3}(x + y)$$

som innsatt $\hat{\beta}$ gir

$$\frac{(4\alpha)^3}{(x + y)^2} - 2 \frac{(4\alpha)^3}{(x + y)^2} = -\frac{(4\alpha)^3}{(x + y)^2} < 0$$

og dermed at vi har et maksimumspunkt.

(Fortsettes på side 3.)

Vi har at

$$E[\hat{\beta}] = \frac{1}{4\alpha}[E[X] + E[Y]] = \frac{1}{4\alpha}[\alpha\beta + 3\alpha\beta] = \beta;$$

$$V[\hat{\beta}] = \frac{1}{(4\alpha)^2}[V[X] + V[Y]] = \frac{1}{(4\alpha)^2}[\alpha\beta^2 + 3\alpha\beta^2] = \frac{\beta^2}{4\alpha}.$$

- (c) Når α er heltall, så kan vi bruke at X er en sum av $X_1, \dots, X_\alpha$ som hver er $\text{Gamma}(1, \beta)$ og uavhengige. Tilsvarende er Y sum av $Y_1, \dots, Y_{3\alpha}$ som alle også er $\text{Gamma}(1, \beta)$ og uavhengige. Dermed er $\hat{\beta}$ et gjennomsnitt av 4α uif variable og av sentralgrenseteoremet tilnærmet normalfordelt.

Vi får $\hat{\beta} = 0.497$. Vi har at

$$I(\beta) = -E\left[\frac{\partial^2}{\partial\beta^2}\ell(\alpha, \beta)\right] = -\frac{4\alpha}{\beta^2} + \frac{2}{\beta^3}(\alpha\beta + 3\alpha\beta) = \frac{4\alpha}{\beta^2}$$

Dermed vil $V[\hat{\beta}] \approx \frac{\beta^2}{4\alpha} \approx \frac{\hat{\beta}^2}{4\alpha} = 0.0031$.

Oppgave 3

- (a) Vi har at under $H_0 : \sigma_1^2 = \sigma_2^2$ så er $S_1^2/S_2^2 \sim F_{m-1, n-1}$. Her er $m = n = 15$ og $S_1^2/S_2^2 = 0.596/0.273 = 2.18315$. Fra tabell så ser vi at denne verdien er under 0.05 kvantilen som tilsier (siden vi har en to-sidig test) at P-verdien er større enn 0.1. Dermed ingen grunn til å forkaste H_0 .
- (b) Anta $X_i \stackrel{uif}{\sim} N(\mu_1, \sigma_1^2)$ og $Y_i \stackrel{uif}{\sim} N(\mu_2, \sigma_2^2)$. Hvis vi antar $\sigma_1 = \sigma_2$ så kan vi bruke

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{S_p \sqrt{1/m + 1/n}} \sim t_{m+n-2}$$

der

$$S_p^2 = [(m-1)S_1^2 + (n-1)S_2^2]/(m+n-2) = (0.596 + 0.273)/2 = 0.4345$$

$$m+n-2 = 28$$

Vi har da

$$P(-t_{\alpha/2; 28} \leq \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{S_p \sqrt{1/m + 1/n}} \leq t_{\alpha/2; 28}) = 1 - \alpha$$

Ved å gange med nevner og flytte $\bar{X} - \bar{Y}$ over på andre side av ulikehetstegnene, så får vi konfidensintervaller

$$\bar{X} - \bar{Y} \pm t_{\alpha/2; 28} S_p \sqrt{2/15}$$

For $\alpha = 0.05$ blir $t_{\alpha/2; 28} = 2.048$ og intervallet blir $[0.060, 1.046]$.

For $\alpha = 0.01$ blir $t_{\alpha/2; 28} = 2.763$ og intervallet blir $[-0.112, 1.218]$.

(Fortsettes på side 4.)

- (c) Konklusjon hvis $\alpha = 0.05$: H_0 forkastes på et $\alpha = 0.05$ signifikansnivå.
Konklusjon hvis $\alpha = 0.01$: H_0 forkastes *ikke* på et $\alpha = 0.01$ signifikansnivå.
Dette samsvarer med konfidensintervallene i (b) siden 0 ikke er med i 95% KI men er med i 99% intervallet.
- (d) Når vi gjør mindre antagelser, så vil vi også typisk få svakere konklusjoner, i dette tilfelle høyere P-verdi.

Kvantilplottene gir indikasjon på at det kan være noe avvik fra normalitet, noe som tilsier at det er bedre å bruke den ikke-parametriske metoden. Dermed er det noe tvilsomt om en kan konkludere at det er forskjell mellom de to verdensdeler (det er det egentlig også hvis vi bruker T-testen da vi får forskjellige konklusjoner avhengig av om vi velger $\alpha = 0.05$ eller $\alpha = 0.01$).

Eksamen i STK1110 høsten 2022 - løsningsforslag

Oppgave 1

a

Vi vet at $\bar{X} = 1/15 \sum_{i=1}^{15} X_i \sim N(\mu, \sigma^2/15)$, slik at

$$\frac{\bar{X} - \mu}{S/\sqrt{15}} \sim t_{15-1},$$

der $S = \sqrt{1/(15-1) \sum_{i=1}^{15} (X_i - \bar{X})^2}$ er det empiriske standardavviket. Vi får

$$\begin{aligned} P\left(-t_{0.025,14} \leq \frac{\bar{X} - \mu}{S/\sqrt{14}} \leq t_{0.025,14}\right) &= 0.95 \\ \rightarrow P\left(\bar{X} - t_{0.025,14} \frac{S}{\sqrt{15}} \leq \mu \leq \bar{X} + t_{0.025,14} \frac{S}{\sqrt{15}}\right) &= 0.95. \end{aligned}$$

Et 95% konfidensintervall for μ er dermed gitt ved

$$\bar{x} \pm t_{0.025,14} \frac{s}{\sqrt{15}}.$$

Vi setter inn og får (6.1, 7.2).

b

Vi bruker

$$T = \frac{\bar{X} - 6.2}{S/\sqrt{15}}.$$

Testobservatoren T er da t_{15-1} -fordelt dersom $\mu = 6.2$. Da den alternative hypotesen er at $\mu \neq 6.2$, er det naturlig å forkaste H_0 dersom $T \geq c$ eller $T \leq -c$, der c er slik at signifikansnivået på testen er 5%. Med $c = t_{0.025,14}$ får vi signifikansnivået

$$\begin{aligned} &P(\text{Forkaste } H_0 \mid H_0 \text{ er sann}) \\ &= P\left(\frac{\bar{X} - 6.2}{S/\sqrt{15}} \leq -t_{0.025,14} \cup \frac{\bar{X} - 6.2}{S/\sqrt{15}} \geq t_{0.025,14} \mid \mu = 6.2\right) \\ &= 1 - P\left(-t_{0.025,14} \leq \frac{\bar{X} - 6.2}{S/\sqrt{15}} \leq t_{0.025,14} \mid \mu = 6.2\right) \\ &= 1 - \left(P\left(\frac{\bar{X} - 6.2}{S/\sqrt{15}} \leq t_{0.025,14} \mid \mu = 6.2\right) - P\left(\frac{\bar{X} - 6.2}{S/\sqrt{15}} \leq -t_{0.025,14} \mid \mu = 6.2\right)\right) \\ &= 1 - (0.975 - 0.025) = 0.05, \end{aligned}$$

som ønsket. Vi setter inn og får $t_{obs} = \frac{6.63-6.2}{0.967/\sqrt{15}} = 1.72$. Da $-2.145 = -t_{0.025,14} \leq t_{obs} \leq t_{0.025,14} = 2.145$, kan vi ikke forkaste H_0 ved 5% signifikansnivå. I Oppgave a) fikk vi et 95% konfidensintervall som inneholder 6.2, noe som er i overensstemmelse med resultatene vi får her.

c

Generelt er P-verdien lik sannsynligheten, beregnet under forutsetning av at nullhypotesen er sann, for at vi vil få en verdi av testobservatoren som er minst like mye i motsetning til nullhypotesen som den verdien vi faktisk fikk. Så her er P-verdien lik sannsynligheten, når $\mu = 6.2$, for at vi vil få en verdi av testobservatorene T som er større enn eller lik $|t_{obs}| = 1.72$ eller mindre enn eller lik $-|t_{obs}| = -1.72$, dvs

$$\begin{aligned} P(-|t_{obs}| \leq T \cup T \leq |t_{obs}| \mid \mu = 6.2) &= 1 - P(-|t_{obs}| \leq T \leq |t_{obs}| \mid \mu = 6.2) \\ &= 2 \cdot (1 - P(T \leq |t_{obs}| \mid \mu = 6.2)). \end{aligned}$$

Fra tabellen over kritiske verdier for t-fordelingen ser vi at

$$t_{0.10,14} \leq t_{obs} \leq t_{0.05,14},$$

hvilket betyr at

$$0.20 \leq P(-|t_{obs}| \leq T \cup T \leq |t_{obs}| \mid \mu = 6.2) \leq 0.10,$$

altså at P-verdien ligger mellom 0.20 og 0.10, og er større enn signifikansnivået 5% fra b).

Oppgave 2

a

Likelihood-funksjonen gitt ved

$$L(\beta) \stackrel{uif}{=} \prod_{i=1}^n f(x_i; \beta) = \prod_{i=1}^n f(x_i; \beta) = \prod_{i=1}^n \frac{1}{6\beta^4} x_i^3 e^{-\frac{x_i}{\beta}} = \frac{1}{6^n \beta^{4n}} e^{-\frac{1}{\beta} \sum_{i=1}^n x_i} \prod_{i=1}^n x_i^3.$$

Det gir log-likelihood-funksjonen

$$\log L(\beta) = -n \log(6) - 4n \log(\beta) + 3 \sum_{i=1}^n \log(x_i) - \frac{1}{\beta} \sum_{i=1}^n x_i.$$

Vi får maksimum likelihood-estimatet $\hat{\beta}$ ved å løse ligningen $\frac{\partial \log L(\beta)}{\partial \beta} = 0$.
 Altså er $\hat{\beta}$ løsningen av ligningen

$$-\frac{4n}{\hat{\beta}} + \frac{1}{\hat{\beta}^2} \sum_{i=1}^n x_i = 0,$$

som gir maksimum likelihood-estimatet

$$\hat{\beta}_{ML} = \frac{1}{4n} \sum_{i=1}^n x_i = \frac{\bar{x}}{4},$$

med $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$, og tilsvarende maksimum likelihood-estimator

$$\hat{\beta}_{ML} = \frac{\bar{X}}{4}.$$

b

Fisher informasjonen i én observasjon er gitt ved

$$I(\beta) = -\text{E} \left(\frac{\partial^2 \log f(X_i; \beta)}{\partial \beta^2} \right).$$

Vi har

$$\log(f(X_i; \beta)) = -\log(6) - 4 \log(\beta) + 3 \log(X_i) - \frac{1}{\beta} X_i,$$

slik at

$$\frac{\partial \log f(X_i; \beta)}{\partial \beta} = -\frac{4}{\beta} + \frac{1}{\beta^2} X_i$$

og

$$\frac{\partial^2 \log f(X_i; \beta)}{\partial \beta^2} = \frac{4}{\beta^2} - \frac{2}{\beta^3} X_i.$$

Vi får dermed

$$\begin{aligned} I(\beta) &= -\text{E} \left(\frac{4}{\beta^2} - \frac{2}{\beta^3} X_i \right) \\ &= -\frac{4}{\beta^2} + \frac{2}{\beta^3} \text{E}(X_i) \\ &= -\frac{4}{\beta^2} + \frac{2}{\beta^3} \cdot 4\beta = \frac{4}{\beta^2}. \end{aligned}$$

c

Det er kjent at maksimum likelihood-estimatoren $\hat{\beta}_{ML}$ (under visse regularitetsbetingelser som er oppfylt her) er tilnærmet normalfordelt $N(\beta, \sigma_{\hat{\beta}}^2)$ med $\sigma_{\hat{\beta}}^2 = 1/(nI(\beta))$. Her får vi

$$\sigma_{\hat{\beta}}^2 = 1/(nI(\beta)) = \frac{\beta^2}{4n}.$$

Her kan en alternativt bruke sentralgrenseteoremet, som sier at for store n er $\bar{X} = 4\hat{\beta}_{ML}$ tilnærmet normalfordelt med forventning $E(\bar{X}) = E(X_i) = 4\beta$ og varians $V(\bar{X}) = \frac{1}{n}V(X_i) = \frac{4\beta^2}{n}$, slik at $\hat{\beta}_{ML}$ er tilnærmet normalfordelt med forventning $\frac{1}{4}E(\bar{X}) = \beta$ og varians $\sigma_{\hat{\beta}}^2 = \frac{1}{4^2}V(\bar{X}) = \frac{\beta^2}{4n}$.

d

Grunnet invariansprinsippet for maksimum likelihood-estimatoren er maksimum likelihood-estimatoren for $\psi = g(\beta) = \frac{1}{\beta}$

$$\hat{\psi}_{ML} = g(\hat{\beta}_{ML}) = 4/\bar{X}.$$

e

En apriorifordeling er konjugert med fordelingen til dataene dersom aposteriorifordelingen tilhører samme fordelingsfamilie som apriorifordelingen. Vi har:

$$\begin{aligned}\pi(\psi) &= \frac{1}{\beta_0^{\alpha_0} \Gamma(\alpha_0)} \psi^{\alpha_0-1} e^{-\frac{1}{\beta_0}\psi} \\ f(x_1, \dots, x_n | \psi) &\stackrel{uif}{=} \prod_{i=1}^n f(x_i; \psi) = \frac{\psi^{4n}}{6^n} e^{-\psi \sum_{i=1}^n x_i} \prod_{i=1}^n x_i^3.\end{aligned}$$

Vi vet at tettheten til aposteriorifordelingen til ψ er gitt ved

$$\begin{aligned}\pi(\psi | x_1, \dots, x_n) &= k \cdot \pi(\psi) \cdot f(x_1, \dots, x_n | \psi) \\ &= k \cdot \frac{1}{\beta_0^{\alpha_0} \Gamma(\alpha_0)} \psi^{\alpha_0-1} e^{-\frac{1}{\beta_0}\psi} \cdot \frac{\psi^{4n}}{6^n} e^{-\psi \sum_{i=1}^n x_i} \prod_{i=1}^n x_i^3 \\ &\propto \psi^{\alpha_0+4n-1} e^{-\left(\frac{1}{\beta_0} + \sum_{i=1}^n x_i\right)\psi},\end{aligned}$$

som er proporsjonal med tettheten til $Gamma\left(\alpha_0 + 4n, \frac{1}{\frac{1}{\beta_0} + \sum_{i=1}^n x_i}\right)$. Altså må $[\psi | X_1 = x_1, \dots, X_n = x_n] \sim Gamma\left(\alpha_0 + 4n, \frac{1}{\frac{1}{\beta_0} + \sum_{i=1}^n x_i}\right)$, som i likhet

med apriorifordelingen er en gammafordelingen. Det betyr at apriorifordelingen er konjugert med fordelingen til dataene.

Bayes-estimatoren for ψ er gitt ved

$$\begin{aligned}\hat{\psi}_{Bayes} = E(\psi|X_1, \dots, X_n) &= (\alpha_0 + 4n) \cdot \frac{1}{\frac{1}{\beta_0} + \sum_{i=1}^n X_i} \\ &= \frac{\alpha_0 + 4n}{\frac{1}{\beta_0} + \sum_{i=1}^n X_i} = \frac{\alpha_0/n + 4}{\frac{1}{n\beta_0} + \bar{X}}.\end{aligned}$$

Vi ser at når n blir stor, blir Bayes-estimatoren $\hat{\psi}_{Bayes}$ essensielt den samme som maksimum likelihood-estimatoren $\hat{\psi}_{ML}$.

Oppgave 3

a

Konstantleddet β_0 i den enkle lineære regresjonsmodellen er forventet import når $x_{i1} - \bar{x}_1 = 0$, dvs. når forbruket er lik gjennomsnittet (som er 167 millioner FRF). Fra R-utskriften ser vi at $\hat{\beta}_0 = 30.1$, så når forbruket er gjennomsnittlig, vil en forvente at importen er på 30.1 millioner FRF. Stigningstallet β_1 er forventet endring i importen når forbruket øker med 1 million FRF. Her er $\hat{\beta}_1 = 0.296$, så hvis forbruket øker med 1 million FRF, vil en forvente at billettsalget øker med 0.296 millioner FRF.

Videre vet vi at $(\hat{\beta}_1 - \beta_1)/S_{\hat{\beta}_1} \sim t_{18-2}$, der $S_{\hat{\beta}_1}^2$ er den forventningsrette estimatoren for $\text{Var}(\hat{\beta}_1)$. Et 95% konfidensintervall for β_1 er dermed gitt ved

$$\hat{\beta}_1 \pm t_{0.025, 16} S_{\hat{\beta}_1}.$$

Når vi setter inn tall fra R-utskriften, får vi

$$0.296 \pm 2.120 \cdot 0.0131 = (0.268, 0.323).$$

Vi ser at verdien 0.25 er utenfor konfidensintervallet, dog i nærheten av nedre grense. Det betyr at om vi hadde testet $H_0 : \beta_1 = 0.25$ mot $H_a : \beta_1 \neq 0.25$, altså om forventet økning i importen øker med omtrent 0.25 millioner FRF når forbruket øker med 1 million FRF, ville vi forkaste H_0 ved 5% signifikansnivå.

b

Antakelsene vi gjør i modell (1) er

1. Sammenhengen er lineær: $E(Y|x) = \beta_0 + \beta_1(x_1 - \bar{x}_1)$.
2. Feilleddene ϵ_i er normalfordelt.
3. Variansen er lik for alle verdier av x : $V(\epsilon_i) = \sigma^2$.
4. Feilleddene ϵ_i er uavhengige.

Den første antakelsen kan vi sjekke ved å se på plottet av residualene $e_i = Y_i - \hat{Y}_i$ mot de tilpassede verdiene $\hat{Y}_i$. Dersom sammenhengen er lineær, skal det ikke være noe mønster i dette plottet. Den andre antakelsen kan vi sjekke ved å se på normalfordelingsplottet for de standardiserte residualene. Dersom punktene i plottet ligger omtrent langs diagonalen, kan en gå ut fra at antakelsen om normalfordeling er rimelig. Den tredje antakelsen sjekker en ved å se på plottet av de standardiserte residualene $e_i^* = e_i/s_{e_i}$ mot $\hat{Y}_i$. Dersom antakelsen om lik varians holder, skal det ikke være noe mønster i dette plottet.

I residualplottene for modell (1), ser vi fra normalfordelingsplottet av de standardiserte residualene at antakelsen om normalfordeling ser grei ut. Imidlertid har de to andre plottene et tydelig parabelmønster, som kan tyde på at det er en ikke-lineær, og mer spesifikt en kvadratisk effekt av forbruket på importen. Det medfører også at antakelsen om konstant varians blir brutt.

c

Anta at forbruket er x_1^* , slik at $x_2 = (x_1^* - \bar{x}_1)^2$. Forventet import er nå gitt ved:

$$\begin{aligned} E(Y|x_1^*) &= E(\gamma_0 + \gamma_1(x_1^* - \bar{x}_1) + \gamma_2(x_1^* - \bar{x}_1)^2 + \epsilon) \\ &= \gamma_0 + \gamma_1(x_1^* - \bar{x}_1) + \gamma_2(x_1^* - \bar{x}_1)^2 + \underbrace{E(\epsilon)}_{=0} \\ &= \gamma_0 + \gamma_1(x_1^* - \bar{x}_1) + \gamma_2(x_1^* - \bar{x}_1)^2, \end{aligned}$$

som er en kvadratisk funksjon av forbruket x_1^* . Vi får

$$\begin{aligned} E(Y|x_1^* + 1) - E(Y|x_1^*) &= \gamma_0 + \gamma_1(x_1^* + 1 - \bar{x}_1) + \gamma_2(x_1^* + 1 - \bar{x}_1)^2 - (\gamma_0 + \gamma_1(x_1^* - \bar{x}_1) + \gamma_2(x_1^* - \bar{x}_1)^2) \\ &= \gamma_1 + \gamma_2(x_1^* - \bar{x}_1)^2 + 2\gamma_2(x_1^* - \bar{x}_1) + \gamma_2 - \gamma_2(x_1^* - \bar{x}_1)^2 = \gamma_1 + \gamma_2(1 + 2(x_1^* - \bar{x}_1)). \end{aligned}$$

Altså øker forventet import med $\gamma_1 + \gamma_2(1 + 2(x_1^* - \bar{x}_1))$ når forbruket øker fra x_1^* til $x_1^* + 1$.

Vi har fortsatt $E(Y|\bar{x}_1) = \gamma_0$, slik at konstantleddet γ_0 fortolkes slik som β_0 i modell (1), altså som forventet import når forbruket er gjennomsnittlig. Fortolkningen av γ_1 er imidlertid forskjellig fra fortolkningen av β_1 , da forventet import øker med $\gamma_1 + \gamma_2(1 + 2(x_1^* - \bar{x}_1))$ når forbruket øker med én enhet fra nivået x_1^* . Koeffisienten γ_1 angir altså bare en del av effekten av forbruket på importen, og denne effekten avhenger forøvrig av nivået på forbruket.

d

Hypotesetesten dreier seg om modell (2), som modellerer effekten av forbruk på importen som kvadratisk, er bedre enn den enkle, første modellen med en lineær effekt, dvs.

$$H_0 : \beta_2 = 0 \text{ mot } H_a : \beta_2 \neq 0.$$

Vi ser at den tilsvarende P-verdien er på bare $1.53 \cdot 10^{-6}$, hvilket betyr at vi forkaster H_0 med god margin ved 5% signifikansnivå. Det betyr at det ekstra kvadratiske leddet i modell (2) bidrar signifikant til å forklare importen, hvilket vi også ser av den ekvivalente t-testen for om $\beta_2 \neq 0$ i R-utskriften fra tilpasningen av modell (2). Dermed velger vi modell (2) med kvadratisk effekt av forbruket på importen. Vi legger også merke til at justert R^2 har økt fra 0.9679 i tilpasningen til modell (1) til 0.9930 i tilpasningen til modell (2).

Vi bruker så residualplottene til å sjekke modellantakelsen, som her er

1. Sammenhengen er kvadratisk: $E(Y|x) = \gamma_0 + \gamma_1(x_1 - \bar{x}_1) + \gamma_2(x_1 - \bar{x}_1)^2$.
2. Feilleddene ε_i er normalfordelt.
3. Variansen er lik for alle verdier av x_1 : $V(\varepsilon_i) = \tau^2$.
4. Feilleddene ε_i er uavhengige.

Vi ser av normalfordelingsplottet av de standardiserte residualene at antakelsen om normalfordeling fortsatt ser grei ut. Nå er det imidlertid ikke noe åpenbart mønster i plottene av residualene og av de standardiserte residualene mot de tilpassede verdiene. Dette tyder på at hele effekten av forbruket på importen er fanget opp med en kvadratisk effekt, slik at antakelsen om

konstant varians nå ser rimelig ut. Dette gir en bekreftelse på at en bør velge modell (2) framfor modell (1).

Eksamen i STK1110 høsten 2021 - løsningsforslag

Oppgave 1

a

Vi vet at $\bar{D} = 1/n \sum_{i=1}^{17} D_i \sim N(\mu_D, \sigma_D^2/n)$, slik at

$$\frac{\bar{D} - \mu_D}{S_D/\sqrt{17}} \sim t_{17-1},$$

der $S_D = \sqrt{1/(17-1) \sum_{i=1}^{17} (D_i - \bar{D})^2}$ er det empiriske standardavviket. Vi får

$$\begin{aligned} P\left(-t_{0.025,16} \leq \frac{\bar{D} - \mu_D}{S_D/\sqrt{17}} \leq t_{0.025,16}\right) &= 0.95 \\ \rightarrow P\left(\bar{D} - t_{0.025,16} \frac{S_D}{\sqrt{17}} \leq \mu_D \leq \bar{D} + t_{0.025,16} \frac{S_D}{\sqrt{17}}\right) &= 0.95. \end{aligned}$$

Et 95% konfidensintervall for μ_D er dermed gitt ved

$$\bar{d} \pm t_{0.025,16} \frac{s_D}{\sqrt{17}}.$$

Vi setter inn og får (3.6, 10.9). Vi legger merke til at hele konfidensintervallet for forventet vektøking ligger over 0, hvilket er en indikasjon på at på terapien bidrar til vektøkning.

b

Vi bruker

$$T = \frac{\bar{D} - 0}{S_D/\sqrt{17}} = \frac{\bar{D}}{S_D/\sqrt{17}}.$$

Testobservatoren T er da t_{17-1} -fordelt dersom $\mu_D = 0$. Da den alternative hypotesen er at $\mu_D > 0$, er det naturlig å forkaste H_0 dersom $T \geq c$, der c er slik at signifikansnivået på testen er 5%. Med $c = t_{0.05,16}$ får vi signifikansnivået

$$\begin{aligned} P(\text{Forkaste } H_0 \mid H_0 \text{ er sann}) &= P\left(\frac{\bar{D}}{S_D/\sqrt{17}} \geq t_{0.05,16} \mid \mu_D \leq 0\right) \\ &\leq P\left(\frac{\bar{D}}{S_D/\sqrt{17}} \geq t_{0.05,16} \mid \mu_D = 0\right) \\ &= 0.05, \end{aligned}$$

som ønsket. Vi setter inn og får $t_{obs} = \frac{7.26}{7.16/\sqrt{17}} = 4.18$. Da $t_{obs} \geq -t_{0.05,16} = 1.746$, forkaster vi H_0 ved 5% signifikansnivå og konkluderer med at forventet vektøking etter familierterapi er større enn 0, altså at terapien fungerer. Dette samsvarer godt med resultatene fra Oppgave b).

c

Generelt er P-verdien lik sannsynligheten, beregnet under forutsetning av at nullhypotesen er sann, for at vi vil få en verdi av testobservatoren som er minst like mye i motsetning til nullhypotesen som den verdien vi faktisk fikk. Så her er P-verdien lik sannsynligheten, når $\mu_D = 0$, for at vi vil få en verdi av testobsetvatorene T som er lik $t_{obs} = 4.18$ eller større, dvs

$$P(T \geq t_{obs} \mid \mu_D = 0).$$

Fra tabellen over kritiske verdier for t-fordelingen ser vi at

$$t_{0.001,16} \leq t_{obs} \leq t_{0.0001,16},$$

hvilket betyr at

$$0.0001 \leq P(T \geq t_{obs} \mid \mu_D = 0) \leq 0.001,$$

altså at P-verdien ligger mellom 0.00001 og 0.0001, og er betydelig mindre enn signifikansnivået 5% fra c).

Oppgave 2

a

Vi finner momentestimatoren $\tilde{\beta}$ ved å løse ligningen vi får når vi setter første teoretiske moment $E(X_i)$ lik første empiriske moment $\bar{X} = 1/n \sum_{i=1}^n X_i$. Forventningen $E(X_i)$ får vi ved å bruke opplysningen om r -temomentet til X_i med $r = 1$. Vi får:

$$\tilde{\beta} \Gamma \left(1 + \frac{1}{\alpha} \right) = \bar{X}.$$

Det gir

$$\tilde{\beta} = \frac{\bar{X}}{\Gamma \left(1 + \frac{1}{\alpha} \right)}.$$

b

I henhold til sentralgrenseteoremet er $\bar{X}$ tilnærmet $N(E(X_i), V(X_i)/\sqrt{n})$ -fordelt for store n . Da må $\tilde{\beta}$, som er en konstant ganget med $\bar{X}$, også være

tilnærmet normalfordelt. Videre er:

$$\begin{aligned}
 E(\tilde{\beta}) &= \frac{1}{\Gamma(1 + \frac{1}{\alpha})} E(\bar{X}) = \frac{1}{\Gamma(1 + \frac{1}{\alpha})} E(X_i) = \beta \\
 \sigma_{\tilde{\beta}}^2 &= V(\tilde{\beta}) = \frac{1}{(\Gamma(1 + \frac{1}{\alpha}))^2} V(\bar{X}) \\
 &= \frac{1}{n (\Gamma(1 + \frac{1}{\alpha}))^2} V(X_i) \\
 &= \frac{1}{n (\Gamma(1 + \frac{1}{\alpha}))^2} (E(X_i^2) - (E(X_i))^2) \\
 &= \frac{1}{n (\Gamma(1 + \frac{1}{\alpha}))^2} \left(\beta^2 \Gamma\left(1 + \frac{2}{\alpha}\right) - \beta^2 \left(\Gamma\left(1 + \frac{2}{\alpha}\right) \right)^2 \right) \\
 &= \frac{\beta^2}{n} \left(\Gamma\left(1 + \frac{2}{\alpha}\right) / \Gamma\left(1 + \frac{1}{\alpha}\right)^2 - 1 \right).
 \end{aligned}$$

c

La $x_1, \dots, x_n$ være de observerte verdiene av $X_1, \dots, X_n$. Da er likelihood funksjonen gitt ved

$$L(\beta) \stackrel{uif}{=} \prod_{i=1}^n f(x_i; \alpha, \beta) = \prod_{i=1}^n \frac{\alpha}{\beta^\alpha} x_i^{\alpha-1} e^{-\left(\frac{x_i}{\beta}\right)^\alpha} = \frac{\alpha^n}{\beta^{n\alpha}} e^{-\frac{1}{\beta^\alpha} \sum_{i=1}^n x_i^\alpha} \prod_{i=1}^n x_i^{\alpha-1}.$$

Det gir log-likelihood-funksjonen

$$\log L(\beta) = n \log(\alpha) - n\alpha \log(\beta) + (\alpha - 1) \sum_{i=1}^n \log(x_i) - \frac{1}{\beta^\alpha} \sum_{i=1}^n x_i^\alpha.$$

Vi får maksimum likelihood-estimatet $\hat{\beta}$ ved å løse ligningen $\frac{\partial \log L(\beta)}{\partial \beta} = 0$.

Altså er $\hat{\beta}$ løsningen av ligningen

$$-\frac{n\alpha}{\beta} + \frac{\alpha}{\beta^{\alpha+1}} \sum_{i=1}^n x_i^\alpha = 0,$$

som gir maksimum likelihood-estimatet

$$\hat{\beta} = \left(\frac{1}{n} \sum_{i=1}^n x_i^\alpha \right)^{1/\alpha},$$

og tilsvarende maksimum likelihood-estimator

$$\hat{\beta} = \left(\frac{1}{n} \sum_{i=1}^n X_i^\alpha \right)^{1/\alpha}.$$

d

Det er kjent at maksimum likelihood estimatoren $\hat{\theta}$ (under visse regularitetsbetingelser som er oppfylt her) er tilnærmet normalfordelt $N(\beta, \sigma_{\hat{\beta}}^2)$ med $\sigma_{\hat{\beta}}^2 = 1/(nI(\beta))$. Her får vi

$$\sigma_{\hat{\beta}}^2 = 1/(nI(\theta)) = \frac{\beta^2}{n\alpha^2}.$$

Dermed er

$$\frac{V(\tilde{\beta})}{V(\hat{\beta})} = \alpha^2 \alpha^2 \left(\Gamma\left(1 + \frac{2}{\alpha}\right) / \Gamma\left(1 + \frac{1}{\alpha}\right)^2 - 1 \right) > 1.$$

Da begge estimatorene er tilnærmet normalfordelt med forventning β for store n og variansen til maksimum likelihood-estimatoren $\hat{\beta}$ er minst, vil vi foretrekke denne framfor momentestimatoren $\tilde{\beta}$.

Oppgave 3

a

Enveis variansanalyse dreier seg om sammenligning av forventningsverdien i flere populasjoner, der populasjonene er definert ut fra en bestemt faktor. I dette tilfellet er det type behandling som er faktoren gruppene blir delt inn etter, og vi vil teste om forventet vektøkning i de tre gruppene er den samme eller ikke.

La X_{ij} være vektøkningen til kvinne j i behandlingsgruppe i , der $i = 1$ er kontrollgruppa, $i = 2$ tilsvarer familieterapi og $i = 3$ tilsvarer kognitiv behandling. Vi antar da at

$$X_{ij} = \mu_i + \varepsilon_{ij}, \quad \varepsilon_{ij} \sim N(0, \sigma^2),$$

og at alle X_{ij} -ene er uavhengige. I enveis variansanalyse tester vi hypotesene

$$H_0 : \mu_1 = \mu_2 = \mu_3 \text{ mot } H_a : \text{ minst én } \mu_i \text{ er forskjellig fra de andre.}$$

Vi ser at P-verdien fra F-testen som er brukt er veldig liten (0.0065). Vi forkaster dermed H_0 , og konkluderer med at minst én av behandlingene gir en annen forventet vektøkning enn kontrollgruppa.

b

Vi ser av R-utskriften av $\hat{\beta}_0 = -0.45$ og $\hat{\beta}_1 = 5.03$. Vi har:

$$\begin{aligned} E(Y_i|x_i = 0) &= E(\beta_0 + \beta_1 \cdot 0 + \varepsilon_i) = \beta_0 + E(\varepsilon_i) = \beta_0 \\ E(Y_i|x_i = 1) &= E(\beta_0 + \beta_1 \cdot 1 + \varepsilon_i) = \beta_0 + \beta_1 + E(\varepsilon_i) = \beta_0 + \beta_1. \end{aligned}$$

Det betyr at (estimert) forventet vektøkning for kvinnene i kontrollgruppa er $\hat{\beta}_0 = -0.45$ lb, mens (estimert) ekstra forventet vektøkning for kvinnene som har fått behandling, sammenlignet med de som ikke har fått behandling, er $\hat{\beta}_1 = 5.03$ lb.

Videre vet vi at $(\hat{\beta}_1 - \beta_1)/S_{\hat{\beta}_1} \sim t_{72-2}$, der $S_{\hat{\beta}_1}^2$ er den forventningsrette estimatoren for $\text{Var}(\hat{\beta}_1)$. Et 95% kondidensintervall for β_1 er dermed gitt ved

$$\hat{\beta}_1 \pm t_{0.025,70} S_{\hat{\beta}_1}.$$

Når vi setter tall fra R-utskriften, får vi

$$5.03 \pm 1.994 \cdot 1.879 = (1.28, 8.78).$$

Vi ser at høye konfidensintervallet ligger over verdien 0. Det betyr at vi med stor sikkerhet vet at forventet vektøkning er større blant kvinnene som får behandling enn de som ikke får det, og altså at behandlingen har effekt på forventet vektøkning.

c

Med den nye modellen

$$Y_i = \gamma_0 + \gamma_1 x_{1i} + \gamma_2 x_{2i} + \varepsilon_i^*,$$

får vi

$$\begin{aligned} E(Y_i|x_{1i} = 0, x_{2i} = 0) &= E(\gamma_0 + \gamma_1 \cdot 0 + \gamma_2 \cdot 0 + \varepsilon_i^*) = \gamma_0 + E(\varepsilon_i^*) = \gamma_0 \\ E(Y_i|x_{1i} = 1, x_{2i} = 0) &= E(\gamma_0 + \gamma_1 \cdot 1 + \gamma_2 \cdot 0 + \varepsilon_i^*) = \gamma_0 + \gamma_1 + E(\varepsilon_i^*) = \gamma_0 + \gamma_1 \\ E(Y_i|x_{1i} = 0, x_{2i} = 1) &= E(\gamma_0 + \gamma_1 \cdot 0 + \gamma_2 \cdot 1 + \varepsilon_i^*) = \gamma_0 + \gamma_2 + E(\varepsilon_i^*) = \gamma_0 + \gamma_2. \end{aligned}$$

Det betyr at (estimert) forventet vektøkning for kvinnene i kontrollgruppa er $\hat{\gamma}_0 = -0.45$ lb, mens (estimert) ekstra forventet vektøkning for kvinnene

som har fått familierapi, i forhold til de som ikke har fått behandling er $\hat{\gamma}_1 = 7.72$ lb og (estimert) ekstra forventet vektøkning for kvinnene som har fått familierapi, i forhold til de som ikke har fått behandling er $\hat{\gamma}_2 = 3.46$ lb. Videre er både β_0 og γ_0 lik $E(Y|\text{kvinnen har ikke fått behandling})$, altså er de like.

d

For å teste hypotesene

$$H_0 : \gamma_j = 0 \text{ mot } H_a : \gamma_j \neq 0,$$

$j = 1, 2$ kan vi bruke testobservatorene $T_j = \frac{\hat{\gamma}_j}{S_{\hat{\gamma}_j}}$, der $S_{\hat{\gamma}_j}^2$ er den forventningsrette estimatoren for $V(\hat{\gamma}_j)$. Disse testobservatorene er t_{72-3} -fordelt under H_0 . Vi har et tosidig alternativ, og vil derfor forkaste H_0 for både store positive og store negative verdier av T_j -ene. Vi forkaster da H_0 dersom $T_j \leq -t_{0.025,69}$ eller $T_j \geq t_{0.025,69}$ med $t_{0.025,69} = 1.995$. Alternativt (men dette er ikke påkrevd her) kan en velge å bruke Bonferroni-korreksjonen med 2.5% signifikansnivå i hver test for å få et samlet signifikansnivå på 5% for de to testene bruker vi, og forkaster da H_0 dersom $T_j \leq -t_{0.0125,69}$ eller $T_j \geq t_{0.0125,69}$ med $t_{0.0125,69} = 2.291$.

Fra R-utskriften har vi $t_{1,obs} = 3.285$, som er i forkastningsområdet, og $t_{2,obs} = 1.700$, som ikke er i forkastningsområdet. Vi forkaster altså nullhypotesen om at $\gamma_1 = 0$, men vi kan ikke forkaste nullhypotesen om at $\gamma_2 = 0$. Med andre ord kan vi konkludere med at familierapi har en signifikant effekt på vektøkningen til kvinnene, mens vi ikke kan gjøre det samme for den kognitive behandlingen. Hvis vi sammenligner med resultatene fra Oppgave a) og b), ser det ut til at vektøkningen til de som har fått familierapi skiller seg fra vektøkningen til de andre kvinnene, og at det er det som slår ut i hypotesetestene i a) og b).

Eksamen i STK1110 høsten 2020 - løsningsforslag

Oppgave 1

a

Vi vet at $\bar{X} = 1/n \sum_{i=1}^{28} X_i \sim N(\mu, \sigma^2/n)$, slik at

$$\frac{\bar{X} - \mu}{S/\sqrt{28}} \sim t_{28-1},$$

der $S = \sqrt{1/(28-1) \sum_{i=1}^{28} (X_i - \bar{X})^2}$ er det empiriske standardavviket. Vi får

$$\begin{aligned} P\left(-t_{0.005,27} \leq \frac{\bar{X} - \mu}{S/\sqrt{28}} \leq t_{0.005,27}\right) &= 0.99 \\ \rightarrow P\left(\bar{X} - t_{0.005,27} \frac{S}{\sqrt{28}} \leq \mu \leq \bar{X} + t_{0.005,27} \frac{S}{\sqrt{28}}\right) &= 0.99. \end{aligned}$$

Et 95% konfidensintervall for μ er dermed gitt ved

$$\bar{x} \pm t_{0.005,27} \frac{s}{\sqrt{28}}.$$

Vi setter inn og får (87.6, 107.4).

b

Vi bruker

$$T = \frac{\bar{X} - 115}{S/\sqrt{28}},$$

og da den alternative hypotesen er at $\mu < 115$, er det naturlig å forkaste H_0 dersom $T \leq c$, der c er slik at signifikansnivået på testen er 1%. Med $c = -t_{0.01,27}$ får vi

$$\begin{aligned} P(\text{Forkaste } H_0 \mid H_0 \text{ er sann}) &= P\left(\frac{\bar{X} - 115}{S/\sqrt{28}} \leq -t_{0.01,27} \mid \mu \geq 115\right) \\ &\leq P\left(\frac{\bar{X} - 115}{S/\sqrt{28}} \leq -t_{0.01,27} \mid \mu = 115\right) \\ &= 0.01, \end{aligned}$$

som ønsket. Vi setter inn og får $t_{obs} = \frac{97.52-115}{18.95/\sqrt{28}} = -4.88$. Da $t_{obs} \leq -t_{0.01,27} = -2.473$, forkaster vi H_0 ved 1% signifikansnivå og konkluderer med at eplene

er mindre enn vanlig størrelse. Det er ikke så overraskende da vi fra a) vet at μ med stor sikkerhet ligger mellom 87.6 og 107.4 gram, som ligger et godt stykke nedenfor 115.

c

Generelt er P-verdien lik sannsynligheten, beregnet under forutsetning av at nullhypotesen er sann, for at vi vil få en verdi av testobservatoren som er minst like mye i motsetning til nullhypotesen som den verdien vi faktisk fikk. Så her er P-verdien lik sannsynligheten, når $\mu = 115$, for at vi vil få en verdi av testobsetvatorene T som er lik $t_{obs} = -4.88$ eller mindre, dvs

$$P(T \leq t_{obs} \mid \mu = 115).$$

Fra tabellen over kritiske verdier for t-fordelingen ser vi at

$$-t_{0.00001,27} \leq t_{obs} \leq -t_{0.0001,27},$$

hvilket betyr at

$$0.00001 \leq P(T \leq t_{obs} \mid \mu = 115) \leq 0.0001,$$

altså at P-verdien ligger mellom 0.00001 og 0.0001, og er betydelig mindre enn signifikansnivået 1% fra b).

Oppgave 2

a

Vi finner momentestimatoren $\tilde{\theta}$ ved å løse ligningen vi får når vi setter første teoretiske moment $E(X_i)$ lik første empiriske moment $\bar{X} = 1/n \sum_{i=1}^n X_i$. Vi får:

$$\frac{1}{1 - \tilde{\theta}} = \bar{X}.$$

Det gir

$$\tilde{\theta} = \frac{\bar{X} - 1}{\bar{X}}.$$

b

La $x_1, \dots, x_n$ være de observerte verdiene av $X_1, \dots, X_n$. Da er likelihood funksjonen gitt ved

$$L(\theta) \stackrel{uif}{=} \prod_{i=1}^n f(x_i; \theta) = \prod_{i=1}^n \frac{e^{-\theta x_i} (\theta x_i)^{x_i-1}}{x_i!} = e^{-\theta \sum_{i=1}^n x_i} \theta^{\sum_{i=1}^n x_i - n} \prod_{i=1}^n \frac{x_i^{x_i-1}}{x_i!}.$$

Det gir log-likelihood-funksjonen

$$\log L(\theta) = -n\theta\bar{x} + n(\bar{x} - 1)\log(\theta) + \sum_{i=1}^n (x_i - 1)\log(x_i) - \sum_{i=1}^n \log(x_i!).$$

Vi får maksimum likelihood-estimatet $\hat{\theta}$ ved å løse ligningen $\frac{\partial \log L(\theta)}{\partial \theta} = 0$.
Altså er $\hat{\theta}$ løsningen av ligningen

$$-n\bar{x} + n\frac{\bar{x} - 1}{\hat{\theta}} = 0,$$

som gir maksimum likelihood-estimatet

$$\hat{\theta} = \frac{\bar{x} - 1}{\bar{x}},$$

og tilsvarende maksimum likelihood-estimator

$$\hat{\theta} = \frac{\bar{X} - 1}{\bar{X}}.$$

Vi ser at maksimum likelihood-estimatoren er den samme som momentestimatoren.

c

Fisher informasjonen i én observasjon er gitt ved

$$I(\theta) = -E\left(\frac{\partial^2 \log f(X_i; \theta)}{\partial \theta^2}\right).$$

Vi har

$$\log(f(X_i; \theta)) = -\theta X_i + (X_i - 1)\log(\theta) + (X_i - 1)\log(X_i) - \log(X_i!),$$

slik at

$$\frac{\partial \log f(X_i; \theta)}{\partial \theta} = -X_i + \frac{X_i - 1}{\theta}$$

og

$$\frac{\partial^2 \log f(X_i; \theta)}{\partial \theta^2} = -\frac{X_i - 1}{\theta^2}.$$

Vi får dermed

$$\begin{aligned} I(\theta) &= -\mathbb{E}\left(-\frac{X_i - 1}{\theta^2}\right) \\ &= \frac{\mathbb{E}(X_i) - 1}{\theta^2} \\ &= \frac{1}{\theta^2} \left(\frac{1}{1 - \theta} - 1\right) = \frac{1}{\theta(1 - \theta)}. \end{aligned}$$

d

Det er kjent at maksimum likelihood estimatoren $\hat{\theta}$ (under visse regularitetsbetingelser som er oppfylt her) er tilnærmet normalfordelt $N(\theta, \sigma_{\hat{\theta}}^2)$ med $\sigma_{\hat{\theta}}^2 = 1/(nI(\theta))$. Her får vi

$$\sigma_{\hat{\theta}}^2 = 1/(nI(\theta)) = \frac{\theta(1 - \theta)}{n}.$$

Oppgave 3

a

Konstantleddet β_0 i den enkle lineære regresjonsmodellen er forventet billettsalg når $x_{i1} - \bar{x}_1 = 0$, dvs. når produksjonskostnadene er lik gjennomsnittet (som er 8.74 millioner USD). Fra R-utskriften ser vi at $\hat{\beta}_0 = 85.2$, så når produksjonskostnadene er gjennomsnittlige, vil en forvente at billettsalget er på 85.2 millioner USD. Stigningstallet β_1 er forventet endring i billettsalget når produksjonskostnadene øker med 1 million USD. Her er $\hat{\beta}_1 = 7.98$, så hvis produksjonskostnadene øker med 1 million USD, vil en forvente at billettsalget øker med 7.98 millioner USD.

Videre vet vi at $(\hat{\beta}_1 - \beta_1)/S_{\hat{\beta}_1} \sim t_{10-2}$, der $S_{\hat{\beta}_1}^2$ er den forventningsrette estimatoren for $\text{Var}(\hat{\beta}_1)$. Et 95% kondidensintervall for β_1 er dermed gitt ved

$$\hat{\beta}_1 \pm t_{0.025,8} s_{\hat{\beta}_1}.$$

Når vi setter tall fra R-utskriften, får vi

$$7.98 \pm 2.306 \cdot 1.223 = (5.15, 10.80).$$

Vi ser at verdien 10 er innenfor konfidensintervallet, dog i nærheten av øvre grense. Det betyr at om vi hadde testet $H_0 : \beta_1 = 10$ mot $H_a : \beta_1 \neq 10$, altså

om forventet økning i billettsalget per ekstra million USD investert i filmen er 10 millioner USD, ville vi ikke kunne forkaste H_0 ved 5% signifikansnivå.

b

Det første plottet viser residualene $e_i = Y_i - \hat{Y}_i$ mot $\hat{Y}_i$. Det er ikke noe åpenbart mønster i plottet. Antakelsen om at sammenhengen mellom billettsalg og produksjonskostnader er lineær ser altså ut til å være grei.

Det andre plottet er et normalfordelingsplott av de standardiserte residualene e_i^* . Når disse punktene ikke ligger nær en rett linje, har vi en indikasjon på at feilleddene ikke er normalfordelt. Punktene i plottet ligger omtrent langs en rett linje, med unntak av de største verdiene. Det kan tyde på at antakelsen om at feilleddene er normalfordelt ikke stemmer helt, og at de har en fordeling som er mer tunghalet.

Det tredje plottet viser de standardiserte residualene $e_i^* = e_i/s_{e_i}$ mot $\hat{Y}_i$, og er konstruert for undersøke om variansen til ϵ_i i avhenger av $E(Y_i)$, og altså varierer. Det er ikke noe åpenbart mønster i dette plottet heller, så det ser ikke ut til å være noe alvorlig avvik fra antakelsen om konstant varians.

c

Da $\epsilon_1, \dots, \epsilon_{10} \stackrel{uif}{\sim} N(0, \sigma^2)$, er også Y_i ene uavhengige og normalfordelt med varians σ^2 . Da $\hat{Y}$ er en lineærkombinasjon av Y_i -ene, må denne også være normalfordelt. Vi får

$$\begin{aligned} \sigma_{\hat{Y}}^2 &= \text{Var}(\hat{Y}) = \text{Var}\left(\sum_{i=1}^{10} \left(\frac{1}{10} + \frac{(x_1^* - \bar{x}_1)(x_{i1} - \bar{x}_1)}{S_{xx}}\right) Y_i\right) \\ &\stackrel{uavh.}{=} \left(\sum_{i=1}^{10} \frac{1}{n^2} + \frac{2}{10} \frac{(x_1^* - \bar{x}_1)}{S_{xx}} \sum_{i=1}^{10} (x_{i1} - \bar{x}_1) + \frac{(x_1^* - \bar{x}_1)^2}{S_{xx}^2} \sum_{i=1}^{10} (x_{i1} - \bar{x}_1)^2\right) \text{Var}(Y_i) \\ &= \sigma^2 \left(\frac{1}{10} + \frac{(x_1^* - \bar{x}_1)^2}{S_{xx}}\right). \end{aligned}$$

Til slutt vet vi at $\hat{\beta}_0$ og $\hat{\beta}_1$ er forventningsrette for β_0 og β_1 , slik at

$$E(\hat{Y}) = E(\hat{\beta}_0 + \hat{\beta}_1(x_1^* - \bar{x})) = E(\hat{\beta}_0) + E(\hat{\beta}_1)(x_1^* - \bar{x}) = \beta_0 + \beta_1(x_1^* - \bar{x}) = \mu_{Y|x^*}.$$

Altså er $\hat{Y} \sim N(\mu_{Y|x^*}, \sigma_{\hat{Y}}^2)$.

d

La $S_{\hat{Y}}^2 = S^2 \left(\frac{1}{10} + \frac{(x_1^* - \bar{x}_1)^2}{S_{xx}}\right)$. Da er $S_{\hat{Y}}/\sigma_{\hat{Y}} = S^2/\sigma^2$. Vi får

$$T = \frac{\hat{Y} - \mu_{Y|x^*}}{S_{\hat{Y}}} = \frac{(\hat{Y} - \mu_{Y|x^*})/\sigma_{\hat{Y}}}{S_{\hat{Y}}/\sigma_{\hat{Y}}} = \frac{(\hat{Y} - \mu_{Y|x^*})/\sigma_{\hat{Y}}}{\sqrt{((10-2)S^2/\sigma^2)/(10-2)}} = \frac{Z}{\sqrt{U/8}}$$

der $Z \sim N(0, 1)$ og $U = (10 - 2)S^2/\sigma^2 \sim \chi_8^2$. Dermed er $T \sim t_8$. Vi får

$$\begin{aligned} P\left(-t_{\alpha/2,8} \leq \frac{\hat{Y} - \mu_{Y|x^*}}{S_{\hat{Y}}} \leq t_{\alpha/2,8}\right) &= 1 - \alpha \\ \rightarrow P\left(\hat{Y} - t_{\alpha/2,8}S_{\hat{Y}} \leq \mu_{Y|x^*} \leq \hat{Y} + t_{\alpha/2,8}S_{\hat{Y}}\right) &= 1 - \alpha. \end{aligned}$$

Et $100 \cdot (1 - \alpha)\%$ konfidensintervall for $\mu_{Y|x^*}$ er dermed gitt ved

$$\hat{y} \pm t_{\alpha/2,8}S_{\hat{Y}},$$

der $\hat{y}$ og $s_{\hat{Y}}$ er observerte verdier av $\hat{Y}$ og $S_{\hat{Y}}$.

For $x_1^* = 301$ får vi

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1(x_1^* - \bar{x}) = 85.24 + 7.98 \cdot (301 - 8.74) = 2417.$$

Altså er forventet billettsalg utrolige 2.49 milliarder USD i henhold til modellen. Tilhørende 95% konfidensintervall er gitt ved, der vi får $s = 14.26$ fra R-utskriften,

$$\hat{y} \pm t_{0.025,8}S_{\hat{Y}} = 2417 \pm 2.306 \cdot 14.26 \sqrt{\frac{1}{10} + \frac{(301 - 8.74)^2}{135.864}} = 2417 \pm 824,$$

altså (1592, 3241). Dette er et usedvanlig bredt konfidensintervall, hvilket betyr at det er knyttet svært stor usikkerhet til anslaget $\hat{y}$ for forventet billettsalg.

Verdien $x^* = 301$ ligger langt bortenfor alle observerte verdier x_i . En bør være varsom med å ekstrapolere modellen så langt forbi området med data, og en bør dermed ta estimatet med en klype salt.

e

Konstantleddet β_0 i den multiple lineære regresjonsmodellen er forventet billettsalg når både $x_{i1} - \bar{x}_1 = 0$ og $x_{i2} = 0$, dvs. når produksjonskostnadene er lik gjennomsnittet (som er 8.74 millioner USD) og en ikke har brukt penger på markedsføring. Fra R-utskriften ser vi at $\hat{\beta}_0 = 48.8$, så når produksjonskostnadene er gjennomsnittlige og en bruker penger på markedsføring, vil en forvente at billettsalget er på 48.8 millioner USD. Nå er β_1 er forventet endring i billettsalget når produksjonskostnadene øker med 1 million USD **og** markedsføringskostnadene holdes konstant. Vi ser at $\hat{\beta}_1 = 4.23$, så hvis produksjonskostnadene øker med 1 million USD mens markedsføringskostnadene er de samme, vil en forvente at billettsalget øker med 4.23 millioner

USD. Altså har $\hat{\beta}_1$ endret seg nokså mye fra den enkle lineære regresjonsmodellen, og det skyldes konfundering på grunn av nokså sterk (positiv) korrelasjon mellom produksjons- og markedsføringskostnadene, som vi ser av matrisespredningsplottet. Videre er β_2 forventet endring i billettsalget når markedsføringskostnadene øker med 1 million USD **og** produksjonskostnadene holdes konstant. Vi ser at $\hat{\beta}_2 = 7.44$, så hvis markedsføringskostnadene øker med 1 million USD mens produksjonskostnadene er de samme, vil en forvente at billettsalget øker med 7.44 millioner USD.

Hypotesetesten dreier seg om modellen som inkluderer markedsføringskostnader er bedre enn den enkle, første modellen uten, dvs.

$$H_0 : \beta_2 = 0 \text{ mot } H_a : \beta_2 \neq 0.$$

Vi ser at den tilsvarende P-verdien er på bare 0.0045, hvilket betyr at vi forkaster H_0 med god margin ved 5% signifikansnivå. Det betyr at markedsføringskostnader bidrar signifikant til å forklare billettsalget, hvilket vi også ser av den ekvivalente t-testen for om $\beta_2 \neq 0$ i den øverste utskriften fra R. Dermed velger vi den nye modellen, som inneholder både produksjons- og markedsføringskostnader.

Løsningsforslag til eksamen i STK1110 16. desember 2019

Oppgave 1

a) Hvis vi tester

$$H_0 : \mu \leq 5.0 \quad \text{mot} \quad H_a : \mu > 5.0,$$

er nullhypotesen at mengden organisk karbon i drikkevannet ikke overstiger grenseverdien 5.0 mg/l, mens den alternative hypotesen er at mengden organisk karbon oversiger grenseverdien. Hvis vi forkaster nullhypotesen, vil vi være rimelig sikre på at drikkevannet inneholder for mye organisk karbon.

Hvis vi tester

$$H_0 : \mu \geq 5.0 \quad \text{mot} \quad H_a : \mu < 5.0.$$

er nullhypotesen at mengden organisk karbon i drikkevannet overstiger grenseverdien 5.0 mg/l, mens den alternative hypotesen er at mengden organisk karbon ikke oversiger grenseverdien. Hvis vi forkaster nullhypotesen, vil vi være rimelig sikre på at drikkevannet ikke inneholder for mye organisk karbon.

b) Vi vil teste

$$H_0 : \mu \geq 5.0 \quad \text{mot} \quad H_a : \mu < 5.0.$$

Vi har at $\bar{X} \sim N(\mu, \sigma^2/5)$ og at $(\bar{X} - \mu)/(\sigma/\sqrt{5}) \sim N(0, 1)$. Siden alternativet er $\mu < 5$, er det rimelig å forkaste nullhypotesen hvis

$$Z = \frac{\bar{X} - 5}{\sigma/\sqrt{5}} \leq c$$

for en passende valgt c . For at testen skal få signifikansnivå 5% må vi velge $c = -z_{0.05} = -1.645$. For da har vi at [der Φ er den kumulative standardnormalfordelingen]

$$\begin{aligned} P(\text{forkast } H_0 \mid H_0 \text{ er sann}) &= P\left(\frac{\bar{X} - 5}{\sigma/\sqrt{5}} \leq -z_{0.05} \mid \mu \geq 5\right) \\ &\leq P\left(\frac{\bar{X} - 5}{\sigma/\sqrt{5}} \leq -z_{0.05} \mid \mu = 5\right) \\ &= \Phi(-z_{0.05}) \\ &= 0.05 \end{aligned}$$

som viser at testen har signifikansnivå 5%.

Med tallene i oppgaven finner vi at $\bar{x} = 4.66$. Med $\sigma = 0.5$, får testobservatoren verdien

$$z = \frac{4.66 - 5}{0.5/\sqrt{5}} = -1.52$$

Altså er $z > -z_{0.05} = -1.645$, så vi forkaster ikke nullhypotesen på nivå 5%.

c) Generelt er P-verdien lik sannsynligheten, beregnet under forutsetning at nullhypotesen er sann, for at vi vil få en verdi av testobservatoren som er minst like mye i motsetning til nullhypotesen som den verdien vi faktisk fikk. Så her er P-verdien lik sannsynligheten, når $\mu = 5$, for at vi vil få en verdi av testobsetvatorene Z som er lik -1.52 eller mindre.

Ved å bruke tabellen over den kumulative standardnormalfordelingen, har vi at $\Phi(-1.52) = 0.064$, så P-verdien er 6.4%.

d) Hvis vi tar n vannprøver, får vi en test med signifikansnivå 5% hvis vi forkaster H_0 så sant

$$Z = \frac{\bar{X} - 5}{\sigma/\sqrt{n}} \leq -z_{0.05}$$

Feil av type II betyr at vi ikke forkaster nullhypotesen når den er gal. Vi har her at

$$\begin{aligned} \beta(\mu') &= P(\text{feil av type II} \mid \mu = \mu') \\ &= P(\text{forkaster ikke } H_0 \mid \mu = \mu') \\ &= P\left(\frac{\bar{X} - 5}{\sigma/\sqrt{n}} > -z_{0.05} \mid \mu = \mu'\right) \\ &= P\left(\frac{\bar{X} - \mu'}{\sigma/\sqrt{n}} > -z_{0.05} + \frac{5 - \mu'}{\sigma/\sqrt{n}} \mid \mu = \mu'\right) \\ &= 1 - \Phi\left(-z_{0.05} + \frac{5 - \mu'}{\sigma/\sqrt{n}}\right) \end{aligned}$$

Vi skal bestemme n slik at $\beta(4.5) \leq 0.10$. Nå har vi at $z_{0.05} = 1.645$ og $\sigma = 0.5$, så for $\mu' = 4.5$ skal vi bestemme n slik at

$$1 - \Phi\left(-1.645 + \frac{5 - 4.5}{0.5/\sqrt{n}}\right) \leq 0.10$$

dvs. slik at

$$\Phi(-1.645 + \sqrt{n}) \geq 0.90$$

Nå har vi at $\Phi(1.28) = 0.90$, så vi må velge n slik at

$$-1.645 + \sqrt{n} \geq 1.28$$

eller

$$\sqrt{n} \geq 1.28 + 1.645 = 2.925$$

som gir

$$n \geq 2.925^2 = 8.56$$

Det betyr at ingeniørene må ta minst 9 vannprøver.

e) Når σ er ukjent må vi estimere variansen σ^2 med

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Vi bruker da testobservatoren

$$T = \frac{\bar{X} - 5}{S/\sqrt{5}}$$

Når $\mu = 5$ er testobservatoren t-fordelt med $5 - 1 = 4$ frihetsgrader, så vi får en test med signifikansnivå 5% hvis vi forkaster nullhypotesen så sant $T \leq -t_{0.05,4}$.

Oppgave 2

a) Vi finner momentestimatoren ved å løse ligningen vi får når vi setter første teoretiske moment, dvs. $E(X_i)$, lik første empiriske moment, dvs. $\bar{X}$. Det er gitt i oppgaven at $E(X_i) = \theta\sqrt{\frac{\pi}{2}}$, så her er momentestimatoren $\tilde{\theta}$ gitt ved ligningen

$$\tilde{\theta}\sqrt{\frac{\pi}{2}} = \bar{X}$$

Det gir

$$\tilde{\theta} = \bar{X}\sqrt{\frac{2}{\pi}}$$

Det er videre gitt i oppgaven at $E(X_i^2) = 2\theta^2$. Av det får vi at

$$V(X_i) = E(X_i^2) - [E(X_i)]^2 = 2\theta^2 - \left(\theta\sqrt{\frac{\pi}{2}}\right)^2 = 2\theta^2 - \frac{\pi}{2}\theta^2 = \frac{4-\pi}{2}\theta^2$$

Av sentralgrensesetningen følger det nå at $\bar{X}$ er tilnærmet $N(\mu_X, \sigma_X^2/n)$ -fordelt, der

$$\mu_X = E(X_i) = \theta\sqrt{\frac{\pi}{2}} \quad \text{og} \quad \sigma_X^2 = V(X_i) = \frac{4-\pi}{2}\theta^2$$

Dermed er $\tilde{\theta} = \sqrt{\frac{2}{\pi}}\bar{X}$ tilnærmet normalfordelt med forventningsverdi lik

$$\mu_{\tilde{\theta}} = \sqrt{\frac{2}{\pi}}\mu_X = \sqrt{\frac{2}{\pi}}\theta\sqrt{\frac{\pi}{2}} = \theta$$

og varians lik

$$\sigma_{\tilde{\theta}}^2 = \left(\sqrt{\frac{2}{\pi}}\right)^2 \frac{\sigma_X^2}{n} = \frac{2}{\pi} \cdot \frac{4-\pi}{2} \cdot \frac{\theta^2}{n} = \frac{4-\pi}{n\pi}\theta^2$$

b) La $x_1, \dots, x_n$ være de observerte verdiene av $X_1, \dots, X_n$. Da er likelihood funksjonen gitt ved

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta) = \prod_{i=1}^n \frac{1}{\theta^2} x_i e^{-x_i^2/(2\theta^2)} = \frac{1}{\theta^{2n}} \left(\prod_{i=1}^n x_i \right) \exp\left(-\frac{1}{2\theta^2} \sum_{i=1}^n x_i^2\right)$$

Log-likelihooden blir

$$\ln L(\theta) = -2n \ln \theta + \sum_{i=1}^n x_i - \frac{1}{2\theta^2} \sum_{i=1}^n x_i^2$$

Vi deriver med hensyn på θ og får at

$$\frac{\partial}{\partial \theta} \ln L(\theta) = -\frac{2n}{\theta} + \frac{1}{\theta^3} \sum_{i=1}^n x_i^2$$

Vi får maksimum likelihood estimatet $\hat{\theta}$ ved å løse ligningen $\frac{\partial}{\partial \theta} \ln L(\theta) = 0$. Altså er $\hat{\theta}$ løsningen av ligningen

$$-\frac{2n}{\hat{\theta}} + \frac{1}{(\hat{\theta})^3} \sum_{i=1}^n x_i^2 = 0$$

som gir

$$(\hat{\theta})^2 = \frac{1}{2n} \sum_{i=1}^n x_i^2$$

Maksimum likelihood estimatet blir dermed

$$\hat{\theta} = \sqrt{\frac{1}{2n} \sum_{i=1}^n x_i^2}$$

Vi får maksimum likelihood estimatoren ved å erstatte de observerte x_i -ene med de stokastiske X_i -ene, så maksimum likelihood estimatoren er

$$\hat{\theta} = \sqrt{\frac{1}{2n} \sum_{i=1}^n X_i^2}$$

c) Fisher informasjonen i én observasjon er gitt ved

$$I(\theta) = -E \left(\frac{\partial^2}{\partial \theta^2} \ln f(X_i; \theta) \right)$$

For $X_i > 0$ har vi nå at

$$\ln f(X_i; \theta) = -2 \ln \theta + \ln X_i - \frac{1}{2\theta^2} X_i^2$$

Dermed er

$$\frac{\partial}{\partial \theta} \ln f(X_i; \theta) = -\frac{2}{\theta} + \frac{1}{\theta^3} X_i^2$$

og

$$\frac{\partial^2}{\partial \theta^2} \ln f(X_i; \theta) = \frac{2}{\theta^2} - \frac{3}{\theta^4} X_i^2$$

Det er gitt i oppgaven at $E(X_i^2) = 2\theta^2$. Dermed er Fisher informasjonen i én observasjon gitt ved

$$I(\theta) = -E\left(\frac{2}{\theta^2} - \frac{3}{\theta^4}X_i^2\right) = -\frac{2}{\theta^2} + \frac{3}{\theta^4}E(X_i^2) = -\frac{2}{\theta^2} + \frac{3}{\theta^4}2\theta^2 = -\frac{2}{\theta^2} + \frac{6}{\theta^2} = \frac{4}{\theta^2}$$

d) Det er kjent at maksimum likelihood estimatoren $\hat{\theta}$ (under visse regularitetsbetingelser som er oppfylt her) er tilnærmet normalfordelt med forventningsverdi θ og varians $1/[nI(\theta)]$. Her får vi variansen

$$\sigma_{\hat{\theta}}^2 = \frac{1}{nI(\theta)} = \frac{1}{n(4/\theta^2)} = \frac{\theta^2}{4n}$$

Både momentestimatoren $\tilde{\theta}$ og maksimum likelihood estimatoren $\hat{\theta}$ er tilnærmet normalfordelt med forventning θ . For å sammenligne estimatorene, kan vi dermed sammenligne variansene. Vi finner at

$$\frac{\sigma_{\tilde{\theta}}^2}{\sigma_{\hat{\theta}}^2} = \frac{\frac{4-\pi}{n\pi}\theta^2}{\frac{\theta^2}{4n}} = \frac{4(4-\pi)}{\pi} = 1.093$$

Det betyr at variansen til momentestimatoren $\tilde{\theta}$ er 9.3% større enn variansen til maksimum likelihood estimatoren $\hat{\theta}$, så maksimum likelihood estimatoren er å foretrekke.

Oppgave 3

a) Konstantleddet β_0 i regresjonsmodellen (1) er forventet utslipp når $x_{i1} = 0$, dvs. når lufttrykket er 750 mmHg. Av R-utskriften har vi estimatet $\hat{\beta}_0 = 1.03$, så når lufttrykket er 750 mmHg vil vi forvente at utslippet er 1.03 ppm (parts per milion). Signingskoeffisienten β_1 er forventet endring i utslippet når lufttrykket øker med 1 mmHg. Her har vi estimatet $\hat{\beta}_1 = 0.0182$, så hvis lufttrykket øker med 1 mmHg vil vi forvente at utslippet øker med 0.0182 ppm.

Vi har at $(\hat{\beta}_1 - \beta_1)/S_{\hat{\beta}_1}$ er t-fordelt med $n - 2 = 20 - 2 = 18$ frihetsgrader. [Her er $S_{\hat{\beta}_1}^2$ den vanlige forventningsrette estimatoren for $V(\hat{\beta}_1)$.] Av dette følger det ved et standard argument at et 99% konfidensintervall for β_1 er gitt ved

$$\hat{\beta}_1 \pm t_{0.005,18} \cdot s_{\hat{\beta}_1}$$

Av tabellen først i oppgavesettet har vi at $t_{0.005,18} = 2.878$ og av R-utskriften har vi at $s_{\hat{\beta}_1} = 0.00338$. Vi får dermed konfidensintervallet

$$0.0182 \pm 2.878 \cdot 0.00338$$

dvs. fra 0.0085 ppm til 0.0279 ppm.

b) Vi ser at i modell (1) er $\hat{\beta}_1 = 0.0182$, mens i modell (2) er $\hat{\beta}_1 = 0.0065$. Estimaten for modell (1) er altså nesten tre ganger så stort som estimaten for modell (2). Forklaringen på dette er at regresjonskoeffisienten β_1 ikke betyr det samme i modell (1) og modell (2). I modell (1) er β_1 forventet endring i utslippet når lufttrykket øker med 1 mmHg. Men i modell (2) er β_1 forventet endring i utslippet når lufttrykket øker med 1 mmHg *og luftfuktigheten forblir uendret*. Av matrise-spredningsplottet gitt i oppgaven ser vi at det er negativ korrelasjon mellom

lufttrykk og luftfuktighet. Så når lufttrykket øker, vil typisk luftfuktigheten bli mindre. Og lavere luftfuktighet vil føre til større utslipp. Estimatet for β_1 i modell (1) vil i tillegg til betydningen av lufttrykk også fange opp noe av effekten av luftfuktighet.

c) Hvis lufttrykket er 740 mmHg og luftfuktigheten er 80%, blir forklaringsvariablene $x_1^* = 740 - 750 = -10$ og $x_2^* = 80 - 50 = 30$. Forventet utslipp for disse verdiene av forklaringsvariablene er

$$\mu_{Y \cdot x_1^*, x_2^*} = \beta_0 + \beta_1 x_1^* + \beta_2 x_2^* = \beta_0 - 10\beta_1 + 30\beta_2$$

og en estimator for denne forventningsverdien er

$$\hat{\mu}_{Y \cdot x_1^*, x_2^*} = \hat{\beta}_0 - 10\hat{\beta}_1 + 30\hat{\beta}_2 = 0.9738 - 10 \cdot 0.00645 + 30 \cdot (-0.002655) = 0.830$$

Standardfeilen til estimatoren er

$$\sigma_{\hat{\mu}_{Y \cdot x_1^*, x_2^*}} = \sqrt{V(\hat{\mu}_{Y \cdot x_1^*, x_2^*})}$$

der variansen gitt ved

$$\begin{aligned} V(\hat{\mu}_{Y \cdot x_1^*, x_2^*}) &= V(\hat{\beta}_0 - 10\hat{\beta}_1 + 30\hat{\beta}_2) \\ &= V(\hat{\beta}_0) + (-10)^2 \cdot V(\hat{\beta}_1) + 30^2 \cdot V(\hat{\beta}_2) \\ &\quad + 2 \cdot (-10) \cdot \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) + 2 \cdot 30 \cdot \text{Cov}(\hat{\beta}_0, \hat{\beta}_2) + 2 \cdot (-10) \cdot 30 \cdot \text{Cov}(\hat{\beta}_1, \hat{\beta}_2) \end{aligned} \quad (\text{A})$$

For å bestemme et estimat for variansen (og dermed standardfeilen), trenger vi estimater for variansene og kovariansene i formel (A). Vi kan få estimater for variansene fra R-utskriften, men ikke estimater for kovariansene.

d) Vi setter $\mathbf{C} = (\mathbf{X}'\mathbf{X})^{-1}$. Det er gitt i oppgaven at

$$\mathbf{C} = \begin{pmatrix} c_{00} & c_{01} & c_{02} \\ c_{10} & c_{11} & c_{12} \\ c_{20} & c_{21} & c_{22} \end{pmatrix} = \begin{pmatrix} 0.1460 & 0.0212 & 0.00313 \\ 0.0212 & 0.00483 & 0.000612 \\ 0.00313 & 0.000612 & 0.000138 \end{pmatrix}$$

Vi har at $V(\hat{\beta}_j) = \sigma^2 c_{jj}$ for $j = 0, 1, 2$ og $\text{Cov}(\hat{\beta}_j, \hat{\beta}_\ell) = \sigma^2 c_{j\ell}$ for $j \neq \ell$.

Av R-utskriften har vi at et estimat for σ^2 er $s^2 = 0.0521^2$.

Ved formel (A) har vi da at et estimat for variansen til $\hat{\mu}_{Y \cdot x_1^*, x_2^*}$ er

$$\begin{aligned} \widehat{V}(\hat{\mu}_{Y \cdot x_1^*, x_2^*}) &= \widehat{V}(\hat{\beta}_0) + (-10)^2 \cdot \widehat{V}(\hat{\beta}_1) + 30^2 \cdot \widehat{V}(\hat{\beta}_2) \\ &\quad + 2 \cdot (-10) \widehat{\text{Cov}}(\hat{\beta}_0, \hat{\beta}_1) + 2 \cdot 30 \cdot \widehat{\text{Cov}}(\hat{\beta}_0, \hat{\beta}_2) + 2 \cdot (-10) \cdot 30 \cdot \widehat{\text{Cov}}(\hat{\beta}_1, \hat{\beta}_2) \\ &= s^2 \{c_{00} + 100 \cdot c_{11} + 900 \cdot c_{22} - 20 \cdot c_{01} + 60 \cdot c_{02} - 600 \cdot c_{12}\} \\ &= 0.0521^2 \{0.1460 + 100 \cdot 0.00483 + 900 \cdot 0.000138 - 20 \cdot 0.0212 + 60 \cdot 0.00313 - 600 \cdot 0.000612\} \\ &= 0.0004066 \end{aligned}$$

Et estimat for standardfeilen er dermed

$$s_{\hat{\mu}_{Y \cdot x_1^*, x_2^*}} = \sqrt{\widehat{V}(\hat{\mu}_{Y \cdot x_1^*, x_2^*})} = \sqrt{0.0004066} = 0.0202$$

Et et 95% konfidensintervall for $\mu_{Y \cdot x_1^*, x_2^*}$ er gitt ved

$$\hat{\mu}_{Y \cdot x_1^*, x_2^*} \pm t_{0.025, 17} \cdot s_{\hat{\mu}_{Y \cdot x_1^*, x_2^*}}$$

Av tabellen først i oppgavesettet har vi at $t_{0.025, 17} = 2.110$. Vi får dermed konfidensintervallet

$$0.830 \pm 2.110 \cdot 0.0202$$

dvs. fra 0.787 ppm til 0.873 ppm.

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Statistiske metoder og dataanalyse
Løsningsforslag

Eksamensdag: Tirsdag 18. desember 2018

Tid for eksamen: 09.00 – 13.00

Oppgavesettet er på 5 sider.

Vedlegg: Tabell over normalfordelingen

Tillatte hjelpemidler: Formelsamling for STK1100/STK1110.
Godkjent kalkulator.

Kontroller at oppgavesettet er komplett før
du begynner å besvare spørsmålene.

Oppgave 1

a

Siden $E[X] = np$ fås $E[\hat{p}] = \frac{E(X)}{n} = \frac{np}{n} = p$, dvs. $\hat{p}$ er forventningsrett for p

Videre has $V(\hat{p}) = \frac{V(X)}{n^2} = \frac{np(1-p)}{n^2} = \frac{p(1-p)}{n}$.

b

Likelihooden er sannsynligheten (eller tettheten) til observasjonene, her X , innsatt observasjonene og sett på som en funksjon av den (de) ukjente parametrene. Siden $P(X = x) = \binom{n}{x} p^x (1-p)^{n-x}$ når $X \sim \text{Bin}(n, p)$ blir $L(p) = \binom{n}{X} p^X (1-p)^{n-X}$.

Å maksimere $L(p)$ er ekvivalent med å maksimere log-likelihood $l(p) = \ln(L(p)) = \ln\left(\binom{n}{X}\right) + X \ln(p) + (n-X) \ln(1-p)$. Vi har $l'(p) = X/p - (n-X)/(1-p)$ og denne satt lik null gir en ligning med løsning $\hat{p} = X/n$.

Fra generell likelihoodteori has at $\hat{p}$ er tilnærmet normalfordelt med forventning p og varians gitt ved $1/I_n(p) = -1/E[l''(p)]$. Siden $-l''(p) = X/p^2 + (n-X)/(1-p)^2$ som har forventning $-E[l''(p)] = np/p^2 + n(1-p)/(1-p)^2 = n(1/p + 1/(1-p)) = n/(p(1-p))$ fås (tilnærmet) varians for $\hat{p}$ lik $p(1-p)/n$ som er det samme som ble utledet i punkt a.

c

Det er grunn til å tvile på nullhypotesen $H_0 : p = p_0$ hvis det er stor forskjell mellom $\hat{p}$ og p_0 . Vi må ta hensyn til usikkerheten i $\hat{p}$ og derfor er det rimelig å forkaste hvis $|Z(p_0)| = |\hat{p} - p_0| \sqrt{n}/(p_0(1-p_0))$ er stor. Siden 1.96 er 97.5% percentilen i standardnormalfordelingen vil da, under nullhypotesen, $P(|Z(p_0)| > 1.96 | H_0) = 0.05 = \alpha$ som er testen fastsatte nivå. Dette betyr

(Fortsettes på side 2.)

at vi har en test med nivå 0.05 for den aktuelle situasjonen ved å forkaste hvis $|Z(p_0)| = \left| \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)}} \sqrt{n} \right| > 1.96$.

Med $n = 50$ og $X = 15$ blir $\hat{p} = 0.3$ og dermed blir testobservatoren $Z(0.5) = -2.828 < -1.96$, så $H_0 : p = 0.5$ forkastes på 5% nivå. Testens (tilnærmede) P-verdi blir $2P(Z < -2.83) = 2 * 0.0023 = 0.0046$ når Z er standard normalfordelt.


d

En generell sammenheng mellom hypotesetesting (med tosidig alternativ) og konfidensintervall gir at mengden

$$\{\theta_0 : H_0 : \theta = \theta_0 \text{ ikke forkastes med nivå } \alpha\}$$

er et $(1 - \alpha)100\%$ konfidensintervall for θ . I det aktuelle tilfellet er dette $\{p_0 : |Z(p_0)| < 1.96\}$, så dette intervallet blir dermed et tilnærmet 95% konfidensintervall for p .

Med tallene $X = 15$ og $n = 50$ i punkt c får vi følgende plott av $Z(p)$ mot p :



95% konfidensintervallet kan avleses som (0.19, 0.44) (ca.).

Vi har at

$$|Z(p_0)| < 1.96 \Leftrightarrow (\hat{p} - p)^2 n < 1.96^2 p(1-p) \Leftrightarrow p^2 - 2\hat{p}p + \hat{p}^2 < 1.96^2 p/n - 1.96^2 p^2/n$$

som er en 2. gradsuliket i p .

e

Løsningen på 2.gradsuliketen er oppgitt som

$$\frac{\hat{p} + 1.96^2/2n}{1 + 1.96^2/n} \pm \frac{1.96}{\sqrt{n}} \frac{\sqrt{\hat{p}(1-\hat{p}) + 1.96^2/4n}}{1 + 1.96^2/n}$$

Hvis vi fjerner ledd av typen a/n finner vi at intervallet kan tilnærmes med $\hat{p} \pm 1.96\sqrt{\hat{p}(1-\hat{p})/n}$.

(Fortsettes på side 3.)

Med $\frac{\hat{p}-p}{\sqrt{\hat{p}(1-\hat{p})}}\sqrt{n}$ tilnærmet standardnormalfordelt har vi

$$0.95 \approx P(-1.96 < \frac{\hat{p}-p}{\sqrt{\hat{p}(1-\hat{p})}}\sqrt{n} < 1.96).$$

Men $-1.96 < \frac{\hat{p}-p}{\sqrt{\hat{p}(1-\hat{p})}}\sqrt{n} < 1.96 \Leftrightarrow -1.96\frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} < \hat{p}-p < 1.96\frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}}$
som igjen er ekvivalent med $\hat{p} - 1.96\frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} < p < \hat{p} + 1.96\frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}}$, dvs.
 $\hat{p} \pm 1.96\sqrt{\hat{p}(1-\hat{p})/n}$ er et tilnærmet 95% konfidensintervall.

Oppgave 2

a

Estimatene er $\hat{\beta}_0 = 30.511906$, $\hat{\beta}_1 = -0.082898$ for β_0 og β_1 og $s = 2.983$ for σ . Det første parameterestimatet $\hat{\beta}_0$ er et estimat for den forventede reduksjonen når $x_{i1} = 0$ (men siden alle målte temperaturer er betraktelig høyere bør denne verdien fortolkes med forsiktighet). Videre er $\hat{\beta}_1$ et estimat for hvor mye reduksjonen endres når x_{i1} endres med en enhet. Endelig er s et estimat for standard avviket σ for feilleddet ε_i og for variationen i rundt regresjonslinja.

Minste kvadraters estimatene $\hat{\beta}_0$ og $\hat{\beta}_1$ bestemmes som de verdiene (b_0, b_1) som minimerer kvadratsummen $\sum_{i=1}^n (Y_i - b_0 - b_1 x_{i1})^2$

t verdien for $\hat{\beta}_1$ beregnes som $t_1 = \hat{\beta}_1 / se(\hat{\beta}_1) = -0.082898 / 0.007515 = -11.03$ der standardfeilen $\hat{\beta}_1$ er gitt som $0.007515 = se(\hat{\beta}_1)$ ($= s / \sqrt{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2}$). P-verdien for Temperatur beregnes som $2P(T > 14.87)$ der $14.87 = |t_1|$ og T er t-fordelt med $n - 2 = 126$ frihetsgrader.

Siden dette er en enkel lineær regresjonsmodell har vi at R^2 er lik kvadratet av korrelasjonen mellom Y_i og forklaringsvariablen x_{i1} , derfor blir korrelasjonen $-\sqrt{R^2} = -\sqrt{0.4913} = -0.701$ der minustegnet følger siden $\hat{\beta}_1$ er negativ.

b

Grunnen til at $\hat{\beta}_1$ har samme verdi i den enkle lineære regresjonen i punkt a) og den multiple lineære regresjonen i dette punktet er at designet er balansert, vi har like mange observasjoner av hver verdi av x_{i1} for hver verdi x_{i2} . Da vil x_{i1} ikke gi noen informasjon om x_{i2} og de to forklaringsvariablene må være ukorrelerte. Når vi har to ukorrelerte forklaringsvariable vil det å utelate en av dem ikke endre estimert regresjonskoeffisient for den andre.

Selv om det ikke var endring i $\hat{\beta}_1$ er det likevel endring i estimatet s for σ og tilsvarende for σ^2 estimert som $s^2 = \frac{1}{n-3} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$ der $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2}$ er den predikerte verdien ved å bruke begge forklaringsvariable. Dette estimatet er mindre enn s^2 fra den enkle lineære regresjonen siden begge forklaringsvariable er viktige prediktorer for Y_i .

Dette er også grunnen til at den nye $R^2 = 1 - \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$ er større enn den i den enkle lineære regresjonen.

(Fortsettes på side 4.)

Standardfeilen se_1 for $\hat{\beta}_1$ er proporsjonal med s og derfor har dette anslaget blitt mindre i denne situasjonen der forklaringsvariablene er ukorrelert. Dette igjen førte til at t-verdien $\hat{\beta}_1/se_1$ hadde større avvik fra 0.

Siden forklaringsvariablene er ukorrelerte har vi at den multiple R^2 -verdien kan skrives som $R^2 = r_1^2 + r_2^2$ der r_j er korrelasjonen mellom Y_i -ene og x_{ji} -ene. Derfor fås $r_2^2 = R^2 - r_1^2 = 0.722 - 0.491 = 0.231$. Videre blir da korrelasjonen mellom Y_i -ene og x_{2i} -ene lik $-\sqrt{(0.231)} = -0.48$ (hvor igjen minus følger av at $\hat{\beta}_2 < 0$).

c

Det første plottet viser residualene $e_i = Y_i - \hat{Y}_i$ mot tilpassede verdier $\hat{Y}_i$. Den glattede linjen gjennom punktene $(\hat{Y}_i, e_i)$ viser klar kurvatur. Dette indikerer at transformasjoner av forklaringsvariablene eller inklusjon av kvadratledd x_{i1}^2 og x_{i2}^2 og muligens også interaksjonsledd $x_{i1}x_{i2}$ kan forbedre tilpasningen.

Det andre plottet er et qqplot av de ordnede (standardiserte) residualene e_i^* mot persentiler i standardnormalfordelingen. Når disse punktene ikke ligger nær en rett linje har vi en indikasjon på at feilleddene ikke er normalfordelt. Dette igjen kan indikere at å bruke t-fordelingen for å beregne P-values ikke er optimalt (Likelvel, en nærmere kikk på plottet viser at halene i feilleddenes fordeling er lettere enn halene i normalfordelingen og fra dette perspektivet er ikke avviket veldig alvorlig).

Det tredje plottet viser $\sqrt{|e_i^*|}$ mot $\hat{Y}_i$ og er konstruert for undersøke heteroskedastisitet, dvs. om variansen til ε_i avhenger av $E[Y_i]$. Selv om kurven ikke er helt rett har den verdier mellom 0.7 og 1.2 hvilket ikke er betraktet å være så veldig mye så avviket fra konstant varians er neppe alvorlig.

Dette betyr at den delen av modellen som må forbedres er den lineære strukturen ved å inkludere kvadratledd eller transformere forklaringsvariable.

Oppgave 3

a

Siden $SSE/\sigma^2 = (n - k - 1)s^2/\sigma^2 \sim \chi_{n-k-1}^2$ blir

$$E[s^2] = \sigma^2/(n - k - 1)E[(n - k - 1)s^2/\sigma^2] = (\sigma^2/(n - k - 1))(n - k - 1) = \sigma^2,$$

så s^2 er forventningsrett.

Dessuten blir $V(s^2) = (\sigma^4/(n - k - 1)^2)V((n - k - 1)s^2/\sigma^2) = (\sigma^4/(n - k - 1)^2)2(n - k - 1) = 2\sigma^4/(n - k - 1)$ som går mot 0 når $n - k$ går mot uendelig. Ved Tsjebysjeff's ulikhet får vi dermed at for alle $\epsilon > 0$ så vil

$$P(|s^2 - \sigma^2| > \epsilon) < \frac{V(s^2)}{\epsilon^2} = \frac{2\sigma^4}{(n - k - 1)\epsilon^2} \rightarrow 0$$

når $n - k$ går mot uendelig. Dette betyr at s^2 konvergerer (i sannsynlighet) mot σ^2 , dvs. er konsistent for σ^2 .

(Fortsettes på side 5.)

Når $\beta_1 = \beta_2 = \dots = \beta_k = 0$ blir $E[Y] = \beta_0 = \mu$, dvs. alle forventninger blir like. Dermed er $SST/(n-1) = \sum_{i=1}^n (Y_i - \bar{Y})^2/(n-1)$ en forventningsrett estimator for σ^2 . Siden også $(n-1)SST/\sigma^2 \sim \chi_{n-1}^2$ under forutsetningen vil $V(SST/(n-1)) = 2\sigma^4/(n-1)$ og også gå mot 0 når $n-k$ og dermed n går mot uendelig.

Ved å benytte Tshebysjeff igjen blir også $SST/(n-1)$ konsistent for σ^2 .

b

Vi får

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{n-k-1}{n-1} \frac{SSE/(n-k-1)}{SST/(n-1)} \rightarrow 1 - (1-\rho) = \rho$$

siden $\frac{SSE/(n-k-1)}{SST/(n-1)} \rightarrow \frac{\sigma^2}{\sigma^2} = 1$ ved å bruke hintet og $(n-k-1)/(n-1) \rightarrow 1-\rho$ når $n \rightarrow \infty$ og $k/n \rightarrow \rho$.

Tilsvarende for justert R^2 definert som $R_{adj}^2 = 1 - \frac{SSE/(n-k-1)}{SST/(n-1)}$ får vi at teller og nevner begge går mot σ^2 når n og $n-k$ går mot uendelig. Dermed går brøken mot 1 og R_{adj}^2 mot null.

SLUTT

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Løsningsforslag
Eksamensdag: Torsdag 14. desember 2017
Tid for eksamen: 09.00 – 13.00
Oppgavesettet er på 4 sider.
Vedlegg: Ingen
Tillatte hjelpemidler: Formelsamling for STK1100/STK1110.
Godkjent kalkulator.

Kontroller at oppgavesettet er komplett før
du begynner å besvare spørsmålene.

Oppgave 1

a

Under H_0 er $t = (\bar{X} - \mu_0)\sqrt{n}/S \sim t_{24}$ -fordelt siden antall frihetsgrader er $n - 1 = 24$. Med 5% nivå forkaster man da hvis observert $|t| > t_{0.025} = 2.064$ 97.5% persentilen i t_{24} fordelingen.

Her finner vi $t = (2.72 - 2) * 5/\sqrt{3.14} = 2.032$ og altså mindre enn 2.064. Vi forkaster altså ikke nullhypotesen på 5% nivå.

Men $t = 2.032 > 1.711$ som 95-persentilen i t_{24} fordelingen. Dermed ligger P-verdien i intervallet (0.05, 0.10).

b

At $\bar{X} \pm t_{\alpha/2}S/\sqrt{n}$ er et $(1 - \alpha)100\%$ konfidensintervall betyr at

$$P(\bar{X} - t_{\alpha/2}S/\sqrt{n} < \mu_0 < \bar{X} + t_{\alpha/2}S/\sqrt{n}) = 1 - \alpha$$

Men denne begivenheten er ekvivalent med

$$-t_{\alpha/2} < t = \frac{(\bar{X} - \mu_0)\sqrt{n}}{S} < t_{\alpha/2}$$

og $t = \frac{(\bar{X} - \mu_0)\sqrt{n}}{S}$ er den t_{n-1} -fordelte testobservatoren. Nullhypotesen $H_0 : \mu = \mu_0$ forkastes altså nettopp *ikke* for slike verdier μ_0

Her blir konfidensintervallet lik $2.27 \pm 2.064 * \sqrt{3.14}/5 = (1.99, 3.45)$ og $\mu_0 = 2$ ligger (akkurat) innenfor dette intervallet, hvilket altså også innebærer at nullhypotesen $H_0 : \mu = \mu_0 = 2$ ikke forkastes.

(Fortsettes på side 2.)

c

Type II feilen er å unnlate å forkaste når den alternative hypotesen er sann, så for en θ i samsvar med H_a er $\gamma(\theta) = 1 - P(\text{Type II feil} \mid \theta)$.

Man forkaster altså hvis $\bar{X} > \mu_0 + z_{\alpha/2}\sigma/\sqrt{n}$ eller $\bar{X} < \mu_0 - z_{\alpha/2}\sigma/\sqrt{n}$. Men dette er det samme som at $Z = (\bar{X} - \mu)\sqrt{n}/\sigma > (\mu_0 - \mu)\sqrt{n}/\sigma + z_{\alpha/2}$ eller $Z = (\bar{X} - \mu)\sqrt{n}/\sigma < (\mu_0 - \mu)\sqrt{n}/\sigma - z_{\alpha/2}$.

Men siden $Z \sim N(0, 1)$ har den første begivenheten sannsynlighet $1 - \Phi(z_{\alpha/2} - (\mu - \mu_0)\sqrt{n}/\sigma)$ og den andre $\Phi(-z_{\alpha/2} - (\mu - \mu_0)\sqrt{n}/\sigma)$.

Oppgave 2

a

Likelihooden blir $L(\lambda) = \frac{\lambda^X}{X!} \exp(-\lambda)$ hvilket gir log-likelihood $l(\lambda) = -\ln(X!) + X \ln(\lambda) - \lambda$ som har derivert $l'(\lambda) = X/\lambda - 1$. Ved å løse $l'(\hat{\lambda}) = 0$ fås MLE $\hat{\lambda} = X$.

Momentestimatoren er løsningen av ligningen $E[X] = h(\lambda) = X$. Men her er $E[X] = h(\lambda) = \lambda$.

b

Vi har $0.95 \approx P(-1.96 < Z = (\hat{\lambda} - \lambda)/\sqrt{\hat{\lambda}} < 1.96) = P(\hat{\lambda} - 1.96\sqrt{\hat{\lambda}} < \lambda < \hat{\lambda} + 1.96\sqrt{\hat{\lambda}})$ og $\hat{\lambda} \pm 1.96\sqrt{\hat{\lambda}}$ er et tilnærmet 95% konfidensintervall for λ

Intervallet blir $135 \pm 1.96 * \sqrt{135} = (112.2, 157.8)$

Normaltilnærmingen regnes som bra for $\lambda > 10$ og med $X = \hat{\lambda} = 135$ er det god grunn til å anta at λ er vensentlig større enn 10 og dermed at tilnærmingen er god.

c

Dette intervallet gis ved $-1.96 < Z_0 = (\hat{\lambda} - \lambda)/\sqrt{\lambda} < 1.96$ som genererer en 2. gradsulikhhet i λ gitt ved $(\hat{\lambda} - \lambda)^2 < 1.96^2\lambda$ som igjen er ekvivalent $\lambda^2 - (2\hat{\lambda} + 1.96^2)\lambda + \hat{\lambda}^2 < 0$. Løsningen av denne er gitt i formelen.

Grafisk kan løsningen finnes å plote f.eks. $(\hat{\lambda} - \lambda)^2/\lambda$ mot λ og se hvor denne kurven skjærer verdien $1.96^2 \approx 3.84$.

Oppgave 3

a

β_0 estimeres til 311.4, dette er anslaget for antall dødsulykker i 2000. β_1 estimeres til -11.6, så dataene tilsier at vi har hatt en nedgang i dødsulykker på 11.6 per år. Dessuten fås et estimat for standardavviket til Y_i , altså σ , lik 20.88.

Vi har $t = (\hat{\beta}_1 - \beta_1)/se(\beta_1) \sim t_{18-2}$ og dermed blir, med 97.5-persentilen i t_{16} fordelingen lik 2.12, 95% konfidensintervallet for β_1 gitt som $-11.6 \pm$

(Fortsettes på side 3.)

$2.12 * 0.95 = (-13.6, -9.6)$. Siden -10 er med i dette intervallet kan vi ikke forkaste $H_0 : \beta_1 = -10$ på 5% nivå.

Vi har en forklart andel av variasjon $R^2 = 0.90$, altså er det meget sterk sammenheng mellom år og antall dødsulykker over denne perioden.

b

Minste kvadraters estimatorene for (β_0, β_1) er de verdiene som minimerer $\sum_{i=1}^{18} (Y_i - \beta_0 - \beta_1 x_i)^2 = f(\beta_0, \beta_1)$.

Hvis ε_i er normalfordelte (og uavhengige) med forventning 0 og varians σ^2 blir $Y_i \sim N(\mu_i, \sigma^2)$ der $\mu_i = \beta_0 + \beta_1 x_i$ og også uavhengige. Dermed fås likelihood

$$L(\beta_0, \beta_1, \sigma^2) = \prod_{i=1}^{18} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(Y_i - \mu_i)^2\right) = (2\pi\sigma^2)^{-9} \exp\left(-\frac{1}{2\sigma^2}f(\beta_0, \beta_1)\right)$$

Minimering av $f(\beta_0, \beta_1)$ er dermed ekvivalent med maksimering av $L(\beta_0, \beta_1, \sigma^2)$ for enhver gitt σ^2 .

c

Siden $E(Y_i) = \beta_0 + \beta_1 x_i$ blir $E(\bar{Y}) = \beta_0 + \beta_1 \bar{x}$ og dermed fås

$$\begin{aligned} E[\hat{\beta}_1] &= \frac{\sum_i (x_i - \bar{x}) E[(Y_i - \bar{Y})]}{\sum_i (x_i - \bar{x})^2} = \frac{\sum_i (x_i - \bar{x})(\beta_0 + \beta_1 x_i - \beta_0 - \beta_1 \bar{x})}{\sum_i (x_i - \bar{x})^2} \\ &= \beta_1 \frac{\sum_i (x_i - \bar{x})(x_i - \bar{x})}{\sum_i (x_i - \bar{x})^2} = \beta_1 \end{aligned}$$

så vi har forventningsrettet av $\hat{\beta}_1$.

Siden Y_i -ene er uavhengige blir

$$\text{Var}(\hat{\beta}_1) = \frac{\sum_i (x_i - \bar{x})^2 \text{Var}(Y_i)}{[\sum_i (x_i - \bar{x})^2]^2} = \frac{\sigma^2}{\sum_i (x_i - \bar{x})^2}$$

d

I det første plottet ser vi $(\hat{Y}_i, e_i)$ der $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ er de predikerte verdiene og $e_i = Y_i - \hat{Y}_i$ residualene fra modellen. Hvis man ser mønstre i plottet indikerer dette avvik fra linearitetsantagelsen. For det aktuelle plottet er det ikke slike avvik.

Man kan også se om variansen varierer med $\mu_i = \beta_0 + \beta_1 x_i$ hvis variasjonen i e_i øker eller avtar med $\hat{Y}_i$. Heller ikke dette synes å være tilfelle.

Det andre plottet er et qq-plott over de standardiserte residualene e_i^* , som skalerer e_i med S (og influensverdiene slik at alle e_i^* har lik varians). Hvis punktene ligger klart utenfor den rette linja tyder dette på at normalfordelingsantagelsen ikke er tilfredstilt. Dette er heller ikke noe problem her.

Det 3. plottet viser $(\hat{Y}_i, \sqrt{|e_i^*|})$ og brukes til å vurdere mer spesifikt om variansen avhenger av μ_i . Kurven antyder en tendens til litt større varians med store μ_i , men sammenhengen er ikke monoton og ikke spesielt klar.

(Fortsettes på side 4.)

I henhold til Poissonantagelsen bør $\text{Var}(Y_i) = \mu_i$. Plottene viste ikke klart en slik sammenheng. Vi har dessuten at estimatet for σ er $S = 20.88$ og altså $S^2 = 20.88 = 436$. Dette er større enn alle $\hat{Y}_i$ som vil variere fra 125 til 323. Dette indikerer at variasjonen er større enn det Poissonfordelingen tilsier.

SLUTT

Oppgave 1

- (a) Ved den vanlige transformasjonsformelen har $V_i = 2X_i/\theta$ tettheten $g(v) = f(\frac{1}{2}\theta v)^{\frac{1}{2}}\theta$, og dette forenkles til $\frac{1}{2} \exp(-\frac{1}{2}v)$, for $v > 0$. Dette er ganske riktig χ^2_2 -tettheten.

- (b) Fra

$$E \frac{2X_i}{\theta} = 2 \quad \text{og} \quad \text{Var} \frac{2X_i}{\theta} = 4$$

følger $E X_i = \theta$ og $\text{Var} X_i = \theta^2$.

- (c) Estimatoren $\hat{\theta} = \bar{X}$ får forventning θ , og er dermed forventningsrett, og varians θ^2/n .
 (d) Sentralgrenseteoremet medfører her at $\hat{\theta}$ er tilnærmet normalfordelt, med sin forventning θ og sin varians θ^2/n . Dette igjen medfører at

$$t_1 = \frac{\hat{\theta} - \theta}{\hat{\theta}/\sqrt{n}} \approx_d N(0, 1).$$

Det følger av dette at

$$\hat{\theta} \pm 1.96\hat{\theta}/\sqrt{n} = \hat{\theta}(1 \pm 1.96/\sqrt{n})$$

er et konfidensintervall for θ med dekningsgrad tilnærmet 95%.

- Man kan også ta utgangspunkt i at

$$t_2 = \frac{\hat{\theta} - \theta}{\theta/\sqrt{n}} = \sqrt{n}(\hat{\theta}/\theta - 1) \approx_d N(0, 1),$$

hvilket etter transformasjonen fra starten av oppgaven er ensbetydende med

$$\sqrt{n}\{\chi^2_{2n}/(2n) - 1\} \approx_d N(0, 1).$$

Med dette som utgangspunkt, altså $\theta/\sqrt{n}$ som nevner og ikke $\hat{\theta}/\sqrt{n}$, ledes man til

$$\frac{\hat{\theta}}{1 + 1.96/\sqrt{n}} \leq \theta \leq \frac{\hat{\theta}}{1 - 1.96/\sqrt{n}}$$

som tilnærmet 95% konfidensintervall. Endelig kan man også konstruerer et eksakt intervall, via egenskapen $\hat{\theta}/\theta \sim \chi^2_{2n}/(2n)$.

- (e) Her vil $\bar{Y} - \bar{X}$ ha forventning $\theta_2 - \theta_1$, som er null under H_0 , og varians $\theta_1^2/n + \theta_2^2/n$. En fornuftig testobservator er derfor

$$t_1 = \frac{\bar{Y} - \bar{X}}{(\hat{\theta}_1^2/n + \hat{\theta}_2^2/n)^{1/2}},$$

med den den egenskap at $t_1 \approx_d N(0, 1)$ under H_0 . Det samme gjelder

$$t_2 = \frac{\bar{Y} - \bar{X}}{(\hat{\sigma}_1^2/n + \hat{\sigma}_2^2/n)^{1/2}},$$

med de empiriske variansene. Her finner man

$$\begin{aligned} t_1 &= (4.444 - 2.222)/\sqrt{4.444^2/n + 2.222^2/n} = 2.000, \\ t_2 &= (4.444 - 2.222)/\sqrt{2.468^2/n + 4.987^2/n} = 1.786. \end{aligned}$$

Den første er en anelse mer nøyaktig enn den andre, idet man utnytter eksplisitte formler for variansene, men den andre kan alltid skryte av at den er modellrobust. Verdiene t_1 og t_2 ligger på kanten av forkastning for en 0.05-nivå-test.

(f) Fra transformasjonene over finner vi at

$$\sum_{i=1}^n V_i = \frac{2n\bar{X}}{\theta} \sim \chi_{2n}^2.$$

Av dette følger at

$$F = \frac{\bar{Y}}{\bar{X}} = \frac{\theta_2}{\theta_1} \frac{A/(2n)}{B/(2n)} = \rho F_0,$$

der A og B er uavhengige og χ_{2n}^2 -fordelte, som betyr at F_0 er F -fordelt med frihetsgrader $(2n, 2n)$. Fra $\Pr(c \leq F_0 \leq d) = 0.95$, der $c = 0.533$ og $d = 1.875$, pr. tabellen bakerst, følger intervallet $[F/d, F/c]$, som med $F = 2.000$ gir $[1.067, 3.752]$. Data tyder altså på at $\rho > 1$, altså $\sigma_2 > \sigma_1$, på nivå 0.05. Denne analysen er mer presis, altså skarpere, enn den via approksimasjonene over.

Oppgave 2

(a) Siden $\hat{\theta}_i \sim N(\theta_i, \sigma^2)$, med kjent $\sigma = 2.112$, er $\hat{\theta}_i \pm 1.96 \sigma$ et 95% konfidensintervall for θ_i . Altså $13.37 \pm 1.96 \sigma = [9.230, 17.510]$ for Leicester og $7.43 \pm 1.96 \sigma = [3.290, 11.570]$ for Leeds.

(b) Vi har

$$\hat{\theta}_i = \theta_i + \varepsilon_i = \theta_0 + \delta_i + \varepsilon_i \sim N(\theta_0, \sigma^2 + \tau^2)$$

siden en sum av uavhengige normalfordelte størrelser er normalfordelt, og da er det jo nok å beregne forventning og varians.

(c) Størrelsen S^2 er en forventningsrett estimator for variansen til $\hat{\theta}_i$ -ene, altså $\sigma^2 + \tau^2$. Da er det bare å trekke fra og ta en kvadratro, så $\hat{\tau} = (S^2 - \sigma^2)^{1/2} = 2.366$ er et fornuftig estimat for τ .

(d) Under $H_0: \tau = 0$ er S^2 altså den vanlige estimator for σ^2 , og $S^2 \sim \sigma^2 \chi_\nu^2/\nu$, med $\mu = 10$. Vi forkaster H_0 dersom S^2 er stor nok, nemlig $(S^2/\sigma^2)\nu \geq 18.3070$, der denne skranken er 0.95-kvantilen for χ_ν^2 . Dette svarer til $S^2/\sigma^2 \geq 1.8307$ som forkastningsgrense, og her er $S^2/\sigma^2 = 2.2554$. Altså forkaster vi H_0 og tror at $\tau > 0$.

- (e) Vi har $\Pr(c \leq \chi_\nu^2 \leq d) = 0.95$ med $c = 3.2470$ og $d = 20.4832$. Siden $S^2 \sim (\sigma^2 + \tau^2)\chi_\nu^2/\nu$ får vi intervallet $[S^2\nu/d, S^2\nu/c] = [4.9117, 20.9846]$ for parameteren $\sigma^2 + \tau^2$. Ved igjen å trekke fra σ^2 og kvadratrote det til får vi 95% intervallet $[0.6717, 5.1501]$ for τ .

Oppgave 3

- (a) Vi har

$$\ell(p) = x \log p + (n - x) \log(1 - p) + \log \binom{n}{x},$$

med derivert

$$\frac{x}{p} - \frac{n - x}{1 - p}.$$

Settes denne lik 0 får vi $\hat{p} = x/n$, og en sjekk viser at dette virkelig er et maksimum.

- (b) Her får vi

$$\begin{aligned} \ell(p, q, r) &= x \log p + (n - x) \log(1 - p) + y \log q + (n - y) \log(1 - q) \\ &\quad + z \log r + (n - z) \log(1 - r) + c, \end{aligned}$$

der

$$c = \log \binom{n}{x} + \log \binom{n}{y} + \log \binom{n}{z}$$

er en konstant vi i grunnen ikke får bruk for. Om $p = q = r$ holder kan de tre leddene slås sammen, med maksimand $\bar{p} = (x + y + z)/(3n)$.

- (c) Her får vi

$$\begin{aligned} \ell_{\max}(\text{big}) &= x \log \hat{p} + (n - x) \log(1 - \hat{p}) + y \log \hat{q} + (n - y) \log(1 - \hat{q}) \\ &\quad + z \log \hat{r} + (n - z) \log(1 - \hat{r}) + c, \end{aligned}$$

der c er en konstant som blir den samme under både big og under H_0 , og der $\hat{p} = 17/50$, $\hat{q} = 22/50$, $\hat{r} = 14/50$. Vi får $-95.9959 + c$. Under H_0 får vi

$$\begin{aligned} \ell_{\max}(H_0) &= x \log \bar{p} + (n - x) \log(1 - \bar{p}) + y \log \bar{p} + (n - y) \log(1 - \bar{p}) \\ &\quad + z \log \bar{p} + (n - z) \log(1 - \bar{p}) + c = -97.4229 + c. \end{aligned}$$

Differansen blir

$$\Delta = 2\{\ell_{\max}(\text{big}) - \ell_{\max}(H_0)\} = 2.8539.$$

Her er $\Delta \approx_d \chi_2^2$ under H_0 . Verdien 2.8539 er for liten til å gjøre inntrykk på en χ_2^2 (p-verdien blir f.ø. 0.240).

Oppgave 4

- (a) Verdiene $\hat{a} = 18.0346$ og $\hat{b} = 0.0588$ er gitt i utskriften, og

$$\hat{\sigma} = \sqrt{41388.09/(n - 2)} = 47.9514.$$

- (b) Dersom x går ned med 100, går den forventende y ned med $100b$, som estimeres med $100\hat{b} = 5.884$ per hundre tusen, eller ca. 59 reddede mennesker per million.
- (c) For $x_0 = 3900$ blir estimatet for y lik $\hat{y}_0 = \hat{a} + \hat{b}x_0 = 247.51$.
- (d) Vi har

$$Z_0 = Y_0 - \hat{y}_0 = a + bx_0 + \varepsilon_0 - \hat{a} - \hat{b}x_0 = \varepsilon_0 + a - \hat{a} + (b - \hat{b})x_0.$$

Den har forventning 0, siden $\hat{a}$ og $\hat{b}$ er forventningsrette, og variansen blir

$$\text{Var } \varepsilon_0 + \text{Var } \bar{Y} + (x_0 - \bar{x})^2 \text{Var } \hat{b} = \sigma^2 \{1 + 1/n + (x_0 - \bar{x})^2/M\}.$$

Dessuten er Z_0 normalfordelt, qua lineærkombinasjon av uavhengige normalfordelte variable.

- (e) Fra dette får vi

$$t = \frac{Z_0}{\hat{\sigma} \{1 + 1/n + (x_0 - \bar{x})^2/M\}^{1/2}} \sim t_{n-2}.$$

Et prediksjonsintervall som med sannsynlighet 95% vil inneholde Y_0 er derfor

$$\hat{y}_0 \pm 1.734 \{1 + 1/n + (x_0 - \bar{x})^2/M\}^{1/2} = 247.5101 \pm 56.6170 = [149.34, 345.68].$$

Sannheten er f.ø. at y for USA i 1962 var 256.9. Prediksjonsintervallet bygger på flere forutsetninger, bl.a. at modellen kan ekstrapoleres et stykke mot høyre (ingen andre land røyket så meget som USA, i 1962). Dette kan man ikke tro på uten videre, men her har statistikken altså slått til.

- (f) For Ungarn 2014 er det bare å løse ligningen $a + bx_u = y_u = 172.6$ for å komme frem til estimatet $\hat{x}_u = (y_u - \hat{a})/\hat{b} = 2619.48$, antallet sigaretter pr. år pr. person.

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i:	STK1100 — Statistiske metoder og dataanalyse 1 - Løsningsforslag
Eksamensdag:	Mandag 30. november 2015.
Tid for eksamen:	14.30 – 18.00.
Oppgavesettet er på 6 sider.	
Vedlegg:	Tabell over ??
Tillatte hjelpemidler:	Godkjent kalkulator og formelsamling for STK1100/STK1110

Kontroller at oppgavesettet er komplett før du begynner å besvare spørsmålene.

Oppgave 1.

(a) Vi har

$$L(\theta) = f(x_1, \dots, x_n; \theta) \stackrel{\text{uavh}}{=} \prod_{i=1}^n f(x_i; \theta) = \prod_{i=1}^n \frac{1}{\theta^2} x_i e^{-x_i/\theta}$$
$$l(\theta) = \sum_{i=1}^n [-2 \ln(\theta) + \ln(x_i) - x_i/\theta] = -2n \ln(\theta) + \sum_{i=1}^n \ln(x_i) - \frac{1}{\theta} \sum_{i=1}^n x_i$$

(b) Maksimum likelihood prinsippet er å estimere parameteren ved den verdi som maksimerer likelihood funksjonen, som vil tilsvare å maksimere log-likelihood funksjonen. Dette svarer til å velge den parameterverdi som gjør dataene mest "sannsynlige".

Vi har her at

$$\frac{d}{d\theta} l(\theta) = -\frac{2n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n x_i$$

Hvis vi setter dette lik null og løser mhp θ , får vi $\hat{\theta} = \frac{1}{2n} \sum_{i=1}^n x_i$.

(Fortsettes side 2.)

Vi bør i prinsippet også sikre oss at dette er et maks.punkt (men dette har vi ikke lagt mye vekt på i kurset). Vi har at

$$\frac{d^2}{d\theta^2}l(\theta) = \frac{2n}{\theta^2} - \frac{2}{\theta^3} \sum_{i=1}^n x_i$$

Hvis vi setter inn verdien $\hat{\theta}$, får vi $-2n/\hat{\theta}^2$ som er negativ og dermed blir det et maks.punkt

(c) Vi har at momentestimatoren er løsningen av

$$\frac{1}{n} \sum_{i=1}^n x_i = E(X) = 2\theta$$

som gir $\hat{\theta} = \frac{1}{2n} \sum_{i=1}^n x_i$. Videre er

$$E[\hat{\theta}] = E\left[\frac{1}{2n} \sum_{i=1}^n x_i\right] = \frac{1}{2n} \sum_{i=1}^n E[x_i] = \frac{1}{2n} \sum_{i=1}^n 2\theta = \theta$$

og er dermed forventningsrett.

(d) Vi får $\hat{\theta} = 166.40/(2 * 20) = 4.16$. Vi har videre at

$$V(\hat{\theta}) = V\left(\frac{1}{2n} \sum_{i=1}^n x_i\right) = \frac{1}{4n^2} V\left(\sum_{i=1}^n x_i\right) \stackrel{uavh}{=} \frac{1}{4n^2} \sum_{i=1}^n V(x_i) = \frac{1}{4n^2} \sum_{i=1}^n 2\theta^2 = \frac{1}{2n} \theta^2$$

og dermed blir standardfeilen $\sigma_{\hat{\theta}} = \theta/\sqrt{2n}$. Estimert standardfeil blir da $\hat{\sigma}_{\hat{\theta}} = 4.16/\sqrt{40} = 0.658$.

(e) Vi har at

$$\Pr(-z_{\alpha/2} < \frac{\hat{\theta} - \theta}{\hat{\sigma}_{\hat{\theta}}} < z_{\alpha/2}) \approx 1 - \alpha$$

$$\Updownarrow$$

$$\Pr(\hat{\theta} - z_{\alpha/2} \hat{\sigma}_{\hat{\theta}} < \theta < \hat{\theta} + z_{\alpha/2} \hat{\sigma}_{\hat{\theta}}) \approx 1 - \alpha$$

som gir at $\hat{\theta} \pm z_{\alpha/2} \hat{\sigma}_{\hat{\theta}}$ er et tilnærmet $100(1 - \alpha)\%$ konfidensintervall. Setter vi inn data får vi 95% intervallet til å bli $[2.87, 5.45]$.

Alternativt kan en bruke at man har en formel for standard feilen til $\hat{\theta}$

(Fortsettes side 3.)

slik at

$$\begin{aligned}
 \Pr(-z_{\alpha/2} < \frac{\hat{\theta} - \theta}{\theta/\sqrt{2n}} < z_{\alpha/2}) &\approx 1 - \alpha \\
 &\Downarrow \\
 \Pr(-z_{\alpha/2}\sqrt{2n} < \frac{\hat{\theta} - \theta}{\theta} < z_{\alpha/2}/\sqrt{2n}) &\approx 1 - \alpha \\
 &\Downarrow \\
 \Pr(-z_{\alpha/2}/\sqrt{2n} < \frac{\hat{\theta}}{\theta} - 1 < z_{\alpha/2}/\sqrt{2n}) &\approx 1 - \alpha \\
 &\Downarrow \\
 \Pr(1 - z_{\alpha/2}/\sqrt{2n} < \frac{\hat{\theta}}{\theta} < 1 + z_{\alpha/2}/\sqrt{2n}) &\approx 1 - \alpha \\
 &\Downarrow \\
 \Pr(\frac{\hat{\theta}}{1 - z_{\alpha/2}/\sqrt{2n}} > \theta > \frac{\hat{\theta}}{1 + z_{\alpha/2}/\sqrt{2n}}) &\approx 1 - \alpha
 \end{aligned}$$

som gir $\frac{\hat{\theta}}{1 \pm z_{\alpha/2}/\sqrt{2n}}$ som et tilnærmet $100(1 - \alpha)\%$ konfidensintervall. Da får man $[3.18, 6.03]$ som et tilnærmet 95% konfidensintervall

- (f) I bootstrapping så estimerer vi egenskaper til en estimator ved hjelp av simuleringer, basert på at egenskaper som varians, konfidensintervall etc er relatert til hvordan estimatoren oppfører seg ved *gjentatte forsøk*. Problemet i å utføre dette er imidlertid at fordelingen $F(x)$ er ukjent. I ikke-parametrisk bootstrapping bruker vi $\hat{F}(x) = \frac{1}{n} \sum_{i=1}^n I(x_i \leq x)$ som et estimat på $F(x)$ og simulering fra denne svarer til å trekke fra data med tilbakelegging.

Fra simuleringene kan vi da få et Bootstrap persentil intervall som er gitt ved $[2.98, 5.40]$. Dette intervallet er ganske likt det vi fikk ved normaltilnærming, noe som også virker rimelig gitt at histogrammet av bootstrap simuleringene ser ganske normalfordelte ut.

Oppgave 2.

(Fortsettes side 4.)

(a) Vi har at

$$\begin{aligned} L(\beta_0, \beta_1, \sigma^2) &= f(y_1, \dots, y_n; \beta_0, \beta_1, \sigma^2) \stackrel{uavh}{=} \prod_{i=1}^n f(y_i; \beta_0, \beta_1, \sigma^2) \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(y_i - (\beta_0 - \beta_1 x_{i1}))^2} \\ l(\beta_0, \beta_1, \sigma^2) &= \sum_{i=1}^n \left[-\frac{1}{2} \log(2\pi) - \frac{1}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} (y_i - (\beta_0 - \beta_1 x_{i1}))^2 \right] \\ &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - (\beta_0 - \beta_1 x_{i1}))^2 \end{aligned}$$

som viser at maksimering av $l(\beta_0, \beta_1, \sigma^2)$ mhp β_0, β_1 er ekvivalent med minimering av $\sum_{i=1}^n (y_i - (\beta_0 - \beta_1 x_{i1}))^2$ som svarer til minste kvadraters prinsippet.

(b) Den vanlige test-observator er

$$T = \frac{\hat{\beta}_1 - 0}{s_{\hat{\theta}}} = \frac{\hat{\beta}_1 - 0}{\sqrt{\frac{S^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}} \frac{\frac{\hat{\beta}_1 - 0}{\sigma / \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}}{\sqrt{\frac{(n-2)S^2}{\sigma^2(n-2)}}}.$$

Vi har videre at telleren er standard normalfordelt og at $(n-2)S^2/\sigma^2$ er χ^2 -fordelt med $n-2$ frihetsgrader. Ved å bruke at $\hat{\beta}_1$ og S^2 er uavhengige, får vi at $T \sim t_{n-2}$.

Fra utskriften har vi at $t = 10.55$ og tilhørende P-verdi er svært liten som gir klart grunnlag for å forkaste H_0 (på ethvert fornuftig signifikansnivå).

(c) Vi får en økning i forklaringsgrad R^2 fra 0.54 til 0.58. Imidlertid kan denne være noe optimistisk så man bør heller bruke den justerte R^2 . Denne gir også en liten forbedring (fra 0.53 til 0.58) slik at den nye modell er å foretrekke.

(d) Vi har at

$$\begin{aligned} \mathbf{E} &= \mathbf{Y} - \hat{\mathbf{Y}} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}} \\ &= \mathbf{Y} - \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} = [\mathbf{I} - \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T] \mathbf{Y} = [\mathbf{I} - \mathbf{H}] \mathbf{Y} \end{aligned}$$

der $\mathbf{H} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$.

Dermed er residualene lineære kombinasjoner av Y -ene og dermed

(Fortsettes side 5.)

normalfordelte. Videre er

$$\begin{aligned}
 E(\mathbf{E}) &= E([\mathbf{I} - \mathbf{H}]\mathbf{Y}) \\
 &= [\mathbf{I} - \mathbf{H}]E(\mathbf{Y}) \\
 &= [\mathbf{I} - \mathbf{H}]\mathbf{X}\boldsymbol{\beta} \\
 &= [\mathbf{I} - \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T]\mathbf{X}\boldsymbol{\beta} \\
 &= \mathbf{X}\boldsymbol{\beta} - \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{X}\boldsymbol{\beta} \\
 &= \mathbf{X}\boldsymbol{\beta} - \mathbf{X}\boldsymbol{\beta} = \mathbf{0} \\
 \text{Cov}(\mathbf{E}) &= \text{Cov}([\mathbf{I} - \mathbf{H}]\mathbf{Y}) \\
 &= [\mathbf{I} - \mathbf{H}]\text{Cov}(\mathbf{Y})[\mathbf{I} - \mathbf{H}]^T \\
 &= \sigma^2[\mathbf{I} - \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T][\mathbf{I} - \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T] \\
 &= \sigma^2[\mathbf{I} - \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T - \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T + \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T] \\
 &= \sigma^2[\mathbf{I} - \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T] = \sigma^2[\mathbf{I} - \mathbf{H}]
 \end{aligned}$$

(e) Standardiserte residualer er definert ved

$$e_i^* = \frac{e_i}{\sqrt{1 - h_{ii}}}$$

Disse vil alle ha varians σ^2 , noe som gjør det lettere å vurdere disse. (Hvis de også deler på s i definisjonen av e_i^* så er det ok.)

Residualplottene ser ut til å virke rimelige ut ifra antagelsene, bortsett fra at det ser ut til å være en stigende tendens i residualene med indeksnummer som indikerer at det er en slags tid-korrelasjon her.

Oppgave 3.

- (a) Vi har at $E(\hat{p}_K) = p_K$ og $V(\hat{p}_K) = p_K(1 - p_K)/n_k$. Dermed får vi at $E(Z) = 0$ og $V(Z) = 1$. For n_k stor, er Y_k tilnærmet normalfordelt. Siden Z er en lineærkombinasjon av Y_k , blir denne også tilnærmet normalfordelt.
- (b) Vi må først bestemme en testobservator. Her vil det være fornuftig å bruke

$$Z = \frac{\hat{p}_K - 0.339}{\sqrt{0.339(1 - 0.339)/n_k}}$$

som vil være tilnærmet standard normalfordelt når n_k er stor (som her). Vi får i dette tilfellet at $z = -5.78$ som (i absolutt verdi) er klart større enn $z_{0.025} = 1.96$. Vi forkaster derfor H_0 på $\alpha = 0.05$ signifikansnivå.

(Fortsettes side 6.)

(c) Vi har nå at

$$V(\hat{p}_K - \hat{p}_M) = \frac{p_K(1 - p_K)}{n_K} + \frac{p_M(1 - p_M)}{n_M}$$

$$\stackrel{H_0}{=} p(1 - p)(n_K^{-1} + n_M^{-1})$$

som gir at

$$Z = \frac{\hat{p}_K - \hat{p}_M}{\sqrt{\hat{p}(1 - \hat{p})(n_K^{-1} + n_M^{-1})}}$$

er tilnærmet standard normalfordelt når n -ene er store. Her har vi brukt at $\hat{p} = (515+27)/(1520+191) = 0.317$. Da blir $z = -5.528$ (5.544 ved hvis en kun bruker de 3 desimaler) som også er klart signifikant. Da vi har at $|z| > z_{0.000001}$ vet vi i allefall at P-verdien er mindre enn $2 * 0.000001 = 0.000002$.

- (d) Dette vil være en bedre test da vi tar hensyn til usikkerheten i $\hat{p}_M$. Da det er såpass mye data for å estimere $\hat{p}_M$, gjør det ikke den store forskjellen her.
- (e) Hvis vi definerer en forklaringsvariabel x_i til å være lik 1 hvis individ i er en kvinne og 0 hvis det er en mann, vil en logistisk regresjonsmodell svare til at

$$\Pr(Y_i = 1|x_i) = \frac{e^{\beta_0 + \beta_1 x_i}}{1 + e^{\beta_0 + \beta_1 x_i}}$$

$$= \begin{cases} \frac{e^{\beta_0}}{1 + e^{\beta_0}} & x_i = 0 \\ \frac{e^{\beta_0 + \beta_1}}{1 + e^{\beta_0 + \beta_1}} & x_i = 1 \end{cases}$$

Hvis vi nå definerer $p_M = \frac{e^{\beta_0}}{1 + e^{\beta_0}}$ og $p_K = \frac{e^{\beta_0 + \beta_1}}{1 + e^{\beta_0 + \beta_1}}$, så ser vi at $p_K = p_M$ svarer til at β_1 er 0, slik at vi kan teste det innenfor logistisk regresjon.

SLUTT

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — KORT FASIT.

Eksamensdag: Mandag 1. desember 2014.

Tid for eksamen: 14.30 – 18.30.

Oppgavesettet er på 4 sider.

Vedlegg: Tabell over normal-, t -, og χ^2 -fordeling.

Tillatte hjelpemidler: Godkjent kalkulator og formelsamling for STK1100/STK1110.

Kontroller at oppgavesettet er komplett før du begynner å besvare spørsmålene.

Oppgave 1.

$X_1, X_2, \dots, X_n$ er uavhengige Poissonfordelte variable med parameter λt_i .

a)

$$E(\hat{\lambda}) = \frac{\sum_{i=1}^n E(X_i)}{\sum_{i=1}^n t_i} = \frac{\sum_{i=1}^n \lambda t_i}{\sum_{i=1}^n t_i} = \frac{\lambda \sum_{i=1}^n t_i}{\sum_{i=1}^n t_i} = \lambda$$
$$V(\hat{\lambda}) = \frac{\sum_{i=1}^n V(X_i)}{(\sum_{i=1}^n t_i)^2} = \frac{\sum_{i=1}^n \lambda t_i}{(\sum_{i=1}^n t_i)^2} = \frac{\lambda \sum_{i=1}^n t_i}{(\sum_{i=1}^n t_i)^2} = \frac{\lambda}{\sum_{i=1}^n t_i}$$

Innsatt data: $\hat{\lambda} = 3 \cdot 10^{-4}$.

b)

$$L(x_1, \dots, x_n, t_1, \dots, t_n; \lambda) = \prod_{i=1}^n \frac{(\lambda t_i)^{x_i}}{x_i!} \exp(-\lambda t_i)$$
$$\log L = \sum_{i=1}^n x_i \log \lambda + \sum_{i=1}^n x_i \log t_i - \sum_{i=1}^n \log(x_i!) - \lambda \sum_{i=1}^n t_i$$

Deriver $\log L$ mhp. λ og sett lik 0:

$$\frac{\partial \log L}{\partial \lambda} = \frac{\sum_{i=1}^n x_i}{\lambda} - \sum_{i=1}^n t_i = 0$$

Løser ut λ som

$$\frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n t_i}$$

(Fortsettes på side 2.)

og får ML-estimatoren

$$\hat{\lambda} = \frac{\sum_{i=1}^n X_i}{\sum_{i=1}^n t_i}$$

c) En annen mulig estimator for λ er

$$\hat{\lambda} = \frac{\sum_{i=1}^n X_i t_i}{\sum_{i=1}^n t_i^2}.$$

Denne er også forventningsrett (bør vises (enkelt)) og har varians

$$V(\hat{\lambda}) = \frac{\lambda \sum_{i=1}^n t_i^3}{(\sum_{i=1}^n t_i^2)^2}.$$

Kan vise ved innsetting at $V(\hat{\lambda}) \leq V(\hat{\lambda})$ og at vi dermed skal foretrekke $\hat{\lambda}$. Bør referere til MVUE og ML-estimatorenes fordelaktige egenskaper, se s. 357 i boken. Alternativt må man vise generelt at

$$\frac{1}{\sum_{i=1}^n t_i} \leq \frac{\sum_{i=1}^n t_i^3}{(\sum_{i=1}^n t_i^2)^2}$$

dvs.

$$\left(\sum_{i=1}^n t_i^2\right)^2 \leq \sum_{i=1}^n t_i^3 \sum_{i=1}^n t_i.$$

(For $t_i = t \forall i$, får vi likhet.)

Oppgave 2.

a) Vi gjør en standard large sample hypotesetest for en andel p , se kap. 9.3. Hypotesene blir

$$H_0 : p = 0.4 \quad \text{mot} \quad H_a : p > 0.4$$

Vi har $\hat{p} = 0.422$ og $n = 960$. Finner at testobservator under H_0 er $z = 1.391$ og P-verdi $= P(Z \geq 1.391) = 0.082$. Med nivå 0.05 har vi ingen grunn til å forkaste H_0 . Vi kan derfor ikke konkludere med at Ap ville ha fått mer enn 40% av stemmene den dagen.

Oppgave 3.

a)

Vi har $X_i \sim N(\mu_A, \sigma^2)$, $i = 1, \dots, n$ og $Y_i \sim N(\mu_B, \sigma^2)$, $i = 1, \dots, m$. Hypotesene blir

$$H_0 : \mu_A - \mu_B = 0 \qquad H_a : \mu_A - \mu_B > 0$$

Baserer oss på $\bar{X} \sim N(\mu_A, \sigma^2/n)$ og $\bar{Y} \sim N(\mu_B, \sigma^2/m)$. Med kjent varians kan vi bruke en Z-test. Vi skal forkaste nullhypotesen på nivå α når testobservator $Z =$

(Fortsettes på side 3.)

$(\bar{X} - \bar{Y})/\sigma\sqrt{1/n + 1/m}$ er større enn z_α , fordi $Z \sim N(0, 1)$ under H_0 . Med signifikansnivå $\alpha = 0.01$ blir forkastningsområdet verdier over $z_{0.01} = 2.326$. Gitt $\sigma^2 = 4$, $n = 4$, $m = 5$, $\bar{x} = 13$ og $\bar{y} = 10$, blir observert testobservator $z = 2.236$. Nullhypotesen kan derfor ikke forkastes. Data gir ikke grunnlag for å påstå at strand A er mer forurensset enn strand B på nivå 0.01.

b) P-verdi er sannsynligheten for å observere det man har observert, eller noe mer ekstremt, gitt at H_0 er riktig. Evt. minste signifikansnivå som hadde gitt forkastning med de observasjonene man har. Her: Sannsynligheten for å observere en forskjell i gjennomsnitt på +3 eller mer, med 4 og 5 observasjoner, gitt at det egentlig ikke er noen forskjell i forventet forurensningsnivå. P-verdi = $P(Z \geq 2.236) = 0.0125$.

c) Setter $m = n$. Krever

$$P(Z \geq 2.326 \mid \mu_A - \mu_B = 4) \geq 0.95$$

der $Z = (\bar{X} - \bar{Y})/\sigma\sqrt{1/n + 1/n}$. Nå er forventningen til $\bar{X} - \bar{Y}$ ikke lenger 0, men 4, så vi må omordne slik at vi får

$$P\left(\frac{\bar{X} - \bar{Y} - 4}{\sigma\sqrt{1/n + 1/n}} \geq 2.326 - \frac{4}{\sigma\sqrt{1/n + 1/n}}\right) \geq 0.95,$$

der uttrykket til venstre nå er standard normalfordelt. Dette gir at uttrykket til høyre må være mindre eller lik $-z_{0.05}$ og vi finner $n \geq 7.88$, dvs. vi må ha minst 8 observasjoner fra hver strand.

d) Fordi vi antar lik varians bruker vi $S_p^2 = \frac{(n-1)S_A^2 + (m-1)S_B^2}{n+m-2}$ som estimator for σ^2 . Innsatt finner vi da estimatet $S_p^2 = 7.143$.

Testobservator

$$t = \frac{\bar{X} - \bar{Y}}{S_p\sqrt{1/n + 1/m}} \sim t_{n+m-2},$$

er student-t-fordelt med $n + m - 2$ frihetsgrader. Med $n = 4$ og $m = 5$ blir dette 7 frihetsgrader. Observert verdi for testobservator blir $t = 1.67$. Testen blir at vi skal forkaste H_0 for verdier større enn $t_{0.01,7} = 2.998$. Med nivå $\alpha = 0.01$ har vi ingen grunn til å forkaste H_0 .

e) Standard to-utvalgs-t-intervall, $3 \pm 3.499 \cdot \sqrt{7.143} \cdot \sqrt{1/4 + 1/5}$, gir intervallet $(-3.273, 9.273)$. Tolkning se bok kap. 8.1.

Oppgave 4.

a) $\hat{\beta}_0 = 53.33$, $\hat{\beta}_1 = 0.533$ og $\hat{\sigma} = 1.035$. Må kommentere: 1) scatterplott med tilpasset linje, god tilpasning 2) R-squared=0.9887, stor forklaringsgrad 3) alle regresjonskoeffisienter signifikante! 4) qq-plott: normalitetsantakelsen ok 5) residualplottet: ikke noe mønster, feks. konstant varians ok.

(Fortsettes på side 4.)

b) Har at $(\hat{\beta}_1 - \beta_1)/s_{\hat{\beta}_1}$ er t-fordelt med 16 fr.g. Standard utledning gir at intervallet blir $\hat{\beta}_1 \pm t_{0.025,16}s_{\hat{\beta}_1}$. Fra utskriften har vi $\hat{\beta}_1 = 0.533$ og $s_{\hat{\beta}_1} = 0.01428$. Bruker $t_{0.025,16} = 2.12$. Gir 95% konfidensintervall som (0.5027,0.5633).

c) Ved å konstantere at 0 ikke dekkes av 95% konfidensintervallet ovenfor, vet vi at vi kan forkaste nullhypotesen $H_0 : \beta_1 = 0$ til fordel for den tosidige alternativhypotesen $H_a : \beta_1 \neq 0$ på signifikansnivå $\alpha = 0.05$. Generelt har vi sammenheng mellom tosidig testing på nivå α og et $(1 - \alpha) \cdot 100\%$ konfidensintervall.

d) Konfidensintervall for forventet løselighet $\mu_{Y \cdot x^*}$ i punktet x^* , forklaring s. 656 i boken. Prediksjonsintervall for en ny observasjon Y i punktet x^* , forklaring s. 659. Pluss for å utlede formelene og tegne. For $x^* = 35$ grader Celcius finner vi konfidensintervallet (71.47, 72.51) og prediksjonsintervallet (69.74,74.24) fra utskriften.

e)

$$Y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \epsilon_i,$$

der ϵ_i er iid. $N(0, \sigma^2)$, $i = 1, \dots, n$. Ser at 1) annengradsleddet er ikke signifikant og 2) Adjusted R-squared er ikke større enn for den lineære modellen. Den lineære modellen så også ut til å passe godt. Ingen grunn til å bruke et annengradsledd for disse dataene, for de gitte temperaturene. Mulig denne effekten ville blitt synlig for andre temperaturer.

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Fasit - Statistiske metoder og dataanalyse 1.

Eksamensdag: Torsdag 12. desember 2013.

Tid for eksamen: 14.30 – 18.30.

Oppgavesettet er på 4 sider.

Vedlegg: Tabell over normal-, t -, og χ^2 -fordeling.

Tillatte hjelpemidler: Godkjent kalkulator og formelsamling for STK1100/STK1110.

Kontroller at oppgavesettet er komplett før du begynner å besvare spørsmålene.

Oppgave 1.

Har $X_1, X_2, \dots, X_m$ u.i.f. $N(\mu, \sigma_1^2)$ og $Y_1, Y_2, \dots, Y_n$ u.i.f. $N(\mu, \sigma_2^2)$. Målingene fra instrument A og B er også uavhengige av hverandre. De to variansene σ_1^2 og σ_2^2 er kjent for de to instrumentene.

a) Start med at $\bar{X} = \frac{1}{m} \sum_{i=1}^m X_i$ er $N(\mu, \sigma_1^2/m)$. Derfor er $(\bar{X} - \mu)\sqrt{m}/\sigma_1 \sim N(0,1)$ og vi kan sette opp

$$P(-z_{\alpha/2} \leq \frac{(\bar{X} - \mu)}{\sigma_1/\sqrt{m}} \leq z_{\alpha/2}) = 1 - \alpha.$$

Rydder opp slik at vi får intervallet $\bar{x} \pm z_{\alpha/2}\sigma_1/\sqrt{m}$. For 99% ($\alpha = 0.01$) konfidensintervall bruker vi $z_{\alpha/2} = z_{0.005} = 2.58$.

Tolkning: hvis vi konstruerer veldig mange konfidensintervall på denne måten, vil intervallene i det lange løp inneholde den sanne ukjente μ 99% av gangene.

b) $Lengde = 2z_{\alpha/2}\sigma_1/\sqrt{m} \leq w$ gir at $m \geq (2z_{\alpha/2}\sigma_1/w)^2$. Hvis $w = \sigma_1$ blir $m \geq (2z_{\alpha/2})^2$, og innsatt $z_{\alpha/2} = z_{0.005} = 2.58$ gir det $m \geq 27$.

c)

$$L(x_1, \dots, x_m, y_1, \dots, y_n, \mu, \sigma_1^2, \sigma_2^2) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma_1} \exp\left(-\frac{1}{2\sigma_1^2}(x_i - \mu)^2\right) \cdot \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma_2} \exp\left(-\frac{1}{2\sigma_2^2}(y_i - \mu)^2\right)$$
$$\log L \propto -\frac{1}{2\sigma_1^2} \sum_{i=1}^m (x_i - \mu)^2 - \frac{1}{2\sigma_2^2} \sum_{i=1}^n (y_i - \mu)^2$$

(Fortsettes på side 2.)

Deriver $\log L$ mhp. μ og sett lik 0. Løser ut μ som

$$\mu = \frac{\frac{\sum x_i}{\sigma_1^2} + \frac{\sum y_i}{\sigma_2^2}}{\frac{m}{\sigma_1^2} + \frac{n}{\sigma_2^2}}.$$

Maximum Likelihood estimator blir da

$$\hat{\mu}_{ML} = \frac{\frac{m\bar{X}}{\sigma_1^2} + \frac{n\bar{Y}}{\sigma_2^2}}{\frac{m}{\sigma_1^2} + \frac{n}{\sigma_2^2}}.$$

d) $\hat{\mu}_{ML}$ er et vektet gjennomsnitt av de to gjennomsnittene. Gjennomsnitt basert på flere observasjoner og fra instrument med lav varians får mer vekt, hvilket er rimelig. Enkelt å vise forventningsrett siden $E(\bar{X}) = E(\bar{Y}) = \mu$. Enkel regning gir

$$V(\hat{\mu}_{ML}) = \frac{1}{\frac{m}{\sigma_1^2} + \frac{n}{\sigma_2^2}}.$$

Oppgave 2.

a) Modell med standard antakelser side 604 i boken.

$$H_0 : \beta_1 = 0 \quad \text{mot} \quad H_a : \beta_1 \neq 0.$$

Testobservator

$$t = \frac{\hat{\beta}_1}{s_{\hat{\beta}_1}}$$

der $\hat{\beta}_1$ er estimert effekt av gen 1 og $s_{\hat{\beta}_1}$ er standard feil. Er t-fordelt med 82 frihetsgrader når nullhypotesen er sann. Forkaster H_0 når t er meget stor eller meget liten. Finner forkastningsområde fra krav om $P(\text{type I feil}) = P(\text{forkast } H_0 | H_0 \text{ riktig}) \leq \alpha = 0.05$. Gir 'Forkast H_0 hvis $t \geq t_{0.025, 82}$ eller $t \leq -t_{0.025, 82}$ '.

Finner ikke 82 frihetsgrader i tabellen, sikrer oss ved å bruke 60, da skal vi forkaste hvis $t \geq 2$ eller $t \leq -2$. Output i (I) gir $t = \frac{-1.1297}{0.3609} = -3.13$ og vi forkaster.

b) P-verdi er sannsynligheten for å få en observator som er minst så ekstrem i forhold til nullhypotesen som det vi faktisk har observert, gitt at nullhypotesen er sann. Evt. minste signifikansnivå som ville ha gitt forkastning.

P-verdien = $2P(T \geq 3.13)$ der T er t-fordelt m 82 frihetsgrader. Fra tabell finner vi at $2P(T \geq 3.13) \leq 2 \cdot 0.005 = 0.01$ (60 frihetsgrader).

(Fortsettes på side 3.)

c) 95% konfidensintervall for β_1 : $\hat{\beta}_1 \pm t_{0.025, 82} s_{\hat{\beta}_1}$. Bruker 60 frihetsgrader og finner intervallet $(-1.8515, -0.4079)$. En tosidig test med nivå α for en parameter kan utføres ved å sjekke om den hypotisererte verdien ligger utenfor et $(1 - \alpha)100\%$ konfidensintervall for parameteren. Ser her at 0 ikke ligger i 95% konfidensintervall, som stemmer med at vi fikk forkastning på nivå $\alpha = 0.05$.

d) I resultat (II) ser vi at gen 1 ikke lenger er signifikant når vi inkluderer gen 2. Gene 2 er meget signifikant. Hvis vi har informasjon om gen 2, inneholder ikke gen 1 nok tilleggsinformasjon om bentettheten til at den blir signifikant. Dette kan skje når de to kovariatene er korrelert. Vi ser at korrelasjonen mellom gen 1 og gen 2 er 0.73.

e) For den andre modellen er alle kovariater signifikante, og Adjusted R^2 er litt høyere, slik at denne regnes som bedre enn den første. For den andre modellen tolker vi de estimerte effektene slik: Høy genekspresjon for gen 2 har en tendens til å redusere forventet bentetthet, når de andre kovariatene (genene) holdes uendret. Høy genekspresjon for gen 3 har en tendens til å øke forventet bentetthet, når de andre kovariatene (genene) holdes uendret. Samme for gen 4. Vi ser også at gen 3 har størst estimert effekt.

Oppgave 3.

a) Dette er en standard large sample test for en andel, kap. 9.3 i boken. Alternativ hypotese at $p > 0.25$. Finner at testobservator er $z = 2.21$ og P-verdi $= P(Z \geq 2.21) = 0.0136$. Forkaster med nivå 0.05, forkaster ikke med nivå 0.01. Ikke klart at studentene er mer deprimerte enn resten av befolkningen.

Oppgave 4.

X har sannsynlighetstetthet $f(x) = \frac{\theta c^\theta}{x^{\theta+1}}$ når $c < x < \infty$, og $f(x) = 0$ ellers. Her er c minsteinntekten i befolkningsgruppen, mens $\theta > 0$ er en parameter som beskriver lønnsforskjellene i befolkningsgruppen. Har c kjent, mens θ skal estimeres fra uavhengige observasjoner $X_1, X_2, \dots, X_n$. Har

$$\hat{\theta} = \frac{n}{\sum_{i=1}^n \log X_i - n \log c}$$

og at $2n\theta/\hat{\theta}$ er χ^2 -fordelt med $2n$ frihetsgrader. Skal teste

$$H_0 : \theta = \theta_0 \quad \text{mot} \quad H_a : \theta > \theta_0.$$

a) Forkaster når $\hat{\theta} \geq k$, der k finnes fra

$$P(\hat{\theta} \geq k | \theta = \theta_0) \leq \alpha$$

$$P\left(\frac{1}{\hat{\theta}} \leq \frac{1}{k} | \theta = \theta_0\right) \leq \alpha$$

(Fortsettes på side 4.)

$$P\left(\frac{2n\theta_0}{\hat{\theta}} \leq \frac{2n\theta_0}{k}\right) \leq \alpha$$

der $2n\theta_0/\hat{\theta}$ er χ^2 -fordelt med $2n$ frihetsgrader under H_0 . Da må

$$\frac{2n\theta_0}{k} \leq \chi_{1-\alpha, 2n}^2$$

og vi får $k = 2n\theta_0/\chi_{1-\alpha, 2n}^2$

b) Innsatt får vi 'Forkast H_0 dersom $\hat{\theta} \geq 3.61$ '. Finner $\hat{\theta} = 4.22$ og forkaster H_0 på nivå 0.01.

c)

$$\begin{aligned}\beta(\theta') &= P(\hat{\theta} \leq 3.61 | \theta = \theta') \\ &= P\left(\frac{2n\theta}{\hat{\theta}} \geq \frac{2n\theta}{3.61} \mid \theta = \theta'\right) \\ &= P(\chi^2 \geq \frac{2 \cdot 20 \cdot \theta'}{3.61})\end{aligned}$$

der χ^2 er χ^2 -fordelt med 40 frihetsgrader. Krever $\beta(\theta') \leq 0.05$

$$P(\chi^2 \geq 11.1 \cdot \theta') \leq 0.05$$

$$11.1 \cdot \theta' \geq 55.76$$

$$\theta' \geq 5.02$$

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — FASIT.

Eksamensdag: Tirsdag 11. desember 2012.

Tid for eksamen: 14.30 – 18.30.

Oppgavesettet er på 5 sider.

Vedlegg: Tabell over Poisson-, normal-, t -, og F-fordeling.

Tillatte hjelpemidler: Godkjent kalkulator og formelsamling for STK1100/STK1110.

Kontroller at oppgavesettet er komplett før du begynner å besvare spørsmålene.

Oppgave 1.

a) Dette er en standard oppgave om sammenligning av to andeler, kapittel 10.4. Se deler av side 507-509 for utledning (large sample test procedure).

b) Dette er også standard, se side 512 i boken. Uttrykket for variansen blir forskjellig fordi vi i a) har antatt at H_0 er sann, dvs. $p_1 = p_2$.

c) La $\hat{p}_1 = 102/200 = 0.51$, $\hat{p}_2 = 248/400 = 0.62$ og $\hat{p} = (102 + 248)/(200 + 400) = 0.583$. Testobservator i a) får verdi $z = -2.576$. Med tosidig alternativ og $\alpha = 0.05$ må vi sjekke om $z > z_{0.025} = 1.96$ eller $z < -z_{0.025} = -1.96$. Siden observert z er mindre enn -1.96 forkaster vi H_0 og konkluderer på nivå 0.05 at det er signifikant forskjell i andel fulltidsstudenter.

Innsatt i formelen for konfidensintervallet får vi $(-0.194, -0.026)$. At 0 ikke ligger i dette intervallet stemmer med at vi fikk forkastning av hypotesen om at $p_1 = p_2$.

Oppgave 2.

a) Vi setter score kvinner: $X_i \sim N(\mu_1, \sigma^2)$, $i = 1, \dots, n$ og score menn: $Y_i \sim N(\mu_2, \sigma^2)$, $i = 1, \dots, m$. Hypotesene blir

$$H_0 : \mu_1 - \mu_2 = 0$$

$$H_a : \mu_1 - \mu_2 < 0$$

Baserer oss på $\bar{X} \sim N(\mu_1, \sigma^2/n)$ og $\bar{Y} \sim N(\mu_2, \sigma^2/m)$. Fordi vi antar lik varians bruker vi $S_p = S_{pooled} = \frac{(n-1)S_1^2 + (m-1)S_2^2}{n+m}$.

(Fortsettes på side 2.)

Testobservator

$$t = \frac{\bar{X} - \bar{Y}}{S_p \sqrt{1/n + 1/m}} \sim t_{n+m-2},$$

dvs. student-t-fordelt med $n + m - 2$ frihetsgrader. Med $n = 10$ og $n = 9$ blir dette 17 frihetsgrader. Fra R-utskriften finner vi observert verdi for t som t-statistic = -0.959 og tilhørende p-verdi = 0.1755. Med nivå $\alpha = 0.05$ har vi ingen grunn til å forkaste H_0 .

b) Hypotesene blir her $H_0 : \sigma_1^2 = \sigma_2^2$ mot $H_a : \sigma_1^2 \neq \sigma_2^2$. Vi vet at

$$\frac{(n-1)S_1^2}{\sigma_1^2} \sim \chi_{n-1}^2$$

$$\frac{(m-1)S_2^2}{\sigma_2^2} \sim \chi_{m-1}^2$$

Testobservator

$$f = \frac{(n-1)S_1^2/\sigma_1^2(n-1)}{(m-1)S_2^2/\sigma_2^2(m-1)} = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F_{n-1, m-1}$$

dvs. F-fordelt med $n - 1$ og $m - 1$ frihetsgrader. Innsatt n og m blir dette 9 og 8 frihetsgrader. Under H_0 er $f = \frac{S_1^2}{S_2^2} = 1.6688$ og vi finner p-verdi = 0.4822 fra utskriften. Med nivå $\alpha = 0.1$ har vi ingen grunn til å forkaste H_0 .

c) Vi har modellen

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{1i} x_{2i} + \epsilon_i$$

Med indikatorvariabelen $x_2 = 1$ for kvinner og $x_2 = 0$ for menn, får vi modellene

Kvinner: $y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 + \beta_3 x_{1i} + \epsilon_i = (\beta_0 + \beta_2) + (\beta_1 + \beta_3) x_{1i} + \epsilon_i$

Menn: $y_i = \beta_0 + \beta_1 x_{1i} + \epsilon_i$

β_2 blir dermed forskjellen mellom kvinner og menn i grunnleggende lønnstillegg, og β_3 blir forskjellen mellom kvinner og menn i uttelling for score (dvs. forskjellen i stigningstall).

d) $\hat{\beta}_2 = -31.123$, noe som betyr at kvinner typisk får ca. 31\$ mindre i lønnstillegg i utgangspunktet. Men her er p-verdi = 0.5293, så denne forskjellen er ikke signifikant. For uttelling for score, derimot, har vi klare resultater: $\hat{\beta}_3 = -3.96$, som betyr at stigningstallet, som sier hvor mye lønnsøkning man kan forvente for hvert ekstra poeng for arbeidsinnsats, er betraktelig lavere for kvinner enn for menn. Her er p-verdi = 0.00029 og forskjellen signifikant på alle rimelige nivåer.

e) Vi har at $\hat{\beta}_3 \sim N(\beta_3, \sigma_{\hat{\beta}_3}^2)$ og videre

$$\frac{\hat{\beta}_3 - \beta_3}{S_{\hat{\beta}_3}} \sim t_{n-(3-1)} = t_{15}.$$

(Fortsettes på side 3.)

Et $(1 - \alpha)100\%$ konfidensintervall finnes fra

$$P(-t_{\alpha/2,15} < \frac{\hat{\beta}_3 - \beta_3}{S_{\hat{\beta}_3}} < t_{\alpha/2,15}) = 1 - \alpha.$$

Med $\alpha = 0.01$ trenger vi $t_{0.005,15} = 2.947$, slik at et 99% konfidensintervall for β_3 blir $\hat{\beta}_3 \pm 2.947 * S_{\hat{\beta}_3} = -3.96 \pm 2.947 \cdot 0.8437 = -3.96 \pm 2.4864 = (-6.45, -1.47)$.

Hvis vi velger ut 19 personer tilfeldig og beregner et slik 99% konfidensintervall for β_3 mange ganger, vil vi i det lange løp få intervaller som dekker den sanne verdien av β_3 i 99% av tilfellene.

f) "Multiple R-squared" finnes ved $R^2 = 1 - SSE/SST$, eller som kvadratet av korrelasjonen mellom observerte responser y_i og predikerte responser $\hat{y}_i$, $i = 1, \dots, n$. Tall mellom 0 og 1, som gir andelen av variasjonen i y som kan forklares av modellen. I plottet ser vi klart at det er forskjell i stigningstall for kvinner og menn. Bør nevne residualplott og normalfordelingsplott for residualene.

Oppgave 3.

a) Med modellen $y_i = \beta x_i + \epsilon_i$, $i = 1, \dots, n$, setter vi opp uttrykket for kvadratavikene $\sum_{i=1}^n (y_i - \beta x_i)^2$. Deriverer med hensyn på β og setter lik 0:

$$\frac{\partial}{\partial \beta} \sum_{i=1}^n (y_i - \beta x_i)^2 = 0$$

$$2 \sum_{i=1}^n (y_i - \beta x_i)(-x_i) = 0$$

$$\sum_{i=1}^n y_i x_i - \beta \sum_{i=1}^n x_i^2 = 0$$

$$\hat{\beta}_{MK} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}$$

$$E(\hat{\beta}_{MK}) = \frac{\sum_{i=1}^n x_i E(y_i)}{\sum_{i=1}^n x_i^2} = \frac{\sum_{i=1}^n x_i \beta x_i}{\sum_{i=1}^n x_i^2} = \beta$$

$$V(\hat{\beta}_{MK}) = \frac{\sum_{i=1}^n x_i^2 V(y_i)}{(\sum_{i=1}^n x_i^2)^2} = \frac{\sum_{i=1}^n x_i^2 \sigma^2}{(\sum_{i=1}^n x_i^2)^2} = \frac{\sigma^2}{\sum_{i=1}^n x_i^2}$$

(Fortsettes på side 4.)

b)

$$E(\hat{\beta}_A) = \frac{\sum_{i=1}^n E(y_i)}{\sum_{i=1}^n x_i} = \frac{\beta \sum_{i=1}^n x_i}{\sum_{i=1}^n x_i} = \beta$$

$$V(\hat{\beta}_A) = \frac{\sum_{i=1}^n V(y_i)}{(\sum_{i=1}^n x_i)^2} = \frac{n\sigma^2}{(\sum_{i=1}^n x_i)^2} = \frac{\sigma^2}{n\bar{x}^2}$$

Skal sammenligne

$$\frac{\sigma^2}{n\bar{x}^2} \quad \text{og} \quad \frac{\sigma^2}{\sum_{i=1}^n x_i^2}.$$

Vet at $\sum_{i=1}^n (x_i - \bar{x})^2 \geq 0$ alltid er sant. Ved enkel regning finner vi fra dette at $\sum_{i=1}^n x_i^2 \geq n\bar{x}^2$ alltid. Derfor er

$$\frac{\sigma^2}{\sum_{i=1}^n x_i^2} \leq \frac{\sigma^2}{n\bar{x}^2},$$

dvs. $V(\hat{\beta}_{MK}) \leq V(\hat{\beta}_A)$ og vi velger derfor $\hat{\beta}_{MK}$.

Oppgave 4.

a) Skal teste $H_0 : \lambda = 1$ mot $H_a : \lambda > 1$ med $\alpha = 0.05$. Naturlig å forkaste H_0 når $X \geq k$, der k finnes fra

$$P(X \geq k \mid \lambda = 1) \leq 0.05$$

$$1 - P(X < k \mid \lambda = 1) \leq 0.05$$

$$P(X < k \mid \lambda = 1) \geq 0.95$$

Fra Tabell: $P(X \leq 3 \mid \lambda = 1) = P(X < 4 \mid \lambda = 1) = 0.981$.

Så $k = 4$, dvs. man må minst observere 4 tilfeller for å kunne forkaste på nivå 0.05.

b) $P(X \geq 4 \mid \lambda = 2) = 1 - P(X \leq 3 \mid \lambda = 2) = 1 - 0.857 = 0.143$

$$P(\text{Type II feil}) = 0.857$$

c) Siden $X_i \sim \text{Poisson}(n_i p)$, har vi

$$P(X_i = x_i) = \frac{(n_i p)^{x_i} e^{-n_i p}}{x_i!}.$$

Likelihood for m år blir da

$$L(p) = \prod_{i=1}^m \frac{(n_i p)^{x_i} e^{-n_i p}}{x_i!}$$

(Fortsettes på side 5.)

Log-likelihood blir

$$\text{loglik}(p) = \sum_{i=1}^m [x_i \log(n_i p) - n_i p - \log(x_i!)]$$

$$\begin{aligned} \frac{\partial}{\partial p} \text{loglik}(p) &= \sum_{i=1}^m \left[\frac{x_i n_i}{n_i p} - n_i \right] \\ &= \sum_{i=1}^m \left[\frac{x_i}{p} - n_i \right] \\ &= \frac{\sum_{i=1}^m x_i}{p} - \sum_{i=1}^m n_i \end{aligned}$$

Setter lik 0 og finner MLE

$$\hat{p} = \frac{\sum_{i=1}^m X_i}{\sum_{i=1}^m n_i}$$

$$E(\hat{p}) = \frac{\sum_{i=1}^m E(X_i)}{\sum_{i=1}^m n_i} = \frac{\sum_{i=1}^m n_i p}{\sum_{i=1}^m n_i} = p$$

$$V(\hat{p}) = \frac{\sum_{i=1}^m V(X_i)}{(\sum_{i=1}^m n_i)^2} = \frac{\sum_{i=1}^m n_i p}{(\sum_{i=1}^m n_i)^2} = \frac{p}{\sum_{i=1}^m n_i}$$

UNIVERSITETET I OSLO

Det matematisk-naturvitenskapelige fakultet

Eksamen i: STK1110 — Løsningsforslag: Statistiske metoder og dataanalyse

Eksamensdag: Fredag 9. desember 2011

Tid for eksamen: 14.30 – 18.30

Oppgavesettet er på 5 sider.

Vedlegg: Tabell over normalfordeling,
tabell over t-fordeling og
tabell over χ^2 -fordeling

Tillatte hjelpemidler: Formelsamling STK1100/STK1110 og
godkjent kalkulator

Kontroller at oppgavesettet er komplett før
du begynner å besvare spørsmålene.

Dette løsningsforslaget er mer detaljert enn det vil være rimelig å vente
av en eksamensbesvarelse.

Oppgave 1

a) Residualene er definert som $y_i - \hat{\beta}_0 - \hat{\beta}_1 \text{lengde}_i - \hat{\beta}_2 \text{alder}_i$, der $\hat{\beta}_0$, $\hat{\beta}_1$ og $\hat{\beta}_2$ er estimatene for koeffisientene i forventningene til responsvariablene. De er med andre ord differansene mellom observasjonene og de tilpassede verdiene. For en veltilpasset modell skal de ikke vise noen systematikk, og plottene av residualene mot tilpassede verdier og uavhengige variable kan avsløre slike systematiske avvik.

1. Mangel på lineær sammenheng med de uavhengige variablene kan vise seg i plott av residualene mot disse variablene. Det kan gjøre det nødvendig å ta med kvadratiske ledd for eksempel.
2. Ikke konstant varians kan vise seg i plott av residualene mot de uavhengige variablene, men også i plott mot tilpasset verdi. Her vil man kunne få et inntrykk av om variansen øker med forventningen.
3. Outliers kan vise seg som residualer med stor absoluttverdi.
4. Hvis normalfordelingsplottet ikke er en rett linje, indikerer det at antagelsen om normalfordelte restledd ikke er berettiget.

I dette tilfellet ser det ikke ut til å være noen systematikk i residualplottene, og normalfordelingsplottet ser også nokså rettlignet ut. Det er en residual som er noe større enn de andre. Dessuten kan det se ut som om variansen er mindre for høy alder, men ingen av disse er tydelige nok til å endre inntrykket av god tilpasning. Det er dessuten få observasjoner, så eventuelle avvik vil være vanskelige å oppdage.

I tillegg er en de r^2 -verdi på 0.97 uttrykk for at en stor del av variasjonen i responsverdiene forklares ved variasjoen i de uavhengige variablene lengde og alder.

- b) Et 95% konfidensintervall for koeffesienten for alder β_2 har grenser $\hat{\beta}_2 \pm t_{0.025,6} s_{\hat{\beta}_2}$ der $s_{\hat{\beta}_2}$ er den estimerte standardfeilen til $\hat{\beta}_2$. Den kritiske verdien, $t_{\alpha,n}$, i t-fordelingen er gitt ved $P(T > t_{\alpha,n}) = \alpha$ der den tilfeldige variabelen T er t-fordelt med n frihetsgrader. I dette tilfellet er antallet observasjoner 9 og antallet parametre i den lineære delen 3, slik at antallet frihetsgrader er 6. Fra tabellen er $t_{0.025,6} = 2.447$. Fra utskriften er $\hat{\beta}_2 = 7.1498$ og $s_{\hat{\beta}_2} = 4.0309$ slik at konfidensintervallet har grenser $7.1498 \pm 2.447 \times 4.0309$ som gir konfidensintervallet $(-2.713425, 17.013089)$
- c) Her er det rimelig å forkaste nullhypotesen for store verdier av $\hat{\beta}_2$. Siden $t = \hat{\beta}_2 / s_{\hat{\beta}_2}$ er t-fordelt med 6 frihetsgrader under H_0 har en test med nivå 5% forkastningsområde $\{t_{obs} > t_{0.05,6}\}$. Fra tabellen er $t_{0.05,6} = 1.943$ og $t_{obs} = 1.774$, slik at nullhypotesen ikke forkastes. P-verdien i utskriften, 0.126468, gjelder den tosidige testen, og er lik $P(|T_6| > t_{obs})$ der den tilfeldige variabelen T_6 er t-fordelt med 6 frihetsgrader. For den ensidige testen er P-verdien $P(T_6 > t_{obs}) = P(|T_6| > t_{obs})/2$, altså $0.126468/2 = 0.063234$.

Oppgave 2

- a) Under alternativet er sannsynligheten for at et av forsøkene er en suksess mindre en $1/2$. Man kan derfor forvente at det trengs flere forsøk før første suksess enn tilfellet er hvis suksesssannsynligheten er $1/2$. Fra formelsamlingen er $E(X) = 1/p$. (Dette følger også av at $E(X) = \sum_{i=1}^{\infty} xp(x-1)^{x-1} = p \sum_{i=1}^{\infty} x(1-p)^{x-1}$. Leddvis derivasjon av $1/p = \sum_{i=0}^{\infty} (1-p)^x$ gir at $-1/p^2 = -\sum_{i=0}^{\infty} x(1-p)^{x-1} = -\sum_{i=1}^{\infty} x(1-p)^{x-1}$. Innsatt gir dette $E(X) = 1/p$.) Siden $1/p$ er avtagende i p , er forventningen er større for verdier under alternativet, slik at store verdier av X tyder på at nullhypotesen er gal og at den skal forkastes. Dette gir forkastningsområde av formen $\{x|x > x_0\}$ der x_0 velges slik at nivåkravet holder.
- b) Fra formelen for en geometrisk fordeling er generelt $P(X \geq x) = \sum_{i=x}^{\infty} p(1-p)^{i-1} = (1-p)^{x-1}$, $x = 1, 2, \dots$ Derfor er $P(X \geq x_0+1|p = 1/2) = (\frac{1}{2})^{x_0}$. At nivået er 0.10 medfører derfor at $(\frac{1}{2})^{x_0} \leq 0.1$ eller $2^{x_0} \geq 10$, dvs $x_0 = 4$. Vi forkaster derfor hvis antallet forsøk som er nødvendig før første suksess er 5 eller mer. Dette kan også regnes ut direkte $P(X > 3) = 1 - P(X \leq 3) = 1 - (1/2 + 1/4 + 1/8) = 1/8 = 0.125$ og $P(X > 4) = 1 - P(X \leq 4) = 1 - (1/2 + 1/4 + 1/8 + 1/16) = 1/16 = 0.0625$.
- c) Feil av type II består i at nullhypoteser som er gale ikke forkastes. I dette tilfellet betyr det at nullhypotesen ikke forkastes hvis $p < 1/2$. Spesielt vil dette bety for $p = 1/4$ at $P(\text{ikke forkaste } H_0 | p = 1/4) = P(X \leq 4 | p = 1/4) = 1 - P(X \geq 5 | p = 1/4) = 1 - (\frac{3}{4})^4 = 0.6836$.

$P(\text{forkaste } H_0|p) = P(X \geq 5|p) = (1-p)^4$. Dette er en avtagende funksjon i p . Derfor er $(1-p)^4 < (\frac{1}{2})^4 < 0.1$ når $p \geq 1/2$ som viser at testen også har nivå 0.1 for å teste nullhypotesen $H_0 : p \geq \frac{1}{2}$ mot den alternative hypotesen $H_a : p < \frac{1}{2}$.

Oppgave 3

a) Likelihooden til observasjonene kan skrives

$$\prod_{i=1}^9 \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(y_i - \beta_0 - \beta_1 x_i)^2\right)$$

slik at logaritmen til likelihooden, $\log L$, er

$$\log L = -(n/2) \log(2\pi) - n \log(\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^9 (y_i - \beta_0 - \beta_1 x_i)^2$$

Denne størrelsen maksimeres med hensyn på β_0 og β_1 hvis $Q = \sum_{i=1}^9 (y_i - \beta_0 - \beta_1 x_i)^2$ minimeres. Verdiene som gir maksimum av $\log L$ definerer sannsynlighetsestimatorene og verdiene som minimerer Q minste kvadraters estimatorene, og disse må derfor være de samme.

Derivasjon av $\log L$ med hensyn på σ gir

$$-n/\sigma - \frac{1}{2\sigma^3}(-2) \sum_{i=1}^9 (y_i - \beta_0 - \beta_1 x_i)^2.$$

Ved å sette inn for sannsynlighetsestimatorene for β_0 og β_1 , sette uttrykket lik null og løse med hensyn på σ fås at sannsynlighetsestimatoren for σ^2 blir $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^9 (y_i - \beta_0 - \beta_1 x_i)^2$. Fra pensum og formelsamlingen STK1100/STK1110 følger at $n\hat{\sigma}^2/\sigma^2$ er χ^2 -fordelt med $n-2$ frihetsgrader. Forventningen til en χ^2 -fordelt variabel er lik antall frihetsgrader, dvs at $E(n\hat{\sigma}^2/\sigma^2) = n-2$ eller $E(\hat{\sigma}^2) = \frac{n-2}{n}\sigma^2$, slik at $\hat{\sigma}^2$ ikke er forventningsrett.

b) Siden $\hat{\beta}_1$ er forventningsrett vil store og små verdier av $\hat{\beta}_1 - 5.0$ tyde på at H_0 er gal og skal forkastes. Det betyr at $\hat{\beta}_1 - 5$ er et rimelig utgangspunkt som testobservator. Fra pensum vet vi at $\hat{\beta}_1$ er $N(\beta, \sigma^2 / \sum_{i=1}^9 (x_i - \bar{x})^2)$ -fordelt og $n\hat{\sigma}^2/\sigma^2 = (n-2)S^2/\sigma^2$ er $\chi^2_{(n-2)}$ fordelt. Nå er $n = 9$, slik at $(n-2)S^2/\sigma^2$ er χ^2 -fordelt med 7 frihetsgrader. Uttrykk

$$t = \frac{\hat{\beta}_1 - 5}{S / \sqrt{\sum_{i=1}^9 (x_i - \bar{x})^2}} = \frac{\frac{\hat{\beta}_1 - 5}{\sigma / \sqrt{\sum_{i=1}^9 (x_i - \bar{x})^2}}}{\sqrt{\frac{(n-2)S^2}{\sigma^2} / (n-2)}}.$$

Siden S^2 og $\hat{\beta}_1$ er uavhengige, betyr det at t er t- eller Studentfordelt med 7 frihetsgrader under H_0 . Vi forkaster hvis den observerte verdien av t observatoren, t_{obs} enten er mindre enn $-t_{\alpha/2,7}$ eller større enn $t_{\alpha/2,7}$ der α er nivået.

- c) Fra utskriften er den estimerte standardfeilen til $\hat{\beta}_1$, dvs. $s_{\hat{\beta}_1} = S/\sqrt{\sum_{i=1}^9 (x_i - \bar{x})^2}$ lik 0.5249 som gir at den observerte verdien av testobservatoren blir $t_{obs} = (5.9967 - 5.0)/0.5249 = 1.842$. Fra tabellen er $t_{0.025,7} = 2.365$ slik at nullhypotesen ikke forkastes.

P-verdien er sannsynligheten for å observere noe mer ekstremt dvs mindre enn -1.842 eller større enn 1.842 . Fra tabellen ser man at $P(t_7 > 1.895) = 0.05$ og $P(t_7 > 1.415) = 0.1$. P-verdien ligger derfor mellom 0.1 og 0.2 og like over 0.1.

- d) En forventningsrett estimator for forventet vekt av en fisk med lengde $50\text{cm} = 500\text{mm}$ er $\hat{\mu} = \hat{\beta}_0 + \hat{\beta}_1 \times 500$. Fra uttrykkene til $\hat{\beta}_0$ og $\hat{\beta}_1$ er $\hat{\mu} = \hat{\beta}_0 + \hat{\beta}_1 \times 500 = \bar{Y} + \hat{\beta}_1(500 - \bar{x}) = \sum_{i=1}^9 Y_i [1/9 + (x_i - \bar{x})(500 - \bar{x})/S_{xx}]$, der $\bar{x}$ er gjennomsnittet av de ni vektene og $S_{xx} = \sum_{i=1}^9 (x_i - \bar{x})^2$. Siden observasjonene $Y_1, \dots, Y_9$ er uavhengige er derfor $\hat{\mu}$ en lineær kombinasjon av uavhengige normalfordelte variable, og derfor selv normalfordelt med varians $V(\hat{\mu}) = \sum_{i=1}^9 V(Y_i) [1/9 + (x_i - \bar{x})(500 - \bar{x})/S_{xx}]^2 = \sigma^2 (1/9 + (500 - \bar{x})^2 / S_{xx}) = \sigma^2 (1/9 + (500 - \bar{x})^2 / S_{xx}) = \sigma^2_{\hat{\mu}}$. Standardfeilen til $\hat{\mu}$ estimeres med $S\sqrt{(1/9 + (500 - \bar{x})^2 / S_{xx})}$. Det betyr at $(\hat{\mu} - \mu)/\sigma_{\hat{\mu}}$ er standard normalfordelt og $(\hat{\mu} - \mu)/s_{\hat{\mu}}$ t-fordelt med $n - 2$ frihetsgrader.

Et 95% konfidensintervall har derfor grensen $\hat{\mu} \pm t_{0.025,7} s_{\hat{\mu}}$ der $t_{0.025,7}$ er den kritiske verdien definert ved $P(T > t_{\alpha,k}) = \alpha$ når T er t-fordelt med k frihetsgrader.

Estimatet for μ er $-1828.09 + 5.966 \times 500 = 1155.31$. I dette tilfellet er også $S_{xx} = \sum_{i=1}^9 (x_i - \bar{x})^2 = \sum_{i=1}^9 (x_i^2) - 9 \times \bar{x}^2 = 1714916 - 9 \times (3924/9)^2 = 4052$ og $s_{\hat{\mu}} = 33.41 \sqrt{1/9 + (500 - (3924/9)^2 / 4052)} = 35.39$. Fra tabellen er $t_{0.025,7} = 2.365$ slik at grensene til konfidensintervallet blir $1155.31 \pm 2.365 \times 35.39$ som gir intervallet $(1071.63, 1238.99)$.

- e) Et estimat for en ny fisk med lengde 50cm er fortsatt $\hat{Y} = \hat{\mu}$. Da er prediksjonsfeilen $Y - \hat{Y}$. Ved å bruke uttryket for $\hat{\mu}$ fra forrige punkt kan dette skrives $Y - \hat{Y} = Y - \sum_{i=1}^9 Y_i [1/9 + (x_i - \bar{x})(500 - \bar{x})/S_{xx}]$. Her er $Y, Y_1, \dots, Y_7$ avhengige normalfordelte variable. Siden $Y - \hat{Y}$ er en lineær kombinasjon av dem, er $Y - \hat{Y}$ også normalfordelt med forventning $E(Y - \hat{Y}) = [\beta_0 + \beta_1 \times 500] - [\beta_0 + \beta_1 \times 500] = 0$. Variablene er uavhengige slik at variansen er $V(Y - \hat{Y}) = V(Y) + V(\hat{Y}) = \sigma^2 + \sigma^2 (1/9 + (500 - \bar{x})^2 / S_{xx}) = \sigma^2 + \sigma_{\hat{\mu}}^2$. Da er $(Y - \hat{Y})/\sigma \sqrt{1 + (1/9 + (500 - \bar{x})^2 / S_{xx})}$ standard normalfordelt og $(Y - \hat{Y})/S \sqrt{1 + (1/9 + (500 - \bar{x})^2 / S_{xx})}$ t-fordelt med 7 frihetsgrader. Derfor er

$$0.95 = P(-t_{0.025,7} < (Y - \hat{Y})/S \sqrt{1 + (1/9 + (500 - \bar{x})^2 / S_{xx})} < t_{0.025,7}) = P(\hat{Y} - t_{0.025,7} S \sqrt{1 + (1/9 + (500 - \bar{x})^2 / S_{xx})} < Y < \hat{Y} + t_{0.025,7} S \sqrt{1 + (1/9 + (500 - \bar{x})^2 / S_{xx})})$$

slik at et 95% prediksjonsintervall har grense $\hat{\mu} \pm t_{0.025,7} s \sqrt{1 + (1/9 + (500 - \bar{x})^2 / S_{xx})} = \hat{\mu} \pm t_{0.025,7} s \sqrt{1 + (1/9 + s_{\hat{\mu}}^2)}$.

Tolkningen er at hvis man gjentatte ganger observerer 9 fisk med samme lengder som i denne undersøkelsen og hver gang beregner

prediksjonsintervall som ovenfor, vil i 95% av tilfellene en tiende fisk som er 50cm lang ha en vekt som ligger innen prediksjonsintervallene.

I dette tilfellet blir grensene $1155.31 \pm 2.365 \times 33.41 \sqrt{1 + 1/9 + (500 - (3924/9)^2/4025)}$ som gir intervallet (1040.23, 1270.40).

Med stor grad av sikkerhet vil derfor en ny fisk med lengde 50cm veie mellom 1.040 og 1.270 kg.

- f) Det som kalles "Multiple R-squared" i utskriften eller r^2 har tolkning som andelen av variasjonen i responsen som forklares ved variasjonen i de uavhengige variable. I dette tilfellet andelen av variasjonen i vekten til fiskene som kan forklares ved variasjonen i lengdene. Tallet 0.9486 viser at en stor slik andel forklares.

r^2 er definert som $1 - SSE/SST$ der SST er den totale variasjonen $SST = \sum_{i=1}^9 (y_i - \bar{y})^2$ og SSE er den residuale kvadratsummen $SSE = \sum_{i=1}^9 (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 = \sum_{i=1}^9 (y_i - \hat{y}_i)^2$.

Men $SSE = \sum_{i=1}^9 (y_i - \hat{y})^2 = \sum_{i=1}^9 [(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)]^2 = \sum_{i=1}^9 [(y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) - \hat{\beta}_1 x_i)]^2 = \sum_{i=1}^9 [(y_i - \bar{y}) - \hat{\beta}_1 (x_i - \bar{x})]^2 = \sum_{i=1}^9 (y_i - \bar{y})^2 - 2\hat{\beta}_1 \sum_{i=1}^9 (y_i - \bar{y})(x_i - \bar{x}) + \hat{\beta}_1^2 \sum_{i=1}^9 (x_i - \bar{x})^2 = SST - 2\hat{\beta}_1 (\hat{\beta}_1 S_{xx}) + \hat{\beta}_1^2 S_{xx} = SST - \hat{\beta}_1^2 S_{xx}$.

Herav følger at $SST - SSE = \hat{\beta}_1^2 S_{xx}$ slik at $r^2 = 1 - SSE/SST = \hat{\beta}_1^2 S_{xx} / S_{yy} = S_{xy}^2 / S_{xx} S_{yy}$ siden $\hat{\beta}_1 = \sum_{i=1}^9 y_i (x_i - \bar{x}) / \sum_{i=1}^9 (x_i - \bar{x})^2 = S_{xy} / S_{xx}$. Men $S_{xy}^2 / S_{xx} S_{yy}$ er ikke annet en kvadratet av den empiriske korrelasjonskoeffesienten. Betegner vi den med r_e har vi altså $r^2 = (r_e)^2$.

SLUTT

Løsningsforslag til eksamen i STK1110 10. desember 2010

Løsningsforslaget har med flere detaljer enn det vil bli krevd til eksamen.

Oppgave 1

a) Det er tilpasset en multipl linear regresjonsmodell av formen

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \epsilon_i$$

Her er responsen Y_i bensinforbruket for bil nummer i , mens forklaringsvariablene x_{i1} , x_{i2} og x_{i3} er henholdsvis antall hestekrefter for motoren, vekten til bilen og slagvolumet for motoren. Videre angir ϵ_i -ene de tilfeldige avvikene, som antas å være uavhengige og $N(0, \sigma^2)$ -fordelte.

I R-utskriften står det følgende i kolonnene i tabellen:

Estimate:	Minste kvadraters estimater for β_0 , β_1 , β_2 og β_3 .
Std. Error:	Estimerte standardfeil til estimatene nevnt i forrige punkt.
t value:	Testobservatorer for testing av $H_0 : \beta_j = 0$ mot $H_a : \beta_j \neq 0$; $j = 0, 1, 2, 3$. Testobservatorene er forholdet mellom estimatene og de estimerte standardfeilene.
Pr(> t):	P-verdier for testene nevnt i forrige punkt.

Under tabellen er **Residual standard error** oppgitt. Det er estimatet for σ . Videre er det gitt **Multiple R-squared**. Denne står for R^2 , som er et mål for hvor stor andel av variasjonen i responsen (dvs. bensinforbruket) som er forklart av regresjonsmodellen (dvs. av antall hestekrefter, vekt og slagvolum).

b) Vi lar som i forrige punkt β_3 være regresjonskoeffisienten for slagvolum. Vi vil teste nullhypotesen $H_0 : \beta_3 = 0$ mot den alternative hypotesen $H_0 : \beta_3 \neq 0$. Vi bruker da testobservatoren $T = \hat{\beta}_3 / S_{\hat{\beta}_3}$, der $S_{\hat{\beta}_3}$ er en estimator for standardfeilen til $\hat{\beta}_3$. Hvis nullhypotesen er sann, er testobservatoren t-fordelt med $19 - 4 = 15$ frihetsgrader.

En test med signifikansnivå α forkaster H_0 hvis

$$T \leq -t_{\alpha/2, 15} \quad \text{eller} \quad T \geq t_{\alpha/2, 15}$$

Av R-utskriften i punkt a er minste kvadraters estimat for regresjonskoeffisienten $\hat{\beta}_3 = -0.23979$, mens estimatet for standardfeilen er $s_{\hat{\beta}_3} = 0.07335$. Testobservatoren T får dermed verdien $t = -0.23979/0.07335 = -3.27$. Fra tabellen over t-fordelingene, finner vi at $t_{0.005, 15} = 2.947$ og $t_{0.001, 15} = 3.733$. Vi forkaster altså nullhypotesen hvis signifikansnivået er $2 \cdot 0.005 = 0.01 = 1\%$, men ikke hvis signifikansnivået er $2 \cdot 0.001 = 0.002 = 0.2\%$. P-verdien for testen (jf. oppgave 2b) er dermed mellom 0.2% og 1% . Vi forkaster nullhypotesen og konkludere med at slagvolumet har en signifikant effekt for bensinforbruket.

Estimatet $\hat{\beta}_3 = -0.24$ forteller oss at hvis slagvolumet økes med én liter og antall hestekrefter og vekten av bilen ikke endres, så vil forventet bensinforbruk bli redusert med 0.24 liter per mil. Hvis vi sammenligner biler med samme motorstyrke og samme vekt, vil vi altså forvente at den bilen som har størst slagvolum bruker minst bensin. Av plottet først i oppgaven ser det ut til at bensinforbruket øker med slagvolumet. Men det kommer av at en bil som har stort slagvolum typisk også vil veie mer og ha en sterkere motor enn en bil med mindre slagvolum.

c) Som i punkt a lar vi β_1 være regresjonskoeffisienten for hestekrefter. Det betyr at β_1 er forventet endring i bensinforbruket når styrken til motoren økes med én hestekraft og vekt og slagvolum ikke endres. Vi vil bestemme et 95% konfidensintervall for $\theta = 10\beta_1$.

Vi har at $(\hat{\beta}_1 - \beta_1)/S_{\hat{\beta}_1}$ er t-fordelt med 15 frihetsgrader. Det gir

$$P\left(-t_{0.025, 15} < \frac{\hat{\beta}_1 - \beta_1}{S_{\hat{\beta}_1}} < t_{0.025, 15}\right) = 0.95$$

Av dette følger på vanlig måte at

$$P\left(\hat{\beta}_1 - t_{0.025, 15} S_{\hat{\beta}_1} < \beta_1 < \hat{\beta}_1 + t_{0.025, 15} S_{\hat{\beta}_1}\right) = 0.95$$

Vi ganger med 10 på begge sider av ulikhetene og får (siden $\theta = 10\beta_1$)

$$P\left(10\hat{\beta}_1 - 10 t_{0.025, 15} S_{\hat{\beta}_1} < \theta < 10\hat{\beta}_1 + 10 t_{0.025, 15} S_{\hat{\beta}_1}\right) = 0.95$$

Et 95% konfidensintervall for θ er dermed gitt som

$$\left(10\hat{\beta}_1 - 10 t_{0.025, 15} S_{\hat{\beta}_1}, 10\hat{\beta}_1 + 10 t_{0.025, 15} S_{\hat{\beta}_1}\right)$$

Fra R-utskriften finner vi estimatene $\hat{\beta}_1 = 0.00604$ og $s_{\hat{\beta}_1} = 0.00148$, og av tabellen for t-fordelingene finner vi $t_{0.025, 15} = 2.131$. Det gir følgende 95% konfidensintervall for θ

$$(10 \cdot 0.00604 - 10 \cdot 2.131 \cdot 0.00148, 10 \cdot 0.00604 + 10 \cdot 2.131 \cdot 0.00148)$$

dvs. (0.029, 0.092). Det betyr at vi med stor grad av sikkerhet kan si at når motorstyrken økes med 10 hestekrefter (og vekt og slagvolum ikke endres), så vil forventet bensinforbruk øke med mellom 0.029 og 0.092 liter per mil.

d) I punkt a skrev vi opp modellen for den multiple lineære regresjonen. Modellen bygger på følgende forutsetninger:

- (i) Forventet bensinforbruk avhenger lineært av de tre forklaringsvariablene (x_1 = hestekrefter, x_2 = vekt og x_3 = slagvolum)
- (ii) De tilfeldige avvikene (dvs. ϵ_i -ene) har alle samme varians.
- (iii) De tilfeldige avvikene er normalfordelte.
- (iv) De tilfeldige avvikene er uavhengige.

For å kontrollere disse forutsetningene kan vi lage ulike plott av residualene. Residualene er gitt ved

$$e_i = y_i - \hat{y}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \hat{\beta}_3 x_{i3})$$

der y_i -ene er de observerte forbrukene av bensin. Residualene er prediksjoner av de uobserverte ϵ_i -ene, og hvis forutsetningene for regresjonsanalysen er rimelig godt oppfylt, skal residualene oppføre seg (omtrent) som uavhengige og $N(0, \sigma^2)$ -fordelte variabler.

Plottet øverst til venstre er et normalfordelingsplott av residualene. Hvis de tilfeldige avvikene er normalfordelte vil punktene i dette plottet ligge noenlunde på en rett linje. Det er tilfellet her, så forutsetning (iii) er rimelig godt oppfylt.

Plottet øverst til høyre er et plott av residualene mot de tilpassede verdiene ($\hat{y}_i$ -ene). Hvis de tilfeldige avvikene alle har samme varians, vil residualene fordele seg tilfeldig (i y -retningen), mens en "viftefasong" av residualene vil være et tegn på at de tilfeldige avvikene ikke har samme varians. Her fordeler residualene seg noenlunde tilfeldig, så forutsetning (ii) er rimelig godt oppfylt.

De tre nederste plottene er plott av residualene mot hver av forklaringsvariablene. Hvis forventet bensinforbruk avhenger lineært av en forklaringsvariabel, vil residualene fordele seg tilfeldig (i y -retningen), mens et systematisk mønster for residualene (f. eks. en krumning) vil tyde på at sammenhengen ikke er lineær. Her fordeler residualene seg noenlunde tilfeldig, så forutsetning (i) er rimelig godt oppfylt for alle forklaringsvariablene (muligens med unntak av slagvolum der det er antydning til en viss krumning).

Ingen av residualplottene som er gitt i oppgaven egner seg til å kontrollere forutsetning (iv). Men det er antageligvis en uproblematisk forutsetning her.

Oppgave 2

a) La X være antall seksere vi får når marmorteringen blir kastet 204 ganger. Da er X binomisk(n, p)-fordelt, der $n = 204$ og p er sannsynligheten for å få sekser når vi kaster marmorteringen.

Vi vil teste nullhypotesen $H_0 : p = p_0$ mot den alternative hypotesen $H_a : p > p_0$, der $p_0 = \frac{1}{6}$. Vi innfører

$\hat{p} = X/n$ og merker oss at $np_0 = 204 \cdot \frac{1}{6} = 34$ og $n(1 - p_0) = 204 \cdot \frac{5}{6} = 170$ begge er større enn 10. Det følger da at

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} = \frac{\hat{p} - \frac{1}{6}}{\sqrt{\frac{\frac{1}{6} \cdot \frac{5}{6}}{204}}} = \frac{\hat{p} - 1/6}{\sqrt{5/7344}}$$

er tilnærmet standardnormalfordelt hvis H_0 er sann.

La z_α være som gitt i læreboka. Da er $P(Z \geq z_\alpha) = \alpha$ hvis H_0 er sann. Vi får derfor en test med signifikansnivå 5% hvis vi forkaster H_0 såsant $Z \geq z_{0.05} = 1.645$.

Da marmorteringen ble kastet 204 ganger, fikk en sekser i 54 av kastene. Testobservatoren Z får da verdien

$$z = \frac{54/204 - 1/6}{\sqrt{5/7344}} = 3.76$$

Siden $z = 3.76 \geq 1.645$ forkaster vi nullhypotesen. Konklusjonen er da at sannsynligheten for å få sekser med marmorteringen er større enn en seksdel.

b) P-verdien til en test er det minste signifikansnivået α som gir forkastning av nullhypotesen. Litt mer uformelt, kan vi si at P-verdien er sannsynligheten for å få et resultat som det vi har fått, eller et resultat som er enda mer i favør av den alternative hypotesen, bare på grunn av tilfeldigheter (dvs. hvis H_0 er sann).

Tabellen over den kumulative standardnormalfordelingen $\Phi(z)$ som er gitt i læreboka dekker verdier av z fra -3.49 til 3.49 . Siden testobservatoren har verdien 3.76 , klarer vi ikke å bestemme P-verdien helt nøyaktig av tabellen. Men av tabellen ser vi at vi får en test med signifikansnivå 0.02% hvis vi forkaster H_0 såsant $Z \geq 3.49$. Vi vil altså forkaste nullhypotesen på dette nivået, så P-verdien er mindre enn 0.02%. Det betyr at det er svært usannsynlig å få 54 eller flere seksere i 204 kast hvis sannsynligheten for sekser er $1/6$. Vi er derfor veldig sikre på at sannsynligheten for å få sekser med marmorteringen er større enn en seksdel.

c) Da terningen av jern ble kastet 204 ganger, fikk en sekser i 42 av kastene. Testobservatoren Z i punkt a får da verdien

$$z = \frac{42/204 - 1/6}{\sqrt{5/7344}} = 1.50$$

Siden $z = 1.50 < 1.645$ forkaster vi ikke nullhypotesen på signifikansnivå 5%. Vi kan derfor ikke konkludere med at sannsynligheten for å få sekser med terningen av jern er større enn en seksdel. (Men siden P-verdien er såpass liten som 6.7% har vi en indikasjon på at sannsynligheten for sekser kan være større enn en seksdel, men at testen ikke har nok styrke til å oppdage det.)

d) Vi gjør en feil av type II hvis vi ikke forkaster nullhypotesen når den er gal. Vi forkaster ikke H_0 på signifikansnivå 5% hvis $Z < 1.645$. Hvis sannsynligheten for å få sekser med terningen av jern er $p = 0.20$, blir sannsynligheten for feil av type II

$$\begin{aligned} \beta(0.20) &= P(Z < 1.645 | p = 0.20) \\ &= P\left(\frac{\hat{p} - 1/6}{\sqrt{5/7344}} < 1.645 \mid p = 0.20\right) \\ &= P\left(\hat{p} < 1/6 + 1.645\sqrt{5/7344} \mid p = 0.20\right) \\ &= P\left(\frac{\hat{p} - 0.20}{\sqrt{0.20 \cdot 0.80/204}} < \frac{1/6 - 0.20 + 1.645\sqrt{5/7344}}{\sqrt{0.20 \cdot 0.80/204}} \mid p = 0.20\right) \\ &= P\left(\frac{\hat{p} - 0.20}{\sqrt{0.20 \cdot 0.80/204}} < 0.34 \mid p = 0.20\right) \\ &= 0.633 \end{aligned}$$

Her får vi den siste likheten fra tabellen over den kumulative standardnormalfordelingen siden

$$\frac{\hat{p} - 0.20}{\sqrt{0.20 \cdot 0.80/204}}$$

er (tilnærmet) standardnormalfordelt når $p = 0.20$. Sannsynligheten for feil av type II er altså 63.3% hvis sannsynligheten for å få sekser med terningen av jern er 20%.

e) Hvis vi kaster terningen av jern n ganger, vil en test med signifikansnivå 5% forkaste H_0 såsant

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} = \frac{\hat{p} - \frac{1}{6}}{\sqrt{\frac{\frac{1}{6} \cdot \frac{5}{6}}{n}}} = \frac{\hat{p} - 1/6}{\sqrt{5/(36n)}} \geq 1.645$$

jf. punkt a. Hvis sannsynligheten for å få sekser med terningen av jern er $p = 0.20$, blir sannsynligheten for feil av type II (jf. punkt d):

$$\begin{aligned} \beta(0.20) &= P(Z < 1.645 | p = 0.20) \\ &= P\left(\frac{\hat{p} - 1/6}{\sqrt{5/(36n)}} < 1.645 \mid p = 0.20\right) \\ &= P\left(\hat{p} < 1/6 + 1.645\sqrt{5/(36n)} \mid p = 0.20\right) \\ &= P\left(\frac{\hat{p} - 0.20}{\sqrt{0.20 \cdot 0.80/n}} < \frac{1/6 - 0.20 + 1.645\sqrt{5/(36n)}}{\sqrt{0.20 \cdot 0.80/n}} \mid p = 0.20\right) \\ &= P\left(\frac{\hat{p} - 0.20}{\sqrt{0.20 \cdot 0.80/n}} < -0.0833\sqrt{n} + 1.533 \mid p = 0.20\right) \end{aligned}$$

Hvis $p = 0.20$ er $(\hat{p} - 0.20)/\sqrt{0.20 \cdot 0.80/n}$ tilnærmet standardnormalfordelt. Av tabellen over den kumulative standardnormalfordelingen har vi dermed at

$$P\left(\frac{\hat{p} - 0.20}{\sqrt{0.20 \cdot 0.80/n}} < -0.84 \mid p = 0.20\right) = 0.20$$

For at sannsynligheten for feil av type II skal være 20% hvis $p = 0.20$ må derfor n bestemmes slik at

$$-0.0833\sqrt{n} + 1.533 = -0.84$$

Det gir

$$n = \left(\frac{1.533 + 0.84}{0.0833}\right)^2 = 811.5$$

Hvis sannsynligheten for feil av type II skal være 20% når $p = 0.20$ må vi kaste terningen omtrent 810 ganger.

Oppgave 3

a) Minste kvadraters estimatorer for β_0 og β_1 er de verdiene av b_0 og b_1 som minimerer kvadratsummen

$$SS(b_0, b_1) = \sum_{i=1}^n (Y_i - b_0 - b_1(x_i - \bar{x}))^2$$

Vi deriverer med hensyn på b_0 og finner

$$\frac{\partial}{\partial b_0} SS(b_0, b_1) = -2 \sum_{i=1}^n (Y_i - b_0 - b_1(x_i - \bar{x}))$$

$$\begin{aligned}
&= -2 \left(\sum_{i=1}^n Y_i - nb_0 - b_1 \sum_{i=1}^n (x_i - \bar{x}) \right) \\
&= -2 \left(\sum_{i=1}^n Y_i - nb_0 \right)
\end{aligned}$$

der den siste likheten følger siden $\sum_{i=1}^n (x_i - \bar{x}) = 0$. Vi deriverer også med hensyn på b_1 og får

$$\begin{aligned}
\frac{\partial}{\partial b_1} \text{SS}(b_0, b_1) &= -2 \sum_{i=1}^n (Y_i - b_0 - b_1(x_i - \bar{x})) (x_i - \bar{x}) \\
&= -2 \left(\sum_{i=1}^n (x_i - \bar{x}) Y_i - b_0 \sum_{i=1}^n (x_i - \bar{x}) - b_1 \sum_{i=1}^n (x_i - \bar{x})^2 \right) \\
&= -2 \left(\sum_{i=1}^n (x_i - \bar{x}) Y_i - b_1 \sum_{i=1}^n (x_i - \bar{x})^2 \right) \\
&= -2 \left(\sum_{i=1}^n (x_i - \bar{x}) Y_i - S_{xx} b_1 \right)
\end{aligned}$$

der $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$.

Minste kvadraters estimatorer for $\hat{\beta}_0$ og $\hat{\beta}_1$ er løsningene av de ligningene vi får når vi setter de partiell deriverte lik null. Det gir

$$\begin{aligned}
\sum_{i=1}^n Y_i - n\hat{\beta}_0 &= 0 \\
\sum_{i=1}^n (x_i - \bar{x}) Y_i - S_{xx} \hat{\beta}_1 &= 0
\end{aligned}$$

Minste kvadraters estimatorer er dermed

$$\begin{aligned}
\hat{\beta}_0 &= \frac{1}{n} \sum_{i=1}^n Y_i = \bar{Y} \\
\hat{\beta}_1 &= \frac{\sum_{i=1}^n (x_i - \bar{x}) Y_i}{S_{xx}} = \sum_{i=1}^n \frac{x_i - \bar{x}}{S_{xx}} Y_i
\end{aligned}$$

b) Vi bruker at $E(Y_i) = \beta_0 + \beta_1(x_i - \bar{x})$ og får

$$\begin{aligned}
E(\hat{\beta}_0) &= E \left(\frac{1}{n} \sum_{i=1}^n Y_i \right) = \frac{1}{n} \sum_{i=1}^n E(Y_i) \\
&= \frac{1}{n} \sum_{i=1}^n (\beta_0 + \beta_1(x_i - \bar{x})) \\
&= \frac{1}{n} n\beta_0 + \frac{1}{n} \beta_1 \sum_{i=1}^n (x_i - \bar{x}) \\
&= \beta_0 + 0 = \beta_0
\end{aligned}$$

Det viser at $\hat{\beta}_0$ er forventningsrett.

Vi finner videre at

$$\begin{aligned}
 E(\hat{\beta}_1) &= E\left(\sum_{i=1}^n \frac{x_i - \bar{x}}{S_{xx}} Y_i\right) = \sum_{i=1}^n \frac{x_i - \bar{x}}{S_{xx}} E(Y_i) \\
 &= \sum_{i=1}^n \frac{x_i - \bar{x}}{S_{xx}} (\beta_0 + \beta_1(x_i - \bar{x})) \\
 &= \frac{\beta_0}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) + \frac{\beta_1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x})^2 \\
 &= 0 + \frac{\beta_1}{S_{xx}} S_{xx} = \beta_1
 \end{aligned}$$

Det viser at også $\hat{\beta}_1$ er forventningsrett.

c) Vi bruker at $V(Y_i) = \sigma^2$ og får siden Y_i -ene er uavhengige

$$V(\hat{\beta}_0) = V\left(\frac{1}{n} \sum_{i=1}^n Y_i\right) = \frac{1}{n^2} \sum_{i=1}^n V(Y_i) = \frac{1}{n^2} n\sigma^2 = \frac{\sigma^2}{n}$$

og

$$\begin{aligned}
 V(\hat{\beta}_1) &= V\left(\sum_{i=1}^n \frac{x_i - \bar{x}}{S_{xx}} Y_i\right) = \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{S_{xx}}\right)^2 V(Y_i) \\
 &= \frac{\sigma^2}{S_{xx}^2} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{\sigma^2}{S_{xx}^2} S_{xx} = \frac{\sigma^2}{S_{xx}}
 \end{aligned}$$

For kovariansen får vi når vi bruker hintet

$$\begin{aligned}
 \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) &= \text{Cov}\left(\sum_{i=1}^n \frac{1}{n} Y_i, \sum_{i=1}^n \frac{x_i - \bar{x}}{S_{xx}} Y_i\right) \\
 &= \sum_{i=1}^n \frac{1}{n} \frac{x_i - \bar{x}}{S_{xx}} V(Y_i) \\
 &= \frac{\sigma^2}{n S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) = 0
 \end{aligned}$$

d) Vi bruker resultatet i punkt b og finner at

$$\begin{aligned}
 E(\hat{\mu}_{Y \cdot x^*}) &= E\left(\hat{\beta}_0 + \hat{\beta}_1(x^* - \bar{x})\right) \\
 &= E(\hat{\beta}_0) + E(\hat{\beta}_1)(x^* - \bar{x}) \\
 &= \beta_0 + \beta_1(x^* - \bar{x}) = \mu_{Y \cdot x^*}
 \end{aligned}$$

så estimatoren er forventningsrett. Videre får vi av resultatet i punkt c

$$\begin{aligned}
 V(\hat{\mu}_{Y \cdot x^*}) &= V\left(\hat{\beta}_0 + \hat{\beta}_1(x^* - \bar{x})\right) \\
 &= V(\hat{\beta}_0) + V\left(\hat{\beta}_1(x^* - \bar{x})\right) + 2 \text{Cov}\left(\hat{\beta}_0, \hat{\beta}_1(x^* - \bar{x})\right) \\
 &= V(\hat{\beta}_0) + (x^* - \bar{x})^2 V(\hat{\beta}_1) + 2(x^* - \bar{x}) \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) \\
 &= \frac{\sigma^2}{n} + (x^* - \bar{x})^2 \frac{\sigma^2}{S_{xx}} + 2(x^* - \bar{x}) \cdot 0
 \end{aligned}$$

$$= \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)$$

Alternativt kan vi finne variansen ved å skrive $\hat{\mu}_{Y \cdot x^*}$ som en lineærkombinasjon av Y_i -ene (jf. punkt e) og bruke formelen for variansen til en lineærkombinasjon av uavhengige variabler.

e) Av resultatet i punkt a har vi at

$$\begin{aligned} \hat{\mu}_{Y \cdot x^*} &= \hat{\beta}_0 + (x^* - \bar{x})\hat{\beta}_1 \\ &= \frac{1}{n} \sum_{i=1}^n Y_i + (x^* - \bar{x}) \sum_{i=1}^n \frac{x_i - \bar{x}}{S_{xx}} Y_i \\ &= \sum_{i=1}^n \left(\frac{1}{n} + \frac{(x^* - \bar{x})(x_i - \bar{x})}{S_{xx}} \right) Y_i \end{aligned}$$

Altså er $\hat{\mu}_{Y \cdot x^*}$ en lineærkombinasjon av normalfordelte stokastiske variabler, så $\hat{\mu}_{Y \cdot x^*}$ er normalfordelt.

Det følger av dette at

$$Z = \frac{\hat{\mu}_{Y \cdot x^*} - E(\hat{\mu}_{Y \cdot x^*})}{\sqrt{V(\hat{\mu}_{Y \cdot x^*})}} = \frac{\hat{\mu}_{Y \cdot x^*} - \mu_{Y \cdot x^*}}{\sigma \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}}}$$

er standardnormalfordelt.

Siden $\hat{\mu}_{Y \cdot x^*}$ er en funksjon av $\hat{\beta}_0$ og $\hat{\beta}_1$, som er uavhengige av S^2 , er Z og $V = (n-2)S^2/\sigma^2$ uavhengige. Videre er V kji-kvadratfordelt med $n-2$ frihetsgrader. Dermed er

$$\frac{Z}{\sqrt{V/(n-2)}} = \frac{\frac{\hat{\mu}_{Y \cdot x^*} - \mu_{Y \cdot x^*}}{\sigma \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}}}}{\sqrt{\frac{(n-2)S^2}{\sigma^2} / (n-2)}} = \frac{\hat{\mu}_{Y \cdot x^*} - \mu_{Y \cdot x^*}}{S \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}}}$$

t-fordelt med $n-2$ frihetsgrader.

La nå $t_{\alpha/2, n-2}$ være som gitt i læreboka. Da har vi at

$$P \left(-t_{\alpha/2, n-2} < \frac{\hat{\mu}_{Y \cdot x^*} - \mu_{Y \cdot x^*}}{S \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}}} < t_{\alpha/2, n-2} \right) = 1 - \alpha$$

Vi omformer ulikhetene og får at dette er det samme som

$$P \left(-t_{\alpha/2, n-2} S \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}} < \hat{\mu}_{Y \cdot x^*} - \mu_{Y \cdot x^*} < t_{\alpha/2, n-2} S \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}} \right) = 1 - \alpha$$

som igjen er det samme som

$$P \left(\hat{\mu}_{Y \cdot x^*} - t_{\alpha/2, n-2} S \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}} < \mu_{Y \cdot x^*} < \hat{\mu}_{Y \cdot x^*} + t_{\alpha/2, n-2} S \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}} \right) = 1 - \alpha$$

Et $100(1 - \alpha)\%$ konfidensintervall for $\mu_{Y \cdot x^*}$ er dermed gitt ved

$$\left(\hat{\mu}_{Y \cdot x^*} - t_{\alpha/2, n-2} S \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}}, \hat{\mu}_{Y \cdot x^*} + t_{\alpha/2, n-2} S \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}} \right)$$

Fasit eksamen STK1110 2. desember 2009

Oppgave 1

- a). La differansene $D_i = A_i - B_i$ der A_i og B_i er avkastning i måned i for hhv. megler A og megler B, $i = 1, \dots, 36$. Differansene har forventning μ ; $\mu = 0$ betyr at det er ingen forskjell på meglerne, $\mu < 0$ betyr at megler A har mindre avkastning enn megler B, som er det vi vil undersøke om er tilfelle.

Testobservator

$$T = \frac{\bar{D}}{s_D/\sqrt{36}},$$

der s_D er empirisk standardavvik til differansene. $T \sim t$ -fordelt med 35 frihetsgrader når H_0 er sann, under antakelse om at D_i -ene er uavhengige og normalfordelte.

- b). Finner forkastningsområdet i henhold til $P(\text{forkast } H_0 | H_0 \text{ riktig}) \leq 0.01$. Forkast H_0 når observert verdi av T (t) er mindre enn -2.441 ($-t_{0.01,34}$). 35 frihetsgrader er ikke oppgitt i tabellen, bruker 34 for å være garantert at nivået opprettholdes. $t = (-1.1 - 0.95)/(5.89/6) = -2.088$, ingen grunn til å forkaste H_0 på nivå 0.01.

P -verdi = $P(T \leq -2.088)$ når $T \sim t(35)$, fra tabell må denne ligge mellom 0.01 og 0.025 (igjen tabell for 34 frihetsgrader). Ganske liten P -verdi, forkastning på nivå 0.05, ikke på nivå 0.01. Trolig ikke nok til å overbevise i retten, kan ikke utelukke at det er tilfeldig at megler A kommer så dårlig ut i forhold til megler B som han gjør.

- c). Starter med at vi vet at $\frac{(n-1)s_D^2}{\sigma^2} \sim \chi_{n-1}^2$ under antakelsen om normalfordeling.

$$P(\chi_{0.975,n-1}^2 < \frac{(n-1)s_D^2}{\sigma^2} < \chi_{0.025,n-1}^2) = 0.95$$

gir etter enkel manipulering

$$P\left(\sqrt{\frac{(n-1)s_D^2}{\chi_{0.025,n-1}^2}} < \sigma < \sqrt{\frac{(n-1)s_D^2}{\chi_{0.975,n-1}^2}}\right) = 0.95.$$

Innsatt $n = 36$, $s_D = 5.89$, $\chi_{0.025,35}^2 = 53.203$, $\chi_{0.975,35}^2 = 20.569$ får vi intervallet (4.78, 7.68).

- d) Se s. 503-504 i boken. Dersom avkastningene for A og B kan betraktes som to uavhengige utvalg, vil en toutvalgstest gi flere frihetsgrader og lavere β (høyere styrke). Men naturlig å anta at det er en positiv avhengighet i avkastningen hver måned for de to meglerne (pga. markedet de begge opererer i), slik at en toutvalgstest ikke vil være riktig å bruke.

Oppgave 2

- a). β_1 er forventet endring i prothorombintid for ett milligram endring i dose (likt for kvinner og menn). β_2 er forventet forskjell i prothorombintid mellom kvinner og

menn ved samme dose. Rimelig fra plottet med en linje for kvinner og en for menn, men usikkert om de er parallelle, slik modellen sier de skal være (kan se ut som om kvinnene har høyere stigningstall enn menn).

b). 95% konfidensintervall for β_2 :

$$\frac{\hat{\beta}_2 - \beta_2}{s_{\hat{\beta}_2}} \sim t(n - (k + 1)),$$

som her blir $20 - (2 + 1) = 17$ frihetsgrader. Gir intervallet (2.97, 4.61) for β_2 . Forkaster $H_0 : \beta_2 = 0$ og konkluderer med $H_a : \beta_2 \neq 0$ på nivå .05 fordi 0 ikke ligger inne i intervallet. Generelt gjelder dette for $(1 - \alpha) \cdot 100\%$ konfidensintervall og test med tosidig alternativ på nivå α .

c). Residualer $e_i = y_i - \hat{y}_i$, $i = 1, \dots, 20$, der $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2}$.

Bør nevne forskjellige typer residualplott, og normalfordelingsplott for residualene. Multippel $R^2 = [\text{korrelasjonen mellom } y_i \text{ og } \hat{y}_i]^2$ tolkes som andelen av variasjonen i Y som kan forklares av regresjonsmodellen. 87.3% er rimelig høyt.

d). Ser på forventet prothrombintid for dose x_1 ,

$$\mu_Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2,$$

og for dose $x_1 + d$,

$$\mu'_Y = \beta_0 + \beta_1(x_1 + d) + \beta_2 x_2.$$

$\mu'_Y - \mu_Y = \beta_1 d$ er endring i forventet prothrombintid når dosen økes med d milligram, ser at denne er uavhengig av kjønn. Innfører interaksjonsledd - ny modell

$$\mu_Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2.$$

Da har vi

$$\mu'_Y = \beta_0 + \beta_1(x_1 + d) + \beta_2 x_2 + \beta_3(x_1 + d)x_2$$

og $\mu'_Y - \mu_Y = \beta_1 d + \beta_3 d x_2$. Det gir endring i forventet prothrombintid på $\beta_1 d$ for menn og $(\beta_1 + \beta_3)d$ for kvinner. Fra plottet ser det rimelig ut med forskjellig stigningstall for kvinner og menn, trolig interaksjon!

Oppgave 3

a). Må gjenkjenne at $X \sim \text{bin}(n, p)$. ML:

$$\text{lik}(x; p) = \binom{n}{x} p^x (1 - p)^{n-x}$$

$$\text{loglik}(x; p) = \log \binom{n}{x} + x \log p + (n - x) \log(1 - p)$$

$$\frac{\partial \log \text{lik}(x; p)}{\partial p} = \frac{x}{p} - \frac{(n-x)}{1-p} = 0$$

gir $\hat{p} = X/n$. Ikke påkrevet å vise at annenderiverte er negativ. Alternativ utledning via indikatorvariable, se s. 347 i boken. Moment: $E(X) = np$ settes lik observert verdi, gir også $\hat{p} = X/n$. Også her likestilt å innføre indikatorvariable.

- b). $E(\hat{p}) = E(X/n) = E(X)/n = np/n = p$, $V(\hat{p}) = V(X/n) = V(X)/n^2 = np(1-p)/n^2 = p(1-p)/n$.

$$P(|\hat{p} - p| > t) \leq \frac{p(1-p)}{nt^2} \rightarrow 0$$

når $n \rightarrow \infty$.

- c). $\hat{p} \sim N(p, p(1-p)/n)$. Tester $H_0 : p = 0.6$ mot $H_a : p > 0.6$. Velger nivå 0.05. Forkast H_0 når $\hat{p} > k$, $k = 0.6 + 1.645\sqrt{0.6 \cdot 0.4/200} = 0.657$. Observerer $\hat{p} = 122/200 = 0.61$; ingen grunn til å forkaste, vi kan ikke være sikre på at mer enn 60% vil vaksinere seg.
- d). Har fra binomisk fordeling at $E(X) = np$ og $V(X) = np(1-p)$. Hvis $\hat{p}$ er ML, er $\hat{\mu} = n\hat{p}$ og $\hat{\sigma}^2 = n\hat{p}(1-\hat{p})$ ML for $E(X)$ og $V(X)$ pga. invarians-egenskapen til ML-estimatorer. Innsatt $\hat{p} = X/n$ i $\hat{\sigma}^2$ får vi

$$E(\hat{\sigma}^2) = E(X) - \frac{1}{n}E(X^2) = E(X) - \frac{1}{n}(V(X) + E(X)^2) = (n-1)p(1-p)$$

som ikke er lik $np(1-p)$. Men ny estimator $\frac{n}{n-1}\hat{\sigma}^2$ vil være forventningsrett.

Løsningsforslag

Oppgave 1

- a) $\frac{X_i - \mu_0}{\sigma}$, $i = 1, \dots, 5$ er uavhengige og standard $N(0, 1)$ fordelte. Da er $\frac{(X_i - \mu_0)^2}{\sigma^2}$, $i = 1, \dots, 5$ uavhengige og χ^2 -fordelte med en frihetsgrad. Da er summen χ^2 -fordelt med antall frihetsgrader lik summen av antall frihetsgrader til hvert av leddene. Altså er $\frac{1}{\sigma^2} \sum_{i=1}^5 (X_i - \mu_0)^2 \sim \chi^2$ -fordelt med 5 frihetsgrader.

Da vet vi at $E[\frac{1}{\sigma^2} \sum_{i=1}^5 (X_i - \mu_0)^2] = 5$, dvs antall frihetsgrader, eller $E[\sum_{i=1}^5 (X_i - \mu_0)^2] = 5\sigma^2$ slik at $\frac{1}{5} \sum_{i=1}^5 (X_i - \mu_0)^2$ er en forventingsrett estimator for σ^2 . Variansen til en χ^2 -fordelt variabel er to ganger antall frihetsgrader, slik at

$$Var(\frac{1}{5} \sum_{i=1}^5 (X_i - \mu_0)^2) = Var(\frac{\sigma^2}{5} \sum_{i=1}^5 (X_i - \mu_0)^2 / \sigma^2) = \frac{\sigma^4}{25} \times 2 \times 5 = \frac{2\sigma^4}{5}$$

- b) Hvis $\sigma^2 > \sigma_0^2$, kan en forvente store verdier av $\sum_{i=1}^5 (X_i - \mu_0)^2$. Det er derfor rimelig å forkaste for store verdier av denne observatoren, dvs forkastningsområdet har formen $\{\sum_{i=1}^5 (X_i - \mu_0)^2 > k\}$.

Kravet om nivå α betyr at $\alpha = P(\text{forkaste } H_0 | H_0 \text{ riktig}) = P(\sum_{i=1}^5 (X_i - \mu_0)^2 > k | \sigma^2 = \sigma_0^2) = P(\sum_{i=1}^5 (X_i - \mu_0)^2 / \sigma_0^2 > k / \sigma_0^2 | \sigma^2 = \sigma_0^2)$ Derfor er $k / \sigma_0^2 = \chi_{1-\alpha, 5}^2$ der $\chi_{1-\alpha, 5}^2$ er $1 - \alpha$ kvantilen i χ^2 -fordelingen med 5 frihetsgrader.

En test med nivå α en blir derfor: Forkast H_0 når $\frac{1}{\sigma_0^2} \sum_{i=1}^5 (X_i - \mu_0)^2 > \chi_{1-\alpha, 5}^2$.

- c) Med tallene i oppgave er $\sum_{i=1}^5 (x_i - 100)^2 = 19.4$. Siden $\sigma_0^2 = 2$ er p-verdien $P(\chi_5^2 > 19.4/2 = 9.7)$ der χ_5^2 er en χ^2 -fordelt tilfeldig variabel med 5 frihetsgrader.

I dette tilfellet er $P(\chi_5^2 \leq 9.24) = 0.9$ og $P(\chi_5^2 \leq 11.07) = 0.95$, slik at p-verdien ligger mellom 0.05 og 0.1.

Ovenfor har vi beregnet sannsynligheten for at en χ_5^2 -fordelt variabel skal være større en den realiserte verdien av testobservatoren, som er en måte å definere p-verdier. En alternativ ekvivalent definisjon fås

ved å ta utgangspunkt i at en test med nivå α gir forkastning hvis $9.7 > \chi^2_{1-\alpha,5}$. Høre side i ulikheten er avtagende i α , slik at p-verdien er minste signifikansnivå som gjør at man forkaster nullhypotesen.

Oppgave 2

a) Antagelser:

- i) $x_1, \dots, x_{12}$ er faste gitte tall
- ii) $E[e_i] = 0, i = 1, \dots, 12$ slik at sammenhengen mellom $E[Y]$ og x er lineær.
- iii) $Var(e_i) = \sigma^2, i = 1, \dots, 12$, dvs uavhengig av $x_1, \dots, x_{12}$.
- iv) $e_i, i = 1, \dots, 12$ er uavhengige.

Dessuten antas ofte

- v) $e_i \sim N(0, \sigma^2), i = 1, \dots, 12$.

Egenskaper: Fra antagelsene i)-iv) kan det vises at estimatorene $\hat{\beta}_0$ og $\hat{\beta}_1$ er forventningsrette og at $Var(\hat{\beta}_0)$, $Var(\hat{\beta}_1)$ og $Cov(\hat{\beta}_0, \hat{\beta}_1)$ kan uttrykkes ved σ^2 og verdiene av den uavhengige variabelen, $x_1, \dots, x_{12}$.

b)

$$\hat{\beta}_1 = \frac{\sum y_i(x_i - \bar{x})}{\sum (x_i - \bar{x})^2} = \frac{\sum y_i x_i - (\sum y_i)(\sum x_i)/12}{\sum x_i^2 - (\sum x_i)(\sum x_i)/12} =$$

$$\frac{381.526 - 16.078 \times 280.869/12}{21.873 - 16.078 \times 16.078/12} = \frac{5.208}{0.331} = 15.728$$

Konfidensintervall: Med konfidenskoeffisient $1 - \alpha$ har konfidensintervallet grensene

$$\hat{\beta}_1 \pm t_{1-\alpha/2, n-2} s / \sqrt{\sum (x_i - \bar{x})^2}$$

der $n = 12$ og $t_{1-\alpha/2, n-2}$ er $1 - \alpha/2$ -fraktilen i t-fordelingen med $n - 2$ frihetsgrader og $s^2 = RSS/(n - 2)$.

Siden $t_{0.975, 10} = 2.23$, har 95%-konfidensintervallet grensene

$15.528 \pm 2.23 * \sqrt{(41.645/10) / \sqrt{((21.873 - 16.078 * 16.078/12))}}$ dvs.
(7.82, 23.64)

c)

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ Y_2 \\ Y_3 \\ \vdots \\ Y_{11} \\ Y_{12} \end{pmatrix}, \mathbf{X} = \begin{pmatrix} x_1 & z_1 \\ x_2 & z_2 \\ x_3 & z_3 \\ \vdots & \vdots \\ x_{11} & z_{11} \\ x_{12} & z_{12} \end{pmatrix} = \begin{pmatrix} 1.44 & 8 \\ 1.50 & 10 \\ 1.24 & 6 \\ \vdots & \vdots \\ 1.55 & 12 \\ 1.45 & 9 \end{pmatrix}, \mathbf{Y} = \begin{pmatrix} e_1 \\ e_2 \\ e_3 \\ \vdots \\ e_{11} \\ e_{12} \end{pmatrix}$$

og

$$\alpha = \begin{pmatrix} \alpha_1 \\ \alpha_2 \end{pmatrix}$$

d)

$$\mathbf{X}^T \mathbf{X} = \begin{pmatrix} 21.873 & 144.247 \\ 144.247 & 976.0 \end{pmatrix},$$

$$(\mathbf{X}^T \mathbf{X})^{-1} = \begin{pmatrix} 1.804 & -0.267 \\ -0.267 & 0.040 \end{pmatrix},$$

$$(\mathbf{X}^T \mathbf{y}) = \begin{pmatrix} 381.526 \\ 2534.908 \end{pmatrix}$$

$$\begin{pmatrix} \hat{\alpha}_1 \\ \hat{\alpha}_2 \end{pmatrix} = \begin{pmatrix} 1.804 & -0.267 \\ -0.267 & 0.040 \end{pmatrix} \begin{pmatrix} 381.526 \\ 2534.908 \end{pmatrix} = \begin{pmatrix} -- \\ -0.471 \end{pmatrix}$$

Estimert standardfeil: $\sqrt{28.3/10} \times \sqrt{0.04} = 0.336$

Oppgave 3

a) Se Rice for utledning:

$$\text{ME: } \tilde{\lambda} = \sum_i X_i / n$$

$$\text{SME: } \hat{\lambda} = \sum_i X_i / n$$

$$\text{Numerisk: } \hat{\lambda} = (0 \times 9 + 1 \times 7 + 2 \times 3 + 3 \times 1) / 20 = 16 / 20 = 0.8$$

- b) Se notat om konfidensintervall for utledning: Tilnærmet fordeling til $\hat{\lambda}$ for store verdier av n , dvs $n\lambda > 10$,

$$\frac{\sqrt{n}(\hat{\lambda} - \lambda)}{\sqrt{\hat{\lambda}}} \text{ tilnærmet } N(0, 1)$$

90% konfidensintervall har grenser: $\hat{\lambda} \pm 1.96\sqrt{\hat{\lambda}/n}$

Numerisk: $0.8 \pm 1.96\sqrt{0.8/20} = 0.8 \pm 1.96 \times 0.2 = 0.8 \pm 0.39$.

- c) La $Y_i = 1$ når $X_i = 0$ og $Y_i = 0$ når $X_i = 1, 2, \dots, 20$. Dette definerer $n = 20$ Bernoulli forsøk: (i) To kjennetegn, $Y_i = 1$ eller $Y_i = 0$, (ii) uavhengighet siden $X_1, \dots, X_n$ er uavhengige, (iii) konstant suksesssannsynlighet $P(Y_i = 1) = P(X_i = 0) = \exp(-\lambda)$. Siden antallet ulykkesfrie måneder, Y , er antallet suksesser, $Y_i = 1$, er Y binomisk fordelt

Punksannsynlighet :

$$P(Y_i = y) = \binom{n}{y} (\exp(-\lambda))^y (1 - \exp(-\lambda))^{n-y}, \quad y = 0, \dots, n$$

Momentestimatoren finnes fra ligningen $\frac{\sum_{i=1}^n Y_i}{n} = \exp(-\lambda)$, dvs. $\tilde{\lambda} = -\log(Y/n)$.

Numerisk: $\tilde{\lambda} = -\log(9/20) = 0.7985 \approx 0.8$. Log likelihood:

$$l(\lambda) = \log\left(\binom{n}{y}\right) - y\lambda + (n - y) \log(1 - \exp(-\lambda))$$

SME finnes fra ligningen

$$y + (n - y) \frac{1}{1 - \exp(-\lambda)} (-\exp(-\lambda)) = 0, \quad y = n \exp(-\lambda)$$

som gir estimatoren $\hat{\lambda} = -\log(Y/n)$.

Numerisk: $\hat{\lambda} = -\log(9/20) = 0.7985 \approx 0.8$.

- d) Fra sentralgrenseteoremet vil for store verdier av n

$$\frac{\sqrt{n}(Y/n - \exp(-\lambda))}{\sqrt{\exp(-\lambda)(1 - \exp(-\lambda))}} \text{ være tilnærmet } N(0, 1)$$

fordelt. Da er også

$$\frac{\sqrt{n}(Y/n - \exp(-\lambda))}{\sqrt{\exp(-\hat{\lambda})(1 - \exp(-\hat{\lambda}))}} \text{ tilnærmet } N(0, 1)$$

fordelt slik at

$$\begin{aligned} 0.9 &\approx P(-1.96 < \frac{\sqrt{n}(Y/n - \exp(-\lambda))}{\sqrt{\exp(-\hat{\lambda})(1 - \exp(-\hat{\lambda}))}} < 1.96) \\ &= P(Y/n - 1.96\sqrt{\exp(-\hat{\lambda})(1 - \exp(-\hat{\lambda}))}/\sqrt{n} < \exp(-\lambda)) \\ &< Y/n + 1.96\sqrt{\exp(-\hat{\lambda})(1 - \exp(-\hat{\lambda}))}/\sqrt{n} \\ &= P(-\log(Y/n + 1.96\sqrt{\exp(-\hat{\lambda})(1 - \exp(-\hat{\lambda}))}/\sqrt{n}) < \lambda) \\ &< -\log(Y/n - 1.96\sqrt{\exp(-\hat{\lambda})(1 - \exp(-\hat{\lambda}))}/\sqrt{n}) \end{aligned}$$

Numerisk: Det tilnærmede konfidensintervallet blir derfor

$$(-\log(0.45 + 1.96 \times \sqrt{0.45 \times 0.55}/\sqrt{20}), -\log(0.45 - 1.96 \times \sqrt{0.45 \times 0.55}/\sqrt{20})) = (0.40, 1.46).$$

Løsningsforslag til eksamen i
STK1110 5. desember 2007

Oppgave 1

a) Vi antar at slaktevektene til kalkunene fra Virginia er observerte verdier av stokastiske variabler X_1, X_2, X_3, X_4 som er uavhengige og $N(\mu_1, \sigma^2)$ -fordelte, og at slaktevektene til kalkunene fra Wisconsin er observerte verdier av stokastiske variabler Y_1, Y_2, Y_3, Y_4, Y_5 som er uavhengige og $N(\mu_2, \sigma^2)$ -fordelte. Vi antar også at X_i -ene og Y_j -ene er uavhengige.

Vi lar $\bar{X}$ være gjennomsnittet av X_i -ene og $\bar{Y}$ være gjennomsnittet av Y_j -ene. Videre lar vi S_1^2 være den empiriske variansen for X_i -ene og S_2^2 den empiriske variansen for Y_j -ene. Endelig innfører vi

$$S_p^2 = \frac{4-1}{4+5-2} S_1^2 + \frac{5-1}{4+5-2} S_2^2 = \frac{3}{7} S_1^2 + \frac{4}{7} S_2^2.$$

Et 90% konfidensintervall for $\mu_2 - \mu_1$ er gitt ved (se avsnitt 11.2.1 i Rice):

$$(\bar{Y} - \bar{X}) \pm t_{0.95} \cdot S_p \sqrt{\frac{1}{4} + \frac{1}{5}},$$

der $t_{0.95} = 1.895$ er 95% fraktilen i t -fordelingen med $4 + 5 - 2 = 7$ frihetsgrader.

For tallene i oppgaven har vi $\bar{X} = 12.625$, $\bar{Y} = 13.600$, $S_1 = 0.655$, $S_2 = 1.440$ og

$$S_p = \sqrt{\frac{3}{7} \cdot 0.655^2 + \frac{4}{7} \cdot 1.440^2} = 1.170.$$

Et 90% konfidensintervall blir:

$$(13.600 - 12.625) \pm 1.895 \cdot 1.170 \cdot \sqrt{\frac{1}{4} + \frac{1}{5}},$$

dvs. 0.975 ± 1.487 . Det betyr at vi med rimelig grad av sikkerhet kan si at $\mu_2 - \mu_1$ ligger mellom -0.51 kg og 2.46 kg. (Merk at det er galt å si det er 90% sannsynlig at $\mu_2 - \mu_1$ ligger mellom -0.51 og 2.46 . For $\mu_2 - \mu_1$ er et (ukjent) reelt tall, som enten ligger mellom -0.51 og 2.46 eller ikke gjør det. Vi kan derimot si at vi har 90% tiltro til at $\mu_2 - \mu_1$ ligger mellom -0.51 og 2.46 . Med det mener vi at konfidensintervall som er beregnet slik vi har gjort det her, vil inneholde den sanne differansen i 90% av tilfellene i "det lange løp".)

b) En test med signifikansnivå 5% for nullhypotesen $H_0 : \mu_1 = \mu_2$ mot den alternative hypotesen $H_1 : \mu_1 \neq \mu_2$, forkaster H_0 hvis (se avsnitt 11.2.1 i Rice)

$$T = \frac{\bar{Y} - \bar{X}}{S_p \sqrt{\frac{1}{4} + \frac{1}{5}}} > t_{0.975} \quad \text{eller hvis} \quad T < -t_{0.975},$$

der $t_{0.975} = 2.365$ er 97.5% fraktilen i t -fordelingen med $4 + 5 - 2 = 7$ frihetsgrader.

Med tallene i oppgaven finner vi

$$T = \frac{13.600 - 12.625}{1.170 \sqrt{\frac{1}{4} + \frac{1}{5}}} = 1.242.$$


Vi ser at $T = 1.242 < 2.365$, så vi forkaster ikke H_0 på 5% nivå.

c) P -verdien til en test er det minste signifikansnivået som gir forkastning av nullhypotesen. Litt mer uformelt, kan vi si at P -verdien er sannsynligheten for å få et resultat som det vi har fått, eller et resultat som er enda mer i favør av den alternative hypotesen, bare på grunn av tilfeldigheter (dvs. når H_0 er sann).

For t -fordelingen med 7 frihetsgrader finner vi av tabellen at $t_{0.80} = 0.896$ og $t_{0.90} = 1.415$. Det betyr at en test med nivå 40% vil forkaste H_0 , mens en test med nivå 20% ikke vil gjøre det. P -verdien er derfor mellom 20% og 40%. (Bedre klarer vi ikke å bestemme P -verdien av tabellen.)

Oppgave 2

a) Diagrammet gir et plott av vekten til kalkunene mot alderen ved slakting (Virginia= x , Wisconsin= o).



Vi ser at punktene ligger tilnærmet på to parallelle rette linjer, en linje for Virginia og en linje for Wisconsin.

b) Parameteren β_1 angir forventet vektøkning for kalkunene i løpet av én uke. Parameteren β_2 angir forventet forskjell i vekt mellom like gamle kalkuner fra Wisconsin og Virginia.

Modellen (1) sier at forventet vekt som funksjon av alder følger to parallelle rette linjer. Stigningstallet for linjene er β_1 og avstanden mellom dem er β_2 . Det er rimelig ut fra plottet.

c) En test med signifikansnivå 5% for nullhypotesen $H_0 : \beta_2 = 0$ mot den alternative hypotesen $H_1 : \beta_2 \neq 0$, forkaster H_0 hvis (se avsnitt 14.4.5 i Rice)

$$T = \frac{\hat{\beta}_2}{S_{\hat{\beta}_2}} > t_{0.975} \quad \text{eller hvis} \quad T < -t_{0.975},$$

der $t_{0.975} = 2.447$ er 97.5% fraktilen i t -fordelingen med $9 - 3 = 6$ frihetsgrader.

Med tallene i oppgaven finner vi $T = 2.094/0.235 = 8.91$. Vi ser at $T = 8.91 > 2.447$, så vi forkaster H_0 på 5% nivå. (Vi har $t_{0.995} = 3.707$, så P -verdien er mindre enn 1%. Mer nøyaktig klarer vi ikke å bestemme P -verdien ut fra tabellen.)

Når vi sammenligner like gamle kalkuner, slik vi gjør her, veier kalkunene fra Wisconsin signifikant mer enn kalkunene fra Virginia. I punkt b i oppgave 1, tar vi ikke hensyn til alderen til kalkunene, og da er det ikke signifikant forskjell i vekten for kalkuner fra de to statene.

d) Vi innfører matrisen $\mathbf{C} = (\mathbf{X}^T \mathbf{X})^{-1}$ og skriver

$$\mathbf{C} = \begin{pmatrix} c_{00} & c_{01} & c_{02} \\ c_{10} & c_{11} & c_{12} \\ c_{20} & c_{21} & c_{22} \end{pmatrix}$$

Da er kovariansmatrisen til $\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2)^T$ gitt ved $\Sigma_{\hat{\beta}\hat{\beta}} = \sigma^2 \mathbf{C}$ (se avsnitt 14.4.2 i Rice). Spesielt gir det at $\text{Var} \hat{\beta}_1 = \sigma^2 c_{11}$.

Videre er $S^2 = RSS/(9 - 3)$ en forventningsrett estimator for σ^2 (se avsnitt 14.4.3 i Rice). Den estimerte standardfeilen til $\hat{\beta}_1$ er dermed $S_{\hat{\beta}_1} = \sqrt{S^2 c_{11}}$.

Med tallene i oppgaven blir $S^2 = 0.5648/6 = 0.0941$ og $c_{11} = 0.0222$. Den estimerte standardfeilen til $\hat{\beta}_1$ er dermed $S_{\hat{\beta}_1} = \sqrt{0.0941 \cdot 0.0222} = 0.0457$.

Et 95% konfidensintervall for β_1 er gitt ved (se avsnitt 14.4.5 i Rice):

$$\hat{\beta}_1 \pm t_{0.975} \cdot S_{\hat{\beta}_1},$$

der $t_{0.975} = 2.447$ er 97.5% fraktilen i t -fordelingen med $9 - 3 = 6$ frihetsgrader. Med tall får vi $0.448 \pm 2.447 \cdot 0.0457$, dvs. 0.448 ± 0.112 . Det betyr at vi med rimelig grad av sikkerhet kan si at forventet vektøkning for kalkunene er mellom 0.34 kg og 0.56 kg per uke. (Se også punkt a i oppgave 1 når det gjelder fortolkning av konfidensintervall.)

Oppgave 3

a) La Y ha sannsynlighetstettheten (2). For $y > 0$ er den kumulative fordelingen til Y gitt ved:

$$\begin{aligned} F(y | \theta) &= \int_{-\infty}^y f(u | \theta) du = \int_0^y \frac{u}{\theta} e^{-u^2/2\theta} du \\ &= \left[-e^{-u^2/2\theta} \right]_0^y = 1 - e^{-y^2/2\theta} \end{aligned}$$

Medianen $y_{0.50}$ er gitt ved at $F(y_{0.50} | \theta) = 0.50$. Det gir:

$$\begin{aligned} 1 - \exp\left(-\frac{y_{0.50}^2}{2\theta}\right) &= \frac{1}{2} \\ -\frac{y_{0.50}^2}{2\theta} &= -\log 2 \\ y_{0.50} &= \sqrt{2\theta \log 2} \end{aligned}$$

b) $Y_1, Y_2, \dots, Y_{20}$ er uavhengige og identisk fordelte med sannsynlighetstetthet gitt ved (2). Da er likelihooden:

$$\text{lik}(\theta) = \prod_{i=1}^{20} f(Y_i | \theta) = \prod_{i=1}^{20} \frac{Y_i}{\theta} e^{-Y_i^2/2\theta}$$

Log-likelihooden blir dermed:

$$\begin{aligned} l(\theta) &= \sum_{i=1}^{20} \left\{ \log Y_i - \log \theta - \frac{Y_i^2}{2\theta} \right\} \\ &= \sum_{i=1}^{20} \log Y_i - 20 \log \theta - \frac{1}{2\theta} \sum_{i=1}^{20} Y_i^2 \end{aligned}$$

Den deriverte (m.h.p. θ) blir

$$l'(\theta) = -\frac{20}{\theta} + \frac{1}{2\theta^2} \sum_{i=1}^{20} Y_i^2$$

Maksimum likelihood estimatoren $\hat{\theta}$ er løsningen av ligningen $l'(\hat{\theta}) = 0$. Det gir

$$\frac{20}{\hat{\theta}} = \frac{1}{2\hat{\theta}^2} \sum_{i=1}^{20} Y_i^2$$

$$\hat{\theta} = \frac{1}{40} \sum_{i=1}^{20} Y_i^2$$

c) Bedriften ønsker å teste

$$H_0 : y_{0.50} \leq 1000 \quad \text{mot} \quad H_1 : y_{0.50} > 1000$$

Nå har vi at

$$\begin{aligned} y_{0.50} &\leq 1000 \\ \sqrt{2\theta \log 2} &\leq 10^3 \\ 2\theta \log 2 &\leq 10^6 \\ \theta &\leq 10^6 / (2 \log 2) \end{aligned}$$

Bedriften ønske derfor å teste

$$H_0 : \theta \leq \theta_0 \quad \text{mot} \quad H_1 : \theta > \theta_0$$

der $\theta_0 = 10^6 / (2 \log 2)$.

d) Siden den alternative hypotesen er $H_1 : \theta > \theta_0$, er det rimelig å forkaste H_0 hvis $\hat{\theta} > k$. Vi vil bestemme k slik at tesen får nivå 5%. Vi har at

$$\begin{aligned} P(\text{forkast } H_0 \mid H_0 \text{ sann}) &= P(\hat{\theta} > k \mid \theta \leq \theta_0) \\ &\leq P(\hat{\theta} > k \mid \theta = \theta_0) \\ &= P\left(\frac{1}{40} \sum_{i=1}^{20} Y_i^2 > k \mid \theta = \theta_0\right) \\ &= P\left(\frac{1}{\theta_0} \sum_{i=1}^{20} Y_i^2 > \frac{40k}{\theta_0} \mid \theta = \theta_0\right) \\ &= P\left(\chi^2 > \frac{40k}{\theta_0}\right) \end{aligned}$$

der χ^2 er χ^2 -kvadrat-fordelt med 40 frihetsgrader.

Nå har vi av tabellen at

$$P(\chi^2 > 55.76) = 1 - P(\chi^2 \leq 55.76) = 1 - 0.95 = 0.05$$

Vi får derfor en test med nivå 5% hvis bestemmer k ved ligningen $40k/\theta_0 = 55.76$, dvs.

$$k = \frac{55.76 \theta_0}{40} = \frac{55.76 \cdot 10^6}{40 \cdot 2 \log 2} = 1.006 \cdot 10^6$$

e) Hvis $y_{0.50} = 1250$, har vi at $\sqrt{2\theta \log 2} = 1250$, dvs.

$$\theta = \frac{1250^2}{2 \log 2} = 1.127 \cdot 10^6$$

For denne verdien av θ blir teststyrken:

$$\begin{aligned} \gamma(\theta) &= P(\text{forkast } H_0 \mid \theta) \\ &= P(\hat{\theta} > k \mid \theta) \\ &= P\left(\frac{1}{40} \sum_{i=1}^{20} Y_i^2 > k \mid \theta\right) \\ &= P\left(\frac{1}{\theta} \sum_{i=1}^{20} Y_i^2 > \frac{40k}{\theta} \mid \theta\right) \\ &= P\left(\chi^2 > \frac{40k}{\theta}\right) \\ &= P\left(\chi^2 > \frac{40 \cdot 1.006 \cdot 10^6}{1.127 \cdot 10^6}\right) \\ &= P(\chi^2 > 35.70) \end{aligned}$$

Av tabellen finner vi:

$$\begin{aligned} P(\chi^2 > 34.87) &= 1 - P(\chi^2 \leq 34.87) = 1 - 0.30 = 0.70 \\ P(\chi^2 > 37.13) &= 1 - P(\chi^2 \leq 37.13) = 1 - 0.40 = 0.60 \end{aligned}$$

Det betyr at teststyrken er mellom 60% og 70%.

Vi gjør en feil av type II hvis vi ikke forkaster H_0 når den er gal. Sannsynligheten for feil av type II er derfor lik én minus teststyrken. Her blir sannsynligheten for feil av type II mellom 30% og 40%.